

Chapitre 21

Mise en œuvre sur R et Python

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Statistique inférentielle

1 Exercices du chapitre

Exercice 1 — Écart-type d'échantillon, écart-type de population

Un analyste dispose des $n = 20$ chiffres d'affaires mensuels (en k dh) d'une entreprise, considérés comme la population complète des mois observés depuis son ouverture : $\bar{x} = 49,9$, $\sum_i (x_i - \bar{x})^2 = 1\,303,15$. Il calcule dans R : `sd(ca) # 6.8587`.

- (a) Que calcule exactement la fonction `sd()` de R – la formule utilisée, et son dénominateur ?
- (b) Puisque ces 20 mois constituent ici la population entière (et non un échantillon d'une population plus vaste), quelle correction faut-il appliquer à `sd(ca)` pour obtenir le véritable écart-type de population ? Calculer sa valeur.
- (c) Pourquoi R ne propose-t-il pas directement une fonction pour cette seconde quantité ?

Exercice 2 — Le piège `numpy` contre `pandas`

Un stagiaire calcule l'écart-type d'un petit échantillon de $n = 10$ délais de livraison (en jours) : 12, 15, 14, 18, 11, 16, 13, 17, 15, 14. Il obtient deux résultats différents selon l'outil utilisé, sans comprendre pourquoi.

- (a) Calculer la moyenne, puis $\sum_i (x_i - \bar{x})^2$.
- (b) Calculer l'écart-type avec un dénominateur $n - 1$ (convention `pandas.std()`), puis avec un dénominateur n (convention `numpy.std()` par défaut).
- (c) Calculer l'écart relatif entre les deux résultats. Le cours affirme que « sur cinq cents observations l'écart est invisible ; sur dix il est de 5 % » – votre calcul confirme-t-il cet ordre de grandeur ? Pourquoi l'écart entre les deux conventions se réduit-il quand n augmente ?

Exercice 3 — Avec ou sans correction de continuité

On reprend le test de proportion du fil rouge : $k = 13$ succès sur $n = 50$, $H_0 : p = 0,15$.

- (a) Calculer $z = (f - p_0) / \sqrt{p_0(1 - p_0)/n}$ et z^2 (la statistique **sans** correction de continuité, celle que `prop.test(..., correct=FALSE)` renvoie).
- (b) Calculer la statistique **avec** correction de continuité : $\chi_{\text{corr}}^2 = \frac{(|k - np_0| - 0,5)^2}{np_0} + \frac{(|(n - k) - n(1 - p_0)| - 0,5)^2}{n(1 - p_0)}$ (celle que `prop.test()` renvoie par défaut).
- (c) Comparer les deux statistiques et leurs p -values respectives ($\chi_{0,95;1}^2 = 3,841$). Les deux versions mènent-elles à la même conclusion au seuil de 5 % ? Le cours affirme que « les deux sont défendables ; ce qui ne l'est pas, c'est de ne pas savoir laquelle on emploie » – expliquer ce que cela signifie concrètement pour un rapport d'étude.

2 Exercices cumulatifs (chapitres 1 à 21)

Exercice 4 — La couverture des intervalles, vérifiée par simulation – et re-vérifiée par le cours lui-même

Le cours simule 10 000 échantillons de taille 40, calcule à chaque fois l'intervalle de confiance à 95 % de la moyenne, et compte combien contiennent la vraie moyenne $m = 7\,158,26$. Résultat : 95,03 % des intervalles la contiennent (au lieu d'exactement 95,00 %).

- (a) Un étudiant en conclut que la méthode des intervalles de confiance du chapitre 8 est légèrement fautive, puisqu'elle ne donne pas exactement 95,00 %. Le taux de couverture observé, 95,03 %, est-il lui-même une valeur **fixe**, ou est-ce, comme toute quantité calculée sur un tirage (ici, 10 000 simulations), une variable aléatoire dotée d'une loi ?
- (b) En traitant ce taux de couverture comme une proportion observée sur $n = 10\,000$ « essais »

(chaque essai valant 1 si l'intervalle contient m , 0 sinon), calculer son erreur-type sous $H_0 : p = 0,95$ (formule du chapitre 10 : $\sqrt{p_0(1-p_0)/n}$), puis un intervalle de confiance à 95 % pour ce taux de couverture. La valeur observée de 95,03 % est-elle statistiquement distinguable de 95,00 % ?

- (c) Le cours résume tout son parcours en une phrase : « une statistique calculée sur un échantillon est une variable aléatoire, et l'on connaît sa loi ». Expliquer en quoi la question (b) de cet exercice est elle-même une application, ultime et un peu vertigineuse, de cette phrase – au résultat même de la simulation censée l'illustrer.

3 Applications en sciences économiques

Exercice 5 — Lire un tableau de régression pour un comité de direction

Un logiciel de statistique affiche la sortie suivante pour une régression du salaire sur l'ancienneté :

	Coefficient	Erreur-type	t	p
Constante	4 347,23	177,18	24,54	< 0,0001
Ancienneté	277,17	15,06	18,41	< 0,0001

$$R^2 = 0,4049, \hat{\sigma}_\varepsilon = 2008, F(1;498) = 338,8.$$

- (a) En une page maximum, rédiger pour un comité de direction (qui n'a jamais suivi ce cours) un paragraphe qui explique ce que dit ce tableau sur le lien entre ancienneté et salaire, sans utiliser les mots « coefficient », « significatif » ou « R^2 » sans les expliquer immédiatement en langage courant.
- (b) Ce même comité demande : « Peut-on dire que 40,49 % du salaire d'un employé vient de son ancienneté ? ». Corriger précisément cette formulation.
- (c) Le comité voit que $t = 24,54$ pour la constante est encore plus grand que $t = 18,41$ pour l'ancienneté, et en déduit que « la constante est le facteur le plus important du modèle ». Expliquer pourquoi ce raisonnement est erroné.

Exercice 6 — Un bug silencieux dans une analyse Python

Un analyste teste, sur $n = 15$ agences commerciales, si le taux de croissance moyen des ventes dépasse significativement un objectif de 2,5 % ($H_0 : m = 2,5$, $H_1 : m > 2,5$). Il trouve $\bar{x} = 3,25$ %. Pour l'écart-type, il utilise par erreur `numpy.std()` (qui divise par n) au lieu de `pandas.Series.std()` (qui divise par $n - 1$), et obtient $s_{\text{numpy}} = 1,3364$, alors que le bon écart-type d'échantillon est $s = 1,3833$.

- (a) Calculer $se(\bar{x}) = s/\sqrt{n}$ correctement (avec $s = 1,3833$), puis calculer t et conclure au seuil de 5 % ($t_{0,95;14} = 1,761$, test unilatéral).
- (b) Refaire le même calcul avec l'écart-type erroné $s_{\text{numpy}} = 1,3364$ (l'erreur de l'analyste). La conclusion change-t-elle ?
- (c) Ce cas est-il un exemple isolé, ou bien – à la lumière du cours – une illustration d'un risque systématique ? Que devrait vérifier tout analyste avant de publier un résultat de test produit par un script Python ou R ?