

Chapitre 3

Proportion et variance

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Statistique inférentielle


1 Exercices du chapitre

Correction — Exercice 1

(a) $\sigma(F) = \sqrt{\frac{0,30 \times 0,70}{80}} = \sqrt{0,0026250} \approx 0,0512$.

(b) $np = 80 \times 0,30 = 24 \geq 5$ et $n(1-p) = 80 \times 0,70 = 56 \geq 5$: les deux conditions sont largement vérifiées, l'approximation normale est légitime.

(c) $Z = \frac{0,35 - 0,30}{0,0512} \approx 0,976$, d'où $P(F \geq 0,35) = 1 - \Phi(0,976) \approx 0,1646$, soit environ 16,5 %.



Correction — Exercice 2

(a) $\bar{x} = \frac{50,2 + 50,5 + 49,8 + 50,1 + 50,3 + 49,9}{6} \approx 50,1333$ mm.

(b) $s_n^2 = \frac{1}{6} \sum (x_i - \bar{x})^2 \approx 0,0556$.

(c) $s^2 = \frac{1}{5} \sum (x_i - \bar{x})^2 \approx 0,0667$. On vérifie $s^2 = s_n^2 \times \frac{6}{5} = 0,0556 \times 1,2 \approx 0,0667$. Une fois $\bar{x}$ calculée à partir des 6 observations, les 6 écarts $(x_i - \bar{x})$ ne sont plus tous libres : leur somme vaut 0 par construction, si bien que seuls $5 = n - 1$ d'entre eux le sont réellement. Diviser par n au lieu de $n - 1$ revient à moyenner sur **trop** de termes « libres » supposés, ce qui biaise systématiquement s_n^2 vers le bas.

$x_1 - \bar{x}$	$x_2 - \bar{x}$	$x_3 - \bar{x}$	$x_4 - \bar{x}$	$x_5 - \bar{x}$	$x_6 - \bar{x}$
-----------------	-----------------	-----------------	-----------------	-----------------	-----------------


5 écarts libres, le 6^e est imposé par $\sum (x_i - \bar{x}) = 0$

Correction — Exercice 3

(a) $(n-1) \frac{s^2}{\sigma^2} = 14 \times \frac{42}{30} = 19,6$.

(b) $E(\chi_k^2) = k$; pour $k = n - 1 = 14$, $E(\chi_{14}^2) = 14$.

(c) La valeur observée, 19,6, est supérieure à l'espérance théorique 14, mais reste d'un ordre de grandeur **comparable** : ce n'est pas, à l'œil, une valeur extravagante pour une loi χ_{14}^2 (dont l'écart-type vaut $\sqrt{2 \times 14} \approx 5,3$, si bien que 19,6 n'est qu'à un peu plus d'un écart-type au-dessus de la moyenne). À ce stade intuitif du cours, rien ne permet donc de rejeter fermement l'hypothèse $\sigma^2 = 30$; un test rigoureux, avec un seuil de décision explicite fondé sur les quantiles de χ_{14}^2 , sera développé plus loin dans le cours.



2 Exercices cumulatifs (introduction à chapitre 3)

Correction — Exercice 4

(a) $\sigma(F) = \sqrt{\frac{0,214 \times 0,786}{50}} = \sqrt{0,0033641} \approx 0,0580$. Conditions : $np = 50 \times 0,214 = 10,7 \geq 5$ et $n(1-p) = 50 \times 0,786 = 39,3 \geq 5$: validité de l'approximation normale confirmée, comme annoncé dans le cours.

(b) $Z = \frac{0,10}{0,0580} \approx 1,724$, d'où $P(|F-p| > 0,10) = 2 \times [1 - \Phi(1,724)] \approx 2 \times 0,0423 \approx 0,0847$, soit environ 8,5 % : un écart de 10 points entre la proportion observée sur l'échantillon et la vraie proportion de la population resterait donc, dans ce cas, un événement relativement rare mais pas exceptionnel.

(c) $(n-1) \frac{s^2}{\sigma^2} = 49 \times \frac{2\,250,98^2}{2\,598,10^2} \approx 49 \times 0,7506 \approx 36,78$. Cette valeur est **inférieure** à l'espérance théorique $n-1 = 49$ d'une loi χ_{49}^2 (dont l'écart-type vaut $\sqrt{2 \times 49} \approx 9,9$), l'écart restant de l'ordre d'un écart-type : l'écart-type d'échantillon s , calculé sur $n = 50$ salariés tirés systématiquement, est donc quelque peu inférieur à l'écart-type de la population entière σ , mais cela demeure tout à fait compatible avec la variabilité d'échantillonnage attendue d'une loi χ_{49}^2 , sans qu'il faille y voir un signe de biais du tirage.


3 Applications en sciences économiques

Correction — Exercice 5

(a) La fonction $p \mapsto p(1-p) = p - p^2$ a pour dérivée $1-2p$, nulle en $p = 0,5$, et sa dérivée seconde vaut $-2 < 0$: $p = 0,5$ est bien un **maximum**, de valeur $0,5 \times 0,5 = 0,25$. Pour $n = 1\,000$, $\sigma(F) = \sqrt{0,25/1\,000} = \sqrt{0,00025} \approx 0,0158$.

(b) Puisque $p(1-p) \leq 0,25$ pour tout $p \in [0, 1]$, on a toujours $\sigma(F) = \sqrt{p(1-p)/n} \leq \sqrt{0,25/n} = 0,5/\sqrt{n}$. Pour $n = 1\,000$: $0,5/\sqrt{1\,000} \approx 0,0158$, la même valeur que le maximum calculé en (a), puisque le pire cas est justement atteint en $p = 0,5$.

(c) Cette borne **ne dépend pas** de p : elle majore l'écart-type de F quel que soit le résultat réel de l'élection, connu ou non à l'avance. En multipliant cette borne par 1,96 (quantile à 95 % de la loi normale), on obtient $1,96 \times 0,0158 \approx 0,031$, soit une marge d'erreur d'environ 3 points au niveau de confiance de 95 % — exactement la marge « ± 3 points » traditionnellement annoncée par les instituts de sondage. Comme cette borne correspond au **pire cas** ($p = 0,5$), l'institut peut l'utiliser pour **tous** les candidats sans avoir besoin de connaître, ni même d'estimer, le résultat effectif de l'élection : la marge réellement atteinte pour un candidat éloigné de 50 % des intentions de vote serait en réalité légèrement plus faible.



Correction — Exercice 6

(a) Diviser par n au lieu de $n-1$ produit, en moyenne sur de nombreux échantillons, une estimation s_n^2 **systématiquement inférieure** à la vraie variance σ^2 du procédé : $E(s_n^2) = \frac{n-1}{n} \sigma^2 < \sigma^2$. Le service de contrôle qualité **sous-estimerait** donc en permanence la variabilité réelle du procédé, ce qui pourrait conduire à ne pas détecter une dérive de production alors qu'elle existe déjà.

(b) On perd exactement **un** degré de liberté parce qu'un seul paramètre, la moyenne $\bar{x}$, a été estimé à partir des données avant de calculer les écarts $(x_i - \bar{x})$: la contrainte $\sum_{i=1}^n (x_i - \bar{x}) = 0$ impose une relation linéaire unique entre les n écarts, si bien que seuls $n - 1$ d'entre eux peuvent varier librement une fois les $n - 1$ premiers connus (le dernier est alors entièrement déterminé). Estimer un second paramètre imposerait une seconde contrainte, et donc une seconde perte de degré de liberté.

(c) L'intuition qui se généralise est la suivante : **chaque quantité estimée à partir de l'échantillon (et non fixée à l'avance) « consomme » une unité d'information disponible pour évaluer la dispersion résiduelle**; en régression, où l'on estime typiquement deux paramètres (une ordonnée à l'origine et une pente) avant de calculer les résidus, on perd ainsi deux degrés de liberté, d'où le diviseur $n - 2$ qu'on retrouvera au chapitre 19.