

Statistique inférentielle

Chapitre 3 : Proportion et variance

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique inférentielle

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — La proportion comme moyenne de Bernoulli

Un contrôle qualité vise à estimer la proportion p de pièces défectueuses produites par une chaîne de fabrication. On considère que $p = 0,30$ (valeur admise pour cet exercice) et on prélève un échantillon aléatoire de $n = 80$ pièces.

- (a) Calculer $\sigma(F) = \sqrt{p(1-p)/n}$, l'écart-type de la proportion d'échantillon F .
- (b) Vérifier les deux conditions de validité $np \geq 5$ et $n(1-p) \geq 5$ pour cet échantillon.
- (c) En admettant l'approximation normale, calculer $P(F \geq 0,35)$.

Exercice 2 — L'énigme du diviseur $n-1$

On mesure l'épaisseur (en mm) de $n = 6$ pièces prélevées sur une même chaîne de production : 50,2 ; 50,5 ; 49,8 ; 50,1 ; 50,3 ; 49,9.

- (a) Calculer la moyenne d'échantillon $\bar{x}$.
- (b) Calculer la variance « biaisée » $s_n^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$ (division par n).
- (c) Calculer la variance corrigée $s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$ (division par $n-1$). Vérifier que $s^2 = s_n^2 \times \frac{n}{n-1}$, et expliquer en une phrase, à l'aide de la notion de degré de liberté, pourquoi s_n^2 sous-estime systématiquement σ^2 .

Exercice 3 — Statistique du khi-deux et degrés de liberté

On admet que, pour une population normale, $(n-1)s^2/\sigma^2$ suit une loi χ_{n-1}^2 . On dispose d'un échantillon de taille $n = 15$ pour lequel $s^2 = 42$, et on suppose (à titre d'hypothèse à évaluer) que $\sigma^2 = 30$.

- (a) Calculer la valeur prise par la statistique $(n-1)s^2/\sigma^2$ sur cet échantillon.
- (b) Rappeler l'espérance théorique d'une loi χ_k^2 de k degrés de liberté, et calculer cette valeur pour $k = n-1$.
- (c) Comparer la valeur observée en (a) à l'espérance théorique de (b). Cet écart paraît-il, à ce stade intuitif du cours, de nature à remettre en cause l'hypothèse $\sigma^2 = 30$?

2 Exercices cumulatifs (introduction à chapitre 3)

Exercice 4 — Proportion et variance dans le fil rouge

On reprend le fil rouge : population de $N = 500$ salariés, $\sigma = 2598,10$ dh (écart-type de la population, calculé par division par N) ; échantillon systématique de $n = 50$ salariés, d'écart-type corrigé $s = 2250,98$ dh (calculé par division par $n-1$). On sait par ailleurs que, dans cette population, la proportion de salariés titulaires d'un diplôme de niveau Bac+5 est $p = 0,214$.

- (a) Pour un échantillon de taille $n = 50$, calculer $\sigma(F) = \sqrt{p(1-p)/n}$ pour la proportion de diplômés Bac+5, et vérifier les conditions $np \geq 5$ et $n(1-p) \geq 5$.
- (b) En admettant l'approximation normale, calculer la probabilité que la proportion d'échantillon F s'écarte de p de plus de 0,10 en valeur absolue, c'est-à-dire $P(|F - p| > 0,10)$.
- (c) Calculer la statistique $(n-1)s^2/\sigma^2$ à partir des valeurs $s = 2250,98$ dh et $\sigma = 2598,10$ dh de l'échantillon fil rouge. Cette valeur est-elle proche de l'espérance théorique $n-1 = 49$ d'une loi χ_{49}^2 ? Que peut-on en dire, à ce stade intuitif, sur la compatibilité de s^2 avec σ^2 ?

3 Applications en sciences économiques

Exercice 5 — Pourquoi les instituts de sondage annoncent-ils toujours la même marge d'erreur ?

Un institut de sondage réalise des enquêtes électorales sur des échantillons de taille $n = 1\,000$, quel que soit le candidat ou le parti étudié, et communique systématiquement une marge d'erreur « de ± 3 points », indépendamment du résultat obtenu.

- (a) Montrer que $p(1 - p)$ est maximal pour $p = 0,5$, et calculer $\sigma(F)$ dans ce cas pour $n = 1\,000$.
- (b) En déduire que $\sigma(F) \leq 0,5/\sqrt{n}$ quel que soit p , et calculer cette borne pour $n = 1\,000$.
- (c) Expliquer pourquoi cette borne justifie qu'un institut de sondage communique une marge d'erreur unique, valable pour tous les candidats, sans connaître à l'avance le résultat de l'élection.

Exercice 6 — Degrés de liberté et contrôle statistique de la qualité

Un service de contrôle qualité teste régulièrement des échantillons de $n = 10$ pièces pour surveiller la variance d'un procédé de fabrication, en calculant à chaque fois $s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$.

- (a) Un technicien propose de diviser systématiquement par $n = 10$ plutôt que par $n - 1 = 9$ pour « simplifier les calculs ». Quel est l'effet de ce choix sur l'estimation de la variance du procédé, en moyenne sur de nombreux échantillons ?
- (b) Pourquoi perd-on exactement **un** degré de liberté dans ce calcul, et pas deux ou trois ? Relier la réponse au fait que $\sum (x_i - \bar{x}) = 0$ par construction.
- (c) Le cours indique que ce principe (« perdre un degré de liberté par paramètre estimé à partir des données ») se généralisera plus loin, notamment en régression avec un diviseur $n - 2$. Formuler, en une phrase, l'intuition qui permet d'anticiper ce résultat sans le démontrer.


1 Exercices du chapitre

Correction — Exercice 1

(a) $\sigma(F) = \sqrt{\frac{0,30 \times 0,70}{80}} = \sqrt{0,0026250} \approx 0,0512$.

(b) $np = 80 \times 0,30 = 24 \geq 5$ et $n(1-p) = 80 \times 0,70 = 56 \geq 5$: les deux conditions sont largement vérifiées, l'approximation normale est légitime.

(c) $Z = \frac{0,35 - 0,30}{0,0512} \approx 0,976$, d'où $P(F \geq 0,35) = 1 - \Phi(0,976) \approx 0,1646$, soit environ 16,5 %.



Correction — Exercice 2

(a) $\bar{x} = \frac{50,2 + 50,5 + 49,8 + 50,1 + 50,3 + 49,9}{6} \approx 50,1333$ mm.

(b) $s_n^2 = \frac{1}{6} \sum (x_i - \bar{x})^2 \approx 0,0556$.

(c) $s^2 = \frac{1}{5} \sum (x_i - \bar{x})^2 \approx 0,0667$. On vérifie $s^2 = s_n^2 \times \frac{6}{5} = 0,0556 \times 1,2 \approx 0,0667$. Une fois $\bar{x}$ calculée à partir des 6 observations, les 6 écarts $(x_i - \bar{x})$ ne sont plus tous libres : leur somme vaut 0 par construction, si bien que seuls $5 = n - 1$ d'entre eux le sont réellement. Diviser par n au lieu de $n - 1$ revient à moyenniser sur **trop** de termes « libres » supposés, ce qui biaise systématiquement s_n^2 vers le bas.

$x_1 - \bar{x}$	$x_2 - \bar{x}$	$x_3 - \bar{x}$	$x_4 - \bar{x}$	$x_5 - \bar{x}$	$x_6 - \bar{x}$
-----------------	-----------------	-----------------	-----------------	-----------------	-----------------


5 écarts libres, le 6^e est imposé par $\sum (x_i - \bar{x}) = 0$

Correction — Exercice 3

(a) $(n-1) \frac{s^2}{\sigma^2} = 14 \times \frac{42}{30} = 19,6$.

(b) $E(\chi_k^2) = k$; pour $k = n - 1 = 14$, $E(\chi_{14}^2) = 14$.

(c) La valeur observée, 19,6, est supérieure à l'espérance théorique 14, mais reste d'un ordre de grandeur **comparable** : ce n'est pas, à l'œil, une valeur extravagante pour une loi χ_{14}^2 (dont l'écart-type vaut $\sqrt{2 \times 14} \approx 5,3$, si bien que 19,6 n'est qu'à un peu plus d'un écart-type au-dessus de la moyenne). À ce stade intuitif du cours, rien ne permet donc de rejeter fermement l'hypothèse $\sigma^2 = 30$; un test rigoureux, avec un seuil de décision explicite fondé sur les quantiles de χ_{14}^2 , sera développé plus loin dans le cours.



2 Exercices cumulatifs (introduction à chapitre 3)

Correction — Exercice 4

(a) $\sigma(F) = \sqrt{\frac{0,214 \times 0,786}{50}} = \sqrt{0,0033641} \approx 0,0580$. Conditions : $np = 50 \times 0,214 = 10,7 \geq 5$ et $n(1-p) = 50 \times 0,786 = 39,3 \geq 5$: validité de l'approximation normale confirmée, comme annoncé dans le cours.

(b) $Z = \frac{0,10}{0,0580} \approx 1,724$, d'où $P(|F - p| > 0,10) = 2 \times [1 - \Phi(1,724)] \approx 2 \times 0,0423 \approx 0,0847$, soit environ 8,5 % : un écart de 10 points entre la proportion observée sur l'échantillon et la vraie proportion de la population resterait donc, dans ce cas, un événement relativement rare mais pas exceptionnel.

(c) $(n-1) \frac{s^2}{\sigma^2} = 49 \times \frac{2\,250,98^2}{2\,598,10^2} \approx 49 \times 0,7506 \approx 36,78$. Cette valeur est **inférieure** à l'espérance théorique $n-1 = 49$ d'une loi χ_{49}^2 (dont l'écart-type vaut $\sqrt{2 \times 49} \approx 9,9$), l'écart restant de l'ordre d'un écart-type : l'écart-type d'échantillon s , calculé sur $n = 50$ salariés tirés systématiquement, est donc quelque peu inférieur à l'écart-type de la population entière σ , mais cela demeure tout à fait compatible avec la variabilité d'échantillonnage attendue d'une loi χ_{49}^2 , sans qu'il faille y voir un signe de biais du tirage.


3 Applications en sciences économiques

Correction — Exercice 5

(a) La fonction $p \mapsto p(1-p) = p - p^2$ a pour dérivée $1 - 2p$, nulle en $p = 0,5$, et sa dérivée seconde vaut $-2 < 0$: $p = 0,5$ est bien un **maximum**, de valeur $0,5 \times 0,5 = 0,25$. Pour $n = 1\,000$, $\sigma(F) = \sqrt{0,25/1\,000} = \sqrt{0,00025} \approx 0,0158$.

(b) Puisque $p(1-p) \leq 0,25$ pour tout $p \in [0, 1]$, on a toujours $\sigma(F) = \sqrt{p(1-p)/n} \leq \sqrt{0,25/n} = 0,5/\sqrt{n}$. Pour $n = 1\,000$: $0,5/\sqrt{1\,000} \approx 0,0158$, la même valeur que le maximum calculé en (a), puisque le pire cas est justement atteint en $p = 0,5$.

(c) Cette borne **ne dépend pas** de p : elle majore l'écart-type de F quel que soit le résultat réel de l'élection, connu ou non à l'avance. En multipliant cette borne par 1,96 (quantile à 95 % de la loi normale), on obtient $1,96 \times 0,0158 \approx 0,031$, soit une marge d'erreur d'environ 3 points au niveau de confiance de 95 % — exactement la marge « ± 3 points » traditionnellement annoncée par les instituts de sondage. Comme cette borne correspond au **pire cas** ($p = 0,5$), l'institut peut l'utiliser pour **tous** les candidats sans avoir besoin de connaître, ni même d'estimer, le résultat effectif de l'élection : la marge réellement atteinte pour un candidat éloigné de 50 % des intentions de vote serait en réalité légèrement plus faible.



Correction — Exercice 6

(a) Diviser par n au lieu de $n-1$ produit, en moyenne sur de nombreux échantillons, une estimation s_n^2 **systématiquement inférieure** à la vraie variance σ^2 du procédé : $E(s_n^2) = \frac{n-1}{n} \sigma^2 < \sigma^2$. Le service de contrôle qualité **sous-estimerait** donc en permanence la variabilité réelle du procédé, ce qui pourrait conduire à ne pas détecter une dérive de production alors qu'elle existe déjà.

(b) On perd exactement **un** degré de liberté parce qu'un seul paramètre, la moyenne $\bar{x}$, a été estimé à partir des données avant de calculer les écarts $(x_i - \bar{x})$: la contrainte $\sum_{i=1}^n (x_i - \bar{x}) = 0$ impose une relation linéaire unique entre les n écarts, si bien que seuls $n - 1$ d'entre eux peuvent varier librement une fois les $n - 1$ premiers connus (le dernier est alors entièrement déterminé). Estimer un second paramètre imposerait une seconde contrainte, et donc une seconde perte de degré de liberté.

(c) L'intuition qui se généralise est la suivante : **chaque quantité estimée à partir de l'échantillon (et non fixée à l'avance) « consomme » une unité d'information disponible pour évaluer la dispersion résiduelle** ; en régression, où l'on estime typiquement deux paramètres (une ordonnée à l'origine et une pente) avant de calculer les résidus, on perd ainsi deux degrés de liberté, d'où le diviseur $n - 2$ qu'on retrouvera au chapitre 19.