Statistique inférentielle

Chapitre 3 : Proportion et variance

Jaouad Madkour

22 octobre 2026

Plan du chapitre

La proportion **2**
- Une proportion est une moyenne . . . 2
- Sur notre échantillon . . . 2
- Sa distribution d'échantillonnage . . . 3
- La loi exacte et son approximation . . . 3
- Trois calculs de la même probabilité . . . 3
- La correction de continuité . . . 4
- Les conditions de validité . . . 4
- L'erreur-type selon la proportion . . . 4
- Un maximum utile à connaître . . . 5
- Les marges d'erreur des sondages . . . 5
- Les dix échantillons systématiques . . . 5

La variance **6**
- L'énigme du dénominateur . . . 6
- Ce que la figure établit . . . 6
- À la main, sur les quatre salaires . . . 6
- La démonstration, en trois lignes . . . 7
- Le degré de liberté . . . 7
- Sur nos deux jeux de chiffres . . . 7
- Les dix échantillons, encore . . . 8

La loi de la variance d'échantillon **8**
- La loi de S^2 . . . 8
- Notre échantillon au regard de cette loi . . . 9
- Ce que dit la figure . . . 9
- Une condition qui compte . . . 9

S'entraîner **10**
- Exercice 1 : le taux d'équipement . . . 10
- Exercice 1 : solution . . . 10
- Exercice 2 : une variance à la main . . . 10
- Exercice 2 : solution . . . 10

Exercice 3 : contrôler une machine 11
Exercice 3 : solution 11

Ce qu'il faut retenir **11**
Le résumé du chapitre 11
La suite 11

La proportion

Une proportion est une moyenne

Le déguisement

Posons $X_i = 1$ si l'individu possède le caractère étudié, 0 sinon. Alors

$$F = \frac{X_1 + \cdots + X_n}{n} = \overline{X}$$

La fréquence observée **est** la moyenne d'une variable indicatrice.

Tout le chapitre 2 s'applique sans un mot de plus

Il suffit de savoir que pour une indicatrice, $E(X_i) = p$ et $\sigma(X_i) = \sqrt{p(1-p)}$ — c'est la loi de Bernoulli.

$$E(F) = p \qquad \sigma(F) = \sqrt{\frac{p(1-p)}{n}}$$

Aucun résultat nouveau : la même formule, avec un σ particulier.

Sur notre échantillon

Treize Bac+5 sur cinquante

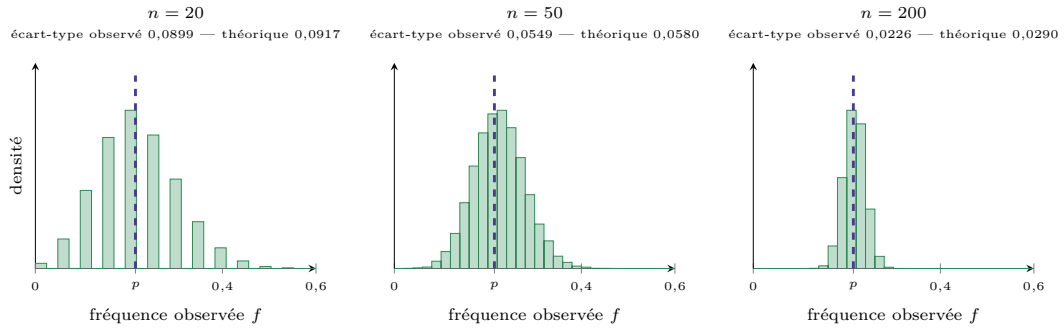
L'indicatrice vaut 1 pour les 13 Bac+5 et 0 pour les 37 autres : sa moyenne est $f = 13/50 = 0{,}26$.
Dans la population, $p = 0{,}214$. D'où l'erreur-type

$$\sigma(F) = \sqrt{\frac{0{,}214 \times 0{,}786}{50}} = \sqrt{0{,}003\,364} = 0{,}058$$

Un écart ordinaire

L'écart $0{,}26 - 0{,}214 = 0{,}046$ représente $0{,}046/0{,}058 = 0{,}79$ erreur-type : moins d'une.
Notre échantillon surreprésente les Bac+5 — mais pas plus qu'un échantillon sur quatre.
C'est la réponse à la première question laissée par le chapitre 2.

Sa distribution d'échantillonnage



Une proportion n'est qu'une moyenne : celle d'une variable qui vaut 1 ou 0.

Tout ce qui a été dit de $\overline{X}$ s'applique donc mot pour mot, avec $\sigma = \sqrt{p(1-p)}$:

$$E(F) = p \qquad \sigma_F = \sqrt{\frac{p(1-p)}{n}} \qquad \text{et } F \text{ tend vers une normale.}$$

À $n = 20$, la loi est encore visiblement discrète et dissymétrique — l'approximation normale serait abusive. La règle usuelle est $np \geq 5$ et $n(1-p) \geq 5$: ici $20 \times 0{,}214 = 4{,}3$, insuffisant.

La loi exacte et son approximation

Derrière la proportion, une binomiale

Le nombre de Bac+5 tirés, nF, suit **exactement** une loi binomiale $\mathcal{B}(n\,;p)$ — pour un tirage avec remise.
La normale n'en est qu'une approximation, d'autant meilleure que n est grand et p éloigné de 0 et de 1.

Les deux premiers moments du nombre de Bac+5

$$E(nF) = 50 \times 0{,}214 = 10{,}7 \qquad \sigma(nF) = \sqrt{50 \times 0{,}214 \times 0{,}786} = 2{,}90$$

On divise par $n = 50$ pour retrouver ceux de F : 0,214 et 0,058.

Trois calculs de la même probabilité

P(au moins 13 Bac+5 sur 50)

Méthode	Calcul	Probabilité
Binomiale exacte	$P(X \geq 13)$	0,261
Normale brute	$P\big(Z \geq (13 - 10{,}7)/2{,}90\big)$	0,214
Normale corrigée	$P\big(Z \geq (12{,}5 - 10{,}7)/2{,}90\big)$	0,267

La normale brute se trompe de cinq points

Elle traite 13 comme un point, alors que la binomiale lui attribue tout un bâton. La version corrigée retrouve la valeur exacte à six millièmes près.

La correction de continuité

Une demi-unité de chaque côté

La binomiale ne prend que des valeurs entières ; la normale, toutes les valeurs. Pour approcher $P(X \geq 13)$, on prend la normale à partir de 12,5 : le bâton de 13 occupe l'intervalle $[12{,}5\,;13{,}5]$.

Quand s'en soucier

Avec $n = 50$, l'oubli de la correction change la probabilité de 0,26 à 0,21 : une erreur de cinq points. Avec $n = 1\,000$, l'écart deviendrait négligeable.
Les logiciels calculent la binomiale exacte : la correction sert surtout au calcul à la main.

Les conditions de validité

Quand peut-on lire une table normale

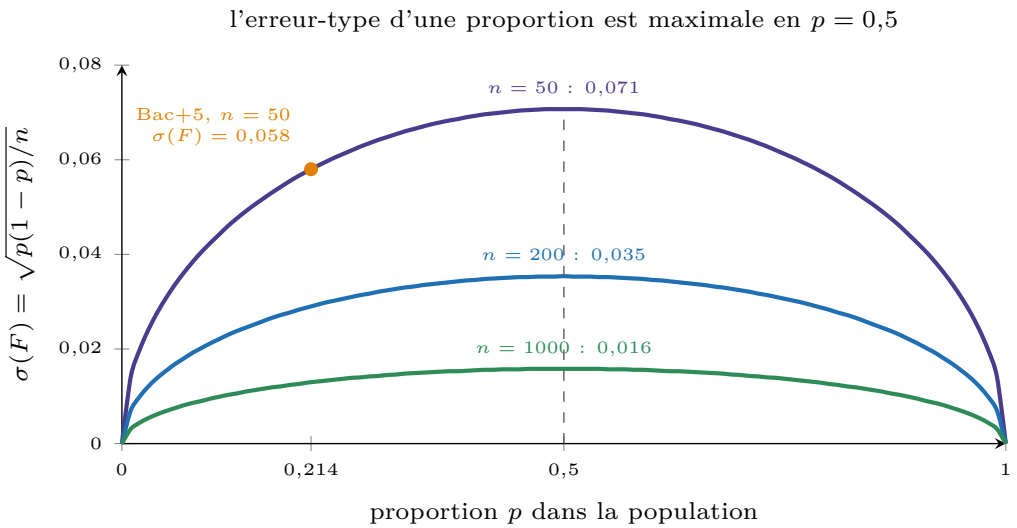
$$np \geq 5 \qquad \text{et} \qquad n(1-p) \geq 5$$

Ces deux conditions viennent de l'approximation normale de la binomiale, chapitre 17 de Probabilités.

Sur nos données

Proportion de diplômés Bac+5 dans la population : $p = 0{,}214$.
$n = 20$: $np = 4{,}3$ — **insuffisant**, la figure montre une loi encore visiblement discrète.
$n = 50$: $np = 10{,}7$ et $n(1-p) = 39{,}3$ — les deux conditions sont remplies.

L'erreur-type selon la proportion



Un maximum utile à connaître

Le pire cas est en p = 0,5

La fonction $p(1-p)$ est maximale en $p = 0{,}5$, où elle vaut 0,25.

$$\sigma(F) \leq \frac{0{,}5}{\sqrt{n}} \qquad \text{quelle que soit la valeur de } p$$

Pourquoi les instituts annoncent toujours la même marge

Ne connaissant pas p avant l'enquête, on dimensionne au cas le plus défavorable.
C'est pourquoi la marge d'erreur publiée est la même quel que soit le résultat : elle est **majorée**, donc valable pour toutes les questions du questionnaire à la fois.

Les marges d'erreur des sondages

La marge maximale, au niveau de confiance 0,95

La marge est $1{,}96 \times 0{,}5/\sqrt{n} \approx 1/\sqrt{n}$:

Taille n	400	1 000	2 500	10 000
Erreur-type	0,025	0,016	0,010	0,005
Marge, points	±4,9	±3,1	±2,0	±1,0

Lire un sondage d'opinion

Un sondage de 1 000 personnes donne un candidat à 52 % : la vraie valeur peut aller de 49 à 55 %. « En tête » n'est pas établi. Pour situer le candidat à un point près, il faudrait 10 000 personnes : dix fois plus.

Les dix échantillons systématiques

La proportion de Bac+5 dans chacun

Départ r	0	1	2	3	4	5	6	7	8	9
Bac+5	13	11	10	12	11	10	11	9	11	9

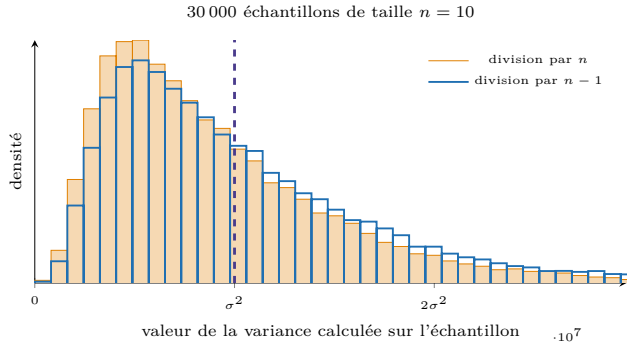
La moyenne des dix proportions vaut exactement $107/500 = 0{,}214 = p$: la proportion d'échantillon est centrée.

Un fichier plus régulier que le hasard

Les dix nombres vont de 9 à 13 : bien moins dispersés qu'un tirage au hasard, qui irait couramment de 6 à 16.
L'ordre du fichier répartit régulièrement les diplômes ; le tirage systématique en profite. Pour le salaire, il n'avait rien changé (chapitre 1) : l'effet d'un plan dépend de la variable étudiée.

La variance

L'énigme du dénominateur



Le décalage se voit à l'œil.

En divisant par n, la moyenne des 30 000 valeurs vaut 6107414 — soit $0.90\,\sigma^2$: **trop petite**.

En divisant par $n - 1$, elle vaut 6786015, soit σ^2 exactement.

Pourquoi ? Les écarts sont mesurés à $\overline{x}$, qui est *lui-même* calculé sur l'échantillon et se place donc au plus près des points. On sous-estime nécessairement la dispersion autour du vrai m.

Le facteur $\dfrac{n}{n-1}$ corrige exactement ce rapprochement. C'est le *degré de liberté* perdu à estimer m.

Ce que la figure établit

Deux formules, deux comportements

$$s_n^2 = \frac{1}{n}\sum_i (x_i - \overline{x})^2 \qquad\qquad s^2 = \frac{1}{n-1}\sum_i (x_i - \overline{x})^2$$

La première **sous-estime** systématiquement σ^2. La seconde est sans biais : $E(S^2) = \sigma^2$.

La raison, en une phrase

Les écarts sont mesurés à $\overline{x}$, qui est calculé **sur le même échantillon** et se place donc au plus près des points.
La somme des carrés obtenue est ainsi la plus petite possible — plus petite que si l'on avait mesuré les écarts au vrai m, que l'on ignore. On sous-estime nécessairement la dispersion.

À la main, sur les quatre salaires

Les seize échantillons du chapitre 2

Pour un couple $(a\,;b)$, la moyenne est $(a+b)/2$ et les deux écarts valent $\pm(a-b)/2$. D'où

$$s_n^2 = \frac{(a-b)^2}{4} \qquad\qquad s^2 = \frac{(a-b)^2}{2}$$

Sur les seize couples, $(a-b)^2$ vaut en moyenne 19 : $E(S_n^2) = 4{,}75$ et $E(S^2) = 9{,}5$.

Le verdict

La vraie variance est $\sigma^2 = 9{,}5$. Diviser par $n = 2$ donne en moyenne **la moitié** de la vraie valeur ; diviser par $n - 1 = 1$ donne **exactement** la vraie valeur.
Le facteur manquant est $(n-1)/n = 1/2$.

La démonstration, en trois lignes

Décomposer autour de m

On écrit $x_i - m = (x_i - \overline{x}) + (\overline{x} - m)$, on élève au carré et l'on somme. Le double produit disparaît, car $\sum(x_i - \overline{x}) = 0$:

$$\sum (x_i - m)^2 = \sum (x_i - \overline{x})^2 + n\,(\overline{x} - m)^2$$

Puis passer aux espérances

À gauche, $E(\sum (X_i - m)^2) = n\,\sigma^2$. À droite, $E(n(\overline{X} - m)^2) = n\,V(\overline{X}) = \sigma^2$. Donc

$$E\Big(\sum (X_i - \overline{X})^2\Big) = n\,\sigma^2 - \sigma^2 = (n-1)\,\sigma^2$$

Il faut diviser par $n - 1$ pour retrouver σ^2 en moyenne.

Le degré de liberté

Ce que le n − 1 compte

Une fois $\overline{x}$ calculé, les n écarts $(x_i - \overline{x})$ ne sont plus libres : leur somme est **nulle** par construction.
Connaissant $n - 1$ d'entre eux, le dernier est déterminé. Il n'y a donc que $n - 1$ écarts réellement indépendants : c'est le **nombre de degrés de liberté**.

Une règle qui reviendra sans cesse

On perd un degré de liberté par paramètre estimé à partir des données.
Ici, un seul : m, remplacé par $\overline{x}$. Au chapitre 19, la régression en estimera deux — pente et ordonnée — et le dénominateur sera $n - 2$. Le principe ne change jamais.

Sur nos deux jeux de chiffres

Population et échantillon

	Formule	Valeur
Population ($N = 500$)	division par N	$\sigma = 2\,598{,}10$
Échantillon ($n = 50$)	division par $n - 1$	$s = 2\,250{,}98$
Échantillon ($n = 50$)	division par n	$s_n = 2\,228{,}35$

Le point de vocabulaire

Sur la **population**, on divise par N : ce n'est pas une estimation, c'est une définition. Le cours de descriptive faisait cela.
Sur un **échantillon** dont on veut estimer σ, on divise par $n - 1$. R (`var`, `sd`) divise par $n - 1$; numpy (`np.var`) divise par n sauf indication contraire. Le chapitre 21 y reviendra.

Les dix échantillons, encore

Les dix écarts-types corrigés

r	0	1	2	3	4
s	2 251	2 662	2 809	2 542	2 715
r	5	6	7	8	9
s	2 943	2 897	2 197	2 424	2 453

Centré sur la bonne valeur

La moyenne des dix variances s^2 vaut 6 765 607, presque exactement la variance de la population calculée en $N-1$: 6 763 649.
Notre échantillon, avec $s = 2\,251$, est simplement l'un des plus bas : il sous-estime la dispersion **par hasard**, non par construction.

La loi de la variance d'échantillon

La loi de S²

Le résultat, pour une population normale

$$\frac{(n-1)\,S^2}{\sigma^2} \sim \chi^2_{n-1}$$

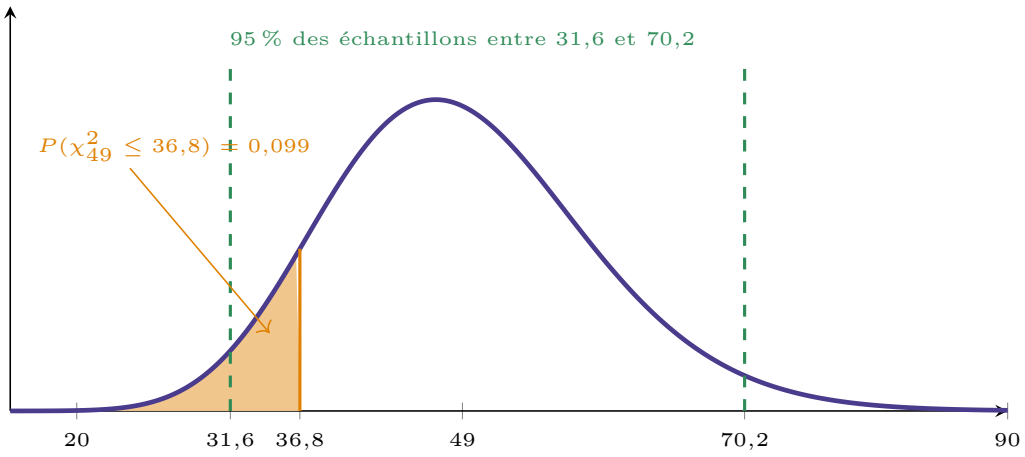
La variance d'échantillon, correctement normalisée, suit une loi du khi-deux à $n-1$ degrés de liberté.

Cela n'a rien d'étonnant

S^2 est une **somme de carrés** d'écarts. Or le khi-deux a été défini, au chapitre 18 de Probabilités, comme une somme de carrés de normales centrées réduites.
Le degré de liberté $n - 1$ est le même que celui du dénominateur : ce n'est pas une coïncidence, c'est la même perte d'information.

Notre échantillon au regard de cette loi

la loi χ^2_{49}, et la valeur de notre échantillon



Ce que dit la figure

Le calcul

$$\frac{(n-1)\,s^2}{\sigma^2} = \frac{49 \times 2\,250{,}98^2}{2\,598{,}10^2} = 36{,}78$$

La loi χ^2_{49} a pour espérance 49 et pour écart-type $\sqrt{98} = 9{,}9$. Notre valeur se situe 1,2 écart-type en dessous de l'espérance, et $P(\chi^2_{49} \leq 36{,}78) = 0{,}099$.

La réponse à la seconde question

Un échantillon sur dix environ sous-estime la variance au moins autant que le nôtre. C'est peu fréquent, mais pas exceptionnel.
Le chapitre 10 retournera ce calcul pour encadrer σ à partir de s.

Une condition qui compte

La normalité, cette fois, n'est pas facultative

Pour la moyenne, le théorème central limite rattrape une population non normale. Pour la variance, **rien ne la rattrape** : la loi du khi-deux suppose une population normale.
Nos salaires sont étirés à droite, avec un aplatissement de 4,8 contre 3 pour une normale. Les probabilités calculées sur S^2 ne sont alors qu'indicatives.

Ce qu'il faut retenir pour la pratique

Un intervalle ou un test sur une **moyenne** est robuste à la forme de la population. Sur une **variance**, il ne l'est pas : on vérifie d'abord la normalité, ou l'on a recours à d'autres

méthodes.

S’entraîner

Exercice 1 : le taux d’équipement

Les ménages équipés d’une voiture

Dans une ville, 30 % des ménages possèdent une voiture. Une enquête interroge 200 ménages pris au hasard ; F est la proportion d’équipés observée.

1. Les conditions d’approximation normale sont-elles remplies ?
2. Calculer $E(F)$ et $\sigma(F)$.
3. Calculer, sans correction de continuité, $P(F > 0{,}35)$.
4. Quelle serait la marge d’erreur maximale à 95 % pour cette taille ?

Exercice 1 : solution

Une proportion, une moyenne

1. $np = 60$ et $n(1-p) = 140$: largement.
2. $E(F) = 0{,}30$ et $\sigma(F) = \sqrt{0{,}30 \times 0{,}70/200} = \sqrt{0{,}001\,05} = 0{,}032\,4$.
3. $z = (0{,}35 - 0{,}30)/0{,}032\,4 = 1{,}54$, d’où $P(F > 0{,}35) = 0{,}061$.
4. $1{,}96 \times 0{,}5/\sqrt{200} = 0{,}069$: $\pm 6{,}9$ points. Ici, la marge réelle est plus petite, $1{,}96 \times 0{,}032\,4 = 0{,}064$, car $p = 0{,}30$ est éloigné de 0,5.

Exercice 2 : une variance à la main

Cinq ventes quotidiennes

Un magasin relève ses ventes de cinq jours tirés au hasard, en milliers de dirhams : 8, 10, 7, 12, 13.

1. Calculer $\overline{x}$, les cinq écarts à la moyenne, et vérifier que leur somme est nulle.
2. Calculer s_n^2 et s^2. Lequel retenir pour estimer la variance des ventes ?
3. On ne communique que quatre écarts : -2, 0, -3, $+2$. Retrouver le cinquième. Que vient-on d’illustrer ?

Exercice 2 : solution

Quatre degrés de liberté

1. $\overline{x} = 50/5 = 10$. Écarts : -2, 0, -3, $+2$, $+3$; somme nulle.
2. $\sum (x_i - \overline{x})^2 = 4 + 0 + 9 + 4 + 9 = 26$, d’où $s_n^2 = 26/5 = 5{,}2$ et $s^2 = 26/4 = 6{,}5$. Pour estimer la variance des ventes, on retient $s^2 = 6{,}5$, sans biais.
3. La somme doit être nulle : le cinquième vaut $-(-2+0-3+2) = +3$. Cinq écarts, mais quatre seulement sont libres : $n - 1 = 4$ degrés de liberté.

Exercice 3 : contrôler une machine

Le poids des paquets

Une machine remplit des paquets dont le poids suit une loi normale d'écart-type $\sigma = 5$ grammes. Chaque matin, on pèse 10 paquets et l'on calcule s^2.

1. Quelle est la loi de $9\,S^2/25$?
2. Le service qualité alerte si $s^2 > 50$, soit le double de σ^2. Quelle est la probabilité d'une fausse alerte un matin donné ?
3. À partir de quel seuil s^2 n'y aurait-il que 5 % de fausses alertes ? (Le quantile à 95 % de χ^2_9 vaut 16,92.)

Exercice 3 : solution

La table du khi-deux

1. $(n-1)S^2/\sigma^2 = 9\,S^2/25 \sim \chi^2_9$, la population étant normale.
2. $s^2 > 50$ équivaut à $9 \times 50/25 = 18$: $P(\chi^2_9 > 18) = 0{,}035$. Une fausse alerte tous les trente matins environ.
3. $9\,s^2/25 > 16{,}92$, soit $s^2 > 47$. Le seuil de 50 est donc un peu plus prudent que la règle des 5 %.

Pourquoi la normalité est ici crédible

Le poids d'un paquet résulte de nombreuses petites variations — dosage, vibration, humidité : c'est le cas typique où la loi normale décrit bien les données.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Une **proportion est une moyenne** d'indicatrices : $E(F) = p$ et $\sigma(F) = \sqrt{p(1-p)/n}$.
2. Conditions de normalité : $np \geq 5$ **et** $n(1-p) \geq 5$; à la main, la correction de continuité améliore l'approximation.
3. $p(1-p)$ est maximal en 0,5 : la marge maximale à 95 % vaut environ $1/\sqrt{n}$.
4. La variance d'échantillon se divise par $n-1$: $E(S^2) = \sigma^2$, alors que $E(S_n^2) = \frac{n-1}{n}\,\sigma^2$.
5. **Un degré de liberté perdu par paramètre estimé** — la règle vaudra jusqu'à la régression.
6. Pour une population normale, $(n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$; ce résultat ne tolère pas l'écart à la normalité.

La suite

Trois distributions, trois lois

Trois distributions d'échantillonnage sont maintenant établies : moyenne, proportion, variance.
Deux lois du cours de probabilités y sont apparues sans qu'on sache encore à quoi elles servent : le khi-deux, et — dès que σ est inconnu — la loi de Student. Le chapitre 4 boucle

cette dette.

La question qui ouvre le chapitre 4

En pratique, σ est inconnu : on le remplace par s. Mais $(\overline{X} - m)/(S/\sqrt{n})$ n'est plus normale, puisque S varie aussi d'un échantillon à l'autre.
Quelle est sa loi ? Pour notre échantillon, elle vaut $(7\,005{,}80 - 7\,158{,}26)/318{,}34 = -0{,}48$.