

Chapitre 19

La régression devient un modèle

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Statistique inférentielle


1 Exercices du chapitre

Correction — Exercice 1

(a) $Y = \beta_0 + \beta_1 X + \varepsilon$, où Y est la vente mensuelle d'une boutique, X sa dépense publicitaire mensuelle. β_0 et β_1 sont des paramètres fixes et inconnus de la relation **vraie**, dans la population de toutes les boutiques comparables. ε regroupe tout ce qui influence les ventes en dehors de la publicité (emplacement, saison, qualité du personnel, hasard).

(b) $\hat{\beta}_1 = \frac{48,6}{12,3} \approx 3,951$. $\hat{\beta}_0 = 182,4 - 3,951 \times 15,2 \approx 122,34$.

(c) **Non** : un nouvel échantillon de 20 boutiques produirait presque certainement des valeurs *différentes* de $\hat{\beta}_0$ et $\hat{\beta}_1$, même si la relation vraie (β_0, β_1) dans la population reste, elle, inchangée – exactement comme $\bar{x}$ varie d'un échantillon à l'autre autour de la moyenne vraie m (chapitre 5). La droite estimée est une variable aléatoire; la droite vraie ne l'est pas.




Correction — Exercice 2

(a) $\sum_i (x_i - \bar{x})^2 = 20 \times 12,3 = 246$. $V(\hat{\beta}_1) = \frac{850}{246} \approx 3,455$. $se(\hat{\beta}_1) = \sqrt{3,455} \approx 1,859$.

(b) $\sum_i (x_i - \bar{x})^2 = 492$. $V(\hat{\beta}_1) = \frac{850}{492} \approx 1,728$. $se(\hat{\beta}_1) = \sqrt{1,728} \approx 1,314$.

(c) Étaler davantage les x observés **allonge le levier** avec lequel on mesure la pente : à variance résiduelle égale, cela réduit mécaniquement $V(\hat{\beta}_1)$ (ici, l'écart-type de la pente diminue d'environ 29 % quand $\sum_i (x_i - \bar{x})^2$ double) – une pente se mesure d'autant mieux que les observations couvrent un grand intervalle de x .



Correction — Exercice 3

(a) **Faux** : c'est la définition de l'**erreur** $\varepsilon_i = y_i - (\beta_0 + \beta_1 x_i)$ (écart à la droite vraie, inconnue). Le **résidu** $e_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$ est l'écart à la droite *estimée*, seul quantité calculable.

(b) **Vrai** : la relation vraie (β_0, β_1) est fixe dans la population; c'est la droite *estimée*, fonction de l'échantillon tiré, qui varie d'un échantillon à l'autre.

(c) **Vrai** : c'est exactement l'énoncé du théorème de Gauss-Markov (BLUE, *Best Linear Unbiased*

Estimator) sous les quatre hypothèses du modèle.

(d) **Faux** : le cours est explicite – sans la troisième hypothèse (homoscédasticité) ou la quatrième (indépendance), $\hat{\beta}_1$ **reste sans biais**, mais son **écart-type est faux** (mal estimé), ce qui invalide les tests et intervalles construits à partir de lui, sans pour autant biaiser l'estimation ponctuelle elle-même.

(e) **Vrai** : sur un grand échantillon, le théorème central limite prend le relais et rend les résultats valables de façon approximative, quelle que soit la loi des erreurs – la cinquième hypothèse (normalité) n'est décisive que pour les **petits** échantillons.


2 Exercices cumulatifs (chapitres 1 à 19)

Correction — Exercice 4

(a) $\hat{\beta}_1 = \frac{9\,859,9}{35,574} \approx 277,17$. $\hat{\beta}_0 = 7\,158,26 - 277,17 \times 10,142 \approx 4\,347,23$. On retrouve exactement les valeurs du cours.

(b) $\sum_i (x_i - \bar{x})^2 = 500 \times 35,574 = 17\,787$. $V(\hat{\beta}_1) = \frac{4\,850\,000}{17\,787} \approx 272,67$. $se(\hat{\beta}_1) = \sqrt{272,67} \approx 16,51$ dh par année d'ancienneté.

(c) « Sans biais » a été défini au chapitre 5 (biais = $E(\hat{\theta}) - \theta$), et « de variance minimale » (efficacité) au chapitre 6, tous deux pour l'estimateur générique $\hat{\theta}$, illustrés notamment par $\bar{X}$ comme estimateur de m . Gauss-Markov, au chapitre 19, ne fait qu'appliquer ce même couple de critères – déjà posés et démontrés en toute généralité – à un nouvel objet, la pente $\hat{\beta}_1$: aucun concept nouveau n'est introduit, seul le terrain d'application change.




3 Applications en sciences économiques

Correction — Exercice 5

(a) Plan A : $V(\hat{\beta}_1) = \frac{120}{8,4} \approx 14,29$, $se(\hat{\beta}_1) \approx 3,78$. Plan B : $V(\hat{\beta}_1) = \frac{120}{42,0} \approx 2,86$, $se(\hat{\beta}_1) \approx 1,69$.

(b) $\frac{se_A}{se_B} = \frac{3,78}{1,69} \approx 2,24$ ($= \sqrt{42,0/8,4} = \sqrt{5}$). Pour un coût de collecte **identique**, le plan B (tailles étalées) estime la pente avec un écart-type plus de deux fois plus petit que le plan A : à budget égal, l'étalement des x est une source de précision « gratuite ».

(c) En se limitant aux entreprises de taille moyenne « faciles à contacter », le cabinet réduirait fortement $\sum_i (x_i - \bar{x})^2$ (comme le plan A) et obtiendrait donc une estimation de la pente beaucoup moins précise (écart-type plus grand), pour le même effort d'enquête – un choix de commodité qui a un coût statistique caché, exactement le risque illustré par cet exercice.



Correction — Exercice 6

(a) **Non**, ce n'est pas la seule interprétation possible : la relation *vraie* β_1 pourrait être parfaitement stable, et les trois pentes estimées (268, 291, 274 dh/an) n'être que l'expression normale de la **variabilité d'échantillonnage** – chaque cohorte annuelle est un échantillon différent de la même population de salariés, et $\hat{\beta}_1$ varie d'un échantillon à l'autre même sous une politique salariale rigoureusement inchangée.

(b) Interprétation alternative : il existe une pente vraie β_1 unique (par exemple autour de 278 dh/an), et les trois valeurs observées (268, 291, 274) sont trois réalisations de l'estimateur $\hat{\beta}_1$ autour de cette valeur vraie, dont l'écart-type $se(\hat{\beta}_1)$ dépend de la taille de chaque cohorte et de l'étalement des anciennetés en son sein.

(c) Il manque l'écart-type $se(\hat{\beta}_1)$ de chacune des trois estimations (ou, à défaut, la taille de chaque cohorte et l'étalement des anciennetés qui permettraient de le calculer). Avec ces écarts-types, on pourrait construire un **intervalle de confiance** pour β_1 chaque année, ou un **test** comparant les pentes d'une année à l'autre – exactement les outils que le chapitre 20 s'apprête à construire pour $\hat{\beta}_1$, en reprenant la logique des chapitres 8 à 15 déjà vue pour $\bar{X}$ et F .