

Statistique inférentielle

Chapitre 19 : La régression devient un modèle

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique inférentielle

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Estimer la droite, avec le regard de l'inférence

Une enseignante étudie la relation entre les dépenses publicitaires mensuelles (en k dh) et les ventes mensuelles (en k dh) de 20 boutiques comparables. On calcule $\text{cov}(x, y) = 48,6$, $V(x) = 12,3$, $\bar{x} = 15,2$, $\bar{y} = 182,4$.

- (a) Écrire le modèle de régression $Y = \beta_0 + \beta_1 X + \varepsilon$ propre à cette situation, en précisant ce que représentent β_0 , β_1 et ε .
- (b) Calculer $\hat{\beta}_1 = \text{cov}(x, y) / V(x)$ et $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$.
- (c) Si l'enseignante reproduisait cette étude sur 20 autres boutiques comparables le mois suivant, obtiendrait-elle exactement les mêmes valeurs de $\hat{\beta}_0$ et $\hat{\beta}_1$? Pourquoi ?

Exercice 2 — La précision de la pente, et le rôle de l'étalement des x

On reprend l'exercice 1 : $n = 20$, $V(x) = 12,3$. On estime la variance résiduelle à $\hat{\sigma}_\varepsilon^2 = 850$.

- (a) Calculer $\sum_i (x_i - \bar{x})^2 = n \times V(x)$, puis $V(\hat{\beta}_1) = \hat{\sigma}_\varepsilon^2 / \sum_i (x_i - \bar{x})^2$ et l'écart-type $\text{se}(\hat{\beta}_1)$.
- (b) L'enseignante envisage un nouvel échantillon de 20 boutiques dont les dépenses publicitaires seraient deux fois plus étalées (donc $\sum_i (x_i - \bar{x})^2$ deux fois plus grand). Recalculer $V(\hat{\beta}_1)$ et $\text{se}(\hat{\beta}_1)$ dans ce cas.
- (c) En une phrase : pourquoi un chercheur qui peut choisir son échantillon a-t-il intérêt à privilégier des observations aux valeurs de x « étalées » plutôt que toutes proches les unes des autres ?

Exercice 3 — Vrai ou faux : le vocabulaire du modèle

Pour chacune des affirmations suivantes, dire si elle est vraie ou fausse, et justifier en une phrase.

- (a) « Le résidu e_i mesure l'écart entre l'observation y_i et la vraie droite de la population. »
- (b) « Si l'on change d'échantillon, c'est la droite *estimée* qui varie ; la droite *vraie* reste, elle, la même. »
- (c) « Sous les quatre hypothèses du modèle, $\hat{\beta}_1$ est l'estimateur linéaire sans biais de variance minimale de β_1 . »
- (d) « Si l'hypothèse d'homoscédasticité est violée, $\hat{\beta}_1$ devient un estimateur biaisé de β_1 . »
- (e) « Sur un échantillon de 500 observations, la normalité des erreurs a peu d'importance pour la validité des tests usuels. »

2 Exercices cumulatifs (chapitres 1 à 19)

Exercice 4 — La pente du fil rouge, sous le regard de l'inférence

On reprend le fil rouge : la relation entre ancienneté (x , en années) et salaire (y , en dh) sur les 500 salariés, avec $\text{cov}(x, y) = 9\,859,9$, $V(x) = 35,574$, $\bar{x} = 10,142$, $\bar{y} = 7\,158,26$.

- (a) Calculer $\hat{\beta}_1$ et $\hat{\beta}_0$, et vérifier qu'on retrouve $\hat{\beta}_1 \approx 277,17$ et $\hat{\beta}_0 \approx 4\,347,23$.
- (b) On donne, pour cette question, une estimation de la variance résiduelle $\hat{\sigma}_\varepsilon^2 = 4\,850\,000$ dh². Calculer $\sum_i (x_i - \bar{x})^2 = n \times V(x)$ (avec $n = 500$), puis $V(\hat{\beta}_1)$ et $\text{se}(\hat{\beta}_1)$.
- (c) Le théorème de Gauss-Markov affirme que $\hat{\beta}_1$ est « sans biais et de variance minimale ». À quels chapitres antérieurs du cours ces deux qualités ont-elles été définies pour la première fois, et pour quel estimateur ? En quoi Gauss-Markov ne fait-il, comme le dit le cours, « qu'appliquer » ce vocabulaire à $\hat{\beta}_1$?

3 Applications en sciences économiques

Exercice 5 — Concevoir une étude : bien choisir l'étendue des x

Un cabinet d'études doit estimer l'effet de la taille des entreprises (mesurée en logarithme du nombre de salariés) sur leur productivité. Il hésite entre deux plans d'échantillonnage de $n = 30$ entreprises chacun, pour un coût de collecte identique. Plan A : entreprises de taille assez homogène, $\sum_i (x_i - \bar{x})^2 = 8,4$. Plan B : entreprises délibérément choisies sur toute la gamme des tailles existantes, $\sum_i (x_i - \bar{x})^2 = 42,0$. On estime $\hat{\sigma}_\varepsilon^2 = 120$ dans les deux cas.

- (a) Calculer $V(\hat{\beta}_1)$ et $se(\hat{\beta}_1)$ pour chacun des deux plans.
- (b) Calculer le rapport $se_A(\hat{\beta}_1)/se_B(\hat{\beta}_1)$. Commenter.
- (c) Le cabinet d'études, pour respecter son budget, envisage de se limiter aux entreprises « faciles à contacter », généralement de taille moyenne. Quel est le risque statistique de ce choix, à la lumière de cet exercice ?

Exercice 6 — Une direction des ressources humaines et l'illusion de la droite unique

La direction des ressources humaines d'un grand groupe estime, chaque année sur la nouvelle cohorte de salariés recrutés, la relation entre ancienneté et salaire par régression. D'une année sur l'autre, la pente estimée $\hat{\beta}_1$ varie : 268 dh/an en année 1, 291 dh/an en année 2, 274 dh/an en année 3.

- (a) Un jeune analyste en conclut que « la politique salariale de l'entreprise change chaque année ». Cette interprétation est-elle la seule possible, à la lumière de la distinction entre relation vraie et droite estimée ?
- (b) Proposer une interprétation alternative, compatible avec une relation vraie β_1 parfaitement stable dans le temps.
- (c) Quelle information manque, dans l'énoncé, pour trancher entre ces deux interprétations (changement réel de politique, ou simple variabilité d'échantillonnage) ? À quel outil du cours (chapitre 20 à venir) faudrait-il recourir pour la construire ?


1 Exercices du chapitre

Correction — Exercice 1

(a) $Y = \beta_0 + \beta_1 X + \varepsilon$, où Y est la vente mensuelle d'une boutique, X sa dépense publicitaire mensuelle. β_0 et β_1 sont des paramètres fixes et inconnus de la relation **vraie**, dans la population de toutes les boutiques comparables. ε regroupe tout ce qui influence les ventes en dehors de la publicité (emplacement, saison, qualité du personnel, hasard).

(b) $\hat{\beta}_1 = \frac{48,6}{12,3} \approx 3,951$. $\hat{\beta}_0 = 182,4 - 3,951 \times 15,2 \approx 122,34$.

(c) **Non** : un nouvel échantillon de 20 boutiques produirait presque certainement des valeurs *différentes* de $\hat{\beta}_0$ et $\hat{\beta}_1$, même si la relation vraie (β_0, β_1) dans la population reste, elle, inchangée – exactement comme $\bar{x}$ varie d'un échantillon à l'autre autour de la moyenne vraie m (chapitre 5). La droite estimée est une variable aléatoire ; la droite vraie ne l'est pas.




Correction — Exercice 2

(a) $\sum_i (x_i - \bar{x})^2 = 20 \times 12,3 = 246$. $V(\hat{\beta}_1) = \frac{850}{246} \approx 3,455$. $se(\hat{\beta}_1) = \sqrt{3,455} \approx 1,859$.

(b) $\sum_i (x_i - \bar{x})^2 = 492$. $V(\hat{\beta}_1) = \frac{850}{492} \approx 1,728$. $se(\hat{\beta}_1) = \sqrt{1,728} \approx 1,314$.

(c) Étaler davantage les x observés **allonge le levier** avec lequel on mesure la pente : à variance résiduelle égale, cela réduit mécaniquement $V(\hat{\beta}_1)$ (ici, l'écart-type de la pente diminue d'environ 29 % quand $\sum_i (x_i - \bar{x})^2$ double) – une pente se mesure d'autant mieux que les observations couvrent un grand intervalle de x .



Correction — Exercice 3

(a) **Faux** : c'est la définition de l'**erreur** $\varepsilon_i = y_i - (\beta_0 + \beta_1 x_i)$ (écart à la droite vraie, inconnue). Le **résidu** $e_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$ est l'écart à la droite *estimée*, seule quantité calculable.

(b) **Vrai** : la relation vraie (β_0, β_1) est fixe dans la population ; c'est la droite *estimée*, fonction de l'échantillon tiré, qui varie d'un échantillon à l'autre.

(c) **Vrai** : c'est exactement l'énoncé du théorème de Gauss-Markov (BLUE, *Best Linear Unbiased*

Estimator) sous les quatre hypothèses du modèle.

(d) **Faux** : le cours est explicite – sans la troisième hypothèse (homoscédasticité) ou la quatrième (indépendance), $\hat{\beta}_1$ **reste sans biais**, mais son **écart-type est faux** (mal estimé), ce qui invalide les tests et intervalles construits à partir de lui, sans pour autant biaiser l'estimation ponctuelle elle-même.

(e) **Vrai** : sur un grand échantillon, le théorème central limite prend le relais et rend les résultats valables de façon approximative, quelle que soit la loi des erreurs – la cinquième hypothèse (normalité) n'est décisive que pour les **petits** échantillons.


2 Exercices cumulatifs (chapitres 1 à 19)

Correction — Exercice 4

(a) $\hat{\beta}_1 = \frac{9859,9}{35,574} \approx 277,17$. $\hat{\beta}_0 = 7158,26 - 277,17 \times 10,142 \approx 4347,23$. On retrouve exactement les valeurs du cours.

(b) $\sum_i (x_i - \bar{x})^2 = 500 \times 35,574 = 17787$. $V(\hat{\beta}_1) = \frac{4850000}{17787} \approx 272,67$. $se(\hat{\beta}_1) = \sqrt{272,67} \approx 16,51$ dh par année d'ancienneté.

(c) « Sans biais » a été défini au chapitre 5 (biais = $E(\hat{\theta}) - \theta$), et « de variance minimale » (efficacité) au chapitre 6, tous deux pour l'estimateur générique $\hat{\theta}$, illustrés notamment par $\bar{X}$ comme estimateur de m . Gauss-Markov, au chapitre 19, ne fait qu'appliquer ce même couple de critères – déjà posés et démontrés en toute généralité – à un nouvel objet, la pente $\hat{\beta}_1$: aucun concept nouveau n'est introduit, seul le terrain d'application change.




3 Applications en sciences économiques

Correction — Exercice 5

(a) Plan A : $V(\hat{\beta}_1) = \frac{120}{8,4} \approx 14,29$, $se(\hat{\beta}_1) \approx 3,78$. Plan B : $V(\hat{\beta}_1) = \frac{120}{42,0} \approx 2,86$, $se(\hat{\beta}_1) \approx 1,69$.

(b) $\frac{se_A}{se_B} = \frac{3,78}{1,69} \approx 2,24$ ($= \sqrt{42,0/8,4} = \sqrt{5}$). Pour un coût de collecte **identique**, le plan B (tailles étalées) estime la pente avec un écart-type plus de deux fois plus petit que le plan A : à budget égal, l'étalement des x est une source de précision « gratuite ».

(c) En se limitant aux entreprises de taille moyenne « faciles à contacter », le cabinet réduirait fortement $\sum_i (x_i - \bar{x})^2$ (comme le plan A) et obtiendrait donc une estimation de la pente beaucoup moins précise (écart-type plus grand), pour le même effort d'enquête – un choix de commodité qui a un coût statistique caché, exactement le risque illustré par cet exercice.



Correction — Exercice 6

(a) **Non**, ce n'est pas la seule interprétation possible : la relation *vraie* β_1 pourrait être parfaitement stable, et les trois pentes estimées (268, 291, 274 dh/an) n'être que l'expression normale de la **variabilité d'échantillonnage** – chaque cohorte annuelle est un échantillon différent de la même population de salariés, et $\hat{\beta}_1$ varie d'un échantillon à l'autre même sous une politique salariale rigoureusement inchangée.

(b) Interprétation alternative : il existe une pente vraie β_1 unique (par exemple autour de 278 dh/an), et les trois valeurs observées (268, 291, 274) sont trois réalisations de l'estimateur $\hat{\beta}_1$ autour de cette valeur vraie, dont l'écart-type $se(\hat{\beta}_1)$ dépend de la taille de chaque cohorte et de l'étalement des anciennetés en son sein.

(c) Il manque l'écart-type $se(\hat{\beta}_1)$ de chacune des trois estimations (ou, à défaut, la taille de chaque cohorte et l'étalement des anciennetés qui permettraient de le calculer). Avec ces écarts-types, on pourrait construire un **intervalle de confiance** pour β_1 chaque année, ou un **test** comparant les pentes d'une année à l'autre – exactement les outils que le chapitre 20 s'apprête à construire pour $\hat{\beta}_1$, en reprenant la logique des chapitres 8 à 15 déjà vue pour $\bar{X}$ et F .