

Chapitre 13

Les deux risques et la puissance

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Statistique inférentielle


1 Exercices du chapitre

Correction — Exercice 1

(a) $\sigma/\sqrt{n} = 1\,200/\sqrt{64} = 1\,200/8 = 150$.

(b) puissance = $1 - \Phi\left(1,645 - \frac{300}{150}\right) = 1 - \Phi(1,645 - 2) = 1 - \Phi(-0,355) \approx 0,639$.

(c) Cette puissance ($\approx 63,9\%$) est **en dessous** de la convention de planification de 80 % : ce test manquerait un écart réel de 300 sur ses données environ 36 % du temps – un risque β non négligeable.



Correction — Exercice 2

(a) $1\,200/\sqrt{100} = 1\,200/10 = 120$.

(b) puissance = $1 - \Phi\left(1,645 - \frac{300}{120}\right) = 1 - \Phi(1,645 - 2,5) = 1 - \Phi(-0,855) \approx 0,804$.

(c) La puissance est passée d'environ 63,9 % ($n = 64$) à environ 80,4 % ($n = 100$), dépassant désormais la convention usuelle de 80 % – pour le **même** écart réel $\delta = 300$ et le **même** risque α . Seule l'augmentation de n a permis ce gain simultané : contrairement à un déplacement du seuil critique (qui aurait échangé α contre β), augmenter n resserre les deux distributions sans dégrader α , améliorant ainsi la puissance « gratuitement » du point de vue du risque de première espèce – au prix, bien sûr, d'un échantillon plus coûteux à collecter.

Correction — Exercice 3

(a) Il commet le premier mésusage identifié par le cours : « les deux groupes sont identiques ». Ne pas rejeter H_0 signifie seulement qu'on **n'a pas montré** de différence avec ces données ; cela ne prouve pas l'égalité stricte des deux méthodes.

(b) Cette généralisation commet le deuxième mésusage (« l'effet est nul ») : avec seulement 30 élèves par méthode, un effet pédagogique réel mais **modeste** pourrait très bien exister sans que ce dispositif, sous-dimensionné pour le détecter, ne le révèle – exactement la logique de la puissance développée dans ce chapitre.

(c) Conclusion correcte : « avec cet échantillon de 30 élèves par méthode, aucune différence n'a pu être détectée entre les deux méthodes pédagogiques au seuil de 5 % ; cela ne permet cependant pas d'affirmer que les deux méthodes sont équivalentes, ni qu'aucune méthode pédagogique n'a d'effet en général – un effet réel mais modeste pourrait échapper à un échantillon de cette taille, comme le montre le calcul de puissance ».

2 Exercices cumulatifs (chapitres 1 à 13)

Correction — Exercice 4

(a) puissance $\approx 1 - \Phi\left(1,96 - \frac{300}{318,34}\right) = 1 - \Phi(1,96 - 0,942) = 1 - \Phi(1,018) \approx 0,154$.

(b) puissance $\approx 1 - \Phi\left(1,96 - \frac{100}{318,34}\right) = 1 - \Phi(1,96 - 0,314) = 1 - \Phi(1,646) \approx 0,050$.

(c) Les deux puissances ($\approx 15,4\%$ pour $\delta = 300$ dh, $\approx 5,0\%$ pour $\delta = 100$ dh, à peine au-dessus du niveau $\alpha/2$) sont très **en dessous** de la convention de 80% : notre échantillon fil rouge de $n = 50$, aussi utile qu'il ait été pour illustrer chaque chapitre, serait en réalité **incapable** de détecter de façon fiable des écarts de salaire moyen de cet ordre de grandeur – une nouvelle confirmation numérique de « les petits effets exigent de gros échantillons ». Taille requise pour 80% de puissance sur $\delta = 300$ dh : $n \approx \left(\frac{(1,96 + 0,842) \times 2\,250,98}{300} \right)^2 \approx 442$ – soit près de 9 fois la taille actuelle de notre échantillon.

3 Applications en sciences économiques

Correction — Exercice 5

(a) Dimensionner le test pour détecter un écart aussi petit que 0,5 point avec une puissance suffisante exigerait un échantillon **beaucoup plus grand** (la taille nécessaire croît comme l'inverse du carré de l'écart à détecter) : le coût de l'expérimentation (temps, trafic détourné vers une variante potentiellement moins bonne) serait disproportionné par rapport à la valeur économique de cet écart, jugé **négligeable** par l'entreprise elle-même.

(b) **Oui**, un tel test, dimensionné pour l'écart de 2 points, aurait une puissance **beaucoup plus faible** pour détecter un écart réel de seulement 0,5 point (un quart de l'écart visé), et pourrait donc fréquemment conclure « aucune différence détectée ». Cela ne remet **pas** en cause la qualité du test : il a été conçu, à raison, pour détecter l'écart économiquement pertinent (2 points), et son incapacité à détecter un écart jugé négligeable (0,5 point) n'est pas un défaut mais une conséquence assumée du dimensionnement.

(c) L'équipe data devrait calculer, **avant** de lancer le test, la taille d'échantillon nécessaire pour atteindre une puissance de 80% sur l'écart économiquement significatif (2 points), en utilisant la formule du chapitre 11 combinée à la logique de puissance de ce chapitre – plutôt que de choisir arbitrairement une durée ou une taille de test, ce qui risquerait de produire une étude sous-dimensionnée et donc, selon le cours, « gaspillée ».

Correction — Exercice 6

(a) Avec $n = 2$ millions d'observations, l'erreur-type de la moyenne ($\sigma/\sqrt{n}$) devient **extrêmement petite** : même un écart réel infime (ici 8 dh) devient alors très grand en nombre d'erreurs-types, ce qui suffit à franchir n'importe quel seuil critique usuel et à produire une p -value minuscule.

(b) La nuance essentielle est que « statistiquement significatif » ne veut pas dire « économiquement important » : un écart de 8 dh sur un revenu moyen de 180 000 dh représente moins de $0,005\%$ de ce revenu, un effet sans portée pratique réelle, quelle que soit la fiabilité statistique de sa détection. La communication devrait éviter le mot « important », et préciser l'ampleur réelle, dérisoire, de l'effet mesuré.

(c) L'administration devrait publier, en plus du résultat du test : (i) une **estimation de l'effet** lui-même (les 8 dh, exprimés en valeur absolue et en pourcentage du revenu moyen) ; (ii) un **intervalle de confiance** pour cet effet, permettant d'apprécier à la fois la précision de l'estimation et son ordre de grandeur réel – exactement la « bonne pratique en deux temps » rappelée par le cours, qui évite de réduire un résultat économique à un simple verdict « significatif » ou « non significatif ».