

Statistique inférentielle

Chapitre 13 : Les deux risques et la puissance

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique inférentielle

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer une puissance

On teste $H_0 : m = 5\,000$ contre $H_1 : m > 5\,000$, au risque $\alpha = 5\%$ ($z_{0,05} = 1,645$), avec $\sigma = 1\,200$ et $n = 64$. On admet la formule puissance $= 1 - \Phi\left(z_\alpha - \frac{\delta}{\sigma/\sqrt{n}}\right)$, où δ est l'écart réel entre la vraie moyenne et 5 000.

- Calculer l'erreur-type $\sigma/\sqrt{n}$.
- Calculer la puissance du test pour détecter un écart réel $\delta = 300$.
- Cette puissance est-elle proche, en dessous, ou au-dessus de la convention de planification de 80 % évoquée dans le cours ?

Exercice 2 — Le seul levier qui améliore vraiment un test

On reprend les données de l'exercice 1 ($\sigma = 1\,200$, $\delta = 300$, $\alpha = 5\%$), mais en portant la taille d'échantillon à $n = 100$.

- Calculer la nouvelle erreur-type.
- Calculer la nouvelle puissance du test.
- Comparer ce résultat à celui de l'exercice 1. En quoi ce calcul illustre-t-il la phrase du cours selon laquelle « augmenter n est la seule action qui améliore vraiment un test » ?

Exercice 3 — Les trois conclusions abusives

Une école compare les résultats moyens de deux méthodes pédagogiques sur un échantillon de 30 élèves par méthode. Le test ne rejette pas H_0 (« pas de différence ») au seuil de 5 %.

- Un enseignant affirme : « les deux méthodes sont donc strictement équivalentes ». Quelle erreur, parmi les trois mésusages du cours, commet-il ?
- Un second enseignant affirme : « cela prouve qu'aucune méthode pédagogique n'a d'effet sur les résultats ». Pourquoi cette généralisation est-elle également abusive ?
- Reformuler la conclusion correcte à donner à la direction de l'école, en des termes qui ne commettent aucun des mésusages identifiés.

2 Exercices cumulatifs (chapitres 1 à 13)

Exercice 4 — La puissance du test sur le fil rouge

On reprend le fil rouge : $n = 50$, $s = 2\,250,98$ dh, erreur-type $= 318,34$ dh (chapitre 4). On envisage un test bilatéral au seuil $\alpha = 5\%$ ($z_{0,025} = 1,96$) sur la moyenne des salaires.

- En utilisant la formule de l'exercice 1 (adaptée au cas bilatéral), calculer la puissance de ce test pour détecter un écart réel $\delta = 300$ dh par rapport à la valeur testée dans H_0 .
- Calculer de même la puissance pour détecter un écart réel $\delta = 100$ dh.
- Ces deux puissances sont-elles proches de la convention de 80 % ? Que révèlent-elles sur la capacité de notre échantillon fil rouge, utilisé depuis le chapitre 1, à détecter de **modestes** écarts de salaire moyen ? En déduire, à l'aide de la formule du chapitre 11, la taille d'échantillon qu'il aurait fallu viser pour atteindre une puissance de 80 % sur un écart de 300 dh (on admettra

$$n \approx \left(\frac{(z_{\alpha/2} + z_\beta) s}{\delta} \right)^2, \text{ avec } z_{0,80} \approx 0,842).$$

3 Applications en sciences économiques

Exercice 5 — Dimensionner un test A/B pour un site marchand

Un site de commerce en ligne souhaite tester si une nouvelle page produit augmente le taux de conversion. Une étude préliminaire suggère qu'un écart de conversion de moins de 0,5 point de pourcentage ne serait pas exploitable pour l'entreprise (effet économiquement négligeable), alors qu'un écart de 2 points serait immédiatement rentable.

- (a) Pourquoi serait-il risqué de dimensionner ce test A/B pour détecter uniquement l'écart de 0,5 point plutôt que celui de 2 points, en termes de coût de l'expérimentation ?
- (b) Si le test est dimensionné pour une puissance de 80 % sur l'écart de 2 points, et que l'écart réel s'avère n'être que de 0,5 point, le test risque-t-il de conclure à tort « aucune différence » ? Pourquoi cela ne remet-il pas en cause la qualité du test tel qu'il a été conçu ?
- (c) Quelle recommandation méthodologique, tirée du cours, l'équipe data devrait-elle suivre avant de lancer ce test A/B, plutôt que de choisir arbitrairement une taille d'échantillon ?

Exercice 6 — Significatif ne veut pas dire important

Une administration fiscale dispose des données de 2 millions de contribuables, et teste si un changement de barème a modifié le revenu déclaré moyen. Le test rejette H_0 avec une p -value extrêmement faible, pour un écart estimé de seulement 8 dh sur un revenu moyen de 180 000 dh.

- (a) Pourquoi un écart aussi minime peut-il devenir « statistiquement significatif » sur un échantillon de cette taille ?
- (b) Un responsable de la communication de l'administration souhaite annoncer que « le changement de barème a eu un effet mesurable et important sur les revenus déclarés ». Quelle nuance faut-il apporter à cette phrase ?
- (c) Quelles deux informations complémentaires (au-delà du simple rejet de H_0), rappelées dans le cours, l'administration devrait-elle publier pour donner une image complète et honnête de ce résultat ?


1 Exercices du chapitre

Correction — Exercice 1

(a) $\sigma/\sqrt{n} = 1\,200/\sqrt{64} = 1\,200/8 = 150$.

(b) puissance $= 1 - \Phi\left(1,645 - \frac{300}{150}\right) = 1 - \Phi(1,645 - 2) = 1 - \Phi(-0,355) \approx 0,639$.

(c) Cette puissance ($\approx 63,9\%$) est **en dessous** de la convention de planification de 80 % : ce test manquerait un écart réel de 300 sur ses données environ 36 % du temps – un risque β non négligeable.



Correction — Exercice 2

(a) $1\,200/\sqrt{100} = 1\,200/10 = 120$.

(b) puissance $= 1 - \Phi\left(1,645 - \frac{300}{120}\right) = 1 - \Phi(1,645 - 2,5) = 1 - \Phi(-0,855) \approx 0,804$.

(c) La puissance est passée d'environ 63,9 % ($n = 64$) à environ 80,4 % ($n = 100$), dépassant désormais la convention usuelle de 80 % – pour le **même** écart réel $\delta = 300$ et le **même** risque α . Seule l'augmentation de n a permis ce gain simultané : contrairement à un déplacement du seuil critique (qui aurait échangé α contre β), augmenter n resserre les deux distributions sans dégrader α , améliorant ainsi la puissance « gratuitement » du point de vue du risque de première espèce – au prix, bien sûr, d'un échantillon plus coûteux à collecter.

Correction — Exercice 3

(a) Il commet le premier mésusage identifié par le cours : « les deux groupes sont identiques ». Ne pas rejeter H_0 signifie seulement qu'on n'a pas montré de différence avec ces données ; cela ne prouve pas l'égalité stricte des deux méthodes.

(b) Cette généralisation commet le deuxième mésusage (« l'effet est nul ») : avec seulement 30 élèves par méthode, un effet pédagogique réel mais **modeste** pourrait très bien exister sans que ce dispositif, sous-dimensionné pour le détecter, ne le révèle – exactement la logique de la puissance développée dans ce chapitre.

(c) Conclusion correcte : « avec cet échantillon de 30 élèves par méthode, aucune différence n'a pu être détectée entre les deux méthodes pédagogiques au seuil de 5 % ; cela ne permet cependant pas d'affirmer que les deux méthodes sont équivalentes, ni qu'aucune méthode pédagogique n'a d'effet en général – un effet réel mais modeste pourrait échapper à un échantillon de cette taille, comme le montre le calcul de puissance ».

2 Exercices cumulatifs (chapitres 1 à 13)

Correction — Exercice 4

(a) puissance $\approx 1 - \Phi\left(1,96 - \frac{300}{318,34}\right) = 1 - \Phi(1,96 - 0,942) = 1 - \Phi(1,018) \approx 0,154$.

(b) puissance $\approx 1 - \Phi\left(1,96 - \frac{100}{318,34}\right) = 1 - \Phi(1,96 - 0,314) = 1 - \Phi(1,646) \approx 0,050$.

(c) Les deux puissances ($\approx 15,4\%$ pour $\delta = 300$ dh, $\approx 5,0\%$ pour $\delta = 100$ dh, à peine au-dessus du niveau $\alpha/2$) sont très **en dessous** de la convention de 80% : notre échantillon fil rouge de $n = 50$, aussi utile qu'il ait été pour illustrer chaque chapitre, serait en réalité **incapable** de détecter de façon fiable des écarts de salaire moyen de cet ordre de grandeur – une nouvelle confirmation numérique de « les petits effets exigent de gros échantillons ». Taille requise pour 80% de puissance sur $\delta = 300$ dh : $n \approx \left(\frac{(1,96 + 0,842) \times 2\,250,98}{300} \right)^2 \approx 442$ – soit près de 9 fois la taille actuelle de notre échantillon.

3 Applications en sciences économiques

Correction — Exercice 5

(a) Dimensionner le test pour détecter un écart aussi petit que 0,5 point avec une puissance suffisante exigerait un échantillon **beaucoup plus grand** (la taille nécessaire croît comme l'inverse du carré de l'écart à détecter) : le coût de l'expérimentation (temps, trafic détourné vers une variante potentiellement moins bonne) serait disproportionné par rapport à la valeur économique de cet écart, jugé **négligeable** par l'entreprise elle-même.

(b) **Oui**, un tel test, dimensionné pour l'écart de 2 points, aurait une puissance **beaucoup plus faible** pour détecter un écart réel de seulement 0,5 point (un quart de l'écart visé), et pourrait donc fréquemment conclure « aucune différence détectée ». Cela ne remet **pas** en cause la qualité du test : il a été conçu, à raison, pour détecter l'écart économiquement pertinent (2 points), et son incapacité à détecter un écart jugé négligeable (0,5 point) n'est pas un défaut mais une conséquence assumée du dimensionnement.

(c) L'équipe data devrait calculer, **avant** de lancer le test, la taille d'échantillon nécessaire pour atteindre une puissance de 80% sur l'écart économiquement significatif (2 points), en utilisant la formule du chapitre 11 combinée à la logique de puissance de ce chapitre – plutôt que de choisir arbitrairement une durée ou une taille de test, ce qui risquerait de produire une étude sous-dimensionnée et donc, selon le cours, « gaspillée ».

Correction — Exercice 6

(a) Avec $n = 2$ millions d'observations, l'erreur-type de la moyenne ($\sigma/\sqrt{n}$) devient **extrêmement petite** : même un écart réel infime (ici 8 dh) devient alors très grand en nombre d'erreurs-types, ce qui suffit à franchir n'importe quel seuil critique usuel et à produire une p -value minuscule.

(b) La nuance essentielle est que « statistiquement significatif » ne veut pas dire « économiquement important » : un écart de 8 dh sur un revenu moyen de 180 000 dh représente moins de $0,005\%$ de ce revenu, un effet sans portée pratique réelle, quelle que soit la fiabilité statistique de sa détection. La communication devrait éviter le mot « important », et préciser l'ampleur réelle, dérisoire, de l'effet mesuré.

(c) L'administration devrait publier, en plus du résultat du test : (i) une **estimation de l'effet** lui-même (les 8 dh, exprimés en valeur absolue et en pourcentage du revenu moyen) ; (ii) un **intervalle de confiance** pour cet effet, permettant d'apprécier à la fois la précision de l'estimation et son ordre de grandeur réel – exactement la « bonne pratique en deux temps » rappelée par le cours, qui évite de réduire un résultat économique à un simple verdict « significatif » ou « non significatif ».