Statistique inférentielle

Chapitre 13 : Les deux risques et la puissance

Jaouad Madkour

22 octobre 2026

Plan du chapitre

Deux façons de se tromper **2**
- Le point de départ . . . 2
- Les deux mondes possibles . . . 2
- Quatre issues, deux erreurs . . . 3
- Les définitions . . . 3
- Ce que coûte chaque erreur . . . 3
- Le seuil ne fait que déplacer le problème . . . 4

Les deux risques de notre test **4**
- La règle, exprimée en dirhams . . . 4
- Les deux risques sur une même figure . . . 5
- Le calcul de β . . . 5
- Ce que changerait un autre seuil . . . 5
- Trois façons d'obtenir le même nombre . . . 6
- Ce que l'on peut calculer, et ce que l'on ne peut pas . . . 6

La puissance **6**
- La définition . . . 6
- Ce dont elle dépend . . . 7
- Lire la courbe . . . 7
- Les quatre leviers . . . 7
- Notre test, selon la taille de l'échantillon . . . 8
- Ce que montre la figure . . . 8
- La taille qui garantit une puissance . . . 8
- La formule appliquée . . . 9
- Le seuil de quatre-vingts pour cent . . . 9
- Pourquoi un effet détecté est souvent exagéré . . . 10

Les mésusages **10**
- Ce que « non significatif » ne veut pas dire . . . 10
- Notre comparaison hommes-femmes . . . 10
- La conclusion à rédiger . . . 11
- Significatif ne veut pas dire important . . . 11

La bonne pratique, en deux temps 11

S'entraîner **12**
Exercice 1 : calculer β 12
Exercice 1 : solution 12
Exercice 2 : dimensionner le contrôle 12
Exercice 2 : solution 12
Exercice 3 : un résultat non significatif 12
Exercice 3 : solution 13

Ce qu'il faut retenir **13**
Le résumé du chapitre 13
La suite 13

Deux façons de se tromper

Le point de départ

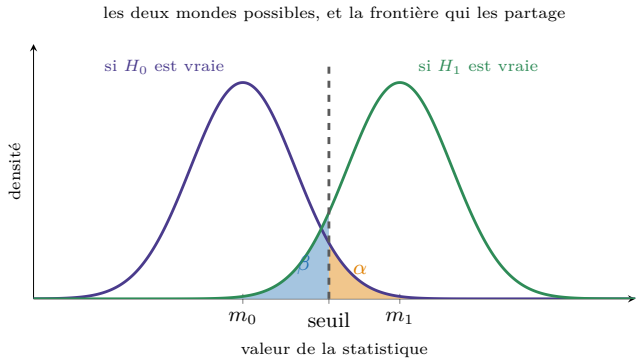
Ce que le chapitre 12 a laissé ouvert

Notre test de $H_0 : m = 6\,500$ contre $H_1 : m > 6\,500$ donne $t = 1{,}589 < 1{,}677$: on ne rejette pas H_0.
Or nous connaissons la population : $m = 7\,158$. **H_0 est fausse, et le test ne l'a pas vu.**
Ce n'est pas une faute de calcul : c'est une erreur que tout test peut commettre.

Les deux questions du chapitre

Combien de chances avait notre test de voir l'écart ? Et que faudrait-il pour qu'il le voie presque toujours ?
Pour y répondre, il faut nommer les deux erreurs possibles et les mesurer.

Les deux mondes possibles



Les deux risques ne sont pas symétriques

α — **erreur de première espèce**
rejeter H_0 alors qu'elle est vraie.
On la fixe : 5 %, 1 %.

β — **erreur de seconde espèce**
ne pas rejeter H_0 alors qu'elle est fausse.
On la subit : elle dépend de m_1, qu'on ignore.

Déplacer le seuil ne supprime rien
vers la droite : α baisse, β monte.
vers la gauche : l'inverse.

Le seul moyen de réduire les deux à la fois est d'**augmenter** n : les deux cloches se resserrent et se séparent.

Quatre issues, deux erreurs

Le tableau des décisions

Décision	H_0 vraie	H_0 fausse
on ne rejette pas H_0	bonne décision $(1-\alpha)$	**erreur de seconde espèce** (β)
on rejette H_0	**erreur de première espèce** (α)	bonne décision $(1-\beta)$

Une seule colonne est la bonne

La réalité est dans l'une des deux colonnes, et on ne sait pas laquelle. Le test choisit une ligne.
Chaque risque se lit **dans sa colonne** : α suppose H_0 vraie, β la suppose fausse. Ils ne s'additionnent pas et ne font pas 1.

Les définitions

Les deux erreurs

$$\alpha = P(\text{rejeter } H_0 \mid H_0 \text{ vraie}) \qquad \beta = P(\text{ne pas rejeter } H_0 \mid H_0 \text{ fausse})$$

α est l'erreur de **première espèce**, β celle de **seconde espèce**.

La dissymétrie fondamentale

α **se fixe** : c'est une décision, prise avant de voir les données. On choisit 5 %, 1 %.
β **se subit** : il dépend de la vraie valeur du paramètre, que l'on ignore. On ne peut que le calculer *pour un écart donné*.

Ce que coûte chaque erreur

Trois situations de gestion

Situation	Erreur de première espèce	Erreur de seconde espèce
contrôle de lot	rejeter un bon lot	accepter un lot défectueux
octroi de crédit	refuser un bon client	prêter à un mauvais payeur
publicité	lancer une campagne inutile	renoncer à une bonne campagne

On protège d'abord contre l'erreur la plus grave

Le test contrôle α et laisse β dépendre des circonstances. On place donc dans H_0 ce qu'il serait le plus coûteux de rejeter à tort.
C'est la règle du chapitre 12 vue sous un autre angle : le choix de H_0 dit **quelle erreur on accepte de mal maîtriser**.

Le seuil ne fait que déplacer le problème

Un arbitrage, pas une optimisation

Déplacer le seuil	Effet sur α	Effet sur β
vers la droite	diminue	augmente
vers la gauche	augmente	diminue

Le seul moyen de gagner sur les deux

Augmenter n. Les deux distributions se resserrent, se chevauchent moins, et les deux risques baissent ensemble.
C'est la seule action qui améliore vraiment un test — et elle coûte de l'argent. Tout le reste n'est qu'un déplacement de la frontière.

Les deux risques de notre test

La règle, exprimée en dirhams

Le seuil sur la moyenne

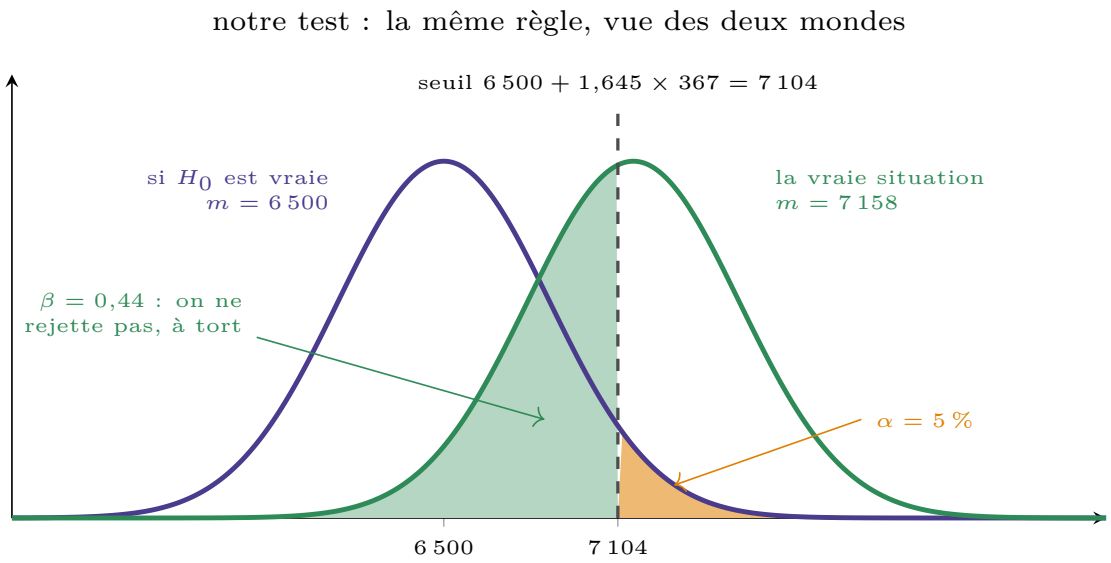
Pour simplifier le calcul, on prend $\sigma = 2\,598$ comme connu : l'erreur-type vaut $2\,598/\sqrt{50} = 367{,}4$ et le seuil unilatéral à 5 % est $z = 1{,}645$.
On rejette H_0 dès que

$$\overline{x} > 6\,500 + 1{,}645 \times 367{,}4 = 7\,104{,}4.$$

Une règle en unités de gestion

La statistique t et le seuil 1,677 se traduisent en un seul nombre parlant : **il faut observer plus de 7 104 dirhams** pour conclure.
Notre échantillon donne 7 006 : il reste sous la barre, d'où le non-rejet.

Les deux risques sur une même figure



Le calcul de β

Si la vraie moyenne vaut 7 158

Sous la vraie situation, $\overline{X}$ suit approximativement $\mathcal{N}(7\,158{,}3\,;\,367{,}4^2)$. On ne rejette pas si $\overline{X} \leq 7\,104{,}4$:

$$\beta = P\left(Z \leq \frac{7\,104{,}4 - 7\,158{,}3}{367{,}4}\right) = P(Z \leq -0{,}147) = 0{,}442.$$

La puissance vaut $1 - 0{,}442 = 0{,}558$.

Un test qui joue presque à pile ou face

Face à un écart réel de 658 dirhams, notre test le détecte un peu plus d'une fois sur deux. Le non-rejet du chapitre 12 n'avait donc rien d'étonnant : **il s'est produit avec une probabilité de** 44 %.

Ce que changerait un autre seuil

Trois niveaux de α, même échantillon de 50

α	z	seuil sur $\overline{x}$	β	puissance
10 %	1,282	6 970,9	0,305	0,695
5 %	1,645	7 104,4	0,442	0,558
1 %	2,326	7 354,8	0,704	0,296

L'arbitrage, chiffré

Passer de 5 % à 1 % divise le risque de première espèce par cinq, mais fait passer β de 0,44 à 0,70.
À 10 %, notre échantillon (7 006 $>$ 6 971) aurait conduit à rejeter H_0. **Le verdict dépend du seuil**, d'où l'obligation de le fixer avant.

Trois façons d'obtenir le même nombre

La puissance de notre test, calculée trois fois

Méthode	Puissance
loi normale, σ supposé connu	0,558
loi de Student non centrale, σ estimé	0,549
20 000 échantillons simulés dans la population	0,549

Et les dix échantillons du chapitre 12

Cinq des dix échantillons systématiques rejetaient H_0, soit une fréquence de 0,5 : exactement ce qu'annonce une puissance de 0,55.
L'approximation normale suffit pour **dimensionner** une étude ; l'écart avec le calcul exact est inférieur à un point.

Ce que l'on peut calculer, et ce que l'on ne peut pas

Ici, on triche : on connaît m

Le calcul de β a utilisé la vraie moyenne 7 158. En pratique, on ne la connaît jamais : sinon, on n'aurait pas besoin de test.
On calcule donc β **pour un écart hypothétique** : « si la vraie moyenne dépassait 6 500 de 300 dirhams, quelle chance aurais-je de le voir ? »

La puissance est une fonction

$$\pi(m) = P(\text{rejeter } H_0 \mid \text{la vraie moyenne vaut } m)$$

À chaque écart possible correspond une puissance. En $m = 6\,500$, π vaut α ; elle croît ensuite vers 1 à mesure que l'écart grandit.

La puissance

La définition

Puissance d'un test

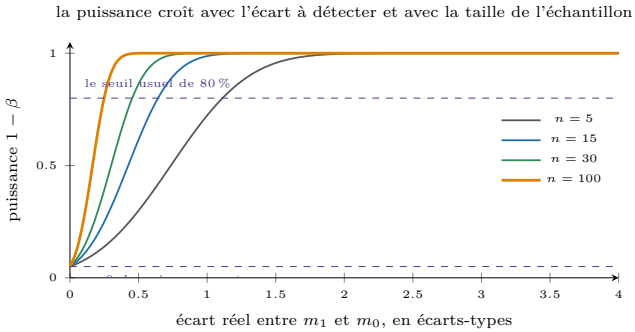
$$\text{puissance} = 1 - \beta = P(\text{rejeter } H_0 \mid H_0 \text{ fausse})$$

C'est la capacité du test à **détecter un écart qui existe**.

La question qu'elle permet enfin de poser

« Mon test n'a rien trouvé » est une information inutilisable tant qu'on ne sait pas ce qu'il était capable de trouver.
La puissance transforme cette phrase en énoncé exploitable : *mon échantillon détectait un écart de* 658 *dirhams une fois sur deux ; un écart de* 300 *lui échappait quatre fois sur cinq.*

Ce dont elle dépend



Trois lectures

Un petit écart est difficile à détecter. À 0,5 écart-type, il faut cent observations pour avoir une chance raisonnable de le voir.

En zéro, la puissance vaut α. Quand H_0 est vraie, on la rejette dans exactement 5 % des cas : c'est la définition du seuil.

La conséquence pratique
Un test non significatif sur un petit échantillon ne dit rien. Il faut calculer la puissance *avant* de collecter — c'est ainsi que se fixe la taille d'échantillon.

Lire la courbe

Quatre lectures

1. En 0, toutes les courbes valent $\alpha = 5\,\%$: quand H_0 est vraie, on la rejette dans 5 % des cas.
2. À un demi écart-type, la puissance vaut 0,30 avec $n = 5$, 0,61 avec $n = 15$, 0,86 avec $n = 30$.
3. Avec $n = 100$, elle vaut pratiquement 1 dès un demi écart-type.
4. Toutes les courbes montent : plus l'écart est grand, plus il se voit.

L'écart se mesure en écarts-types

Ce qui compte n'est pas l'écart en dirhams, mais l'écart **rapporté à la dispersion** : δ/σ. Trois cents dirhams, c'est beaucoup pour une variable très peu dispersée, et presque rien pour nos salaires ($\sigma = 2\,598$).

Les quatre leviers

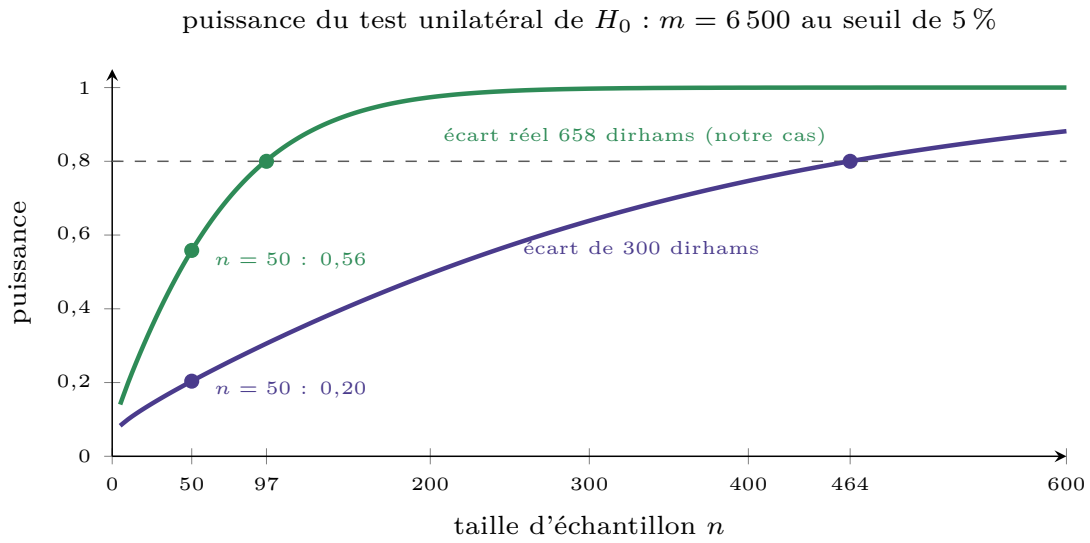
Ce qui fait monter la puissance

Levier	Effet
écart réel plus grand	monte — un gros effet se voit
n plus grand	monte — la seule action du gestionnaire
σ plus petit	monte — moins de bruit
α plus grand	monte — mais on rejette plus à tort

Pourquoi la taille l'emporte

L'écart réel ne se choisit pas, et σ tient à la population. Augmenter α revient à baisser la garde.
Reste n : c'est le seul levier qui augmente la puissance **sans** dégrader α, et le seul que le gestionnaire contrôle vraiment.

Notre test, selon la taille de l'échantillon



Ce que montre la figure

Deux écarts, deux tailles

Pour l'écart réel de 658 dirhams, 50 observations donnent 0,56 ; il en faudrait 97 pour atteindre 80 %.
Pour un écart de 300 dirhams, 50 observations ne donnent que 0,20 ; il en faudrait 464.

Diviser l'écart par deux, multiplier la taille par quatre

L'écart passe de 658 à 300 (à peu près divisé par 2,2), et la taille nécessaire de 97 à 464 (multipliée par 4,8, soit $2{,}2^2$).
C'est la loi en racine carrée du chapitre 11, encore : **la précision se paie au carré**.

La taille qui garantit une puissance

Test unilatéral sur une moyenne

Pour détecter un écart δ avec une puissance $1-\beta$ au seuil α :

$$n = \left(\frac{(z_{1-\alpha} + z_{1-\beta})\,\sigma}{\delta} \right)^2$$

En bilatéral, on remplace $z_{1-\alpha}$ par $z_{1-\alpha/2}$.

D'où vient la formule

On rejette si $\overline{x} > m_0 + z_{1-\alpha}\,\sigma/\sqrt{n}$. Pour que cela arrive avec probabilité $1-\beta$ quand la moyenne vaut $m_0 + \delta$, il faut que ce seuil soit $z_{1-\beta}$ erreurs-types **sous** $m_0 + \delta$.
D'où $\delta = (z_{1-\alpha} + z_{1-\beta})\,\sigma/\sqrt{n}$, puis on isole n.

La formule appliquée

Nos salaires, puissance de 80 pour cent

Avec $z_{0,95} = 1{,}645$, $z_{0,80} = 0{,}842$ et $\sigma = 2\,598$:

- écart de 658 : $n = (2{,}487 \times 2\,598/658)^2 = 96{,}3$, soit 97 ;
- écart de 300 : $n = (2{,}487 \times 2\,598/300)^2 = 463{,}7$, soit 464 ;
- écart d'un demi écart-type : $n = (2{,}487/0{,}5)^2 = 24{,}7$, soit 25.

Le bilatéral coûte plus cher

Pour le même écart de 658 dirhams en bilatéral, $z_{0,975} = 1{,}96$ remplace 1,645 : il faut 123 observations au lieu de 97.
Ne pas savoir dans quel sens chercher se paie en effectif.

Le seuil de quatre-vingts pour cent

Une convention de planification

On dimensionne usuellement une étude pour atteindre une puissance de 80 % sur l'écart que l'on juge économiquement significatif.
Cela signifie accepter de manquer un vrai effet une fois sur cinq.

Le calcul se fait avant, jamais après

Une étude sous-dimensionnée est doublement perdante : si elle ne trouve rien, on ne peut rien conclure ; si elle trouve quelque chose, l'effet estimé est probablement exagéré.
Une étude sans puissance suffisante n'est pas une étude prudente : c'est une étude gaspillée.

Pourquoi un effet détecté est souvent exagéré

Le filtre du seuil

Avec $n = 50$ et un écart réel de 300 dirhams, on ne rejette que si $\overline{x} > 7\,104$, c'est-à-dire si l'échantillon montre un écart **d'au moins** 604 **dirhams**.
Les seules études qui « trouvent » l'effet sont donc celles qui l'ont surestimé du double.

Une leçon pour lire les études publiées

Quand seules les études significatives sont publiées, et qu'elles sont peu puissantes, la littérature exagère systématiquement les effets.
Un résultat spectaculaire obtenu sur un petit échantillon mérite donc **plus** de prudence, pas moins.

Les mésusages

Ce que « non significatif » ne veut pas dire

Trois conclusions abusives

1. « Les deux groupes sont identiques. » — Non : on n'a pas montré de différence.
2. « L'effet est nul. » — Non : il est peut-être réel et trop petit pour ce dispositif.
3. « L'hypothèse est validée. » — Non : elle n'est pas contredite, ce qui est très différent.

La formulation correcte

« Avec ces données, on ne détecte pas d'écart au seuil de 5 %. Le test avait une puissance de tant pour un écart de tant. »
La seconde phrase est celle qui manque presque toujours.

Notre comparaison hommes-femmes

Sur l'échantillon de 50

28 hommes (7 239 dirhams en moyenne) et 22 femmes (6 709) : l'écart vaut 531 dirhams, l'erreur-type de la différence 636, donc $t = 0{,}83$.
On ne rejette pas l'égalité des moyennes. Mais quelle était la puissance de ce test ?

Ce que le test pouvait voir

Écart réel	Puissance (bilatéral, 5 %)
300 dirhams	0,08
1 000 dirhams	0,35
1 783 dirhams	0,80

La conclusion à rédiger

Ce que l'on peut écrire

« Sur cet échantillon, l'écart de salaire entre hommes et femmes n'est pas significatif. Mais le test ne détectait un écart de 1 000 dirhams qu'une fois sur trois. »
Le résultat est donc **compatible** avec une absence d'écart comme avec un écart important.

L'usage politique du non-significatif

Un rapport qui conclut « pas d'écart de salaire » sur la foi d'un test aussi faible n'informe pas : il rassure à bon compte.
Exiger la puissance, ou l'intervalle de confiance de l'écart, suffit à le démasquer.

Significatif ne veut pas dire important

Un million de salariés

Avec $n = 1\,000\,000$ et $\sigma = 2\,598$, l'erreur-type de la moyenne vaut 2,6 dirhams. Un écart de 10 dirhams donne

$$z = 10/2{,}6 = 3{,}85, \qquad p = 0{,}0001.$$

L'écart est hautement significatif. Il représente 0,14 % du salaire moyen.

Le piège inverse, et il est aussi fréquent

Un écart de dix dirhams n'a aucune portée économique, mais aucun test ne s'en soucie.
La significativité statistique mesure la fiabilité de la détection, pas l'ampleur de l'effet. Avec assez de données, tout écart non nul finit par être significatif.

La bonne pratique, en deux temps

Test et intervalle

Toujours accompagner un test d'une **estimation de l'effet** et de son **intervalle de confiance**.
Le test dit *si l'on peut affirmer quelque chose* ; l'intervalle dit *quoi*. Publier l'un sans l'autre est une information tronquée.

Sur nos deux exemples

Hommes-femmes : un intervalle de l'écart d'environ $531 \pm 1\,280$ dirhams dit tout de suite que l'échantillon est trop petit pour trancher.
Un million de salariés : un intervalle de 10 ± 5 dirhams dit tout de suite que l'effet, bien réel, est négligeable.

S'entraîner

Exercice 1 : calculer β

La machine à remplir

Une machine doit remplir des paquets de 500 grammes ; l'écart-type du remplissage vaut $\sigma = 10$ grammes. Pour détecter un sur-remplissage coûteux, on teste $H_0 : m = 500$ contre $H_1 : m > 500$ au seuil de 5 %, sur $n = 25$ paquets.

1. Écrire la règle de décision sur $\overline{x}$.
2. La machine remplit en réalité 504 grammes en moyenne. Calculer β et la puissance.

Exercice 1 : solution

Seuil, puis aire sous la vraie loi

1. Erreur-type $10/\sqrt{25} = 2$. On rejette si $\overline{x} > 500 + 1{,}645 \times 2 = 503{,}29$ grammes.
2. Sous $m = 504$: $\beta = P(Z \leq (503{,}29 - 504)/2) = P(Z \leq -0{,}355) = 0{,}361$.

La puissance vaut 0,639 : un sur-remplissage de 4 grammes échappe au contrôle **plus d'une fois sur trois**.

Exercice 2 : dimensionner le contrôle

Voir deux grammes

On veut maintenant détecter un sur-remplissage de seulement 2 grammes, avec une puissance de 90 %, toujours au seuil unilatéral de 5 % ($z_{0{,}90} = 1{,}282$).

1. Combien de paquets faut-il peser ?
2. Comparer avec les 25 paquets actuels.

Exercice 2 : solution

La formule de la taille

1. $n = ((1{,}645 + 1{,}282) \times 10/2)^2 = 14{,}63^2 = 214{,}1$, soit 215 **paquets**.
2. Huit fois et demi plus qu'aujourd'hui. Exiger un écart deux fois plus petit et une puissance plus forte se paie très cher.

Le responsable qualité peut aussi décider qu'un écart de 2 grammes ne justifie pas ce coût : c'est une décision de gestion, pas de statistique.

Exercice 3 : un résultat non significatif

La campagne en magasin

Une enseigne teste une campagne promotionnelle dans 40 magasins. Le gain moyen de chiffre d'affaires hebdomadaire n'est pas significatif au seuil unilatéral de 5 % ; son erreur-type vaut 150 dirhams. La campagne est rentable si elle rapporte au moins 200 dirhams par semaine.

1. Quelle était la puissance du test pour un gain de 200 dirhams ?
2. Peut-on conclure que la campagne est inefficace ?
3. Combien de magasins aurait-il fallu pour une puissance de 80 % ?

Exercice 3 : solution

Mesurer ce que le test pouvait voir

1. $\pi = P(Z > 1{,}645 - 200/150) = P(Z > 0{,}312) = 0{,}38$.
2. Non. Même si la campagne était rentable, le test avait 62 % de chances de ne rien trouver. Le résultat ne tranche pas.
3. Il faut une erreur-type de $200/2{,}487 = 80{,}4$ dirhams, donc multiplier n par $(150/80{,}4)^2 = 3{,}48$: environ 140 **magasins**.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. α : rejeter H_0 à tort. β : ne pas rejeter alors qu'elle est fausse. α **se fixe**, β **se subit**.
2. Déplacer le seuil échange un risque contre l'autre ; seul **augmenter** n réduit les deux.
3. **Puissance** $= 1 - \beta$: la capacité à détecter un écart réel. En zéro, elle vaut α.
4. Sur nos données, la puissance vaut 0,55 : le non-rejet du chapitre 12 avait 44 % de chances de se produire.
5. $n = \left((z_{1-\alpha} + z_{1-\beta})\,\sigma/\delta\right)^2$: 97 observations pour 658 dirhams, 464 pour 300.
6. « Non significatif » ne prouve pas l'égalité ; « significatif » ne prouve pas l'importance.

La suite

L'outil que tous les logiciels affichent

Reste l'outil que tous les logiciels affichent et que presque personne ne définit correctement : la p-value.
Le chapitre 14 la définit, la calcule, et détaille les contresens qu'elle provoque.

La question laissée ouverte

Notre test donne $t = 1{,}589$, et le seuil 1,677 : on ne rejette pas, mais de peu.
Comment dire « de peu » avec un nombre ? C'est exactement ce que fait la p-value.