Statistique inférentielle

Chapitre 11 : Choisir la taille de l'échantillon

Jaouad Madkour

31 octobre 2026

Plan du chapitre

La question du commanditaire **2**
Un renversement de la formule . . . 2
Le calcul, pas à pas . . . 2
La difficulté, et comment on la contourne . . . 3
Ce que le pré-test a coûté . . . 3
Sur nos salaires . . . 4

Le cas d'une proportion **4**
La formule et son maximum . . . 4
Si l'on a une idée de p . . . 4
Le coût de la précision . . . 5
Ce que la courbe impose . . . 5

La taille de la population **6**
Le résultat qui surprend toujours . . . 6
Ce que change la correction de population finie . . . 6
La correction, chiffrée . . . 6

Les ajustements du terrain **7**
Le taux de réponse . . . 7
Des résultats par sous-groupe . . . 8
L'effet du plan de sondage . . . 8
La contrainte de budget . . . 9

S'entraîner **9**
Exercice 1 : le loyer moyen . . . 9
Exercice 1 : solution . . . 9
Exercice 2 : une proportion attendue . . . 9
Exercice 2 : solution . . . 10
Exercice 3 : un devis complet . . . 10
Exercice 3 : solution . . . 10

Ce qu'il faut retenir **10**
Le résumé du chapitre . . . 10

La suite 11

La question du commanditaire

Un renversement de la formule

On connaît la réponse avant de collecter

Les chapitres précédents partaient de n pour obtenir une précision. Ici on part de la **précision voulue** et l'on en déduit n.
C'est le seul ordre correct en pratique : la taille d'échantillon se décide **avant** la collecte, jamais après.

Pour une moyenne

$$e = z_{\alpha/2}\,\frac{\sigma}{\sqrt{n}} \qquad \Longrightarrow \qquad \boxed{n = \left(\frac{z_{\alpha/2}\,\sigma}{e}\right)^2}$$

où e est la demi-largeur acceptée, dans l'unité de la variable.

Le calcul, pas à pas

Le salaire moyen à 300 dirhams près

On veut $e = 300$ dirhams à 95 %, avec $\sigma \approx 2\,598$:

$$\sqrt{n} = \frac{1{,}96 \times 2\,598}{300} = 16{,}97 \qquad n = 16{,}97^2 = 288{,}1$$

On arrondit **toujours vers le haut** : $n = 289$ salariés.

Pourquoi vers le haut

Avec 288 observations, la demi-largeur serait de 300,05 dirhams : à peine au-dessus de l'objectif, mais au-dessus. L'arrondi vers le haut garantit la précision promise.
La formule suppose aussi un tirage aléatoire simple et un quantile normal ; pour de petits n, on remplacerait 1,96 par le quantile de Student.

Démonstration : La taille se déduit de la demi-largeur, et l'arrondi se fait vers le haut

La demi-largeur $h(n) = z\,\sigma/\sqrt{n}$ décroît strictement quand n croît. On cherche le plus petit entier n tel que $h(n) \le e$; tous les termes étant positifs, on peut élever au carré :

$$z\,\frac{\sigma}{\sqrt{n}} \le e \iff \sqrt{n} \ge \frac{z\,\sigma}{e} \iff n \ge \left(\frac{z\,\sigma}{e}\right)^2.$$

Le plus petit entier qui convient est le plus petit entier supérieur ou égal à $(z\sigma/e)^2$: l'arrondi se fait **par excès**. Ici $(1{,}96 \times 2\,598/300)^2 = 288{,}1$; $h(288) = 300{,}05 > 300$ échoue de peu, et $h(289) = 299{,}5 \le 300$ réussit.

Sensibilité à σ. La taille est proportionnelle à σ^2 : une erreur relative δ sur l'écart-type en

entraîne une d'environ 2δ sur n. Avec le pré-test, $\sigma \approx 2\,255$ au lieu de $2\,598$ ($-13\,\%$), donc $n = 218$ au lieu de 289, soit $(2\,255/2\,598)^2 = 0{,}75$ fois la taille nécessaire. La demi-largeur réellement obtenue avec 218 salariés est alors $1{,}96 \times 2\,598/\sqrt{218} = 345$ dirhams.

Ce que cela dit. La précision varie comme $1/\sqrt{n}$ et la taille comme σ^2 : sous-estimer l'écart-type de 13 % revient à commander une enquête 25 % trop petite, qui donne ± 345 au lieu de ± 300. C'est pourquoi la prudence consiste à majorer σ.

■

La difficulté, et comment on la contourne

La formule demande un écart-type que l'on ignore

Trois solutions, dans l'ordre de préférence :

1. une **étude antérieure** sur la même population ;
2. un **pré-test** sur une trentaine d'observations ;
3. la règle de l'**étendue** : $\sigma \approx (\max - \min)/4$.

Les trois solutions, sur nos données

Source de σ	Valeur	n pour ± 300 dh
La vraie valeur	2 598	289
Pré-test : les 30 premiers du fil rouge	2 255	218
Étendue des 50 : $(13\,600 - 3\,090)/4$	2 628	295

Ce que le pré-test a coûté

Un écart-type estimé trop bas

Le pré-test sous-estime σ de 13 %, et la taille calculée de 25 % : avec 218 salariés, la demi-largeur réelle serait de 345 dirhams, et non de 300.
L'écart-type d'un petit échantillon est lui-même imprécis — le chapitre 10 l'a montré. Il entre au carré dans la formule.

La règle de prudence

On majore l'écart-type tiré d'un pré-test, par exemple en prenant la borne haute de son intervalle de confiance, ou en ajoutant 10 à 20 %.
Une enquête trop petite ne peut plus être rattrapée après coup ; une enquête un peu trop grande coûte seulement un peu plus cher.

Sur nos salaires

La taille selon la précision voulue

Avec $\sigma \approx 2\,598$ et une confiance de 95 % :

Précision voulue	±500 dh	±300 dh	±150 dh	±100 dh
n nécessaire	104	289	1 153	2 593

La taille selon le niveau de confiance

Pour ±300 dirhams :

Confiance	90 %	95 %	99 %
n nécessaire	203	289	498

Le cas d'une proportion

La formule et son maximum

Pour une proportion

$$n = \frac{z_{\alpha/2}^2 \, p(1-p)}{e^2}$$

Ne connaissant pas p, on prend $p = 0{,}5$, qui maximise $p(1-p)$ et donne donc la taille la plus grande — donc sûre.

Les valeurs à connaître

Marge d'erreur	±5 points	±3 points	±2 points	±1 point
n	385	1 068	2 401	9 604

Si l'on a une idée de p

La marge de 5 points selon la proportion attendue

p attendu	0,1	0,2	0,214	0,3	0,5
n nécessaire	139	246	259	323	385

Un gain réel, et un risque

Pour les Bac+5, dont on sait la part voisine de 20 %, 259 salariés suffisent au lieu de 385 : un tiers d'économie.
Mais si la proportion réelle est plus proche de 0,5 que prévu, la marge obtenue sera plus large que promis. Le pire cas reste la seule garantie.

Démonstration : Ce que rapporte et ce que risque une proportion attendue

Pour une indicatrice, $\sigma^2 = p(1-p)$ (chapitre 3) : la formule de la moyenne devient $n(p) = z^2\,p(1-p)/e^2$. Comme $p(1-p) \le \frac{1}{4}$ avec égalité en $p = \frac{1}{2}$ (chapitre 3), $n(p) \le z^2/(4e^2) = n(\frac{1}{2})$: le pire cas est bien la plus grande taille, donc la taille sûre. Le **gain** à connaître p est

$$\frac{n(p)}{n(1/2)} = 4\,p(1-p),$$

soit 0,36 pour $p = 0{,}1$, 0,64 pour $p = 0{,}2$, 0,67 pour $p = 0{,}214$ et 0,84 pour $p = 0{,}3$, ce que l'on retrouve dans le tableau : 139/385, 246/385, 259/385, 323/385.

Le risque. On a dimensionné pour la proportion p_0 avec la taille $n = n(p_0)$, et la vraie proportion est p. La marge réellement obtenue est $e' = z\sqrt{p(1-p)/n}$, et comme $n = z^2 p_0(1-p_0)/e^2$,

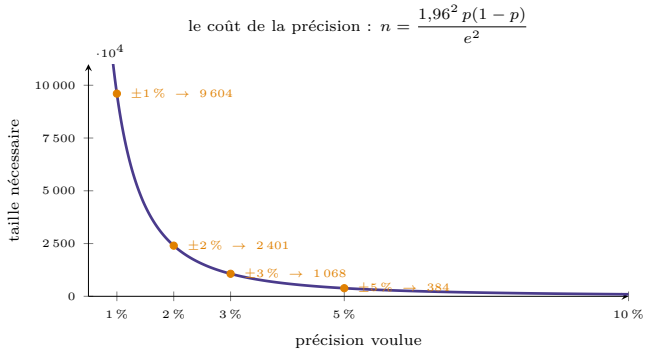
$$e' = e\,\sqrt{\frac{p(1-p)}{p_0(1-p_0)}}.$$

Dans l'exercice 2 ($p_0 = 0{,}15$, $e = 0{,}03$, $n = 545$) : si $p = 0{,}30$, $e' = 0{,}03\sqrt{0{,}21/0{,}1275} \approx 0{,}0385$, soit environ 3,8 points ; si $p = 0{,}5$, $e' \approx 0{,}042$.

Ce que cela dit. Connaître p économise $1 - 4p(1-p)$ de la taille, mais la marge promise n'est tenue que si $p(1-p)$ ne dépasse pas la valeur prévue : on achète une économie contre un risque d'erreur sur p_0, jamais contre le hasard du tirage.

■

Le coût de la précision



Trois usages en gestion

Avant de collecter, on fixe la précision voulue et la formule donne n. C'est le seul ordre correct.

Le budget est une contrainte, pas une variable d'ajustement : diviser n par deux ne dégrade la précision que de $\sqrt{2}$, mais diviser la marge par deux quadruple le coût.

Pour une moyenne, la même logique donne $n = \left(\frac{1{,}96\,\sigma}{e}\right)^2$, où σ vient d'une étude antérieure ou d'un pré-test.

Ce que la courbe impose

La précision est un bien à rendement décroissant

n varie comme $1/e^2$: **diviser la marge par deux quadruple la taille**, donc à peu près le budget.
Passer de ± 3 à ± 1 point multiplie le coût par neuf pour gagner deux points.

Pourquoi tant de sondages font mille personnes

Ce chiffre n'a rien de réglementaire : c'est d'abord un compromis économique, la zone où la courbe commence à s'aplatir.
En dessous, on gagne beaucoup de précision pour peu d'argent. Au-dessus, on dépense beaucoup pour peu de précision supplémentaire.

La taille de la population

Le résultat qui surprend toujours

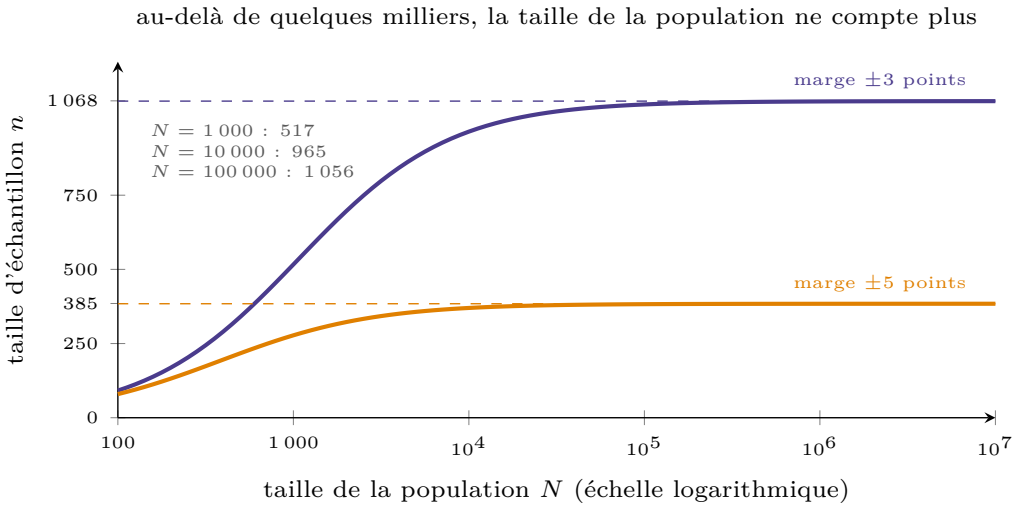
La taille de la population n'intervient pas

La formule ne contient pas N.
Estimer une proportion à ± 3 points demande environ mille personnes — que la population compte cent mille habitants ou cinquante millions.

L'image qui le fait comprendre

Pour juger d'une soupe, il faut goûter une cuillère. Il n'en faut pas davantage si la marmite est plus grande — **à condition qu'elle soit bien remuée**.
Ce « bien remuée » est exactement l'hypothèse du chapitre 1 : le tirage doit être aléatoire.

Ce que change la correction de population finie



La correction, chiffrée

La taille ajustée

Si n dépasse 5 % de N, on peut réduire la taille calculée :

$$n_{\text{ajusté}} = \frac{n}{1 + \dfrac{n-1}{N}}$$

Marge de 3 points, selon N

Population N	1 000	4 000	10 000	100 000	infinie
n ajusté	517	844	966	1 057	1 068

Arrondis à l'entier supérieur, comme partout dans ce chapitre.

Démonstration : La taille ajustée à une population finie

Sans remise, le chapitre 1 donne $V(\overline{X}) = \dfrac{\sigma^2}{n} \cdot \dfrac{N-n}{N-1}$. Notons $n_0 = z^2\sigma^2/e^2$ la taille pour une population infinie. La demi-largeur vaut e lorsque $z^2\,V(\overline{X}) = e^2$, c'est-à-dire

$$\begin{aligned} n_0\,\frac{N-n}{n\,(N-1)} = 1 &\iff n_0\,N - n_0\,n = n\,(N-1) \\ &\iff n_0\,N = n\,(N-1+n_0) \\ &\iff n = \frac{n_0\,N}{N-1+n_0} = \frac{n_0}{1+\dfrac{n_0-1}{N}}. \end{aligned}$$

Ce que la formule montre. La population n'intervient que par le rapport n_0/N. Quand $N \to \infty$, $n \to n_0$; la réduction relative est $1 - \dfrac{1}{1+(n_0-1)/N} \approx \dfrac{n_0}{N}$ quand cette quantité est petite : environ 5 % si n_0 vaut 5 % de N, d'où la règle du cours.

Les colonnes du tableau ($n_0 = 1\,068$) : $N = 1\,000$ donne 516,7 ; $N = 4\,000$ donne 843,1 ; $N = 10\,000$ donne 965,03 ; $N = 100\,000$ donne 1 056,7, soit une économie de 1 % seulement. Arrondis à l'entier supérieur, on lit 517, 844, 966 et 1 057 dans le tableau.

Ce que cela dit. À ± 3 points, interroger mille personnes suffit pour une ville de cent mille habitants comme pour un pays : ce qui borne la précision est n, non la part de la population que l'on interroge, tant que cette part reste faible.

■

Les ajustements du terrain

Le taux de réponse

Contacter plus que l'on n'interroge

Si l'on n'attend que 60 % de réponses, il faut contacter $n/0{,}60$ personnes pour en obtenir n. Cela suppose que les non-répondants ressemblent aux répondants. Sinon, contacter plus de monde ne corrige pas le **biais** de non-réponse (chapitre 1).

Un calcul complet, comme en cabinet

Objectif : ± 3 points sur une population de 4 000 salariés, taux de réponse attendu 60 %.
$n = 1\,068$, puis ajustement : $1\,068/(1 + 1\,067/4\,000) = 843{,}1$, soit 844.

Enfin : $844/0{,}60 = 1\,406{,}7$, soit 1 407 questionnaires à envoyer. **C'est ce dernier nombre qui figure au devis.**

Démonstration : Contacter n sur r personnes pour en obtenir n en moyenne

Supposons que chacune des c personnes contactées réponde indépendamment avec la probabilité r. Le nombre de réponses R suit $\mathcal{B}(c\,;r)$, d'espérance $c\,r$ et d'écart-type $\sqrt{c\,r(1-r)}$. Exiger $E(R) = n$ donne $c = n/r$.

Le calcul du devis. $n = 844$, $r = 0{,}60$: $c = 844/0{,}60 = 1\,406{,}7$, soit 1 407 contacts ; alors $E(R) = 844{,}2$ et $\sigma(R) = \sqrt{1\,407 \times 0{,}6 \times 0{,}4} = 18{,}4$.

Ce que la moyenne ne dit pas. R passe sous 844 avec une probabilité d'environ une chance sur deux. Pour que $R \geq 844$ avec une probabilité de 95 %, il faut environ 1 458 contacts, soit 4 % de plus.

Ce que cela dit. Diviser par le taux de réponse fixe le nombre de réponses **attendu** ; une marge de quelques pour cent protège du hasard du taux de réponse. Aucune des deux ne protège de son biais : si les non-répondants diffèrent des répondants, la taille ne répare rien (chapitre 1).

■

Des résultats par sous-groupe

Une précision par région

Une enquête nationale à ±5 points demande 385 personnes. Si l'on veut **la même précision dans chacune des quatre régions**, il en faut 385 par région : 1 540 au total.

La précision se paie par sous-groupe

Un commanditaire qui demande des résultats « par région, par âge et par sexe » multiplie la taille nécessaire par le nombre de cases. C'est la première question à lui poser, avant tout devis.

L'effet du plan de sondage

Multiplier par l'effet de plan

Les formules supposent un tirage aléatoire simple. Pour un autre plan, on multiplie la taille par l'**effet de plan** (*deff*) :

$$n_{\text{plan}} = \text{deff} \times n_{\text{aléatoire simple}}$$

Deux exemples

Un tirage stratifié par diplôme a, sur nos salaires, un effet de plan de 0,746 (chapitre 1) : $289 \times 0{,}746 = 215{,}6$, soit 216 salariés suffisent pour ±300 dirhams.
Un tirage par grappes d'effet de plan 2 en demande au contraire 578. Le cours d'Échantillonnage calcule ces effets.

La contrainte de budget

Coût fixe et coût unitaire

Le coût d'une enquête s'écrit souvent $C = C_0 + c\,n$: un coût fixe (conception, logiciel, analyse) et un coût par entretien.
Pour un budget B, la taille maximale est $n = (B - C_0)/c$, et la précision accessible s'en déduit.

Un budget de 60 000 dirhams

Coût fixe 15 000 dirhams, 150 dirhams par entretien : $n = 45\,000/150 = 300$ salariés.
La demi-largeur accessible pour le salaire moyen vaut $1{,}96 \times 2\,598/\sqrt{300} = 294$ dirhams. Si l'on exige ± 200, le budget ne suffit pas : il faudrait 649 entretiens.

S'entraîner

Exercice 1 : le loyer moyen

Une étude sur les loyers

Une étude antérieure donne un écart-type des loyers de 1 200 dirhams.

1. Combien de logements faut-il pour estimer le loyer moyen à ± 100 dirhams, à 95 % ?
2. Même question à 99 %.
3. Le pré-test donne finalement $s = 1\,400$. De combien la taille du point 1 change-t-elle ?

Exercice 1 : solution

L'écart-type entre au carré

1. $n = (1{,}96 \times 1\,200/100)^2 = 23{,}52^2 = 553{,}2$, soit 554 logements.
2. $n = (2{,}576 \times 1\,200/100)^2 = 955{,}6$, soit 956 logements.
3. $n = (1{,}96 \times 1\,400/100)^2 = 753{,}0$, soit 753 : +36 % pour un écart-type supérieur de 17 %, car $1{,}4^2/1{,}2^2 = 1{,}36$.

Exercice 2 : une proportion attendue

Le taux d'équipement en ordinateur

Une enquête veut estimer la part des ménages ruraux équipés d'un ordinateur à ± 3 points, à 95 %. Une enquête ancienne situait cette part vers 15 %.

1. Calculer la taille avec $p = 0{,}15$, puis avec $p = 0{,}5$.
2. Laquelle retenir ? Quel est le risque de chaque choix ?

Exercice 2 : solution

Économie contre garantie

1. Avec $p = 0{,}15$: $1{,}96^2 \times 0{,}15 \times 0{,}85 / 0{,}03^2 = 544{,}2$, soit 545. Avec $p = 0{,}5$: 1 068.
2. 545 ménages suffisent **si** la part reste proche de 15 %. Si l'équipement a progressé jusqu'à 30 %, la marge réelle serait de $\pm 3{,}8$ points. Un compromis raisonnable : prendre $p = 0{,}25$ ou 0,30, plausible maximum aujourd'hui.

Exercice 3 : un devis complet

La satisfaction des clients d'une banque

Une banque régionale compte 2 500 clients. Elle veut leur taux de satisfaction à ± 4 points, à 95 %. Le taux de réponse attendu est de 50 % ; chaque questionnaire envoyé coûte 20 dirhams.

1. Calculer la taille théorique, puis la taille ajustée à la population.
2. Combien de questionnaires envoyer, et pour quel coût ?
3. Pourquoi ce calcul suppose-t-il que les non-répondants ressemblent aux répondants ?

Exercice 3 : solution

Trois étapes, un devis

1. $n = 1{,}96^2 \times 0{,}25 / 0{,}04^2 = 600{,}25$, soit 601. Ajustement : $601/(1+600/2\,500) = 484{,}7$, soit 485 réponses.
2. $485/0{,}5 = 970$ questionnaires, pour $970 \times 20 = 19\,400$ dirhams.
3. Doubler les envois augmente le nombre de réponses, pas leur représentativité. Si les mécontents répondent moins, le taux de satisfaction sera surestimé, quelle que soit la taille.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. La taille se calcule **avant** la collecte, à partir de la précision voulue, et s'arrondit vers le haut.
2. Moyenne : $n = (z_{\alpha/2}\,\sigma/e)^2$, avec σ venu d'une étude antérieure ou d'un pré-test — à majorer par prudence.
3. Proportion : $n = z^2_{\alpha/2}\,p(1-p)/e^2$, et l'on prend $p = 0{,}5$ par prudence : 385, 1 068, 2 401.
4. n varie en $1/e^2$: **diviser la marge par deux quadruple le coût**.
5. La **taille de la population n'intervient presque pas** au-delà de quelques milliers — seule compte la qualité du tirage.
6. Sur le terrain : population finie, taux de réponse, sous-groupes, effet de plan, budget.

La suite

La troisième question de l'inférence

Nous savons estimer et encadrer. Reste la troisième question, et la plus fréquente en gestion : **une affirmation est-elle compatible avec les données ?**
C'est la théorie des tests, qui occupe les sept chapitres suivants.

Trois affirmations à mettre à l'épreuve

« Le salaire moyen dépasse 6 500 dirhams. » « La part des Bac+5 est de 15 %. » « Les hommes et les femmes ont le même salaire moyen. »
Le chapitre 12 pose la logique commune aux trois tests.