# Statistique inférentielle

Chapitre 11 : Choisir la taille de l'échantillon

Jaouad Madkour

22 octobre 2026

## Plan du chapitre

**La question du commanditaire** **2**
- Un renversement de la formule . . . 2
- Le calcul, pas à pas . . . 2
- La difficulté, et comment on la contourne . . . 2
- Ce que le pré-test a coûté . . . 3
- Sur nos salaires . . . 3

**Le cas d'une proportion** **4**
- La formule et son maximum . . . 4
- Si l'on a une idée de p . . . 4
- Le coût de la précision . . . 4
- Ce que la courbe impose . . . 5

**La taille de la population** **5**
- Le résultat qui surprend toujours . . . 5
- Ce que change la correction de population finie . . . 5
- La correction, chiffrée . . . 6

**Les ajustements du terrain** **6**
- Le taux de réponse . . . 6
- Des résultats par sous-groupe . . . 6
- L'effet du plan de sondage . . . 7
- La contrainte de budget . . . 7

**S'entraîner** **7**
- Exercice 1 : le loyer moyen . . . 7
- Exercice 1 : solution . . . 7
- Exercice 2 : une proportion attendue . . . 8
- Exercice 2 : solution . . . 8
- Exercice 3 : un devis complet . . . 8
- Exercice 3 : solution . . . 8

**Ce qu'il faut retenir** **8**
- Le résumé du chapitre . . . 8

La suite . . . . . 9

# La question du commanditaire

## Un renversement de la formule

**On connaît la réponse avant de collecter**

Les chapitres précédents partaient de $n$ pour obtenir une précision. Ici on part de la **précision voulue** et l'on en déduit $n$.
C'est le seul ordre correct en pratique : la taille d'échantillon se décide **avant** la collecte, jamais après.

**Pour une moyenne**

$$e = z_{\alpha/2}\,\frac{\sigma}{\sqrt{n}} \qquad \Longrightarrow \qquad \boxed{n = \left(\frac{z_{\alpha/2}\,\sigma}{e}\right)^2}$$

où $e$ est la demi-largeur acceptée, dans l'unité de la variable.

## Le calcul, pas à pas

**Le salaire moyen à 300 dirhams près**

On veut $e = 300$ dirhams à 95 %, avec $\sigma \approx 2\,598$ :

$$\sqrt{n} = \frac{1{,}96 \times 2\,598}{300} = 16{,}97 \qquad n = 16{,}97^2 = 288{,}1$$

On arrondit **toujours vers le haut** : $n = 289$ salariés.

**Pourquoi vers le haut**

Avec 288 observations, la demi-largeur serait de 300,05 dirhams : à peine au-dessus de l'objectif, mais au-dessus. L'arrondi vers le haut garantit la précision promise.
La formule suppose aussi un tirage aléatoire simple et un quantile normal ; pour de petits $n$, on remplacerait 1,96 par le quantile de Student.

## La difficulté, et comment on la contourne

**La formule demande un écart-type que l'on ignore**

Trois solutions, dans l'ordre de préférence :

1. une **étude antérieure** sur la même population ;
2. un **pré-test** sur une trentaine d'observations ;
3. la règle de l'**étendue** : $\sigma \approx (\max - \min)/4$.

**Les trois solutions, sur nos données**

| Source de $\sigma$ | Valeur | $n$ pour $\pm 300$ dh |
|---|---|---|
| La vraie valeur | 2 598 | 289 |
| Pré-test : les 30 premiers du fil rouge | 2 255 | 218 |
| Étendue des 50 : $(13\,600 - 3\,090)/4$ | 2 628 | 295 |

## Ce que le pré-test a coûté

**Un écart-type estimé trop bas**

Le pré-test sous-estime $\sigma$ de 13 %, et la taille calculée de 25 % : avec 218 salariés, la demi-largeur réelle serait de 345 dirhams, et non de 300.
L'écart-type d'un petit échantillon est lui-même imprécis — le chapitre 10 l'a montré. Il entre au carré dans la formule.

**La règle de prudence**

On majore l'écart-type tiré d'un pré-test, par exemple en prenant la borne haute de son intervalle de confiance, ou en ajoutant 10 à 20 %.
Une enquête trop petite ne peut plus être rattrapée après coup ; une enquête un peu trop grande coûte seulement un peu plus cher.

## Sur nos salaires

**La taille selon la précision voulue**

Avec $\sigma \approx 2\,598$ et une confiance de 95 % :

| Précision voulue | $\pm 500$ dh | $\pm 300$ dh | $\pm 150$ dh | $\pm 100$ dh |
|---|---|---|---|---|
| $n$ nécessaire | 104 | 289 | 1 153 | 2 593 |

**La taille selon le niveau de confiance**

Pour $\pm 300$ dirhams :

| Confiance | 90 % | 95 % | 99 % |
|---|---|---|---|
| $n$ nécessaire | 203 | 289 | 498 |

# Le cas d'une proportion

## La formule et son maximum

**Pour une proportion**

$$n = \frac{z^2_{\alpha/2}\, p(1-p)}{e^2}$$

Ne connaissant pas $p$, on prend $p = 0{,}5$, qui maximise $p(1-p)$ et donne donc la taille la plus grande — donc sûre.

**Les valeurs à connaître**

| Marge d'erreur | ±5 points | ±3 points | ±2 points | ±1 point |
|---|---|---|---|---|
| $n$ | 385 | 1 068 | 2 401 | 9 604 |

## Si l'on a une idée de p

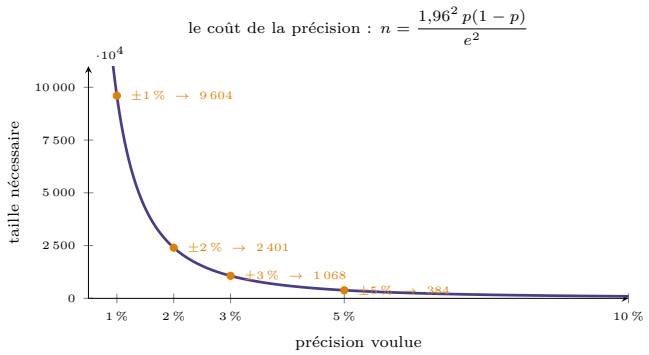
**La marge de 5 points selon la proportion attendue**

| $p$ attendu | 0,1 | 0,2 | 0,214 | 0,3 | 0,5 |
|---|---|---|---|---|---|
| $n$ nécessaire | 139 | 246 | 259 | 323 | 385 |

**Un gain réel, et un risque**

Pour les Bac+5, dont on sait la part voisine de 20 %, 259 salariés suffisent au lieu de 385 : un tiers d'économie.
Mais si la proportion réelle est plus proche de 0,5 que prévu, la marge obtenue sera plus large que promis. Le pire cas reste la seule garantie.

## Le coût de la précision




**Trois usages en gestion**

**Avant de collecter**, on fixe la précision voulue et la formule donne $n$. C'est le seul ordre correct.

**Le budget est une contrainte**, pas une variable d'ajustement : diviser $n$ par deux ne dégrade la précision que de $\sqrt{2}$, mais diviser la marge par deux quadruple le coût.

**Pour une moyenne**, la même logique donne $n = \left(\frac{1{,}96\,\sigma}{e}\right)^2$, où $\sigma$ vient d'une étude antérieure ou d'un pré-test.

### Ce que la courbe impose

**La précision est un bien à rendement décroissant**

$n$ varie comme $1/e^2$ : **diviser la marge par deux quadruple la taille**, donc à peu près le budget.
Passer de $\pm 3$ à $\pm 1$ point multiplie le coût par neuf pour gagner deux points.

**Pourquoi tant de sondages font mille personnes**

Ce chiffre n'a rien de réglementaire : c'est d'abord un compromis économique, la zone où la courbe commence à s'aplatir.
En dessous, on gagne beaucoup de précision pour peu d'argent. Au-dessus, on dépense beaucoup pour peu de précision supplémentaire.

## La taille de la population

### Le résultat qui surprend toujours

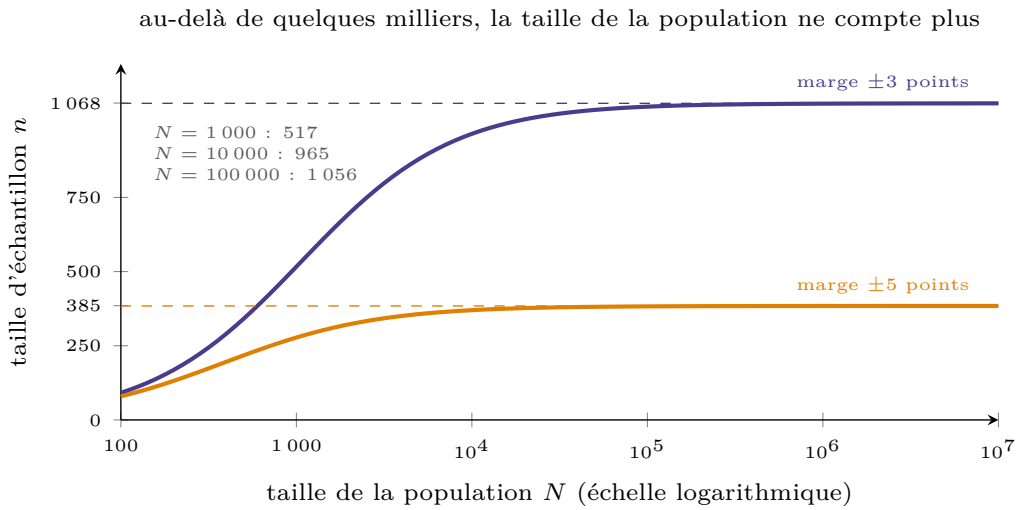
**La taille de la population n'intervient pas**

La formule ne contient pas $N$.
Estimer une proportion à $\pm 3$ points demande environ mille personnes — que la population compte cent mille habitants ou cinquante millions.

**L'image qui le fait comprendre**

Pour juger d'une soupe, il faut goûter une cuillère. Il n'en faut pas davantage si la marmite est plus grande — **à condition qu'elle soit bien remuée**.
Ce « bien remuée » est exactement l'hypothèse du chapitre 1 : le tirage doit être aléatoire.

### Ce que change la correction de population finie



### La correction, chiffrée

**La taille ajustée**

Si $n$ dépasse 5 % de $N$, on peut réduire la taille calculée :

$$n_{\text{ajusté}} = \frac{n}{1 + \dfrac{n-1}{N}}$$

**Marge de 3 points, selon N**

| Population $N$ | 1 000 | 4 000 | 10 000 | 100 000 | infinie |
|---|---|---|---|---|---|
| $n$ ajusté | 517 | 843 | 965 | 1 056 | 1 068 |

## Les ajustements du terrain

### Le taux de réponse

**Contacter plus que l'on n'interroge**

Si l'on n'attend que 60 % de réponses, il faut contacter $n/0{,}60$ personnes pour en obtenir $n$. Cela suppose que les non-répondants ressemblent aux répondants. Sinon, contacter plus de monde ne corrige pas le **biais** de non-réponse (chapitre 1).

**Un calcul complet, comme en cabinet**

Objectif : $\pm 3$ points sur une population de 4 000 salariés, taux de réponse attendu 60 %.
$n = 1\,068$, puis ajustement : $1\,068/(1 + 1\,067/4\,000) = 843{,}1$, soit 844.
Enfin : $844/0{,}60 = 1\,406{,}7$, soit 1 407 questionnaires à envoyer. **C'est ce dernier nombre qui figure au devis.**

### Des résultats par sous-groupe

**Une précision par région**

Une enquête nationale à $\pm 5$ points demande 385 personnes. Si l'on veut **la même précision dans chacune des quatre régions**, il en faut 385 par région : 1 540 au total.

**La précision se paie par sous-groupe**

Un commanditaire qui demande des résultats « par région, par âge et par sexe » multiplie la taille nécessaire par le nombre de cases. C'est la première question à lui poser, avant tout devis.

### L'effet du plan de sondage

**Multiplier par l'effet de plan**

Les formules supposent un tirage aléatoire simple. Pour un autre plan, on multiplie la taille par l'**effet de plan** (*deff*) :

$$n_{\text{plan}} = \text{deff} \times n_{\text{aléatoire simple}}$$

**Deux exemples**

Un tirage stratifié par diplôme a, sur nos salaires, un effet de plan de 0,746 (chapitre 1) : $289 \times 0{,}746 = 215{,}6$, soit 216 salariés suffisent pour $\pm 300$ dirhams.
Un tirage par grappes d'effet de plan 2 en demande au contraire 578. Le cours d'Échantillonnage calcule ces effets.

### La contrainte de budget

**Coût fixe et coût unitaire**

Le coût d'une enquête s'écrit souvent $C = C_0 + c\,n$ : un coût fixe (conception, logiciel, analyse) et un coût par entretien.
Pour un budget $B$, la taille maximale est $n = (B - C_0)/c$, et la précision accessible s'en déduit.

**Un budget de 60 000 dirhams**

Coût fixe 15 000 dirhams, 150 dirhams par entretien : $n = 45\,000/150 = 300$ salariés.
La demi-largeur accessible pour le salaire moyen vaut $1{,}96 \times 2\,598/\sqrt{300} = 294$ dirhams. Si l'on exige $\pm 200$, le budget ne suffit pas : il faudrait 649 entretiens.

## S'entraîner

### Exercice 1 : le loyer moyen

**Une étude sur les loyers**

Une étude antérieure donne un écart-type des loyers de 1 200 dirhams.

1. Combien de logements faut-il pour estimer le loyer moyen à $\pm 100$ dirhams, à 95 % ?
2. Même question à 99 %.
3. Le pré-test donne finalement $s = 1\,400$. De combien la taille du point 1 change-t-elle ?

### Exercice 1 : solution

**L'écart-type entre au carré**

1. $n = (1{,}96 \times 1\,200/100)^2 = 23{,}52^2 = 553{,}2$, soit 554 logements.
2. $n = (2{,}576 \times 1\,200/100)^2 = 955{,}6$, soit 956 logements.
3. $n = (1{,}96 \times 1\,400/100)^2 = 753{,}0$, soit 753 : +36 % pour un écart-type supérieur de 17 %, car $1{,}4^2/1{,}2^2 = 1{,}36$.

### Exercice 2 : une proportion attendue

**Le taux d'équipement en ordinateur**

Une enquête veut estimer la part des ménages ruraux équipés d'un ordinateur à $\pm 3$ points, à 95 %. Une enquête ancienne situait cette part vers 15 %.

1. Calculer la taille avec $p = 0{,}15$, puis avec $p = 0{,}5$.
2. Laquelle retenir ? Quel est le risque de chaque choix ?

### Exercice 2 : solution

**Économie contre garantie**

1. Avec $p = 0{,}15$ : $1{,}96^2 \times 0{,}15 \times 0{,}85 / 0{,}03^2 = 544{,}2$, soit 545. Avec $p = 0{,}5$ : 1 068.
2. 545 ménages suffisent **si** la part reste proche de 15 %. Si l'équipement a progressé jusqu'à 30 %, la marge réelle serait de $\pm 3{,}8$ points. Un compromis raisonnable : prendre $p = 0{,}25$ ou $0{,}30$, plausible maximum aujourd'hui.

### Exercice 3 : un devis complet

**La satisfaction des clients d'une banque**

Une banque régionale compte 2 500 clients. Elle veut leur taux de satisfaction à $\pm 4$ points, à 95 %. Le taux de réponse attendu est de 50 % ; chaque questionnaire envoyé coûte 20 dirhams.

1. Calculer la taille théorique, puis la taille ajustée à la population.
2. Combien de questionnaires envoyer, et pour quel coût ?
3. Pourquoi ce calcul suppose-t-il que les non-répondants ressemblent aux répondants ?

### Exercice 3 : solution

**Trois étapes, un devis**

1. $n = 1{,}96^2 \times 0{,}25 / 0{,}04^2 = 600{,}25$, soit 601. Ajustement : $601/(1+600/2\,500) = 484{,}7$, soit 485 réponses.
2. $485/0{,}5 = 970$ questionnaires, pour $970 \times 20 = 19\,400$ dirhams.
3. Doubler les envois augmente le nombre de réponses, pas leur représentativité. Si les mécontents répondent moins, le taux de satisfaction sera surestimé, quelle que soit la taille.

## Ce qu'il faut retenir

### Le résumé du chapitre

**Six points**

1. La taille se calcule **avant** la collecte, à partir de la précision voulue, et s'arrondit vers le haut.
2. Moyenne : $n = (z_{\alpha/2}\,\sigma/e)^2$, avec $\sigma$ venu d'une étude antérieure ou d'un pré-test — à majorer par prudence.

3. Proportion : $n = z^2_{\alpha/2}\, p(1-p)/e^2$, et l'on prend $p = 0{,}5$ par prudence : 385, 1 068, 2 401.
4. $n$ varie en $1/e^2$ : **diviser la marge par deux quadruple le coût**.
5. La **taille de la population n'intervient presque pas** au-delà de quelques milliers — seule compte la qualité du tirage.
6. Sur le terrain : population finie, taux de réponse, sous-groupes, effet de plan, budget.

## La suite

**La troisième question de l'inférence**

Nous savons estimer et encadrer. Reste la troisième question, et la plus fréquente en gestion : **une affirmation est-elle compatible avec les données ?**
C'est la théorie des tests, qui occupe les sept chapitres suivants.

**Trois affirmations à mettre à l'épreuve**

« Le salaire moyen dépasse 6 500 dirhams. » « La part des Bac+5 est de 15 %. » « Les hommes et les femmes ont le même salaire moyen. »
Le chapitre 12 pose la logique commune aux trois tests.