

Statistique inférentielle

Chapitre 20 : Tester un coefficient

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique inférentielle

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Le test de significativité d'une pente

Une étude porte sur $n = 25$ entreprises : x mesure leurs dépenses de R&D (en millions de dh), y leur taux de croissance du chiffre d'affaires (en %). La régression donne $\hat{\beta}_1 = 1,85$, $\sum_i e_i^2 = 186,4$, $\sum_i (x_i - \bar{x})^2 = 42,8$.

- Calculer $\hat{\sigma}_\varepsilon^2 = \sum_i e_i^2 / (n - 2)$ puis $\hat{\sigma}(\hat{\beta}_1) = \hat{\sigma}_\varepsilon / \sqrt{\sum_i (x_i - \bar{x})^2}$.
- Écrire H_0 et H_1 , calculer $t = \hat{\beta}_1 / \hat{\sigma}(\hat{\beta}_1)$, et donner le degré de liberté.
- Comparer t au seuil $t_{0,975;23} = 2,069$ et conclure au seuil de 5 %. Les dépenses de R&D ont-elles un effet significatif sur la croissance du chiffre d'affaires ?

Exercice 2 — L'intervalle de confiance de la pente, et son usage

On reprend l'exercice 1 : $\hat{\beta}_1 = 1,85$, $\hat{\sigma}(\hat{\beta}_1) \approx 0,435$, ddl = 23.

- Calculer $IC_{95\%}(\beta_1) = \hat{\beta}_1 \pm t_{0,975;23} \times \hat{\sigma}(\hat{\beta}_1)$.
- Rédiger, en une phrase utilisable dans un rapport, l'interprétation économique de cet intervalle (en termes de points de croissance par million de dh de R&D).
- Le cours affirme que « c'est l'intervalle, non la p -value, qui permet de négocier une grille ». En vous appuyant sur votre intervalle, expliquer pourquoi un décideur a besoin de l'intervalle – et pas seulement de savoir que le test rejette H_0 – pour arbitrer un budget de R&D.

Exercice 3 — $F = t^2$, et la différence entre significativité et qualité d'ajustement

Sur un très large échantillon de $n = 1\,000$ observations, une régression simple donne un coefficient très significatif : $t = 6,5$.

- Calculer $F = t^2$ (le F global de la régression, en régression simple).
- Sachant que $R^2 = \frac{F}{F + (n - 2)}$ en régression simple, calculer R^2 .
- Un coefficient avec $t = 6,5$ (très significatif, $p < 0,0001$) et $R^2 \approx 4\%$: ces deux résultats sont-ils contradictoires ? Expliquer, en une phrase, à quelles deux questions différentes répondent le test de significativité et le R^2 .

2 Exercices cumulatifs (chapitres 1 à 20)

Exercice 4 — Le tableau de régression complet du fil rouge

On reprend le fil rouge : régression du salaire sur l'ancienneté, $n = 500$, $\hat{\beta}_1 = 277,17$, $\hat{\sigma}_\varepsilon = 2\,008,34$, $\sum_i (x_i - \bar{x})^2 = 17\,787$ (chapitre 19).

- Calculer $\hat{\sigma}(\hat{\beta}_1) = \hat{\sigma}_\varepsilon / \sqrt{\sum_i (x_i - \bar{x})^2}$ et vérifier qu'on retrouve $\hat{\sigma}(\hat{\beta}_1) \approx 15,06$.
- Calculer $t = \hat{\beta}_1 / \hat{\sigma}(\hat{\beta}_1)$ et vérifier qu'on retrouve $t \approx 18,41$. Conclure au seuil de 5 % (ddl = 498, on prendra un seuil $\approx 1,965$).
- Calculer $IC_{95\%}(\beta_1)$ avec $z \approx 1,96$ (l'approximation normale est légitime avec 498 ddl) et vérifier qu'on retrouve $[247,65; 306,68]$. Vérifier également que $F = t^2 \approx 338,8$, la valeur du chapitre 17 pour une régression à une seule variable explicative.
- Le cours affirme que « un coefficient très significatif dans un modèle médiocre reste un coefficient dans un modèle médiocre », avec ici $R^2 = 0,405$. En reliant ce constat à l'exercice 6 du chapitre 17 (canal de vente, $\eta^2 \approx 0,063$) et à l'exercice 2 du chapitre 17 (engrais, $\eta^2 \approx 0,270$), formuler en une phrase le principe commun aux trois situations, valable aussi bien pour un test de χ^2 , un F

d'ANOVA que pour un t de régression.

3 Applications en sciences économiques

Exercice 5 — Estimer un prix au mètre carré

Une agence immobilière régresse le prix de vente d'appartements (en dh) sur leur surface (en m^2), sur $n = 60$ transactions. Elle obtient $\hat{\beta}_1 = 1\,850$ dh/ m^2 , $\sum_i e_i^2 = 8\,038\,000\,000$ dh², $\sum_i (x_i - \bar{x})^2 = 8\,200$.

- (a) Calculer $\hat{\sigma}_\varepsilon$, $\hat{\sigma}(\hat{\beta}_1)$, et $t = \hat{\beta}_1 / \hat{\sigma}(\hat{\beta}_1)$ (ddl = 58, on prendra un seuil $t_{0,975;58} \approx 2,001$).
- (b) Calculer $IC_{95\%}(\beta_1)$, et $R^2 = F / (F + 58)$ avec $F = t^2$.
- (c) L'agence souhaite annoncer un prix au m^2 « officiel » pour le quartier. Rédiger, en une phrase de rapport professionnel, ce que l'intervalle de confiance permet – et ne permet pas – d'affirmer sur ce prix.

Exercice 6 — Un institut de sondage et la tentation de sur-interpréter

Un institut de sondage étudie, sur $n = 5\,000$ répondants, l'effet du niveau d'étude (en années, x) sur un score d'optimisme économique (points, y). Il trouve $\hat{\beta}_1 = 42$ points par année d'étude, avec $t = 33,4$ (ddl = 4 998) et $R^2 \approx 0,18$.

- (a) Le test de significativité rejette-t-il $H_0 : \beta_1 = 0$ au seuil de 5%? Justifier sans calcul supplémentaire, à partir de la valeur de t .
- (b) Un communiqué de presse de l'institut affirme : « Le niveau d'étude est, de très loin, le facteur qui détermine l'optimisme économique des Marocains ($t = 33,4$, extrêmement significatif) ». Ce communiqué est-il fidèle aux résultats? Que faudrait-il ajouter ou corriger?
- (c) Expliquer, à l'aide de la formule $\hat{\sigma}(\hat{\beta}_1) = \hat{\sigma}_\varepsilon / \sqrt{\sum_i (x_i - \bar{x})^2}$, pourquoi un t aussi écrasant est parfaitement compatible avec un effet qui n'explique, au fond, qu'une modeste partie de la dispersion du score.


1 Exercices du chapitre

Correction — Exercice 1

(a) $\hat{\sigma}_\varepsilon^2 = \frac{186,4}{23} \approx 8,104$, donc $\hat{\sigma}_\varepsilon \approx 2,847$. $\hat{\sigma}(\hat{\beta}_1) = \frac{2,847}{\sqrt{42,8}} \approx 0,435$.

(b) $H_0 : \beta_1 = 0 ; H_1 : \beta_1 \neq 0$. $t = \frac{1,85}{0,435} \approx 4,251$. ddl = $n - 2 = 23$.

(c) $4,251 > t_{0,975;23} = 2,069$: on **rejette** H_0 . Les dépenses de R&D ont un effet significatif sur la croissance du chiffre d'affaires.




Correction — Exercice 2

(a) $IC_{95\%}(\beta_1) = 1,85 \pm 2,069 \times 0,435 \approx 1,85 \pm 0,900 = [0,950 ; 2,750]$.

(b) « Chaque million de dh supplémentaire de dépenses de R&D s'accompagne d'une hausse du taux de croissance du chiffre d'affaires estimée entre 0,95 et 2,75 points, au seuil de confiance de 95 %. »

(c) Savoir seulement que le test rejette H_0 dit « il existe un effet, positif », mais ne dit rien sur son **ampleur** : un décideur qui doit arbitrer un budget de R&D a besoin de savoir si un million de dh supplémentaire rapporte, au pire, un maigre 0,95 point de croissance, ou, au mieux, 2,75 points – deux décisions d'investissement potentiellement très différentes, que seul l'intervalle permet de distinguer. La significativité seule aurait pu tout aussi bien coexister avec un effet de 0,01 point (rejeté avec un intervalle très serré) qu'avec un effet de 10 points.




Correction — Exercice 3

(a) $F = t^2 = 6,5^2 = 42,25$.

(b) $R^2 = \frac{42,25}{42,25 + 998} \approx 0,0406$, soit environ 4 %.

(c) **Non**, ces deux résultats ne sont pas contradictoires : le test de significativité répond à la question « l'effet est-il réel, ou pourrait-il être dû au hasard d'échantillonnage ? » (ici, avec $n = 1\,000$, même un effet de faible ampleur devient très facilement détectable, chapitre 13), tandis que R^2 répond à la question « quelle part de la dispersion de y ce modèle explique-t-il ? » (ici, très peu). Un grand échantillon peut ainsi rendre « écrasante » la significativité d'un effet qui reste, en pratique, économiquement marginal.



2 Exercices cumulatifs (chapitres 1 à 20)


Correction — Exercice 4

$$(a) \hat{\sigma}(\hat{\beta}_1) = \frac{2\,008,34}{\sqrt{17\,787}} \approx \frac{2\,008,34}{133,37} \approx 15,06.$$

(b) $t = \frac{277,17}{15,06} \approx 18,41$. Comme $18,41 \gg 1,965$, on **rejette très largement** $H_0 : \beta_1 = 0$ ($p < 0,0001$) : l'ancienneté a un effet significatif sur le salaire.

(c) $IC_{95\%}(\beta_1) = 277,17 \pm 1,96 \times 15,06 \approx 277,17 \pm 29,52 = [247,65 ; 306,69]$, conforme au cours. $F = t^2 = 18,41^2 \approx 338,9 \approx 338,8$ (l'écart résiduel vient des arrondis intermédiaires).

(d) Le principe commun aux trois situations (khi-deux, F d'ANOVA, t de régression) est que **la significativité statistique et l'intensité (ou la qualité d'ajustement) de la relation sont deux informations indépendantes**, toutes deux nécessaires : un test peut rejeter H_0 avec une force écrasante ($t = 18,41$, $F = 86,28$ au chapitre 17, χ^2 énorme) tout en ne concernant, au fond, qu'une fraction modeste de la dispersion totale ($R^2 = 0,405$ ici, $\eta^2 = 0,270$ pour les engrais, $\eta^2 \approx 0,063$ pour le canal de vente) – le test dit « l'effet est réel », l'indicateur d'intensité (R^2 , η^2) dit « combien il compte », et les deux sont systématiquement nécessaires pour ne pas confondre un effet certain avec un effet dominant.



3 Applications en sciences économiques

Correction — Exercice 5

$$(a) \hat{\sigma}_\varepsilon = \sqrt{8\,038\,000\,000/58} \approx 11\,772 \text{ dh. } \hat{\sigma}(\hat{\beta}_1) = \frac{11\,772}{\sqrt{8\,200}} \approx 130,0 \text{ dh/m}^2. t = \frac{1\,850}{130,0} \approx 14,23. \text{ Comme } 14,23 \gg 2,001, \text{ on rejette } H_0 \text{ très largement.}$$

(b) $IC_{95\%}(\beta_1) = 1\,850 \pm 2,001 \times 130,0 \approx 1\,850 \pm 260,1 = [1\,589,8 ; 2\,110,2] \text{ dh/m}^2$. $F = 14,23^2 \approx 202,5$, $R^2 = \frac{202,5}{202,5 + 58} \approx 0,777$.

(c) « La surface a un effet significatif et important sur le prix de vente (elle explique environ 78 % de sa dispersion) ; chaque m^2 supplémentaire est associé à une hausse de prix estimée entre 1 590 et 2 110 dh, au seuil de confiance de 95 %. » L'intervalle permet d'**encadrer** un prix au m^2 de référence pour le quartier, mais ne permet pas d'affirmer qu'un bien précis se vendra à ce prix exact : environ 22 % de la dispersion des prix reste inexpliquée par la seule surface (emplacement, état, étage, etc.).

Correction — Exercice 6

(a) **Oui** : avec $ddl = 4998$, le seuil $t_{0,975}$ est très proche de 1,96 ; $t = 33,4 \gg 1,96$, donc on rejette $H_0 : \beta_1 = 0$ très largement, $p < 0,0001$.

(b) **Non**, ce communiqué n'est pas fidèle aux résultats : il confond significativité statistique et importance du facteur. Avec $R^2 \approx 0,18$, le niveau d'étude n'explique qu'environ 18 % de la dispersion du score d'optimisme – **plus de 80 % vient d'ailleurs**. Un t écrasant signale seulement que l'effet est réel et non dû au hasard sur un aussi grand échantillon ; il faudrait corriger le communiqué en « le niveau d'étude a un effet réel, mais partiel, sur l'optimisme économique », et publier R^2 à côté de t .

(c) $\hat{\sigma}(\hat{\beta}_1) = \hat{\sigma}_\varepsilon / \sqrt{\sum_i (x_i - \bar{x})^2}$: avec $n = 5\,000$ observations, $\sum_i (x_i - \bar{x})^2$ est nécessairement très grand (chapitre 19 : plus d'observations, dénominateur plus grand), ce qui rend $\hat{\sigma}(\hat{\beta}_1)$ très petit **même si** le bruit résiduel $\hat{\sigma}_\varepsilon$ reste élevé – d'où un $t = \hat{\beta}_1 / \hat{\sigma}(\hat{\beta}_1)$ très grand, sans que cela implique que ce bruit résiduel (donc la part inexpliquée, ici 82 %) ait diminué. Un grand échantillon rend les petits effets

déTECTABLES ; il ne les rend pas plus importants.

