Statistique inférentielle

Chapitre 20 : Tester un coefficient

Jaouad Madkour

31 octobre 2026

Plan du chapitre

La pente, variable aléatoire **2**
Sa distribution d'échantillonnage . . . 2
Ce que montre la simulation . . . 2
Rien de nouveau, tout est déjà là . . . 3
L'erreur-type estimée . . . 4
Le calcul sur notre échantillon . . . 5

Le test de significativité **5**
La question . . . 5
L'application . . . 6
Dix échantillons, dix intervalles . . . 7
Ce que montrent les dix intervalles . . . 7
Tester une autre valeur que zéro . . . 7
La constante . . . 8
La lecture de gestion . . . 8

Prévoir **8**
Deux questions différentes . . . 8
À dix ans d'ancienneté . . . 9
Les deux bandes . . . 10
Ce que montre la figure . . . 10

La sortie d'un logiciel **11**
Tout s'y trouve, et l'on sait maintenant tout lire . . . 11
Le F, le t et le R^2, sur une seule variable . . . 11
Quand une hypothèse tombe . . . 12

S'entraîner **12**
Exercice 1 : lire une sortie . . . 12
Exercice 1 : solution . . . 13
Exercice 2 : un effet non significatif . . . 13
Exercice 2 : solution . . . 13
Exercice 3 : significatif et faible . . . 13

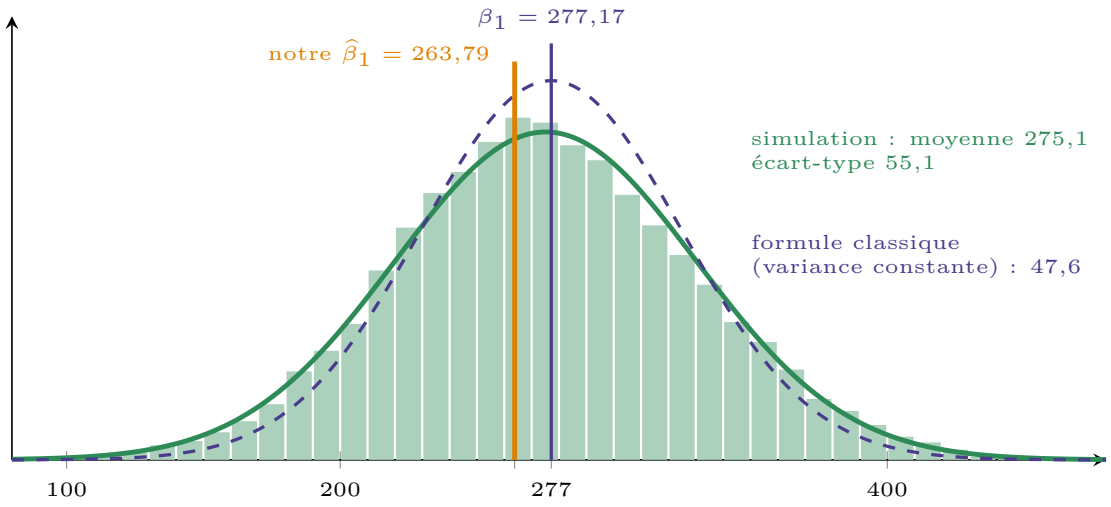
Exercice 3 : solution 13

Ce qu'il faut retenir **14**
Le résumé du chapitre 14
La suite 14

La pente, variable aléatoire

Sa distribution d'échantillonnage

20 000 échantillons : la pente estimée est une variable aléatoire



pente estimée sur un échantillon de 50 salariés

Ce que montre la simulation

Vingt mille échantillons de 50 salariés

La moyenne des 20 000 pentes vaut 275,1, pour une vraie pente de 277,2 : l'estimateur est pratiquement **sans biais**.
La distribution est en cloche : la pente est approximativement **normale**, par le théorème central limite.

Mais plus dispersée que prévu

L'écart-type observé des pentes vaut 55,1. La formule classique $\sigma_\varepsilon / \sqrt{\sum (x_i - \overline{x})^2}$ annonce 47,6.
C'est la conséquence de l'hétéroscédasticité vue au chapitre 19 : la formule suppose une variance constante des erreurs, que nos salaires ne respectent pas.

Démonstration : Quand la variance des erreurs change, la formule classique se trompe

La démonstration du chapitre 19 donne $\hat{\beta}_1 - \beta_1 = \sum_i w_i \varepsilon_i$ avec $w_i = (x_i - \overline{x})/S_{xx}$. Si les erreurs sont indépendantes mais de variances σ_i^2 différentes,

$$V(\hat{\beta}_1) = \sum_i w_i^2 \sigma_i^2 = \frac{\sum_i (x_i - \overline{x})^2 \, \sigma_i^2}{S_{xx}^2},$$

alors que la formule classique $\bar{\sigma}^2/S_{xx} = \sum_i (x_i - \overline{x})^2 \, \bar{\sigma}^2/S_{xx}^2$ remplace chaque σ_i^2 par leur moyenne $\bar{\sigma}^2$. Comme $\sum_i (\sigma_i^2 - \bar{\sigma}^2) = 0$, l'écart entre les deux est

$$V(\hat{\beta}_1) - \frac{\bar{\sigma}^2}{S_{xx}} = \frac{\sum_i (x_i - \overline{x})^2 (\sigma_i^2 - \bar{\sigma}^2)}{S_{xx}^2} = \frac{n \operatorname{Cov}\big((x_i - \overline{x})^2, \, \sigma_i^2\big)}{S_{xx}^2},$$

positif quand la variance des erreurs est plus forte là où $(x_i - \overline{x})^2$ est grand. La formule classique **sous-estime** alors la dispersion de la pente.

Nos données. On prend les 500 salariés comme population, avec leur droite vraie ($\sigma_\varepsilon = 2\,004$ pour l'écart-type des erreurs) et $n = 50$. La formule classique donne $\sigma_\varepsilon \big/ \sqrt{n \operatorname{Var}(x)} = 47{,}5$ (la valeur 47,6 du cours en diffère par le diviseur de la variance résiduelle, N ou $N - 2$). La formule qui tient compte de σ_i, évaluée sur la population, donne $\sqrt{E[(x-\mu)^2 \varepsilon^2] \big/ (n \operatorname{Var}(x)^2)} = 53{,}4$, bien plus proche des 55,1 de la simulation que de 47,6. Il reste un écart, que ce calcul asymptotique ne capte pas à $n = 50$ avec des erreurs asymétriques.

La couverture. L'intervalle est construit avec l'erreur-type classique, 47,6, alors que la dispersion réelle est de 55,1 : le rapport vaut 0,864. La probabilité qu'il contienne β_1 est donc à peu près celle qu'une normale centrée réduite tombe dans $\pm 2{,}011 \times 0{,}864$, soit $2\Phi(1{,}737) - 1 = 0{,}918$, que la simulation du cours confirme (91,9 %).

Ce que cela dit. L'hypothèse 3 n'est pas décorative : quand elle tombe, la pente reste sans biais, mais son erreur-type est fausse, et avec elle l'intervalle et la p-value. Une erreur-type sous-estimée de 14 % coûte déjà plus de trois points de couverture.

■

Rien de nouveau, tout est déjà là

Le parallèle complet

Chapitre 2	Chapitre 20
$\overline{X}$ estime m	$\hat{\beta}_1$ estime β_1
$E(\overline{X}) = m$	$E(\hat{\beta}_1) = \beta_1$
$\sigma(\overline{X}) = \sigma/\sqrt{n}$	$\sigma(\hat{\beta}_1) = \sigma_\varepsilon / \sqrt{\sum (x_i - \overline{x})^2}$
loi normale par le TCL	loi normale par le TCL

La conséquence

Tout ce que les chapitres 9 et 15 ont fait pour la moyenne s'applique à la pente **sans une formule nouvelle**.
Il suffit de remplacer $\overline{x}$ par $\hat{\beta}_1$ et l'erreur-type par la sienne.

L'erreur-type estimée

Deux estimations emboîtées

$$\hat{\sigma}_\varepsilon^2 = \frac{\sum_i e_i^2}{n-2} \qquad\qquad \hat{\sigma}(\hat{\beta}_1) = \frac{\hat{\sigma}_\varepsilon}{\sqrt{\sum_i (x_i - \overline{x})^2}}$$

Pourquoi $n-2$

La règle du chapitre 3 : **un degré de liberté par paramètre estimé**.
Ici deux, $\hat{\beta}_0$ et $\hat{\beta}_1$. Le dénominateur était $n-1$ pour une variance simple ; il sera $n-k-1$ pour une régression à k variables explicatives. Le principe ne change jamais.

Démonstration : Pourquoi la somme des carrés des résidus est divisée par n-2

Comme $y_i - \overline{y} = \beta_1(x_i - \overline{x}) + (\varepsilon_i - \overline{\varepsilon})$, le résidu s'écrit

$$e_i = (y_i - \overline{y}) - \hat{\beta}_1(x_i - \overline{x}) = (\varepsilon_i - \overline{\varepsilon}) - (\hat{\beta}_1 - \beta_1)(x_i - \overline{x}).$$

On élève au carré et l'on somme. Or $\hat{\beta}_1 - \beta_1 = \sum_i (x_i - \overline{x})\varepsilon_i / S_{xx} = \sum_i (x_i - \overline{x})(\varepsilon_i - \overline{\varepsilon})/S_{xx}$, de sorte que le terme croisé vaut $-2(\hat{\beta}_1 - \beta_1)^2 S_{xx}$ et que

$$\sum_i e_i^2 = \sum_i (\varepsilon_i - \overline{\varepsilon})^2 - 2(\hat{\beta}_1 - \beta_1)^2 S_{xx} + (\hat{\beta}_1 - \beta_1)^2 S_{xx} = \sum_i (\varepsilon_i - \overline{\varepsilon})^2 - (\hat{\beta}_1 - \beta_1)^2 S_{xx}.$$

Prenons les espérances. Le premier terme est la somme des carrés des écarts à la moyenne de n variables d'écart-type σ_ε : son espérance est $(n-1)\sigma_\varepsilon^2$ (chapitre 5). Le second a pour espérance $S_{xx}\, V(\hat{\beta}_1) = S_{xx} \cdot \sigma_\varepsilon^2 / S_{xx} = \sigma_\varepsilon^2$ (chapitre 19). Donc

$$E\Big(\sum_i e_i^2\Big) = (n-1)\sigma_\varepsilon^2 - \sigma_\varepsilon^2 = (n-2)\,\sigma_\varepsilon^2,$$

et $\hat{\sigma}_\varepsilon^2 = \sum_i e_i^2/(n-2)$ est sans biais.

D'où vient le 2. Les résidus vérifient deux relations, $\sum_i e_i = 0$ et $\sum_i (x_i - \overline{x})e_i = 0$: le vecteur des n résidus vit dans un espace de dimension $n-2$. Diviser par n (ou par $n-1$) sous-estimerait la variance, parce que la droite est ajustée sur les mêmes points : elle les suit de plus près que la vraie droite.

Nos données. $\sum_i e_i^2 = 128\,830\,945$, donc $\hat{\sigma}_\varepsilon^2 = 128\,830\,945/48 = 2\,683\,978$, $\hat{\sigma}_\varepsilon = 1\,638{,}3$. Avec le diviseur 50, on aurait obtenu 1 605,2 : 2 % trop petit.

Ce que cela dit. Le $n-2$ est le prix de l'estimation des deux paramètres de la droite. Avec k variables explicatives il y aurait $k+1$ paramètres et le diviseur serait $n-k-1$: c'est la règle du chapitre 3 sous sa forme générale.

■

Le calcul sur notre échantillon

Des résidus à l'erreur-type

Somme des carrés des résidus : $\sum e_i^2 = 128\,830\,945$.

$$\hat{\sigma}_\varepsilon^2 = \frac{128\,830\,945}{48} = 2\,683\,978 \qquad \hat{\sigma}_\varepsilon = 1\,638{,}3$$

$$\hat{\sigma}(\hat{\beta}_1) = \frac{1\,638{,}3}{\sqrt{1\,716{,}5}} = \frac{1\,638{,}3}{41{,}43} = 39{,}54$$

Ce que dit ce nombre

Une pente estimée à 264 dirhams par an, avec une erreur-type de 40 : la pente est connue à environ ± 80 dirhams près.

Le test de significativité

La question

La variable explicative sert-elle à quelque chose

$$H_0 : \beta_1 = 0 \qquad H_1 : \beta_1 \neq 0$$

Sous H_0, l'ancienneté n'a aucun effet sur le salaire : la droite vraie est horizontale.

La statistique

$$t = \frac{\hat{\beta}_1 - 0}{\hat{\sigma}(\hat{\beta}_1)} \;\sim\; \text{Student à } n-2 \text{ degrés de liberté}$$

C'est exactement la forme du chapitre 12 : *(observé − prévu par H_0) divisé par l'erreur-type.*

Démonstration : Pourquoi le t de la pente suit Student à n-2 degrés de liberté

On suppose les erreurs normales (hypothèse 5). La démonstration tient en quatre points.

1. *La pente est normale.* $\hat{\beta}_1 = \beta_1 + \sum_i w_i \varepsilon_i$ est une combinaison linéaire de normales indépendantes : $\hat{\beta}_1 \sim \mathcal{N}(\beta_1 ; \sigma_\varepsilon^2 / S_{xx})$ exactement, pour tout n.
2. *La pente et les résidus sont indépendants.* Avec $\hat{\beta}_1 - \beta_1 = \sum_j w_j \varepsilon_j$ et $e_i = \varepsilon_i - \overline{\varepsilon} - (\hat{\beta}_1 - \beta_1)(x_i - \overline{x})$:

$$\mathrm{Cov}(\hat{\beta}_1, e_i) = \sigma_\varepsilon^2 w_i - \sigma_\varepsilon^2 \frac{\sum_j w_j}{n} - (x_i - \overline{x}) \frac{\sigma_\varepsilon^2}{S_{xx}} = \sigma_\varepsilon^2 w_i - 0 - \sigma_\varepsilon^2 w_i = 0.$$

   Pour des variables conjointement normales, covariance nulle équivaut à indépendance : $\hat{\beta}_1$ est indépendante de $\hat{\sigma}_\varepsilon^2$, qui ne dépend que des e_i.
3. *La somme des carrés des résidus est un khi-deux.* Le vecteur des résidus est la projection du vecteur des erreurs sur le sous-espace, de dimension $n \quad - \quad 2$, orthogonal

aux vecteurs $(1,\dots,1)$ et $(x_1,\dots,x_n)$ (les deux relations de la démonstration précédente). La norme au carré de la projection d'un vecteur normal standard sur un espace de dimension d suit une loi χ^2_d (même argument qu'au chapitre 18, admis ici) : $(n-2)\hat{\sigma}^2_\varepsilon/\sigma^2_\varepsilon \sim \chi^2_{n-2}$.

4. *Le quotient.* Avec $Z = (\hat{\beta}_1 - \beta_1)\big/(\sigma_\varepsilon/\sqrt{S_{xx}}) \sim \mathcal{N}(0\,;1)$ et $V = (n-2)\hat{\sigma}^2_\varepsilon/\sigma^2_\varepsilon \sim \chi^2_{n-2}$ indépendants,
$$\frac{Z}{\sqrt{V/(n-2)}} = \frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}_\varepsilon/\sqrt{S_{xx}}} = \frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}(\hat{\beta}_1)}$$
car l'inconnue σ_ε se simplifie. C'est la définition d'une loi de Student à $n-2$ degrés de liberté, exactement comme au chapitre 4 pour la moyenne.

Un contrôle par simulation. Avec $n = 7$ (donc 5 degrés de liberté, seuil 2,571) et des erreurs normales, 20 000 tirages de $t = (\hat{\beta}_1 - \beta_1)/\hat{\sigma}(\hat{\beta}_1)$ dépassent le seuil de Student dans 5,0 % des cas, mais le seuil normal 1,96 dans 10,8 %.

Ce que cela dit. Rien ne change par rapport à la moyenne : une normale divisée par la racine d'un khi-deux indépendant. Le $n-2$ vient de la dimension des résidus, et la loi de Student est exacte quand les erreurs sont normales, approchée sinon.

■

L'application

Sur l'échantillon de 50 salariés

$$t = \frac{263{,}79}{39{,}54} = 6{,}67 \qquad \text{ddl} = 48 \qquad t_{0{,}975\,;48} = 2{,}011 \qquad p = 2 \times 10^{-8}$$

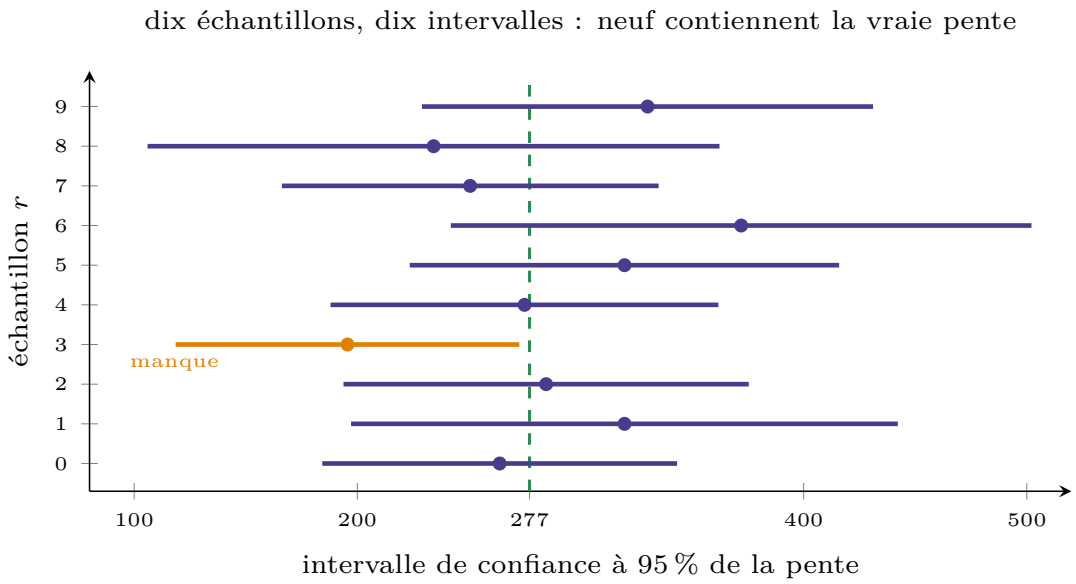
On rejette H_0 : l'ancienneté explique significativement le salaire.

L'intervalle de confiance de la pente

$$263{,}79 \;\pm\; 2{,}011 \times 39{,}54 \;=\; [\,184{,}3\;;\;343{,}3\,]$$

Chaque année d'ancienneté vaut entre 184 et 343 dirhams de salaire mensuel. La vraie pente, 277,17, est dedans.

Dix échantillons, dix intervalles



Ce que montrent les dix intervalles

Neuf sur dix

Les dix échantillons rejettent tous $\beta_1 = 0$: l'effet de l'ancienneté est trop fort pour passer inaperçu à $n = 50$.
Neuf intervalles sur dix contiennent 277,17. L'échantillon $r = 3$ donne [118,6 ; 272,6] et manque la vraie pente de peu.

Une couverture un peu faible

Sur les 20 000 échantillons simulés, l'intervalle classique contient la vraie pente dans 91,9 % des cas, pour 95 % annoncés.
C'est l'erreur-type trop optimiste (47,6 au lieu de 55,1) qui se paie ici : **quand une hypothèse tombe, le niveau annoncé n'est plus tenu**.

Tester une autre valeur que zéro

La grille prévoit 300 dirhams par an

Une convention prévoit une progression de 300 dirhams par année d'ancienneté. Les salaires la respectent-ils ?

$$H_0 : \beta_1 = 300 \qquad t = \frac{263{,}79 - 300}{39{,}54} = -0{,}92 \qquad p = 0{,}36$$

On ne rejette pas : les données sont compatibles avec la grille.

Le test et l'intervalle, encore

300 est dans l'intervalle [184 ; 343] : c'est l'équivalence du chapitre 15, appliquée à la pente. Mais 200 aussi y est : l'échantillon ne permet pas de distinguer une grille à 200 d'une grille à 300 dirhams.

La constante

Son test et son intervalle

$\hat{\beta}_0 = 4\,288{,}72$, erreur-type 468,58, $t = 9{,}15$. Intervalle : [3 346,6 ; 5 230,9], qui contient la vraie valeur 4 347,23.

Un test sans grand intérêt

$H_0 : \beta_0 = 0$ signifie « un salarié sans ancienneté gagne zéro dirham » : personne ne le soutient.
Les logiciels affichent ce test par défaut ; il est presque toujours significatif et presque jamais utile. C'est la pente qui porte la question économique.

La lecture de gestion

Ce qui est utilisable dans un rapport

« Une année d'ancienneté supplémentaire s'accompagne d'une hausse de salaire estimée à 264 dirhams, avec une marge de ±80 dirhams au seuil de 95 %. »
C'est l'intervalle, non la p-value, qui permet de **négocier une grille**. Le test dit seulement qu'il y a bien un effet à discuter.

Significatif ne veut toujours pas dire tout expliquer

$t = 6{,}67$ est net. Et pourtant $R^2 = 0{,}481$: l'ancienneté n'explique que la moitié de la dispersion des salaires de l'échantillon (dans la population, 40,5 %).
Un coefficient très significatif peut cohabiter avec un modèle qui laisse beaucoup inexpliqué. Les deux indicateurs répondent à deux questions différentes.

Prévoir

Deux questions différentes

Une moyenne, ou un individu

Pour une ancienneté x_0, la prévision ponctuelle est $\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$. Mais l'incertitude dépend de la question :

$$\text{salaire moyen : } \hat{\sigma}_\varepsilon \sqrt{\frac{1}{n} + \frac{(x_0 - \overline{x})^2}{\sum (x_i - \overline{x})^2}} \qquad \text{un salarié : } \hat{\sigma}_\varepsilon \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \overline{x})^2}{\sum (x_i - \overline{x})^2}}$$

Le « 1 » qui change tout

Le salaire moyen ne souffre que de l'imprécision de la droite. Un salarié particulier s'en écarte en plus de son erreur propre ε, d'écart-type σ_ε.
Même avec une droite parfaitement connue, la prévision d'un individu resterait imprécise.

Démonstration : Les deux erreurs-types de prévision

Comme $\hat\beta_0 = \overline{y} - \hat\beta_1 \overline{x}$, la prévision en x_0 s'écrit $\hat y_0 = \overline{y} + \hat\beta_1(x_0 - \overline{x})$. Or $\overline{y} = \beta_0 + \beta_1\overline{x} + \overline{\varepsilon}$ et $\hat\beta_1 = \beta_1 + \sum_i w_i\varepsilon_i$, donc $\overline{y}$ et $\hat\beta_1$ ont pour covariance $\sigma_\varepsilon^2 \sum_i w_i/n = 0$: elles sont non corrélées, et

$$V(\hat y_0) = \frac{\sigma_\varepsilon^2}{n} + (x_0 - \overline{x})^2 \, \frac{\sigma_\varepsilon^2}{S_{xx}} = \sigma_\varepsilon^2 \Big(\frac{1}{n} + \frac{(x_0 - \overline{x})^2}{S_{xx}} \Big).$$

C'est l'erreur de prévision **de la moyenne** $\beta_0 + \beta_1 x_0$, que $\hat y_0$ estime sans biais. Pour **un salarié** particulier, $y_0 = \beta_0 + \beta_1 x_0 + \varepsilon_0$, où l'erreur ε_0 du nouveau salarié est indépendante de l'échantillon : l'erreur de prévision $y_0 - \hat y_0$ a une variance égale à $\sigma_\varepsilon^2 + V(\hat y_0)$, d'où le « 1 » de la formule. On remplace σ_ε par $\hat\sigma_\varepsilon$ et l'on prend le quantile de Student à $n-2$ degrés de liberté.

Nos données ($\hat\sigma_\varepsilon = 1\,638{,}3$, $\overline{x} = 10{,}3$, $S_{xx} = 1\,716{,}5$) :

x_0	$1/n$	$(x_0 - \overline{x})^2/S_{xx}$	moyenne	salarié
10	0,0200	0,00005	232,0	1 654,6
25	0,0200	0,1259	625,8	1 753,7

Les deux dernières colonnes donnent l'erreur-type du salaire moyen et celle d'un salarié. Le salaire moyen a pour erreur-type $1\,638{,}3\sqrt{0{,}0200 + 0{,}00005} = 232{,}0$ à dix ans et $1\,638{,}3\sqrt{0{,}0200 + 0{,}1259} = 625{,}8$ à vingt-cinq ans ; pour un salarié, on ajoute 1 sous la racine : $1\,638{,}3\sqrt{1{,}0200 + 0{,}00005} = 1\,654{,}6$ et $1\,638{,}3\sqrt{1{,}0200 + 0{,}1259} = 1\,753{,}7$.

À dix ans, le rapport est $1\,654{,}6/232{,}0 = 7{,}1$, le « sept fois » du cours. Quand on s'éloigne de $\overline{x}$, l'erreur-type de la moyenne est multipliée par 2,7, celle d'un salarié de 6 % seulement.

Ce que cela dit. Le terme $1/n$ et le terme $(x_0 - \overline{x})^2/S_{xx}$ mesurent l'imprécision de la droite, qui est minimale au centre des données et s'évase de part et d'autre. Le « 1 » mesure la dispersion irréductible des individus autour de la droite : il ne diminue pas quand n augmente, d'où l'intervalle de prévision d'un salarié, bien plus large.

■

À dix ans d'ancienneté

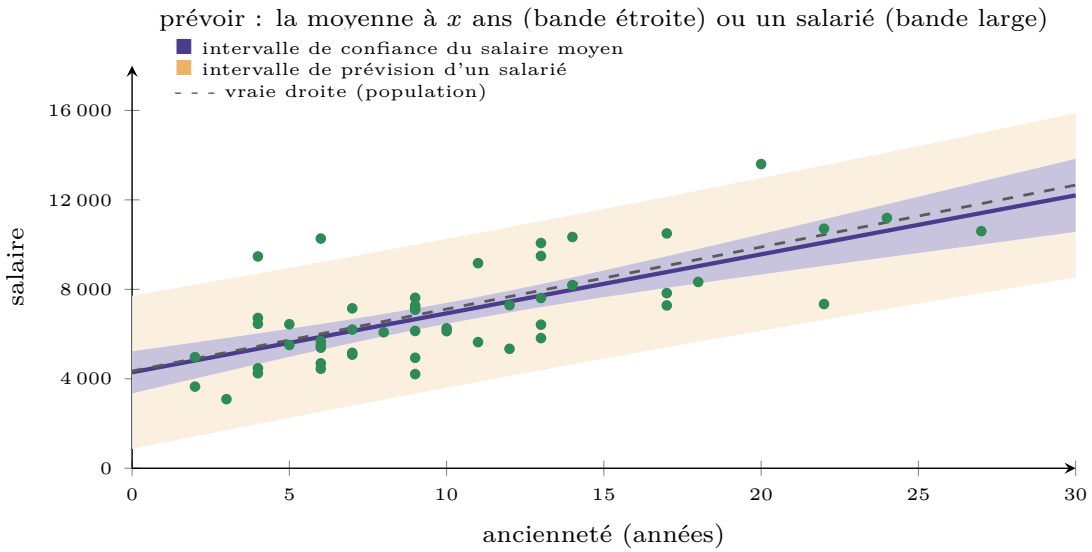
Les deux intervalles

$\hat y_0 = 4\,288{,}72 + 263{,}79 \times 10 = 6\,926{,}7$.
Salaire **moyen** : erreur-type 232, intervalle [6 460 ; 7 393]. La vraie moyenne sur la droite de la population, 7 119, est dedans.
Salaire **d'un salarié** : erreur-type 1 655, intervalle [3 600 ; 10 254].

Sept fois plus large

L'intervalle de prévision est sept fois plus large que celui de la moyenne : c'est la dispersion des salaires autour de la droite.
Dans la population, 89 % des 108 salariés de 9 à 11 ans tombent dans l'intervalle de prévision.

Les deux bandes



Ce que montre la figure

La bande s'évase loin du centre

À 25 ans d'ancienneté, l'erreur-type du salaire moyen passe à 626, contre 232 à 10 ans : l'intervalle devient $[9\,625\,;\,12\,142]$.
Le terme $(x_0 - \overline{x})^2$ pénalise les prévisions éloignées de $\overline{x} = 10{,}3$.

La prudence en extrapolation

Au-delà du domaine observé (2 à 27 ans), la bande s'élargit encore — et, plus grave, rien ne garantit que la relation reste linéaire.
Une prévision hors des données n'est pas seulement imprécise : elle peut être fausse.

La sortie d'un logiciel

Tout s'y trouve, et l'on sait maintenant tout lire

Le tableau standard, sur notre échantillon

	Coefficient	Erreur-type	t	p
Constante	4 288,72	468,58	9,15	$< 0{,}0001$
Ancienneté	263,79	39,54	6,67	$< 0{,}0001$

Intervalles à 95 % : [3 346,6 ; 5 230,9] pour la constante, [184,3 ; 343,3] pour la pente.

Et les indicateurs globaux

$$R^2 = 0{,}481 \qquad \hat{\sigma}_\varepsilon = 1\,638{,}3 \qquad F(1\,;48) = 44{,}50$$

Le F, le t et le R^2, sur une seule variable

Ils disent la même chose

$$6{,}671^2 = 44{,}50$$

En régression simple, le F global **est** le carré du t de la pente : une seule variable, un seul test.
La distinction ne prend son sens qu'en régression multiple, où le F teste toutes les variables ensemble et chaque t une variable à la fois.

Le test de la corrélation

Avec $r = 0{,}694$ ($R^2 = r^2$) :

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} = \frac{0{,}694 \times \sqrt{48}}{\sqrt{1-0{,}481}} = 6{,}67.$$

Tester $\beta_1 = 0$ ou tester l'absence de corrélation, c'est le même test.

Démonstration : En régression simple, F est le carré de t et t se déduit de la corrélation

La décomposition. Les valeurs ajustées $\hat{y}_i = \overline{y} + \hat{\beta}_1(x_i - \overline{x})$ donnent $y_i - \overline{y} = (\hat{y}_i - \overline{y}) + e_i$. Le terme croisé $\sum_i (\hat{y}_i - \overline{y})e_i = \hat{\beta}_1 \sum_i (x_i - \overline{x})e_i$ est nul (chapitre 19), donc

$$\text{SCT} = S_{yy} = \underbrace{\sum_i (\hat{y}_i - \overline{y})^2}_{\text{SCE}} + \underbrace{\sum_i e_i^2}_{\text{SCR}}, \qquad \text{SCE} = \hat{\beta}_1^2\, S_{xx}.$$

Le R^2 et r. Avec $\hat{\beta}_1 = S_{xy}/S_{xx}$: $R^2 = \text{SCE}/\text{SCT} = S_{xy}^2/(S_{xx}S_{yy}) = r^2$.

Le F et le t. Comme $\hat{\sigma}(\hat{\beta}_1)^2 = \hat{\sigma}^2_\varepsilon / S_{xx}$,

$$t^2 = \frac{\hat{\beta}_1^2 S_{xx}}{\hat{\sigma}^2_\varepsilon} = \frac{\text{SCE}}{\text{SCR}/(n-2)} = F(1\,;n-2).$$

Enfin, en divisant numérateur et dénominateur de $\text{SCE}/(\text{SCR}/(n-2))$ par SCT : $t^2 = (n-2)R^2/(1-R^2)$, donc

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$$

(le signe de t est celui de r, qui est celui de $\hat{\beta}_1$).

Nos données. $r = 0{,}6936$, $R^2 = 0{,}4811$: $t = 0{,}6936 \times \sqrt{48}/\sqrt{0{,}5189} = 6{,}671$ et $t^2 = 44{,}50 = F$. Pour l'exercice 3, $r = 0{,}2$ et $n = 102$ donnent $t = 0{,}2 \times 10/0{,}98 = 2{,}04$, tout juste au-dessus de 1,984.

Ce que cela dit. À r fixé, t grandit comme $\sqrt{n-2}$: une corrélation de 0,2, qui n'explique que 4 % de la dispersion, devient significative dès $n = 97$ et le serait à tout niveau de rigueur avec assez d'observations. La significativité mesure si l'effet existe, le R^2 de quelle ampleur : deux questions, deux nombres.

■

Quand une hypothèse tombe

L'erreur-type robuste

Les logiciels proposent une erreur-type dite **robuste à l'hétéroscédasticité**. Sur notre échantillon, elle vaut 42,3 au lieu de 39,5.
À $n = 50$ et avec des erreurs asymétriques, elle ne suffit pas à rétablir une couverture de 95 % : la simulation donne 89,5 %.

Ce que le cours suivant ajoutera

Plusieurs variables explicatives, la multicolinéarité, les variables qualitatives, l'hétéroscédasticité, l'autocorrélation, l'endogénéité.
Aucun de ces sujets n'exige un outil statistique nouveau. Ils appliquent tous ce cours à des situations où l'une des hypothèses du chapitre 19 tombe.

S'entraîner

Exercice 1 : lire une sortie

La demande et le revenu

Sur 27 villes, on régresse la consommation d'un produit sur le revenu moyen. Le logiciel donne une pente de 1,8 avec une erreur-type de 0,6.

1. Tester $\beta_1 = 0$ au seuil de 5 % ($t_{0{,}975\,;25} = 2{,}060$).
2. Construire l'intervalle de confiance de la pente.
3. Peut-on affirmer que la pente dépasse 1 ?

Exercice 1 : solution

t, intervalle, et une autre valeur testée

1. $t = 1{,}8/0{,}6 = 3{,}00 > 2{,}060$: **rejet**, $p = 0{,}006$.
2. $1{,}8 \pm 2{,}060 \times 0{,}6 = [0{,}56\,;\,3{,}04]$.
3. Non : 1 est dans l'intervalle. Le test de $\beta_1 = 1$ donne $t = 0{,}8/0{,}6 = 1{,}33$, non significatif. L'effet existe, mais sa taille reste très incertaine.

Exercice 2 : un effet non significatif

La publicité fait-elle vendre ?

Sur 20 mois, on régresse les ventes (en milliers d'unités) sur le budget publicitaire (en milliers de dirhams). Pente estimée 2,4, erreur-type 1,5.

1. Tester la significativité de la pente ($t_{0{,}975\,;18} = 2{,}101$).
2. Construire l'intervalle de confiance.
3. Le directeur financier conclut : « la publicité ne sert à rien, coupons le budget ». Qu'en penser ?

Exercice 2 : solution

Absence de preuve, encore

1. $t = 2{,}4/1{,}5 = 1{,}60 < 2{,}101$: non-rejet, $p = 0{,}13$.
2. $2{,}4 \pm 2{,}101 \times 1{,}5 = [-0{,}75\,;\,5{,}55]$.
3. Conclusion abusive : l'intervalle contient 0, mais aussi des effets de 5 unités par millier de dirhams, peut-être très rentables. Vingt mois ne suffisent pas à trancher : c'est le chapitre 13.

Exercice 3 : significatif et faible

Une corrélation de 0,2

Sur 102 salariés, la corrélation entre la note d'évaluation annuelle et l'ancienneté vaut $r = 0{,}2$.

1. Tester l'absence de liaison au seuil de 5 % ($t_{0{,}975\,;100} = 1{,}984$).
2. Quelle part de la dispersion des notes l'ancienneté explique-t-elle ?
3. Que dire au service RH qui veut fonder les promotions sur l'ancienneté ?

Exercice 3 : solution

Le test et l'intensité

1. $t = 0{,}2 \times \sqrt{100}/\sqrt{1 - 0{,}04} = 2/0{,}98 = 2{,}04 > 1{,}984$: rejet, de justesse ($p = 0{,}044$).
2. $R^2 = r^2 = 0{,}04$: l'ancienneté explique 4 % de la dispersion des notes.
3. La liaison est réelle mais très faible : l'ancienneté prédit mal la note. Elle ne peut pas, à elle seule, servir de critère de mérite.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. $\widehat{\beta}_1$ est une variable aléatoire, sans biais et approximativement normale — comme $\overline{X}$.
2. $\widehat{\sigma}^2_\varepsilon = \sum e_i^2/(n-2)$; test de significativité $t = \widehat{\beta}_1/\widehat{\sigma}(\widehat{\beta}_1)$, Student à $n-2$ ddl.
3. Sur l'échantillon : $t = 6{,}67$, $\text{IC}_{95\,\%} = [184{,}3\,;\,343{,}3]$, qui contient la vraie pente 277,17.
4. C'est l'**intervalle**, non la p-value, qui sert à décider d'une grille salariale.
5. Prévoir une moyenne ou un individu : deux intervalles, le second bien plus large.
6. En régression simple, $F = t^2$. Quand une hypothèse tombe, le niveau annoncé n'est plus tenu (91,9 % ici).

La suite

Tout a été fait à la main

Tout le cours a été conduit à la main, pour que chaque nombre soit vérifiable.

Le dernier chapitre

Le chapitre 21 refait l'ensemble en quelques lignes de R et de Python — et montre que les logiciels n'affichent rien d'autre que ce que nous venons de calculer.