

Statistique inférentielle

Chapitre 20 : Tester un coefficient

Jaouad Madkour


24 septembre 2026

Plan du chapitre

La pente, variable aléatoire	1
Sa distribution d'échantillonnage	1
Rien de nouveau, tout est déjà là	2
L'erreur-type estimée	2
Le test de significativité	2
La question	2
L'application	3
La lecture de gestion	3
La sortie d'un logiciel	3
Tout s'y trouve, et l'on sait maintenant tout lire	3
Le F et le t , sur une seule variable	4
Ce qu'il faut retenir	4
Le résumé du chapitre	4

La pente, variable aléatoire

Sa distribution d'échantillonnage



La boucle est bouclée

Moyenne des 2 000 pentes : 273.89.

Écart-type : 79.56.

L'estimateur est sans biais : la cloche est centrée sur β_1 , exactement comme $\bar{X}$ l'était sur m .

Et il est asymptotiquement normal, par le théorème central limite — ce qui autorise le même intervalle qu'au chapitre 10 :

$$\hat{\beta}_1 \pm t_{\alpha/2} \hat{\sigma}(\hat{\beta}_1)$$

Sur la population entière : $\hat{\sigma}(\hat{\beta}_1) = 15,06$ et $t = 18,41$. La relation entre ancienneté et salaire est hors de doute.

Rien de nouveau, tout est déjà là

Le parallèle complet

Chapitre 2	Chapitre 20
$\bar{X}$ estime m	$\hat{\beta}_1$ estime β_1
$E(\bar{X}) = m$	$E(\hat{\beta}_1) = \beta_1$
$\sigma(\bar{X}) = \sigma/\sqrt{n}$	$\sigma(\hat{\beta}_1) = \sigma_\varepsilon/\sqrt{\sum (x_i - \bar{x})^2}$
loi normale par le TCL	loi normale par le TCL

La conséquence

Tout ce que les chapitres 9 et 15 ont fait pour la moyenne s'applique à la pente **sans une formule nouvelle**.

Il suffit de remplacer $\bar{x}$ par $\hat{\beta}_1$ et l'erreur-type par la sienne.

L'erreur-type estimée

Deux estimations emboîtées

$$\hat{\sigma}_\varepsilon^2 = \frac{\sum_i e_i^2}{n-2} \quad \hat{\sigma}(\hat{\beta}_1) = \frac{\hat{\sigma}_\varepsilon}{\sqrt{\sum_i (x_i - \bar{x})^2}}$$

Pourquoi $n-2$

La règle du chapitre 3 : **un degré de liberté par paramètre estimé**.

Ici deux, $\hat{\beta}_0$ et $\hat{\beta}_1$. Le dénominateur était $n-1$ pour une variance simple ; il sera $n-k-1$ pour une régression à k variables explicatives. Le principe ne change jamais.

Le test de significativité

La question

La variable explicative sert-elle à quelque chose

$$H_0 : \beta_1 = 0 \quad H_1 : \beta_1 \neq 0$$

Sous H_0 , l'ancienneté n'a aucun effet sur le salaire : la droite vraie est horizontale.

La statistique

$$t = \frac{\hat{\beta}_1 - 0}{\hat{\sigma}(\hat{\beta}_1)} \sim \text{Student à } n-2 \text{ degrés de liberté}$$

C'est exactement la forme du chapitre 12 : *(observé - prévu par H_0) divisé par l'erreur-type*.

L'application

Sur nos cinq cents salariés

$$\hat{\sigma}_\varepsilon = 2\,008,34 \quad \hat{\sigma}(\hat{\beta}_1) = 15,06$$

$$t = \frac{277,17}{15,06} = 18,41 \quad \text{ddl} = 498 \quad p < 0,0001$$

On rejette H_0 : l'ancienneté explique significativement le salaire.

L'intervalle de confiance de la pente

$$277,17 \pm 1,96 \times 15,06 = [247,65 ; 306,68]$$

Chaque année d'ancienneté vaut entre 248 et 307 dirhams de salaire mensuel.

La lecture de gestion

Ce qui est utilisable dans un rapport

« Une année d'ancienneté supplémentaire s'accompagne d'une hausse de salaire estimée à 277 dirhams, avec une marge de ± 30 dirhams au seuil de 95 %. »

C'est l'intervalle, non la p -value, qui permet de **négoier une grille**. Le test dit seulement qu'il y a bien un effet à discuter.

Significatif ne veut toujours pas dire tout expliquer

$t = 18,41$ est écrasant. Et pourtant $R^2 = 0,405$: l'ancienneté n'explique que 40 % de la dispersion des salaires.

Un coefficient très significatif dans un modèle médiocre reste un coefficient dans un modèle médiocre. Les deux indicateurs répondent à deux questions différentes.

La sortie d'un logiciel

Tout s'y trouve, et l'on sait maintenant tout lire

Le tableau standard

	Coefficient	Erreur-type	t	p
Constante	4 347,23	177,18	24,54	< 0,0001
Ancienneté	277,17	15,06	18,41	< 0,0001

Et les indicateurs globaux

$$R^2 = 0,405 \quad \hat{\sigma}_\varepsilon = 2\,008,34 \quad F(1 ; 498) = 338,8$$

Le F et le t , sur une seule variable

Ils disent la même chose

$$18,41^2 = 338,8$$

En régression simple, le F global **est** le carré du t de la pente : une seule variable, un seul test.

La distinction ne prend son sens qu'en régression multiple, où le F teste toutes les variables ensemble et chaque t une variable à la fois.

Ce que le cours suivant ajoutera

Plusieurs variables explicatives, la multicolinéarité, les variables qualitatives, l'hétéroscédasticité, l'autocorrélation, l'endogénéité.

Aucun de ces sujets n'exige un outil statistique nouveau. Ils appliquent tous ce cours à des situations où l'une des quatre hypothèses du chapitre 19 tombe.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. $\hat{\beta}_1$ est une variable aléatoire, sans biais et asymptotiquement normale — comme $\bar{X}$.
2. $\hat{\sigma}_\varepsilon^2 = \sum e_i^2 / (n - 2)$: deux degrés de liberté perdus, deux paramètres estimés.
3. Test de significativité : $t = \hat{\beta}_1 / \hat{\sigma}(\hat{\beta}_1)$, loi de Student à $n - 2$ ddl.
4. Sur nos données : $t = 18,41$, $p < 0,0001$, et $IC_{95\%} = [247,65 ; 306,68]$.
5. C'est l'**intervalle**, non la p -value, qui sert à décider d'une grille salariale.
6. En régression simple, $F = t^2$: les deux tests n'en font qu'un.

La suite

Tout le cours a été conduit à la main, pour que chaque nombre soit vérifiable.

Le chapitre 21 refait l'ensemble en quelques lignes de R et de Python — et montre que les logiciels n'affichent rien d'autre que ce que nous venons de calculer.