

Chapitre 18

Les tests du khi-deux

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Statistique inférentielle


1 Exercices du chapitre

Correction — Exercice 1

(a) Effectif attendu de chaque catégorie : $n \times p_i = 250 \times 0,2 = 50$.

(b) $\chi^2 = \frac{(42 - 50)^2}{50} + \frac{(58 - 50)^2}{50} + \frac{(35 - 50)^2}{50} + \frac{(61 - 50)^2}{50} + \frac{(54 - 50)^2}{50} \approx 9,80$. ddl = $k - 1 = 4$.

(c) $9,80 > \chi_{0,95;4}^2 = 9,488$: on **rejette** (de justesse, $p \approx 0,044$) H_0 . La répartition observée des motifs de réclamation n'est pas conforme à une équirépartition entre les cinq catégories.



Correction — Exercice 2


(a) H_0 : âge et satisfaction sont indépendants. H_1 : ils sont liés. Effectif attendu (moins de 30 ans / satisfait) = $\frac{70 \times 105}{220} \approx 33,41$.

(b) Tableau des attendus :

	Satisfait	Insatisfait
Moins de 30 ans	33,41	36,59
30-45 ans	38,18	41,82
Plus de 45 ans	33,41	36,59

$\chi^2 = \frac{(45 - 33,41)^2}{33,41} + \frac{(25 - 36,59)^2}{36,59} + \frac{(38 - 38,18)^2}{38,18} + \frac{(42 - 41,82)^2}{41,82} + \frac{(22 - 33,41)^2}{33,41} + \frac{(48 - 36,59)^2}{36,59} \approx 15,15$. ddl = $(3 - 1)(2 - 1) = 2$.

(c) $15,15 \gg \chi_{0,95;2}^2 = 5,991$ ($p \approx 0,0005$) : on **rejette** H_0 . Dans cet échantillon, l'âge et la satisfaction sont statistiquement liés : la satisfaction décroît nettement avec l'âge des clients.



Correction — Exercice 3

(a) $p_0 = e^{-2} \approx 0,1353$, $p_1 = 2e^{-2} \approx 0,2707$, $p_2 \approx 0,2707$, $p_3 \approx 0,1804$, $p_4 \approx 0,0902$, $p(\geq 5) = 1 - \sum_{k=0}^4 p_k \approx 0,0527$. Effectifs attendus ($\times 80$) : 10,83 ; 21,65 ; 21,65 ; 14,44 ; 7,22 ; 4,21. La catégorie « 5 ou plus » a un effectif attendu de $4,21 < 5$: elle viole la condition de validité.

(b) On regroupe « 4 » et « 5 ou plus » en une catégorie « 4 ou plus » : $p_{4+} = p_4 + p(\geq 5) \approx 0,0902 + 0,0527 = 0,1429$, effectif attendu $\approx 11,43$. Les 5 catégories regroupées (0, 1, 2, 3, 4+) ont pour attendus : 10,83 ; 21,65 ; 21,65 ; 14,44 ; 11,43 (somme = 80, aucun < 5).

(c) $\chi^2 = \frac{(12 - 10,83)^2}{10,83} + \frac{(19 - 21,65)^2}{21,65} + \frac{(24 - 21,65)^2}{21,65} + \frac{(16 - 14,44)^2}{14,44} + \frac{(9 - 11,43)^2}{11,43} \approx 1,39$. Avec 5 catégories, ddl = 5 - 1 = 4. Comme $1,39 < \chi_{0,95;4}^2 = 9,488$ ($p \approx 0,85$), on **ne rejette pas** H_0 : les données sont tout à fait compatibles avec un modèle de Poisson ($\lambda = 2$).

2 Exercices cumulatifs (chapitres 1 à 18)

Correction — Exercice 4

(a) Adéquation (dé) : $4,94 < 11,07$, on ne rejette pas – rien n'indique que le dé est truqué. Indépendance (diplôme $\times$ sexe) : $0,229 < 5,99$ ($p \approx 0,89$), on ne rejette pas – rien n'indique que diplôme et sexe sont liés dans cette entreprise.

(b) En combinant les trois chapitres, une image cohérente se dessine : le **diplôme** est, dans cette entreprise, le facteur qui structure massivement les salaires ($F = 86,28$, $\eta^2 \approx 0,258$) ; le **sexe**, pris isolément, ne produit aucun écart de salaire détectable ($t \approx -0,001$) ; et le sexe n'est **pas non plus** associé au diplôme lui-même ($\chi^2 = 0,229$), ce qui écarte l'hypothèse d'un effet « caché » du sexe qui transiterait par une sur-représentation dans certains niveaux de diplôme. Autrement dit : ici, le diplôme explique ; le sexe n'explique rien, ni directement, ni indirectement via le diplôme.

(c) Même en cas de rejet, le test du khi-deux aurait seulement établi une **association statistique** entre diplôme et sexe (par exemple, une sur-représentation des femmes ou des hommes dans certains niveaux de diplôme) – pas sa **cause**. Une telle association pourrait provenir de choix d'orientation antérieurs, de politiques de recrutement, ou de bien d'autres mécanismes historiques et sociaux que le test, à lui seul, ne permet ni d'identifier ni de départager.

3 Applications en sciences économiques

Correction — Exercice 5

(a) Effectifs attendus ($n = 100$) : 25, 15, 40, 10, 10.

(b) $\chi^2 = \frac{(28 - 25)^2}{25} + \frac{(15 - 15)^2}{15} + \frac{(42 - 40)^2}{40} + \frac{(10 - 10)^2}{10} + \frac{(5 - 10)^2}{10} \approx 2,96$. Comme $2,96 < \chi_{0,95;4}^2 = 9,488$ ($p \approx 0,56$), on **ne rejette pas** H_0 .

(c) **Non** : « ne pas rejeter » ne prouve jamais l'égalité exacte (chapitre 12) – on peut seulement dire que la répartition observée sur ce contrôle de 100 pièces est **statistiquement compatible** avec la répartition historique annoncée par le fournisseur, sans que cela garantisse une conformité parfaite ni pour cet échantillon ni pour la production future.

Correction — Exercice 6

(a) Effectifs attendus (arrondis) :

	Éco.	Standard	Premium
Nord	42,71	46,43	40,86
Centre	39,43	42,86	37,71
Sud	32,86	35,71	31,43

Tous dépassent 5 : condition de validité respectée. $\chi^2 \approx 41,48$, ddl = $(3 - 1)(3 - 1) = 4$.

(b) $41,48 \gg \chi_{0,999;4}^2 = 9,488$ ($p < 0,0001$) : on **rejette** nettement H_0 . La région et la gamme de produits achetée sont statistiquement liées.

(c) **Non** : le test établit une **association** entre région et gamme achetée, pas que la région **détermine** le pouvoir d'achat – c'est exactement la mise en garde « liaison, pas causalité » du cours. Une formulation prudente serait : « la gamme de produits achetée varie significativement selon la région ». D'autres facteurs corrélés à la région (revenu moyen local, présence de concurrents, structure de

l'offre en magasin) pourraient tout aussi bien expliquer ce lien. Pour aller plus loin, on pourrait croiser directement la région avec des données de revenu des clients, ou contrôler l'effet d'autres variables observables.

