

Statistique inférentielle

Chapitre 18 : Les tests du khi-deux

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique inférentielle

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Test d'adéquation à une loi uniforme

Un service après-vente reçoit des réclamations réparties en 5 catégories de motifs, supposées également fréquentes ($H_0 : p_i = 1/5$ pour chaque catégorie). Sur $n = 250$ réclamations, on observe : 42, 58, 35, 61, 54.

- Calculer l'effectif attendu de chaque catégorie sous H_0 .
- Calculer $\chi^2 = \sum (\text{observé} - \text{attendu})^2 / \text{attendu}$ et le degré de liberté.
- Comparer au seuil $\chi_{0,95;4}^2 = 9,488$ et conclure au seuil de 5%.

Exercice 2 — Test d'indépendance

On étudie le lien entre l'âge des clients et leur satisfaction vis-à-vis d'un service :

	Satisfait	Insatisfait	Total
Moins de 30 ans	45	25	70
30–45 ans	38	42	80
Plus de 45 ans	22	48	70
Total	105	115	220

- Écrire H_0 et H_1 , et calculer l'effectif attendu de chaque case sous H_0 (par exemple, celle « moins de 30 ans / satisfait »).
- Calculer χ^2 et le degré de liberté $(l-1)(c-1)$.
- Comparer au seuil $\chi_{0,95;2}^2 = 5,991$ et conclure. L'âge et la satisfaction sont-ils liés dans cet échantillon?

Exercice 3 — Regrouper des modalités trop rares

Un service de maintenance suppose que le nombre de pannes hebdomadaires suit une loi de Poisson de paramètre $\lambda = 2$. Sur $n = 80$ semaines observées, il souhaite tester cette hypothèse à l'aide des catégories 0, 1, 2, 3, 4, 5 ou plus pannes.

- Calculer les probabilités théoriques $p_k = e^{-\lambda} \lambda^k / k!$ pour $k = 0, 1, 2, 3, 4$, puis $p(\geq 5) = 1 - \sum_{k=0}^4 p_k$, et les effectifs attendus correspondants ($n = 80$). Quelle catégorie viole la condition de validité (effectif attendu < 5) ?
- Regrouper la catégorie problématique avec la catégorie voisine (« 4 ou plus »), et recalculer les probabilités et effectifs attendus des 5 catégories ainsi obtenues (0, 1, 2, 3, 4 ou plus).
- Les effectifs observés sur ces 5 catégories regroupées sont 12, 19, 24, 16, 9. Calculer χ^2 , le degré de liberté (attention : il y a maintenant 5 catégories), et conclure au seuil de 5% ($\chi_{0,95;4}^2 = 9,488$).

2 Exercices cumulatifs (chapitres 1 à 18)

Exercice 4 — Les deux tests du khi-deux du fil rouge

On reprend les deux résultats du cours. Test d'adéquation (le dé à six faces, 600 lancers) : $\chi^2 = 4,94$, ddl = 5, seuil = 11,07. Test d'indépendance (diplôme $\times$ sexe, $n = 500$ salariés, tableau 3×2) : $\chi^2 = 0,229$, ddl = $(3-1)(2-1) = 2$, seuil = 5,99.

- Pour chacun des deux tests, vérifier que le χ^2 annoncé est bien inférieur au seuil, et conclure.
- Au chapitre 17, l'ANOVA sur le diplôme donnait $F = 86,28$ (rejet massif de l'égalité des salaires moyens selon le diplôme). Au chapitre 16, le test de Welch sur le sexe ne rejetait pas l'égalité des salaires moyens. Le test d'indépendance de cette question ajoute une troisième

information : diplôme et sexe sont eux-mêmes indépendants l'un de l'autre dans cette entreprise. En combinant ces trois résultats, quelle image d'ensemble peut-on dresser de la structure des salaires dans cette entreprise, et du rôle respectif du diplôme et du sexe ?

- (c) Le cours souligne que le test du khi-deux « détecte une liaison, pas une causalité ». Même si le test d'indépendance avait rejeté H_0 (diplôme et sexe liés), qu'est-ce que cela aurait – et n'aurait pas – prouvé sur les causes de cette liaison ?

3 Applications en sciences économiques

Exercice 5 — Un fournisseur respecte-t-il la répartition annoncée de ses défauts ?

Un fournisseur affirme que les défauts constatés sur ses pièces se répartissent, historiquement, ainsi : 25 % de type A, 15 % de type B, 40 % de type C, 10 % de type D, 10 % de type E. Sur un contrôle de $n = 100$ pièces défectueuses, on observe : 28, 15, 42, 10, 5.

- Calculer les effectifs attendus sous H_0 (répartition conforme à l'historique du fournisseur).
- Calculer χ^2 et conclure au seuil de 5 % ($\chi_{0,95;4}^2 = 9,488$).
- Cette conclusion permet-elle d'affirmer que la répartition observée est *identique* à la répartition historique ? Reformuler la conclusion avec la prudence qui convient (cf. chapitre 12).

Exercice 6 — La région et la gamme de produits sont-elles liées ?

Une enseigne de distribution étudie la répartition de ses ventes selon la région et la gamme de produits achetée :

	Gamme éco.	Gamme standard	Gamme premium	Total
Nord	65	40	25	130
Centre	30	55	35	120
Sud	20	30	50	100
Total	115	125	110	350

- Vérifier que tous les effectifs attendus dépassent 5 (condition de validité), et calculer χ^2 et le degré de liberté.
- Conclure au seuil de 5 % ($\chi_{0,95;4}^2 = 9,488$).
- La direction marketing souhaite en conclure que « la région détermine le pouvoir d'achat des clients ». Le test du khi-deux permet-il cette formulation ? Proposer une reformulation plus prudente, et une piste (au-delà du test) pour explorer davantage la nature du lien observé.


1 Exercices du chapitre

Correction — Exercice 1

(a) Effectif attendu de chaque catégorie : $n \times p_i = 250 \times 0,2 = 50$.

(b) $\chi^2 = \frac{(42 - 50)^2}{50} + \frac{(58 - 50)^2}{50} + \frac{(35 - 50)^2}{50} + \frac{(61 - 50)^2}{50} + \frac{(54 - 50)^2}{50} \approx 9,80$. ddl = $k - 1 = 4$.

(c) $9,80 > \chi_{0,95;4}^2 = 9,488$: on **rejette** (de justesse, $p \approx 0,044$) H_0 . La répartition observée des motifs de réclamation n'est pas conforme à une équirépartition entre les cinq catégories.



Correction — Exercice 2


(a) H_0 : âge et satisfaction sont indépendants. H_1 : ils sont liés. Effectif attendu (moins de 30 ans / satisfait) = $\frac{70 \times 105}{220} \approx 33,41$.

(b) Tableau des attendus :

	Satisfait	Insatisfait
Moins de 30 ans	33,41	36,59
30-45 ans	38,18	41,82
Plus de 45 ans	33,41	36,59

$\chi^2 = \frac{(45 - 33,41)^2}{33,41} + \frac{(25 - 36,59)^2}{36,59} + \frac{(38 - 38,18)^2}{38,18} + \frac{(42 - 41,82)^2}{41,82} + \frac{(22 - 33,41)^2}{33,41} + \frac{(48 - 36,59)^2}{36,59} \approx 15,15$. ddl = $(3 - 1)(2 - 1) = 2$.

(c) $15,15 \gg \chi_{0,95;2}^2 = 5,991$ ($p \approx 0,0005$) : on **rejette** H_0 . Dans cet échantillon, l'âge et la satisfaction sont statistiquement liés : la satisfaction décroît nettement avec l'âge des clients.



Correction — Exercice 3

(a) $p_0 = e^{-2} \approx 0,1353$, $p_1 = 2e^{-2} \approx 0,2707$, $p_2 \approx 0,2707$, $p_3 \approx 0,1804$, $p_4 \approx 0,0902$, $p(\geq 5) = 1 - \sum_{k=0}^4 p_k \approx 0,0527$. Effectifs attendus ($\times 80$) : 10,83 ; 21,65 ; 21,65 ; 14,44 ; 7,22 ; 4,21. La catégorie « 5 ou plus » a un effectif attendu de $4,21 < 5$: elle viole la condition de validité.

(b) On regroupe « 4 » et « 5 ou plus » en une catégorie « 4 ou plus » : $p_{4+} = p_4 + p(\geq 5) \approx 0,0902 + 0,0527 = 0,1429$, effectif attendu $\approx 11,43$. Les 5 catégories regroupées (0, 1, 2, 3, 4+) ont pour attendus : 10,83 ; 21,65 ; 21,65 ; 14,44 ; 11,43 (somme = 80, aucun < 5).

(c) $\chi^2 = \frac{(12 - 10,83)^2}{10,83} + \frac{(19 - 21,65)^2}{21,65} + \frac{(24 - 21,65)^2}{21,65} + \frac{(16 - 14,44)^2}{14,44} + \frac{(9 - 11,43)^2}{11,43} \approx 1,39$. Avec 5 catégories, ddl = 5 - 1 = 4. Comme $1,39 < \chi_{0,95;4}^2 = 9,488$ ($p \approx 0,85$), on **ne rejette pas** H_0 : les données sont tout à fait compatibles avec un modèle de Poisson ($\lambda = 2$).

2 Exercices cumulatifs (chapitres 1 à 18)

Correction — Exercice 4

(a) Adéquation (dé) : $4,94 < 11,07$, on ne rejette pas – rien n'indique que le dé est truqué. Indépendance (diplôme $\times$ sexe) : $0,229 < 5,99$ ($p \approx 0,89$), on ne rejette pas – rien n'indique que diplôme et sexe sont liés dans cette entreprise.

(b) En combinant les trois chapitres, une image cohérente se dessine : le **diplôme** est, dans cette entreprise, le facteur qui structure massivement les salaires ($F = 86,28$, $\eta^2 \approx 0,258$) ; le **sexe**, pris isolément, ne produit aucun écart de salaire détectable ($t \approx -0,001$) ; et le sexe n'est **pas non plus** associé au diplôme lui-même ($\chi^2 = 0,229$), ce qui écarte l'hypothèse d'un effet « caché » du sexe qui transiterait par une sur-représentation dans certains niveaux de diplôme. Autrement dit : ici, le diplôme explique ; le sexe n'explique rien, ni directement, ni indirectement via le diplôme.

(c) Même en cas de rejet, le test du khi-deux aurait seulement établi une **association statistique** entre diplôme et sexe (par exemple, une sur-représentation des femmes ou des hommes dans certains niveaux de diplôme) – pas sa **cause**. Une telle association pourrait provenir de choix d'orientation antérieurs, de politiques de recrutement, ou de bien d'autres mécanismes historiques et sociaux que le test, à lui seul, ne permet ni d'identifier ni de départager.

3 Applications en sciences économiques

Correction — Exercice 5

(a) Effectifs attendus ($n = 100$) : 25, 15, 40, 10, 10.

(b) $\chi^2 = \frac{(28 - 25)^2}{25} + \frac{(15 - 15)^2}{15} + \frac{(42 - 40)^2}{40} + \frac{(10 - 10)^2}{10} + \frac{(5 - 10)^2}{10} \approx 2,96$. Comme $2,96 < \chi_{0,95;4}^2 = 9,488$ ($p \approx 0,56$), on **ne rejette pas** H_0 .

(c) **Non** : « ne pas rejeter » ne prouve jamais l'égalité exacte (chapitre 12) – on peut seulement dire que la répartition observée sur ce contrôle de 100 pièces est **statistiquement compatible** avec la répartition historique annoncée par le fournisseur, sans que cela garantisse une conformité parfaite ni pour cet échantillon ni pour la production future.

Correction — Exercice 6

(a) Effectifs attendus (arrondis) :

	Éco.	Standard	Premium
Nord	42,71	46,43	40,86
Centre	39,43	42,86	37,71
Sud	32,86	35,71	31,43

Tous dépassent 5 : condition de validité respectée. $\chi^2 \approx 41,48$, ddl = $(3 - 1)(3 - 1) = 4$.

(b) $41,48 \gg \chi_{0,99;4}^2 = 9,488$ ($p < 0,0001$) : on **rejette** nettement H_0 . La région et la gamme de produits achetée sont statistiquement liées.

(c) **Non** : le test établit une **association** entre région et gamme achetée, pas que la région **détermine** le pouvoir d'achat – c'est exactement la mise en garde « liaison, pas causalité » du cours. Une formulation prudente serait : « la gamme de produits achetée varie significativement selon la région ». D'autres facteurs corrélés à la région (revenu moyen local, présence de concurrents, structure de

l'offre en magasin) pourraient tout aussi bien expliquer ce lien. Pour aller plus loin, on pourrait croiser directement la région avec des données de revenu des clients, ou contrôler l'effet d'autres variables observables.

