Statistique inférentielle

Chapitre 18 : Les tests du khi-deux

Jaouad Madkour

31 octobre 2026

Plan du chapitre

Le principe commun **2**
Des effectifs, pas des moyennes . . . 2
Pourquoi diviser par l'attendu . . . 2
D'où vient la loi du khi-deux . . . 3

Le test d'adéquation **3**
La question . . . 3
Le dé du cours de probabilités . . . 4
Le calcul, case par case . . . 4
Notre échantillon est-il représentatif ? . . . 5
Le test de représentativité . . . 5
Deux cases : le khi-deux retrouve le test z . . . 5
Avec des paramètres estimés : la normalité . . . 6
Un usage professionnel du même test . . . 6

Le test d'indépendance **7**
La question . . . 7
Pourquoi $(l-1)(c-1)$ degrés de liberté . . . 7
Diplôme et sexe, dans l'échantillon . . . 8
Le verdict . . . 8
La lecture . . . 9
Mesurer l'intensité de la liaison . . . 9
Un tableau deux sur deux . . . 9

Les conditions et les pièges **10**
La condition de validité . . . 10
Regrouper pour rendre le test valide . . . 11
Deux limites à connaître . . . 12

La carte des tests **13**
Les six tests du cours, sur une seule page . . . 13
Comment s'en servir . . . 13
Les tests du cours, sur nos données . . . 13

S'entraîner **14**
Exercice 1 : la fréquentation hebdomadaire . . . 14
Exercice 1 : solution . . . 14
Exercice 2 : la satisfaction par agence . . . 14
Exercice 2 : solution . . . 15
Exercice 3 : le même tableau, dix fois plus grand . . . 15
Exercice 3 : solution . . . 15

Ce qu'il faut retenir **15**
Le résumé du chapitre . . . 15
La suite . . . 16

Le principe commun

Des effectifs, pas des moyennes

Le dernier type de données

Salaire, ancienneté : des grandeurs, sur lesquelles on calcule des moyennes.
Diplôme, région, sexe : des **catégories**, sur lesquelles on ne peut que compter. Aucun test précédent ne s'applique.

La statistique du khi-deux

$$\chi^2 = \sum_{\text{cases}} \frac{(\text{observé} - \text{attendu})^2}{\text{attendu}}$$

Deux tests, une seule formule : ce qui change est le calcul de l'**attendu**.

Pourquoi diviser par l'attendu

Un écart n'a pas le même poids partout

Dix de plus que prévu sur un effectif attendu de 20 : considérable.
Dix de plus sur un effectif attendu de 10 000 : négligeable.
La division ramène tous les écarts à une échelle commune. Sans elle, les grosses cases écraseraient tout.

Trois conséquences immédiates

1. La statistique est **positive** — c'est une somme de carrés.
2. Le test est **toujours unilatéral à droite** : seuls les grands écarts contredisent H_0.
3. Elle suit approximativement une loi du **khi-deux** (chapitre 3), dont le degré de liberté dépend du test.

D'où vient la loi du khi-deux

Une somme de carrés d'écarts réduits

Dans chaque case, l'effectif observé fluctue autour de l'attendu avec une variance proche de l'attendu. L'écart réduit (observé − attendu)/$\sqrt{\text{attendu}}$ est donc à peu près normal centré réduit.
Le χ^2 additionne les carrés de ces écarts : c'est la définition de la loi du khi-deux, aux contraintes près.

Les quantiles utiles

ddl	1	2	3	4	5	6
seuil à 5 %	3,84	5,99	7,81	9,49	11,07	12,59
seuil à 1 %	6,63	9,21	11,34	13,28	15,09	16,81

Le test d'adéquation

La question

Une distribution suit-elle une loi donnée

H_0 : la distribution observée est conforme à la loi théorique.
Effectif attendu de la modalité i : $n \times p_i$, où p_i vient de la loi supposée.
Degrés de liberté : $k-1$, où k est le nombre de modalités.

D'où vient le -1

La règle du chapitre 3 : un degré de liberté perdu par contrainte imposée aux données.
Ici une seule : la somme des effectifs attendus doit égaler n. Si la loi théorique comportait des paramètres estimés sur l'échantillon, il faudrait en retrancher autant.

Démonstration : Pourquoi le khi-deux d'adéquation a k-1 degrés de liberté

Les effectifs $(O_1, \dots, O_k)$ suivent une loi multinomiale de paramètres n et $(p_1, \dots, p_k)$: chaque O_i est binomial $\mathcal{B}(n\,; p_i)$, donc $E(O_i) = np_i$ et $V(O_i) = np_i(1-p_i)$. Comme $O_i + O_j$ est binomial $\mathcal{B}(n\,; p_i + p_j)$, la formule de la variance d'une somme donne $\mathrm{Cov}(O_i, O_j) = -np_ip_j$ pour $i \neq j$.

Une espérance exacte. $E[(O_i - np_i)^2/(np_i)] = np_i(1-p_i)/(np_i) = 1 - p_i$, donc

$$E(\chi^2) = \sum_{i=1}^{k} (1 - p_i) = k - 1 \quad \text{pour tout } n.$$

C'est exactement l'espérance d'une loi χ^2_{k-1} (chapitre 3) : avec k degrés de liberté, la loi de référence serait trop grande d'une unité.

Pourquoi $k-1$. Posons $Y_i = (O_i - np_i)/\sqrt{np_i}$. Ces variables ont pour variance $1 - p_i$ et pour covariance $-\sqrt{p_ip_j}$: leur matrice de covariance est $I - uu^\top$, avec $u = (\sqrt{p_1}, \dots, \sqrt{p_k})$ de norme 1 puisque $\sum p_i = 1$. Or $P = I - uu^\top$ vérifie $P^2 = I - 2uu^\top + u(u^\top u)u^\top = P$: c'est

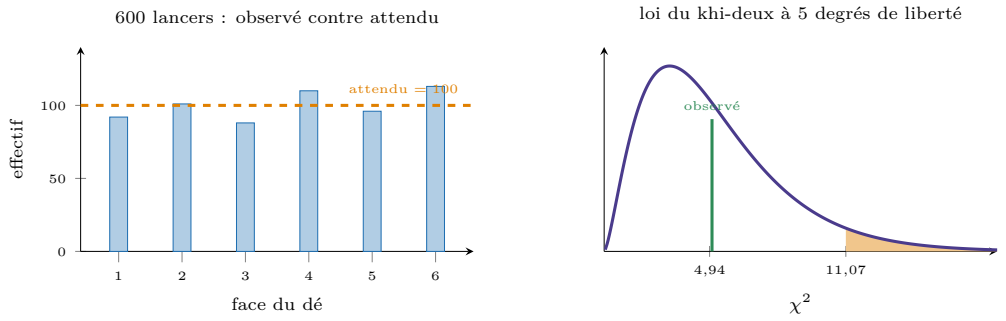
le projecteur orthogonal sur l'hyperplan $u^\perp$, de dimension $k-1$. Et Y vit dans cet hyperplan, car $u^\top Y = \sum_i (O_i - np_i)/\sqrt{n} = 0$ puisque $\sum_i O_i = n$. Quand n est grand, Y est à peu près la projection PZ d'un vecteur Z de k normales centrées réduites indépendantes (théorème central limite). La statistique $\chi^2 = \|Y\|^2$ est alors le carré de la norme d'un vecteur normal standard de dimension $k-1$, c'est-à-dire la somme des carrés de $k-1$ normales indépendantes : une loi χ^2_{k-1} par définition.

Le dé. Avec $k = 6$, $E(\chi^2) = 5$: la valeur observée, 4,94, est ce qu'on attend d'un dé équilibré.

Ce que cela dit. Le « -1 » n'est pas une convention : c'est la contrainte $\sum O_i = n$, qui enlève une dimension au vecteur des écarts. Chaque paramètre estimé sur l'échantillon impose une contrainte de plus et retire une dimension de plus (résultat admis ici), d'où $k-1-r$ pour r paramètres estimés.

■

Le dé du cours de probabilités



$$\chi^2 = \sum_i \frac{(\text{observé}_i - \text{attendu}_i)^2}{\text{attendu}_i} = 4{,}94 \qquad \text{seuil à } 5\,\% : 11{,}07 \qquad \text{on ne rejette pas.}$$

Les écarts sont mis au carré, puis rapportés à l'effectif attendu. Diviser par l'attendu est essentiel : un écart de 10 sur un effectif de 100 n'a pas le même poids qu'un écart de 10 sur un effectif de 10 000.

Le test est **toujours unilatéral à droite** : seuls les grands écarts contredisent H_0. Un χ^2 anormalement *petit* ne prouve pas l'adéquation — il signale plutôt des données trop belles pour être vraies.

Le calcul, case par case

Six cents lancers, cent attendus par face

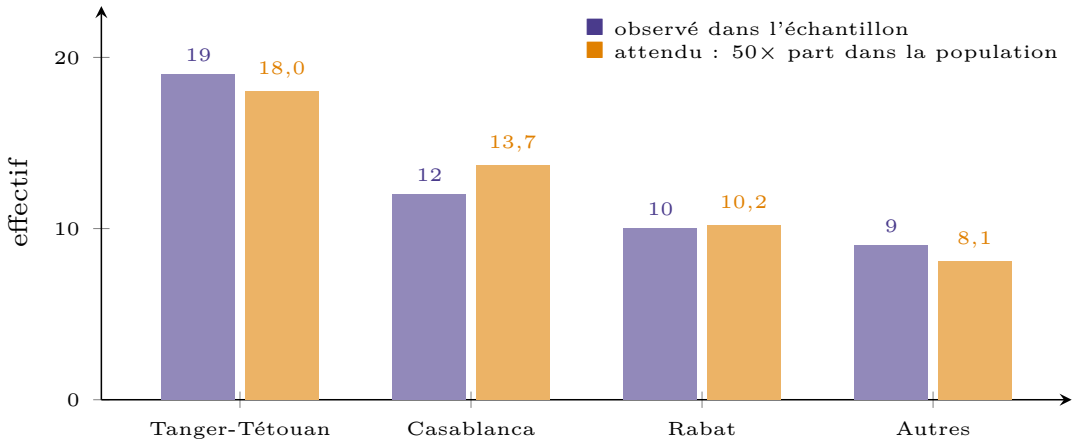
Face	1	2	3	4	5	6
observé	92	101	88	110	96	113
écart	-8	$+1$	-12	$+10$	-4	$+13$
contribution	0,64	0,01	1,44	1,00	0,16	1,69

La lecture

$\chi^2 = 4{,}94$ pour 5 degrés de liberté, seuil 11,07, $p = 0{,}42$: on ne rejette pas. Rien ne permet d'affirmer que le dé est truqué.

Notre échantillon est-il représentatif ?

l'échantillon de 50 reproduit-il la répartition régionale de l'entreprise ?



Le test de représentativité

Les régions, contre les parts de la population

H_0 : les 50 salariés se répartissent entre régions comme les 500. Attendus : $50 \times 0{,}360 = 18{,}0$; 13,7 ; 10,2 ; 8,1.

$$\chi^2 = \frac{1^2}{18{,}0} + \frac{1{,}7^2}{13{,}7} + \frac{0{,}2^2}{10{,}2} + \frac{0{,}9^2}{8{,}1} = 0{,}37 \qquad \text{ddl} = 3,\ p = 0{,}95$$

Un contrôle de routine en sondage

Les dix échantillons systématiques passent tous ce contrôle (p de 0,30 à 0,95).
Un institut de sondage fait ce test sur chaque enquête : âge, sexe, région, comparés au recensement. Le cours d'Échantillonnage (chapitres 13 et 14) s'en sert pour redresser les estimations.

Deux cases : le khi-deux retrouve le test z

La part de Bac+5, vue comme une adéquation

$H_0 : p = 0{,}15$. Observés : 13 Bac+5 et 37 autres. Attendus : 7,5 et 42,5.

$$\chi^2 = \frac{5{,}5^2}{7{,}5} + \frac{5{,}5^2}{42{,}5} = 4{,}745 = 2{,}178^2$$

C'est exactement le carré du z du chapitre 15, et la p-value est la même : 0,029.

Un seul test, deux habits

Avec deux modalités, le khi-deux à 1 degré de liberté **est** le test bilatéral d'une proportion : $\chi^2_1 = Z^2$, et $3{,}84 = 1{,}96^2$.

Le khi-deux généralise ce test à plus de deux modalités.

Démonstration : Avec deux modalités, le khi-deux est le carré du z

Avec $k = 2$, les effectifs sont $O_1 = X$ et $O_2 = n - X$, les attendus np et $n(1-p)$. Comme $O_1 + O_2 = n = E_1 + E_2$, on a $O_2 - E_2 = -(O_1 - E_1)$: les deux écarts ont la même valeur absolue, et

$$\chi^2 = (O_1 - np)^2\Big(\frac{1}{np} + \frac{1}{n(1-p)}\Big) = \frac{(O_1 - np)^2}{np(1-p)} = \Big(\frac{f-p}{\sqrt{p(1-p)/n}}\Big)^2 = z^2,$$

car $\frac{1}{np} + \frac{1}{n(1-p)} = \frac{1}{np(1-p)}$ et que l'on divise numérateur et dénominateur par n^2 avec $f = O_1/n$. Comme χ^2_1 est le carré d'une normale, $P(\chi^2_1 > z^2) = P(|Z| > |z|)$: les p-values coïncident, et le seuil 3,84 est $1{,}96^2$.

Notre cas. 13 Bac+5 et 37 autres, attendus 7,5 et 42,5 : $5{,}5^2/7{,}5 + 5{,}5^2/42{,}5 = 4{,}033 + 0{,}712 = 4{,}745 = 2{,}178^2$.

Ce que cela dit. Le test du khi-deux n'est pas un test nouveau : à deux modalités, c'est le test du chapitre 15 sous une autre écriture, et ce qu'il ajoute est de traiter, avec la même formule, trois modalités ou davantage.

■

Avec des paramètres estimés : la normalité

Les salaires de l'échantillon sont-ils normaux ?

On découpe la loi $\mathcal{N}(7\,006\,;\,2\,251^2)$ en 5 classes de probabilité 0,2 : 10 attendus par classe.
Observés : 10, 14, 10, 5, 11.
$\chi^2 = 4{,}2$. Deux paramètres ont été estimés (m et σ) : ddl $= 5 - 1 - 2 = 2$, seuil 5,99, $p = 0{,}12$.
On ne rejette pas.

Non rejeté, et pourtant faux

La population est nettement asymétrique (coefficient 1,16) : H_0 est fausse. Mais avec 50 observations, ce test ne la rejette qu'**une fois sur trois** (puissance simulée 0,30).
Ne pas rejeter la normalité sur un petit échantillon ne prouve pas la normalité : c'est le chapitre 13, encore.

Un usage professionnel du même test

Contrôler les hypothèses d'un modèle

Vérifier qu'un nombre de pannes suit une loi de Poisson, qu'une durée d'attente est bien exponentielle, qu'une série de rendements est normale.
Chaque fois qu'un modèle **suppose** une loi, ce test est le moyen de contrôler la supposition — au lieu de la laisser implicite.

Un khi-deux trop petit

Le test ne rejette que pour les grandes valeurs. Mais un χ^2 **anormalement petit** est suspect lui aussi : des données qui collent trop bien à la théorie ont parfois été arrangées.

Le test d'indépendance

La question

Deux caractères sont-ils liés

H_0 : les deux variables sont indépendantes.
Effectif attendu : $\dfrac{n_{i\bullet} \times n_{\bullet j}}{n}$.
Degrés de liberté : $(l-1)(c-1)$, pour l lignes et c colonnes.

L'attendu vient tout droit des probabilités

Sous indépendance, $p_{ij} = p_{i\bullet} \times p_{\bullet j}$ — c'est la définition de l'indépendance du cours de probabilités.
En multipliant par n, on obtient exactement la formule ci-dessus. **Le test ne fait que confronter cette prédiction aux effectifs observés.**

Pourquoi (l − 1)(c − 1) degrés de liberté

Les cases que l'on peut remplir librement

Les totaux de lignes et de colonnes sont fixés. Dans un tableau 3×2, dès que l'on connaît deux cases de la première colonne, tout le reste se déduit des totaux.
Il reste $(3-1) \times (2-1) = 2$ cases libres : 2 degrés de liberté.

La même règle partout

Un degré de liberté par case, moins un par contrainte. Ici, les contraintes sont les totaux de lignes et de colonnes.

Démonstration : Les effectifs attendus et les degrés de liberté de l'indépendance

Sous l'hypothèse d'indépendance, $p_{ij} = a_i b_j$, où a_i est la probabilité de la ligne i et b_j celle de la colonne j, avec $\sum_i a_i = 1$ et $\sum_j b_j = 1$. Le modèle a donc $(l-1)+(c-1)$ paramètres libres, à estimer sur l'échantillon.

Les estimations. La vraisemblance des effectifs n_{ij} est maximale quand on maximise $\sum_{ij} n_{ij} \ln(a_i b_j) = \sum_i n_{i\bullet} \ln a_i + \sum_j n_{\bullet j} \ln b_j$ sous les deux contraintes. Chaque somme se traite à part : maximiser $\sum_i n_{i\bullet} \ln a_i$ sous $\sum a_i = 1$ conduit, par un multiplicateur de Lagrange λ, à $n_{i\bullet}/a_i = \lambda$ pour tout i, donc $\hat{a}_i = n_{i\bullet}/n$; de même $\hat{b}_j = n_{\bullet j}/n$. L'effectif attendu est

$$n\,\hat{a}_i\,\hat{b}_j = \frac{n_{i\bullet}\,n_{\bullet j}}{n}.$$

Les degrés de liberté. On part de $lc-1$ (les lc cases, liées par $\sum n_{ij} = n$), on retranche les pa-

ramètres estimés :

$$(lc-1)-(l-1)-(c-1) = lc-l-c+1 = (l-1)(c-1).$$

Notre tableau. Diplôme × sexe : $\hat{a} = (20,17,13)/50$ et $\hat{b} = (22,28)/50$, d'où un attendu de $50 \times 0{,}40 \times 0{,}44 = 8{,}80$ pour « Bac, femmes ». Le calcul donne $\chi^2 = 0{,}2345$, avec $5-2-1=2$ degrés de liberté, soit $(3-1)(2-1)$.

Ce que cela dit. Le test d'indépendance n'est qu'un test d'adéquation à un modèle, celui du produit des marges, dont on estime les paramètres sur les données ; la règle « un degré de liberté par case, moins un par paramètre estimé » s'applique sans exception, ici comme pour la normalité du début de ce chapitre $(5-1-2=2)$.

■

Diplôme et sexe, dans l'échantillon

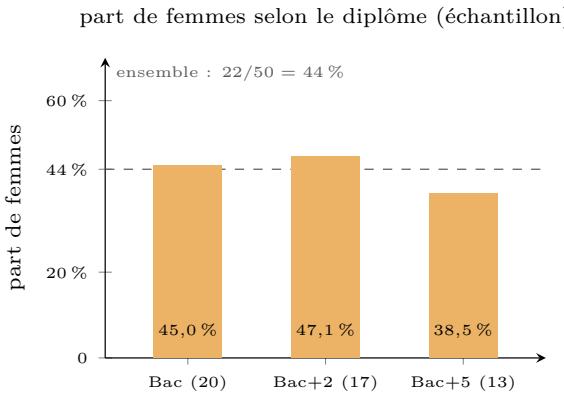
Observés, et attendus sous l'indépendance

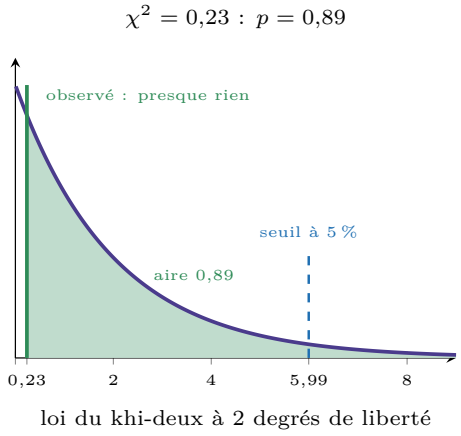
Diplôme	Femmes	Hommes	Total
Bac	9 (8,80)	11 (11,20)	20
Bac+2	8 (7,48)	9 (9,52)	17
Bac+5	5 (5,72)	8 (7,28)	13
Total	22	28	50

Le calcul d'un attendu

Bac et femmes : $20 \times 22/50 = 8{,}80$. Si diplôme et sexe étaient indépendants, 44 % de femmes dans chaque niveau donneraient 8,80 femmes parmi les 20 Bac.
On en observe 9 : l'écart est minime.

Le verdict





La lecture

Le calcul

$$\chi^2 = \frac{0{,}20^2}{8{,}80} + \frac{0{,}20^2}{11{,}20} + \cdots + \frac{0{,}72^2}{7{,}28} = 0{,}234$$

ddl $= (3-1)(2-1) = 2$, seuil 5,99, $p = 0{,}89$: les effectifs observés collent aux attendus. On ne rejette pas l'indépendance.

Ce que dit la population

Dans les 500 salariés, la part de femmes vaut 42,9 %, 42,0 % et 44,9 % selon le diplôme : diplôme et sexe y sont pratiquement indépendants.
Le test a donc pris la bonne décision. Avec le chapitre 16 : ni le sexe seul, ni sa liaison au diplôme ne structurent la rémunération ; **le diplôme, lui, la structure** (chapitre 17).

Mesurer l'intensité de la liaison

Le V de Cramér

$$V = \sqrt{\frac{\chi^2}{n \times \min(l-1,\, c-1)}}$$

Il va de 0 (indépendance) à 1 (liaison parfaite), et **ne dépend pas de** n.

Sur nos données

Échantillon : $V = \sqrt{0{,}234/50} = 0{,}07$. Population : $V = \sqrt{0{,}229/500} = 0{,}02$.
Deux liaisons très faibles. Le χ^2 dit si la liaison est détectable ; V dit si elle est forte.

Un tableau deux sur deux

Bac+5 ou non, selon le sexe

	Femmes	Hommes
Bac+5	5	8
autre diplôme	17	20

$\chi^2 = 0{,}219$ avec 1 degré de liberté, $p = 0{,}64$.

C'est le test de deux proportions

Au chapitre 16, la comparaison des parts de Bac+5 donnait $z = 0{,}468$: et $0{,}468^2 = 0{,}219$.
Pour un tableau 2×2, le khi-deux d'indépendance **est** le test bilatéral de deux proportions.

Démonstration : Un tableau deux sur deux, le khi-deux est le carré du z de deux proportions

Prenons le tableau $\begin{pmatrix} a & b \\ c & d \end{pmatrix}$, de total $n = a+b+c+d$, de marges $n_{1\bullet} = a+b$, $n_{2\bullet} = c+d$, $n_{\bullet 1} = a+c$, $n_{\bullet 2} = b+d$. L'attendu de la case a est $E_a = (a+b)(a+c)/n$ et

$$a - E_a = \frac{a(a+b+c+d) - (a+b)(a+c)}{n} = \frac{ad-bc}{n}.$$

Les trois autres cases ont le même écart en valeur absolue (les marges sont fixées : une seule case est libre). Donc $\chi^2 = \left(\frac{ad-bc}{n}\right)^2 \sum_{ij} 1/E_{ij}$, avec

$$\sum_{ij} \frac{1}{E_{ij}} = n\Big(\frac{1}{n_{1\bullet}} + \frac{1}{n_{2\bullet}}\Big)\Big(\frac{1}{n_{\bullet 1}} + \frac{1}{n_{\bullet 2}}\Big) = \frac{n^3}{n_{1\bullet} n_{2\bullet} n_{\bullet 1} n_{\bullet 2}}, \qquad \text{d'où} \qquad \chi^2 = \frac{n\,(ad-bc)^2}{n_{1\bullet}\, n_{2\bullet}\, n_{\bullet 1}\, n_{\bullet 2}}.$$

Le z de deux proportions. Les deux groupes sont les colonnes, le « succès » est la première ligne : $f_1 = a/(a+c)$, $f_2 = b/(b+d)$ et la proportion commune est $\hat{p} = n_{1\bullet}/n$. Alors $f_1 - f_2 = \dfrac{ad-bc}{n_{\bullet 1} n_{\bullet 2}}$ et

$$z^2 = \frac{(f_1 - f_2)^2}{\hat{p}(1-\hat{p})(\frac{1}{n_{\bullet 1}} + \frac{1}{n_{\bullet 2}})} = \frac{(ad-bc)^2}{n_{\bullet 1}^2 n_{\bullet 2}^2} \cdot \frac{n^2}{n_{1\bullet} n_{2\bullet}} \cdot \frac{n_{\bullet 1} n_{\bullet 2}}{n} = \frac{n\,(ad-bc)^2}{n_{1\bullet}\, n_{2\bullet}\, n_{\bullet 1}\, n_{\bullet 2}} = \chi^2.$$

Notre cas. Bac+5 selon le sexe : $a = 5$, $b = 8$, $c = 17$, $d = 20$, $ad - bc = -36$ et $\chi^2 = 50 \times 36^2/(13 \times 37 \times 22 \times 28) = 0{,}2187 = 0{,}4677^2$.

Ce que cela dit. Le khi-deux d'indépendance 2 × 2 et le test de deux proportions sont le même test, et la p-value 0,64 aussi. La proportion commune du chapitre 16 y apparaît sous la forme des attendus calculés avec les marges.

■

Les conditions et les pièges

La condition de validité

Des effectifs attendus suffisants

Tout effectif **attendu** doit être au moins égal à 5.
Sinon, on regroupe des modalités voisines — ou l'on emploie un test exact. La condition porte sur l'attendu, jamais sur l'observé.

Diplôme et région, dans l'échantillon

Le tableau 3 × 4 compte 12 cases pour 50 personnes. Les attendus vont de 2,3 à 7,6 : 10 **cases sur** 12 sont sous 5.
Le χ^2 calculé (5,80, $p = 0{,}45$) n'est pas fiable : sa loi n'est pas celle du khi-deux.

Démonstration : Ce que vaut le niveau de cinq pour cent quand l'attendu est petit

Le seuil est calculé pour la loi continue χ^2_{k-1}, alors que la statistique ne prend qu'un nombre fini de valeurs. On peut mesurer l'écart **exactement**. Pour k modalités équiprobables et n observations, on énumère toutes les répartitions $(O_1, \dots, O_k)$, on leur donne leur probabilité multinomiale $\dfrac{n!}{O_1! \cdots O_k!}\, k^{-n}$, et l'on additionne celles pour lesquelles χ^2 dépasse le seuil à 5 %.
Le niveau réel dépend de l'effectif attendu $E = n/k$ de chaque case :

attendu E	1	2	3	5	10	20
$k = 3$ modalités	11,1 %	5,3 %	5,0 %	4,3 %	4,8 %	5,4 %
$k = 4$ modalités	1,6 %	3,4 %	4,8 %	4,2 %	4,5 %	4,9 %

Pour $E = 1$, le niveau annoncé de 5 % est en réalité de 11 % avec trois modalités et de 1,6 % avec quatre : le test rejette beaucoup trop ou presque jamais, selon le hasard de la discrétisation. À partir de $E = 5$, et jusqu'à $E = 25$ dans cette énumération, le niveau reste entre 4,1 % et 6,0 %.

Ce que cela dit. Le seuil « 5 » n'est pas une frontière nette : il marque l'ordre de grandeur à partir duquel la loi du khi-deux décrit correctement une statistique discrète. En dessous, le niveau annoncé n'est plus tenu, dans un sens ou dans l'autre, et la p-value de 0,45 du tableau diplôme × région (dont dix cases sur douze ont un attendu inférieur à 5) ne se lit plus avec la table : on regroupe les modalités, ou l'on emploie un test exact.

■

Regrouper pour rendre le test valide

Deux modalités de chaque côté

	Tanger-Tétouan	autres régions
Bac	7 (7,6)	13 (12,4)
Bac+2 ou plus	12 (11,4)	18 (18,6)

Tous les attendus dépassent 5. $\chi^2 = 0{,}13$, 1 degré de liberté, $p = 0{,}72$.

Le prix du regroupement

Le test devient valide, mais il répond à une question **plus grossière** : la région de Tanger-Tétouan se distingue-t-elle par son niveau de diplôme ?
Le regroupement se décide sur le sens économique des modalités, jamais pour obtenir un résultat.

Deux limites à connaître

Liaison n'est pas causalité

Le khi-deux détecte une **liaison**, pas une **causalité** : c'est la mise en garde du cours de descriptive, inchangée.

Sensible à la taille de l'échantillon

À proportions identiques, multiplier tous les effectifs par 10 multiplie le χ^2 par 10. Sur cent mille observations, la moindre irrégularité devient significative.
Il faut alors accompagner le test d'un indicateur d'intensité, comme le V de Cramér.

Démonstration : Le V de Cramér est compris entre 0 et 1 et ne dépend pas de n

Notons $p_{ij} = n_{ij}/n$ et $p_{i\bullet}$, $p_{\bullet j}$ les marges. Le terme $(n_{ij} - n_{i\bullet}n_{\bullet j}/n)^2 \big/ (n_{i\bullet}n_{\bullet j}/n)$ se développe en $n\,p_{ij}^2/(p_{i\bullet}p_{\bullet j}) - 2n_{ij} + n_{i\bullet}n_{\bullet j}/n$, et la somme sur toutes les cases de $-2n_{ij} + n_{i\bullet}n_{\bullet j}/n$ vaut $-2n + n = -n$. Donc

$$\frac{\chi^2}{n} = \sum_{ij} \frac{p_{ij}^2}{p_{i\bullet}\,p_{\bullet j}} - 1.$$

La borne. Comme $p_{ij} \leq p_{\bullet j}$, on a $\dfrac{p_{ij}^2}{p_{i\bullet}p_{\bullet j}} \leq \dfrac{p_{ij}}{p_{i\bullet}}$, et la somme de droite sur j vaut 1 pour chaque ligne i : la double somme est au plus l, donc $\chi^2/n \leq l - 1$. En échangeant lignes et colonnes (car $p_{ij} \leq p_{i\bullet}$), $\chi^2/n \leq c - 1$. Ainsi

$$0 \leq \chi^2 \leq n\,\min(l-1,\,c-1) \qquad \text{et} \qquad V = \sqrt{\frac{\chi^2}{n\,\min(l-1,\,c-1)}} \in [0\,;1].$$

La borne 1 est atteinte : un tableau diagonal ($n_{ij} = 0$ hors de la diagonale) donne $\chi^2 = n(l-1)$.

Ne pas dépendre de n. Si l'on multiplie tous les effectifs par λ, les p_{ij} ne changent pas : χ^2/n est inchangé, donc χ^2 est multiplié par λ et V ne bouge pas. C'est l'exercice 3 : $\chi^2 = 2{,}0$ pour 2×100 clients et 20,0 pour $2 \times 1\,000$ clients, avec dans les deux cas $V = 0{,}10$. La p-value, elle, passe de 0,16 à moins de 0,0001.

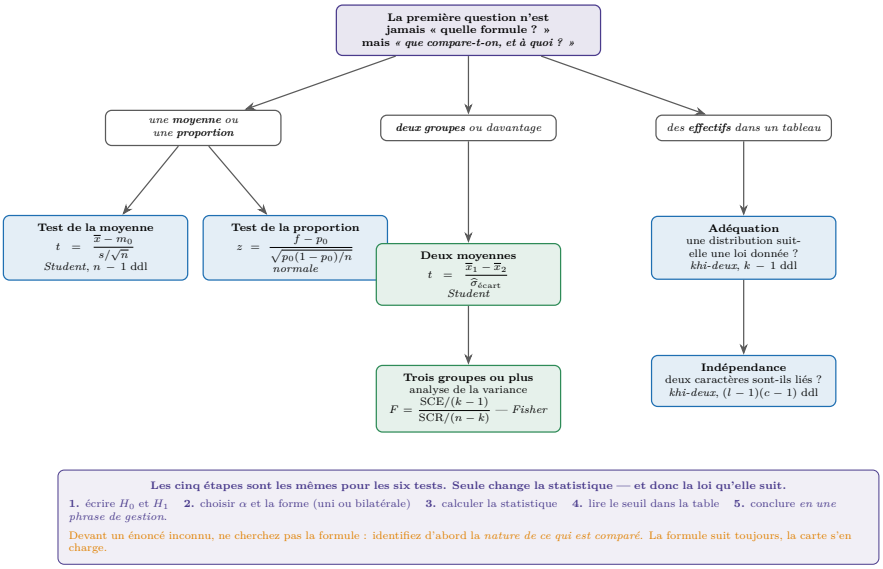
Nos données. Diplôme et sexe : $V = \sqrt{0{,}2345/50} = 0{,}068$ dans l'échantillon, $\sqrt{0{,}2292/500} = 0{,}021$ dans la population ; le tableau des trois agences : $\sqrt{18{,}2/300} = 0{,}246$.

Ce que cela dit. Le χ^2 mesure à la fois l'intensité de la liaison et l'effectif ; V retire l'effectif. C'est pourquoi un résultat « très significatif » sur cent mille observations peut cacher un V de quelques centièmes.

■

La carte des tests

Les six tests du cours, sur une seule page



Comment s'en servir

Trois questions, dans cet ordre

1. **Que compare-t-on ?** Un paramètre à une valeur, deux groupes, plusieurs groupes, ou des effectifs.
2. **De quelle nature sont les données ?** Quantitatives ou catégorielles.
3. **Les observations vont-elles deux par deux ?** Si oui, il faut apparier.

Le réflexe à prendre pour l'examen

Devant un énoncé inconnu, ne cherchez pas la formule : identifiez d'abord **la nature de ce qui est comparé**.
Les cinq étapes sont ensuite les mêmes pour les six tests. La formule suit toujours ; c'est l'identification qui se rate.

Les tests du cours, sur nos données

Une même entreprise, six questions

Question	Test	Résultat
salaire moyen supérieur à 6 500 ?	t, une moyenne	$p = 0{,}059$, non-rejet
part de Bac+5 égale à 15 % ?	z, une proportion	$p = 0{,}029$, rejet
hommes et femmes, même salaire ?	Welch	$p = 0{,}41$, non-rejet
salaire identique selon le diplôme ?	ANOVA	$p = 0{,}020$, rejet
diplôme indépendant du sexe ?	khi-deux	$p = 0{,}89$, non-rejet
échantillon représentatif des régions ?	adéquation	$p = 0{,}95$, non-rejet

Les clients se répartissent-ils également ?

Un magasin ouvert cinq jours par semaine a reçu 200 clients : 35 le lundi, 38 le mardi, 42 le mercredi, 40 le jeudi, 45 le vendredi.

1. Tester au seuil de 5 % l'hypothèse d'une fréquentation uniforme.
2. Le gérant veut supprimer une caissière le lundi. Le test l'y autorise-t-il ?

Quarante attendus par jour

1. $\chi^2 = (25 + 4 + 4 + 0 + 25)/40 = 1{,}45$; ddl $= 4$, seuil 9,49 : non-rejet ($p = 0{,}84$).
2. Le test ne prouve pas l'uniformité : il dit qu'avec 200 clients, l'écart du lundi (35 contre 40) n'est pas distinguable du hasard. Il faudrait plusieurs semaines d'observation pour trancher.

Un tableau trois sur deux

On interroge 100 clients dans chacune de trois agences.

Agence	satisfaits	non satisfaits
A	60	40
B	45	55
C	30	70

1. Calculer les effectifs attendus sous l'indépendance.
2. Tester l'indépendance au seuil de 5 % et mesurer l'intensité de la liaison.

Attendus, khi-deux, V de Cramér

1. 135 satisfaits sur 300 : attendus 45 satisfaits et 55 non satisfaits dans chaque agence.
2. Seules A et C s'écartent, de 15 dans chaque case : $\chi^2 = 2 \times (15^2/45 + 15^2/55) = 2 \times (5{,}00 + 4{,}09) = 18{,}2$. ddl $= 2$, seuil 5,99 : **rejet** ($p = 0{,}0001$).

$V = \sqrt{18{,}2/300} = 0{,}25$: une liaison nette, sans être écrasante. L'agence C mérite un audit.

Quand n change, à proportions égales

Une campagne est testée auprès de deux groupes de 100 clients : 55 achats dans le premier groupe, 45 dans le second. Une seconde étude, sur deux groupes de 1 000, trouve exactement les mêmes proportions (550 et 450).

1. Calculer le χ^2 et conclure dans les deux cas.
2. Comparer les deux V de Cramér. Qu'en conclure ?

Le khi-deux grandit avec n, pas V

1. Première étude : attendus 50 partout, $\chi^2 = 4 \times 25/50 = 2{,}0 < 3{,}84$: non-rejet ($p = 0{,}16$). Seconde : $\chi^2 = 20{,}0$: **rejet** ($p < 0{,}0001$).
2. $V = \sqrt{2/200} = \sqrt{20/2\,000} = 0{,}10$ dans les deux cas. La liaison est **la même**, faible ; seule la capacité à la détecter a changé.

Six points

1. Le khi-deux traite les **effectifs de catégories** : $\chi^2 = \sum(\text{observé} - \text{attendu})^2/\text{attendu}$, toujours unilatéral à droite.
2. **Adéquation** : attendu $= n\,p_i$, ddl $= k - 1 -$ (paramètres estimés). Dé : $\chi^2 = 4{,}94$; régions : 0,37.
3. **Indépendance** : attendu $= n_{i\bullet} n_{\bullet j}/n$, ddl $= (l-1)(c-1)$. Diplôme et sexe : $\chi^2 = 0{,}234$, $p = 0{,}89$.
4. Avec deux cases ou un tableau 2×2, le khi-deux retrouve les tests z des chapitres 15 et 16.
5. Condition : tout effectif **attendu** au moins égal à 5 ; sinon, regrouper.
6. Le χ^2 grandit avec n ; le V **de Cramér** mesure l'intensité de la liaison.

Deux variables quantitatives

Le cours a traité une moyenne, deux groupes, plusieurs groupes, un tableau. Il reste la situation la plus riche : **deux variables quantitatives**.

Le prochain chapitre

La statistique descriptive s'arrêtait à une droite d'ajustement. Le chapitre 19 en fait un modèle, estimé sur l'échantillon — et ouvre la porte à l'économétrie.