

Statistique inférentielle

Chapitre 4 : Les trois lois de l'inférence

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique inférentielle

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Utiliser la loi de Student

On prélève un échantillon de $n = 9$ pièces sur une chaîne de production dont on souhaite vérifier que le poids moyen respecte la norme $m_0 = 120$ g. L'échantillon donne $\bar{x} = 126$ g et un écart-type corrigé $s = 15$ g. On rappelle $t_{0,975;8} = 2,306$ (table de Student).

- Pourquoi doit-on utiliser la loi de Student plutôt que la loi normale pour ce test, alors que le chapitre 2 utilisait la loi normale pour $\bar{X}$?
- Calculer $T = \frac{\bar{x} - m_0}{s/\sqrt{n}}$.
- Comparer $|T|$ au quantile $t_{0,975;8} = 2,306$. Ce résultat est-il compatible, à ce stade intuitif, avec l'hypothèse que le poids moyen réel de la production est bien 120 g?

Exercice 2 — Une statistique du khi-deux qui n'est pas une variance

On lance un dé 60 fois et on obtient les effectifs suivants pour les faces 1 à 6 : 8, 11, 9, 13, 7, 12. Si le dé est parfaitement équilibré, chaque face est attendue 10 fois.

- Calculer la statistique $\sum_{\text{faces}} \frac{(\text{observé} - \text{attendu})^2}{\text{attendu}}$.
- De quelle des deux formules du cours (variance estimée, ou somme d'écarts au carré standardisés) cette statistique relève-t-elle? À quelle grande famille de tests statistiques appartient-elle (sans en calculer le seuil, qui sera vu dans un chapitre ultérieur)?
- Expliquer pourquoi une statistique de ce type ne peut jamais être négative, et pourquoi seule une valeur **grande** de cette statistique remettrait en cause l'hypothèse d'un dé équilibré (test toujours unilatéral à droite).

Exercice 3 — Construire la statistique de Fisher

Deux laboratoires mesurent, chacun sur son propre échantillon, la variance corrigée d'un même procédé de fabrication supposé identique dans les deux laboratoires : laboratoire 1, $n_1 = 13$ mesures, $s_1^2 = 45$; laboratoire 2, $n_2 = 9$ mesures, $s_2^2 = 20$.

- Rappeler la définition générale de la statistique de Fisher $F = \frac{\chi_{d_1}^2/d_1}{\chi_{d_2}^2/d_2}$, et expliquer pourquoi, sous l'hypothèse que les deux procédés ont la **même** variance théorique, elle se simplifie ici en $F = s_1^2/s_2^2$.
- Calculer F , ainsi que les degrés de liberté $d_1 = n_1 - 1$ et $d_2 = n_2 - 1$ associés.
- Un collègue affirme qu'un rapport $F = 2,25$ prouve à lui seul que les deux procédés ont des variances différentes. Que manque-t-il à son raisonnement pour pouvoir conclure rigoureusement (indice : penser au rôle du seuil issu de la table de Fisher, non calculé ici)?

2 Exercices cumulatifs (chapitres 1 à 4)

Exercice 4 — Le fil rouge, avec la vraie loi de Student

On reprend une dernière fois le fil rouge : $N = 500$ salariés, $m = 7\,158,26$ dh; échantillon systématique de $n = 50$ salariés, $\bar{x} = 7\,005,80$ dh, σ (population) = 2 598,10 dh, s (échantillon, $\div (n - 1)$) = 2 250,98 dh. On rappelle $t_{0,975;49} = 2,010$.

- Au chapitre 2, on a calculé Z en utilisant l'écart-type de la **population** $\sigma = 2\,598,10$ dh (avec correction de population finie), une situation en réalité rare en pratique puisqu'on ne connaît

presque jamais σ . Calculer maintenant $T = \frac{\bar{x} - m}{s/\sqrt{n}}$ en utilisant l'écart-type de l'échantillon $s = 2\,250,98$ dh (sans correction de population finie, pour rester dans le cadre standard de ce chapitre).

- (b) Comparer $|T|$ au quantile $t_{0,975;49} = 2,010$. Cette conclusion confirme-t-elle celle obtenue au chapitre 1 (comparaison intuitive à 1 erreur-type) et au chapitre 2 (calcul de Z) ?
- (c) En pratique, pourquoi un statisticien qui ne connaîtrait que l'échantillon (et non $\sigma = 2\,598,10$ dh, qui suppose de connaître toute la population) serait-il contraint d'utiliser T plutôt que Z ? Pourquoi, ici, les deux méthodes mènent-elles néanmoins à des conclusions très proches ?

3 Applications en sciences économiques

Exercice 5 — Le prix de l'ignorance dans une petite enquête d'entreprise

Un cabinet de conseil interroge $n = 10$ entreprises d'un secteur pour estimer leur marge bénéficiaire moyenne, sans connaître l'écart-type de la population. On rappelle $t_{0,975;9} = 2,262$ (table de Student) contre $z_{0,975} = 1,960$ (loi normale).

- (a) Calculer le « surcoût » en pourcentage du quantile de Student par rapport au quantile normal, $\left(\frac{t_{0,975;9}}{z_{0,975}} - 1 \right) \times 100$.
- (b) Le cabinet de conseil utilise, par erreur, le quantile normal 1,960 au lieu de 2,262 pour construire son intervalle de confiance sur la marge moyenne. Ce choix conduit-il à un intervalle trop étroit ou trop large par rapport à ce qu'exige rigoureusement la petite taille de l'échantillon ?
- (c) En quoi cette erreur pourrait-elle avoir des conséquences économiques concrètes si le cabinet présente son intervalle de confiance, à tort trop étroit, comme base d'une recommandation d'investissement à un client ?

Exercice 6 — Comparer le risque de deux portefeuilles avec Fisher

Un gérant d'actifs compare la variance des rendements mensuels de deux portefeuilles sur des échantillons indépendants : portefeuille A, variance corrigée $s_A^2 = 64$ (en points de pourcentage au carré) ; portefeuille B, variance corrigée $s_B^2 = 25$.

- (a) Calculer la statistique de Fisher $F = s_A^2/s_B^2$ pour comparer la dispersion des deux portefeuilles.
- (b) Le portefeuille A a-t-il, sur cet échantillon, un rendement mensuel plus volatil que le portefeuille B ? De combien de fois, approximativement, sa variance est-elle supérieure ?
- (c) Pourquoi un gérant de risques voudrait-il, avant de comparer les **moyennes** de rendement des deux portefeuilles par un test de Student, commencer par examiner un rapport de variances comme celui-ci (indice : penser à l'hypothèse d'égalité des variances souvent requise par les tests de comparaison de moyennes) ?


1 Exercices du chapitre

Correction — Exercice 1

(a) Au chapitre 2, on supposait σ **connu**, ce qui donne directement une loi normale pour $Z = (\bar{X} - m)/(\sigma/\sqrt{n})$. Ici, σ est **inconnu** et remplacé par son estimation s : cette substitution introduit une seconde source de variabilité (celle de s lui-même), ce qui change la loi de la normale vers la loi de Student à $n - 1$ degrés de liberté.

(b) $T = \frac{126 - 120}{15/\sqrt{9}} = \frac{6}{5} = 1,2$.

(c) $|T| = 1,2 < t_{0,975;8} = 2,306$: l'écart observé est tout à fait compatible avec l'hypothèse $m_0 = 120$ g ; rien, à ce stade intuitif, ne permet de rejeter cette hypothèse.



Correction — Exercice 2

(a)
$$\frac{(8-10)^2 + (11-10)^2 + (9-10)^2 + (13-10)^2 + (7-10)^2 + (12-10)^2}{10} = \frac{4+1+1+9+9+4}{10} = \frac{28}{10} = 2,8.$$

(b) Cette statistique relève de la **seconde** formule du cours, $\sum (\text{observé} - \text{attendu})^2 / \text{attendu}$, et non de l'estimation d'une variance : elle appartient à la famille des **tests d'adéquation** (ici, tester si le dé suit la loi uniforme attendue), l'une des deux grandes familles de tests fondés sur le khi-deux.

(c) Chaque terme de la somme est un carré divisé par un nombre positif (l'effectif attendu), donc chaque terme est ≥ 0 , et la somme l'est aussi : la statistique ne peut jamais être négative. Un dé parfaitement équilibré produirait, par chance, de petits écarts et donc une statistique **proche de zéro** ; seul un très grand écart entre observé et attendu (dé déséquilibré) pousse la statistique vers de grandes valeurs. Le test est donc **unilatéral à droite** : on rejette l'hypothèse d'équilibre uniquement pour des valeurs suffisamment **grandes** de la statistique, jamais pour des valeurs petites.

Correction — Exercice 3


(a) Chaque $\chi_{d_i}^2$ provient de $(n_i - 1)s_i^2/\sigma_i^2$. Si $\sigma_1^2 = \sigma_2^2 = \sigma^2$ (hypothèse d'égalité des variances), alors

$$F = \frac{[(n_1 - 1)s_1^2/\sigma^2]/(n_1 - 1)}{[(n_2 - 1)s_2^2/\sigma^2]/(n_2 - 1)} = \frac{s_1^2/\sigma^2}{s_2^2/\sigma^2} = \frac{s_1^2}{s_2^2}$$

le σ^2 commun se simplifiant exactement, d'où la formule pratique $F = s_1^2/s_2^2$.

(b) $F = 45/20 = 2,25$, avec $d_1 = n_1 - 1 = 12$ et $d_2 = n_2 - 1 = 8$.

(c) Il manque la comparaison de $F = 2,25$ à un **seuil critique** lu dans une table de Fisher à $(d_1, d_2) = (12, 8)$ degrés de liberté, pour un niveau de risque donné (par exemple 5 %) : seule cette comparaison permet de dire si l'écart entre les deux variances estimées est **trop grand** pour être imputable au seul hasard d'échantillonnage, ou s'il reste dans la marge de fluctuation normale d'un rapport de deux khi-deux. Affirmer une différence « prouvée » sans ce seuil est prématuré.



2 Exercices cumulatifs (chapitres 1 à 4)

Correction — Exercice 4

$$(a) T = \frac{7\,005,80 - 7\,158,26}{2\,250,98/\sqrt{50}} = \frac{-152,46}{318,34} \approx -0,479.$$

(b) $|T| \approx 0,479 < t_{0,975;49} = 2,010$: l'écart reste tout à fait plausible sous l'hypothèse d'un tirage sans biais. Cette conclusion **confirme** exactement celle du chapitre 1 (où l'on comparait intuitivement l'écart à une seule erreur-type, $\text{ratio} \approx 0,479$ — ici retrouvé presque au chiffre près, car le dénominateur 318,34 est en réalité l'erreur-type utilisée dès le chapitre 1) et celle du chapitre 2 ($Z \approx -0,437$ avec correction de population finie) : dans les trois cas, rien ne suggère un biais du tirage systématique.

(c) En pratique, un statisticien ne dispose presque jamais de σ , qui exigerait de connaître la dispersion de la population **entière** : il doit donc estimer σ par s , calculé sur son seul échantillon, et utiliser en conséquence la loi de Student plutôt que la loi normale. Ici, les deux méthodes mènent à des conclusions très proches car $n = 49$ degrés de liberté est déjà **grand** : le quantile de Student (2,010) est très proche du quantile normal (1,960), l'écart entre les deux lois s'estompant précisément lorsque n devient grand, comme l'avait annoncé le cours.

3 Applications en sciences économiques

Correction — Exercice 5

$$(a) \left(\frac{2,262}{1,960} - 1 \right) \times 100 \approx 15,4 \, \%.$$

(b) En utilisant 1,960 au lieu de 2,262, le cabinet **sous-estime** le quantile qu'il faudrait rigoureusement utiliser : il construit donc un intervalle de confiance **trop étroit** d'environ 15,4 % par rapport à ce qu'exige la petite taille de l'échantillon ($n = 10$).

(c) Un intervalle de confiance trop étroit donne une **fausse impression de précision** sur la marge bénéficiaire moyenne réelle du secteur : le client pourrait fonder une décision d'investissement sur une estimation présentée comme plus fiable qu'elle ne l'est réellement, et être surpris par une variabilité effective plus grande que celle annoncée — un risque d'autant plus trompeur que la sous-estimation est **systématique** (elle se produirait à chaque petite enquête de ce type) et non due au hasard.

Correction — Exercice 6

$$(a) F = s_A^2/s_B^2 = 64/25 = 2,56.$$

(b) **Oui**, sur cet échantillon, le portefeuille A affiche une variance des rendements mensuels environ 2,56 fois supérieure à celle du portefeuille B : ses rendements apparaissent nettement plus volatils.

(c) De nombreux tests de comparaison de **moyennes** (test de Student à deux échantillons avec variance commune supposée, dit « pooled ») reposent explicitement sur l'hypothèse que les deux populations comparées ont la **même** variance théorique. Si cette hypothèse est fautive — ce qu'un rapport de Fisher nettement supérieur à 1 peut suggérer —, le test de Student usuel n'est plus valide tel quel, et il faut recourir à une variante adaptée (variances inégales) ; vérifier d'abord l'homogénéité des variances avec Fisher évite ainsi d'appliquer, à tort, un test conçu pour des variances égales.