Statistique inférentielle

Chapitre 4 : Les trois lois de l'inférence

Jaouad Madkour

22 octobre 2026

Plan du chapitre

Une dette envers les probabilités **2**
Trois lois présentées, jamais employées . . . 2
Les trois, ensemble . . . 2
Les trois définitions, rappelées . . . 3

La loi du khi-deux **3**
Une somme de carrés . . . 3
Sa forme selon le nombre de degrés de liberté . . . 4
Lire une table du khi-deux . . . 4
Ses deux apparitions dans le cours . . . 4

La loi de Student **5**
D'où elle vient . . . 5
Pourquoi c'est bien une Student . . . 5
Ce que la substitution coûte . . . 5
Des queues plus épaisses . . . 6
Les queues, en chiffres . . . 6
Sur notre échantillon . . . 7
Quand la population n'est pas normale . . . 7
Ce que montre la simulation . . . 7

La loi de Fisher **8**
Un rapport de deux khi-deux . . . 8
Comparer deux dispersions, sur nos données . . . 8
Ses deux emplois principaux . . . 9
Les liens entre les quatre lois . . . 9

La carte des lois **9**
Quelle loi pour quelle statistique . . . 9
Les tables, avec un logiciel . . . 10

S'entraîner **10**
Exercice 1 : lire les tables . . . 10
Exercice 1 : solution . . . 10

Exercice 2 : quelle loi ? 11
Exercice 2 : solution 11
Exercice 3 : le prix de l'ignorance 11
Exercice 3 : solution 11

Ce qu'il faut retenir **12**
Le résumé du chapitre 12
La suite 12

Une dette envers les probabilités

Trois lois présentées, jamais employées

Le chapitre 18 de Probabilités les annonçait

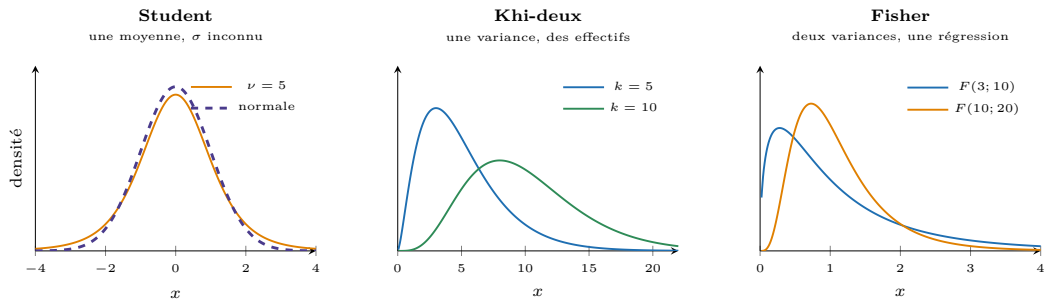
Khi-deux, Student et Fisher y étaient définies comme des lois **fabriquées** à partir de la normale — sans qu'aucun phénomène économique ne les suive.
Il était dit qu'elles ne serviraient qu'aux tests. Nous y sommes.

Leur point commun

Aucune ne décrit une population. Toutes décrivent le comportement d'une **statistique calculée sur un échantillon** :

- une variance estimée ;
- une moyenne dont on a dû estimer l'écart-type ;
- un rapport de deux variances estimées.

Les trois, ensemble



Ces trois lois sont exactement celles du chapitre 19 des probabilités — et voici enfin à quoi elles servent.

Student apparaît dès qu'on remplace σ par s : moyenne, différence de moyennes, coefficient de régression.
Khi-deux apparaît dès qu'on additionne des écarts *au carré* : variance d'un échantillon, adéquation, indépendance.
Fisher apparaît dès qu'on compare deux variances : analyse de la variance, test global d'une régression.

Le fil est toujours le même : *quelle statistique je calcule* détermine *quelle loi je dois lire.*

Les trois définitions, rappelées

Trois constructions à partir de la normale

Soit $Z, Z_1, \dots, Z_k$ des variables $\mathcal{N}(0\,;1)$ indépendantes.

Loi	Construction	Espérance	Variance
χ^2_k	$Z_1^2 + \cdots + Z_k^2$	k	$2k$
t_k	$Z \Big/ \sqrt{\chi^2_k / k}$	0	$k/(k-2)$
$F_{d_1,\,d_2}$	$(\chi^2_{d_1}/d_1) \Big/ (\chi^2_{d_2}/d_2)$	$d_2/(d_2-2)$	—

Le nombre de degrés de liberté

Dans les trois cas, k compte le nombre de carrés **indépendants** que l'on a additionnés. C'est le même nombre que le chapitre 3 a appelé degré de liberté : $n-1$ écarts libres autour de $\overline{x}$.

La loi du khi-deux

Une somme de carrés

Le cas le plus simple : un seul carré

$\chi^2_1 = Z^2$. Or $Z^2 \leq 3{,}84$ équivaut à $|Z| \leq 1{,}96$:

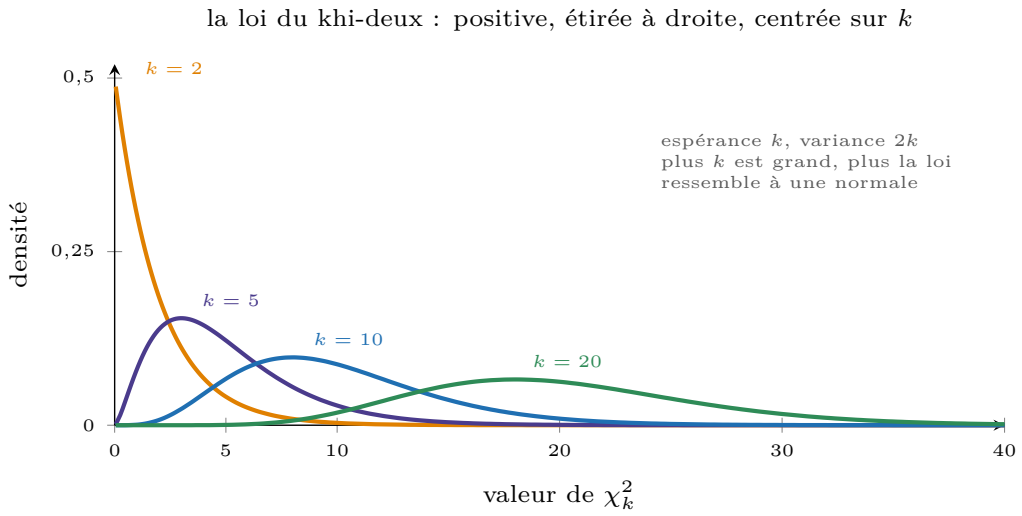
$$P(\chi^2_1 \leq 3{,}84) = P(-1{,}96 \leq Z \leq 1{,}96) = 0{,}95$$

Le quantile à 95 % du khi-deux à un degré est le carré du quantile normal : $1{,}96^2 = 3{,}84$.

Ajouter des carrés

Chaque carré ajouté apporte en moyenne 1 : d'où $E(\chi^2_k) = k$. La somme ne peut être négative, et elle est étirée à droite, car un seul grand écart suffit à la gonfler.
Quand k grandit, le théorème central limite s'applique à cette somme : la loi devient presque normale.

Sa forme selon le nombre de degrés de liberté



Lire une table du khi-deux

Quelques quantiles

k	2,5 %	95 %	97,5 %
1	0,001	3,841	5,024
5	0,831	11,070	12,833
10	3,247	18,307	20,483
49	31,555	66,339	70,222

Une loi qui n'est pas symétrique

Pour $k = 49$, l'espérance vaut 49, mais les quantiles à 2,5 et 97,5 % sont à 17,4 en dessous et 21,2 au-dessus.
On ne peut donc jamais écrire « $49 \pm$ quelque chose » : les deux bornes se lisent séparément dans la table. Le chapitre 10 en tirera un intervalle **non centré** pour σ^2.

Ses deux apparitions dans le cours

Variance et tableaux d'effectifs

$$\frac{(n-1)\,S^2}{\sigma^2} \sim \chi^2_{n-1} \qquad \sum_{\text{cases}} \frac{(\text{observé} - \text{attendu})^2}{\text{attendu}} \approx \chi^2$$

Estimation d'une variance d'un côté (chapitres 3 et 10) ; tests d'adéquation et d'indépendance de l'autre (chapitre 18).

Le signe qui ne trompe pas

Dès qu'une procédure additionne des **écarts au carré**, un khi-deux apparaît.
Deux conséquences immédiates : la loi est **positive**, et le test des tableaux est **unilatéral à droite** — seuls les grands écarts contredisent l'hypothèse.

La loi de Student

D'où elle vient

Le problème

Le chapitre 2 a établi que $\dfrac{\overline{X}-m}{\sigma/\sqrt{n}}$ suit une loi normale.
Mais σ est un paramètre de la population : **inconnu**. On le remplace par S, calculé sur l'échantillon — et la quantité change de loi.

Le résultat, pour une population normale

$$T = \frac{\overline{X}-m}{S/\sqrt{n}} \sim t_{n-1}, \text{ Student à } n-1 \text{ degrés de liberté}$$

Pourquoi c'est bien une Student

Diviser haut et bas par σ

$$T = \frac{\dfrac{\overline{X}-m}{\sigma/\sqrt{n}}}{\sqrt{\dfrac{(n-1)S^2/\sigma^2}{n-1}}} = \frac{Z}{\sqrt{\chi^2_{n-1}/(n-1)}}$$

Le numérateur est normal (chapitre 2) ; le carré du dénominateur est un khi-deux divisé par son degré de liberté (chapitre 3).

La condition cachée

La définition de Student exige que Z et χ^2 soient **indépendantes**. Pour une population normale, $\overline{X}$ et S^2 le sont — un résultat remarquable, propre à la loi normale.
σ a disparu du résultat : c'est ce qui rend T **utilisable**.

Ce que la substitution coûte

Deux sources d'incertitude au lieu d'une

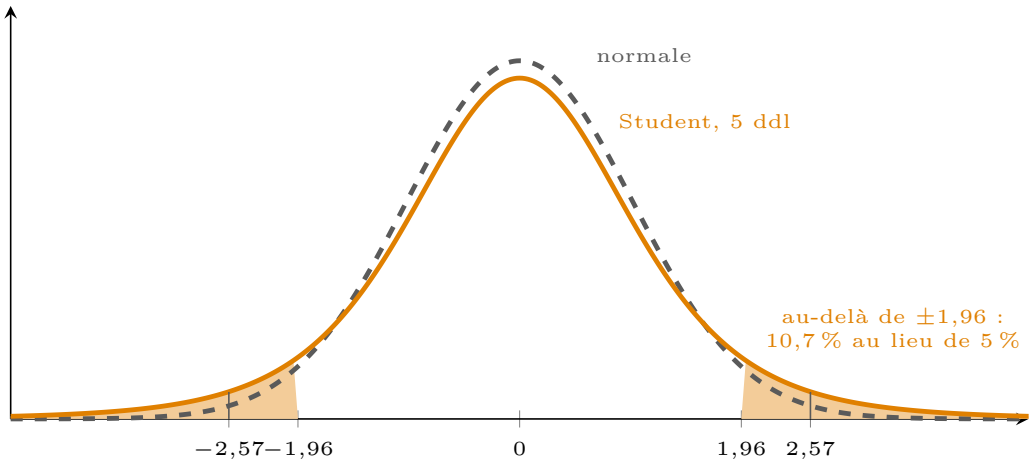
Au numérateur, $\overline{X}$ varie. Au dénominateur, S varie **aussi**.
Quand un petit échantillon donne par hasard un s trop petit, le rapport explose. C'est pourquoi Student a des **queues plus épaisses** que la normale : les valeurs extrêmes y sont plus fréquentes.

Le prix, chiffré

Degrés de liberté	Quantile à 97,5 %	Surcoût
5	2,571	+31 %
10	2,228	+14 %
30	2,042	+4 %
∞	1,960	—

Des queues plus épaisses

Student à 5 degrés de liberté contre la loi normale



Les queues, en chiffres

Ce qu'on risque à garder 1,96

ddl k	5	10	15	30	49	∞
risque réel	10,7 %	7,8 %	6,9 %	5,9 %	5,6 %	5 %
variance	1,67	1,25	1,15	1,07	1,04	1

Le risque réel est $P(|T_k| > 1{,}96)$; la variance de T_k vaut $k/(k-2)$.

L'erreur que l'on commet sans Student

Avec six observations, utiliser 1,96 au lieu de 2,571 fait passer le risque d'erreur annoncé de 5 % à plus de 10 % : on se croit deux fois plus sûr qu'on ne l'est.
Au-delà de trente observations, l'écart devient minime.

Sur notre échantillon

Cinquante salariés

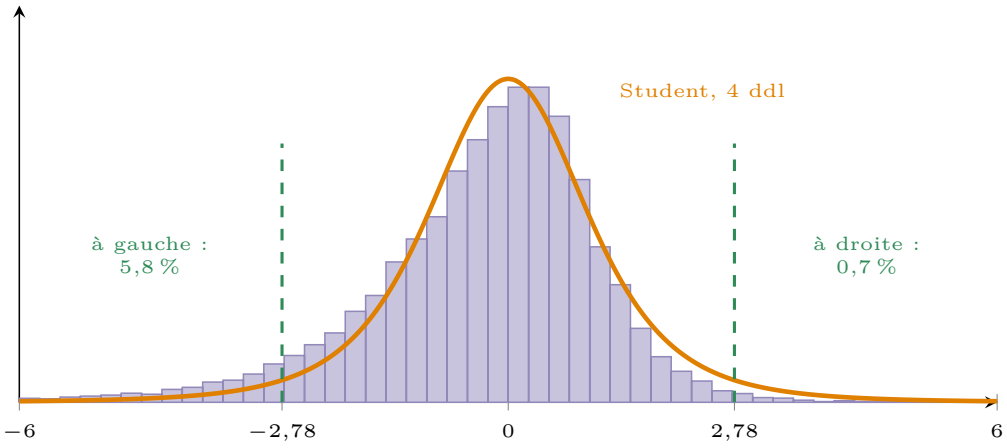
$n = 50$, donc $\nu = 49$ degrés de liberté, et $t_{0{,}975\,;49} = 2{,}010$ — contre 1,96 pour la normale : un élargissement de 2,6 %.
La statistique annoncée à la fin du chapitre 3 vaut $t = (7\,005{,}80 - 7\,158{,}26)/318{,}34 = -0{,}48$, et $P(|T_{49}| \geq 0{,}48) = 0{,}63$: une valeur des plus ordinaires.

La règle pratique

Utilisez **toujours** Student dès que σ est inconnu, c'est-à-dire pratiquement toujours.
Les logiciels le font sans qu'on le demande. Au-delà de trente observations, la différence ne se voit plus — mais elle ne coûte rien, et en dessous elle est indispensable.

Quand la population n'est pas normale

20 000 valeurs de T calculées sur 5 salaires tirés parmi les 500



attendu : 2,5 % de chaque côté

Ce que montre la simulation

Cinq salaires, puis cinquante

On tire 20 000 échantillons avec remise dans nos salaires, étirés à droite, et l'on calcule T chaque fois.

n	$T < -t$	$T > t$	Total	Attendu
5	5,8 %	0,7 %	6,6 %	5 %
50	4,3 %	1,4 %	5,8 %	5 %

Pourquoi la loi penche à gauche

Un échantillon qui contient un gros salaire a une moyenne élevée, mais aussi un s élevé : le rapport reste modéré. Un échantillon de petits salaires a une moyenne basse **et** un petit s : le rapport devient très négatif.
Le total reste proche de 5 % dès $n = 50$; la répartition entre les deux côtés, non. Le chapitre 15 s'en souviendra pour les tests unilatéraux.

La loi de Fisher

Un rapport de deux khi-deux

La construction

$$F = \frac{\chi^2_{d_1}/d_1}{\chi^2_{d_2}/d_2}$$

Deux degrés de liberté, un pour chaque variance comparée : d_1 au numérateur, d_2 au dénominateur. L'ordre compte.

Le rapport de deux variances d'échantillon

Pour deux échantillons indépendants, tirés de populations normales de **même** variance :

$$\frac{S_1^2}{S_2^2} \sim F_{n_1-1,\, n_2-1}$$

Si les deux variances sont égales, le rapport est proche de 1 ; un rapport très éloigné de 1 les met en doute.

Comparer deux dispersions, sur nos données

Les hommes et les femmes de l'échantillon

Groupe	Effectif	Écart-type s
Hommes	28	2 344,86
Femmes	22	2 142,01

$F = 2\,344{,}86^2/2\,142{,}01^2 = 1{,}198$, à comparer à $F_{27,\,21}$: 95 % des valeurs sont entre 0,447 et 2,335.

La conclusion

1,198 est au milieu de la zone : rien n'indique que les salaires des hommes soient plus dispersés que ceux des femmes.
Ce résultat servira au chapitre 16, où la comparaison des **moyennes** suppose, dans sa version classique, des variances égales.

Ses deux emplois principaux

ANOVA et régression

L'analyse de la variance (chapitre 17) compare la dispersion *entre* les groupes à la dispersion *à l'intérieur* des groupes.
Le test global d'une régression (chapitre 20) compare la variance expliquée à la variance résiduelle. Le « F de Fisher » qu'affiche tout logiciel d'économétrie sort de là.

Deux quantiles qui reviendront

$F_{0,95}(2\,;47) = 3{,}195$: le seuil de l'ANOVA des trois diplômes sur notre échantillon de 50.
$F_{0,95}(1\,;48) = 4{,}043 = 2{,}0106^2$: le carré du quantile de Student à 48 degrés.

Les liens entre les quatre lois

Une seule famille

Relation	Ce qu'elle dit
$\chi^2_1 = Z^2$	un khi-deux à un degré est un carré de normale
$t_k^2 = F_{1,\,k}$	un Student au carré est un Fisher à un degré
$t_k \to \mathcal{N}(0\,;1)$	Student devient normale quand k grandit
$d_1\, F_{d_1,\,k} \to \chi^2_{d_1}$	Fisher devient khi-deux quand k grandit

Pourquoi c'est utile

Un test de Student bilatéral et un test de Fisher à un degré de liberté donnent **exactement** la même conclusion. Le chapitre 20 le vérifiera sur la régression : $t^2 = F$.

La carte des lois

Quelle loi pour quelle statistique

La carte, en une ligne par cas

Ce que l'on calcule	Loi à lire
une moyenne, σ **connu**	normale
une moyenne, σ **estimé**	Student, $n-1$ ddl
une proportion, n grand	normale
une variance	khi-deux, $n-1$ ddl
des effectifs de tableau	khi-deux
un rapport de variances	Fisher

Le seul réflexe à acquérir

La question n'est jamais « quelle formule ? » mais « **quelle statistique ai-je calculée ?** ».
La statistique détermine la loi ; la loi fournit le seuil ; le seuil donne la conclusion. Cet enchaînement est celui de tous les chapitres qui suivent, sans exception.

Les tables, avec un logiciel

Les quantiles en une instruction

Quantile	R	Python (`scipy.stats`)
$t_{0{,}975\,;49}$	`qt(0.975, 49)`	`t.ppf(0.975, 49)`
$\chi^2_{0{,}95\,;10}$	`qchisq(0.95, 10)`	`chi2.ppf(0.95, 10)`
$F_{0{,}95}(2\,;47)$	`qf(0.95, 2, 47)`	`f.ppf(0.95, 2, 47)`

La table papier reste utile

À l'examen, on lit la table ; en entreprise, on demande au logiciel. Dans les deux cas, il faut savoir **quelle** loi et **quels** degrés de liberté demander : aucun logiciel ne le décide à notre place.

S'entraîner

Exercice 1 : lire les tables

Quatre lectures

À l'aide des tables (ou d'un logiciel), donner :

a. le quantile $t_{0{,}975}$ à 15 degrés de liberté ;
b. le quantile à 95 % du khi-deux à 10 degrés de liberté ;
c. le quantile à 95 % de $F_{3,\,20}$;
d. la probabilité $P(T_{10} > 2{,}228)$.

Puis vérifier que $1{,}96^2 = 3{,}84$ et dire de quel quantile il s'agit.

Exercice 1 : solution

Quatre valeurs de table

a. $t_{0{,}975\,;15} = 2{,}131$.
b. $\chi^2_{0{,}95\,;10} = 18{,}307$.
c. $F_{0{,}95}(3\,;20) = 3{,}098$.
d. $2{,}228$ est le quantile à 97,5 % de t_{10} : $P(T_{10} > 2{,}228) = 0{,}025$.

$1{,}96^2 = 3{,}8416$: c'est le quantile à 95 % de χ^2_1, puisque $\chi^2_1 = Z^2$.

Exercice 2 : quelle loi ?

Trois statistiques

On dispose de deux échantillons indépendants, de tailles $n_1 = 16$ et $n_2 = 21$, tirés de populations normales de même variance σ^2 ; $\overline{X}_1$ et S_1^2 sont la moyenne et la variance du premier. Donner la loi de :

1. $\dfrac{\overline{X}_1 - m_1}{S_1/4}$;
2. $15\,S_1^2/\sigma^2$;
3. S_1^2/S_2^2.

Exercice 2 : solution

La statistique dicte la loi

1. $\sqrt{16} = 4$: c'est le T de Student, à $n_1 - 1 = 15$ degrés de liberté.
2. $(n_1 - 1)S_1^2/\sigma^2 \sim \chi^2_{15}$.
3. Les variances étant égales, $S_1^2/S_2^2 \sim F_{15,\,20}$.

Ce qui fait l'hypothèse

Les trois résultats exigent des populations **normales**. Le troisième exige en plus l'égalité des variances : c'est précisément ce qu'un test de Fisher met à l'épreuve.

Exercice 3 : le prix de l'ignorance

Six relevés de prix

Un analyste relève le prix d'un produit dans 6 magasins tirés au hasard. Il calcule $\overline{x}$ et s, puis écrit que la vraie moyenne a 95 % de chances d'être dans $\overline{x} \pm 1{,}96\,s/\sqrt{6}$.

1. Quel quantile aurait-il dû utiliser ?
2. De combien son intervalle est-il trop étroit ?
3. Quelle est la vraie probabilité de couverture de son intervalle, sachant que $P(|T_5| \leq 1{,}96) = 0{,}893$?

Exercice 3 : solution

Une assurance surévaluée

1. σ est estimé, $n = 6$: Student à 5 degrés de liberté, $t_{0{,}975\,;5} = 2{,}571$.
2. $2{,}571/1{,}96 = 1{,}31$: l'intervalle correct est 31 % plus large.
3. Son intervalle ne couvre la vraie moyenne qu'avec la probabilité 0,893 : il annonce 5 % de risque et en prend près de 11 %.

La leçon

L'erreur ne se voit pas sur un seul échantillon : elle se paie en moyenne, sur toutes les études faites de la même façon.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Khi-deux, Student et Fisher décrivent des **statistiques d'échantillon**, jamais des populations.
2. **Khi-deux** : une somme de carrés ; positive, étirée à droite, d'espérance k.
3. **Student** apparaît dès qu'on remplace σ par S : queues plus épaisses, prix de l'ignorance — 31 % à cinq degrés, 4 % à trente.
4. Avec une population asymétrique, T penche : le total des queues reste proche de 5 %, leur répartition non.
5. **Fisher** apparaît dès qu'on compare deux variances : ANOVA et régression ; $t_k^2 = F_{1,\,k}$.
6. La statistique calculée détermine la loi à lire — c'est le seul enchaînement à retenir.

La suite

La boîte à outils est complète

Nous savons comment se comportent la moyenne, la proportion et la variance d'un échantillon, et quelles lois lire.
La troisième partie s'en sert pour répondre à la première question de l'inférence : **quelle valeur unique retenir pour le paramètre ?**

Trois candidats pour le salaire moyen

Pour estimer m, on pourrait retenir la moyenne 7 005,80, la médiane de l'échantillon, ou le milieu entre le plus petit et le plus grand salaire.
Lequel est le meilleur, et selon quel critère ? Le chapitre 5 commence par définir ce qu'est un **bon** estimateur.