

Statistique inférentielle

Introduction : La troisième face

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique inférentielle

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Paramètre ou statistique ?

Pour chacune des grandeurs suivantes, indiquer s'il s'agit d'un **paramètre** ou d'une **statistique**, et donner la notation appropriée (lettre grecque ou majuscule latine pour un paramètre, lettre latine minuscule pour une statistique) :

- (a) Le revenu moyen de **tous** les ménages marocains.
- (b) Le revenu moyen calculé sur un échantillon de 2 000 ménages interrogés par une enquête.
- (c) La proportion de chômeurs dans **l'ensemble** de la population active.
- (d) La proportion de chômeurs observée dans un sondage réalisé auprès de 1 000 actifs.

Exercice 2 — Corriger une confusion de vocabulaire

Un étudiant écrit dans sa copie : « L'enquête menée sur 80 entreprises du secteur textile révèle que le chiffre d'affaires moyen **des entreprises marocaines du secteur** est de 4,2 millions de dh, avec un écart-type **de la population** de 1,1 million de dh. »

- (a) Identifier précisément l'erreur commise dans cette phrase.
- (b) Réécrire la phrase correctement, en distinguant bien ce qui est **connu et calculé sur l'échantillon** de ce qui reste **inconnu dans la population**.
- (c) Cette erreur est-elle une simple maladresse de rédaction, ou traduit-elle une confusion conceptuelle plus profonde ? Justifier.

Exercice 3 — La statistique d'échantillon est une variable aléatoire

Un contrôle qualité mesure la proportion d'articles défectueux sur 5 échantillons différents de 100 articles, prélevés à 5 moments différents de la même journée de production : 3 %, 5 %, 2 %, 6 %, 4 %.

- (a) Ces cinq proportions sont-elles identiques ? Si le taux de défaut **réel** de la chaîne de production était resté rigoureusement constant tout au long de la journée, cela devrait-il surprendre ?
- (b) Calculer l'étendue de ces cinq proportions observées.
- (c) En quoi ce résultat illustre-t-il l'idée que la proportion d'échantillon F n'est pas un nombre fixe mais une **variable aléatoire**, possédant elle-même une loi, une espérance et un écart-type ?

2 Applications en sciences économiques

Exercice 4 — Pourquoi ne teste-t-on pas toutes les ampoules ?

Un fabricant d'ampoules souhaite connaître la durée de vie moyenne de sa production annuelle de 2 millions d'ampoules.

- (a) Pourquoi est-il **impossible** de mesurer la durée de vie de chaque ampoule produite pour en déduire la moyenne exacte de la population ?
- (b) Parmi les trois raisons usuelles justifiant le recours à un échantillon (le coût, le délai, la destruction), laquelle est ici la plus déterminante ?
- (c) Un actionnaire propose, pour « être sûr », de tester la moitié de la production. Expliquer en une phrase pourquoi cette proposition, bien qu'apparemment prudente, est absurde sur le plan économique.

Exercice 5 — Identifier le type de question inférentielle

Une chaîne de distribution se pose successivement les trois questions suivantes.

- (a) « Quel est, au mieux de nos informations, le panier moyen d'achat de nos clients ce mois-ci ? »
- (b) « Entre quelles deux valeurs peut-on affirmer, avec un risque d'erreur maîtrisé, que se situe le panier moyen réel de l'ensemble de la clientèle ? »
- (c) « Le nouveau programme de fidélité a-t-il réellement fait progresser le panier moyen par rapport à l'an dernier, ou l'écart observé pourrait-il n'être dû qu'au hasard de l'échantillonnage ? »

Associer chacune de ces trois questions à l'une des trois démarches du cours (estimation ponctuelle, intervalle de confiance, test d'hypothèse), et expliquer en une phrase ce qui les distingue toutes les trois, bien qu'elles reposent sur le même outil sous-jacent.

1 Exercices du chapitre

Correction — Exercice 1

- (a) **Paramètre** : c'est une caractéristique de l'ensemble de la population marocaine, fixe (à un instant donné) et inconnue. Notation : m (ou μ).
- (b) **Statistique** : elle est calculée sur un échantillon de 2 000 ménages, donc connue mais dépendante de l'échantillon tiré. Notation : $\bar{x}$.
- (c) **Paramètre** : caractéristique de l'ensemble de la population active. Notation : p .
- (d) **Statistique** : calculée sur l'échantillon des 1 000 actifs interrogés. Notation : f .

Correction — Exercice 2

- (a) L'erreur est d'attribuer à **l'ensemble** des entreprises marocaines du secteur (la population, dont les paramètres sont **inconnus**) des valeurs qui n'ont en réalité été calculées que sur les 80 entreprises **effectivement interrogées** (l'échantillon). La phrase confond une **statistique connue** avec un **paramètre inconnu**.
- (b) Version correcte : « L'enquête menée sur un **échantillon** de 80 entreprises du secteur textile donne un chiffre d'affaires **moyen d'échantillon** $\bar{x} = 4,2$ millions de dh, avec un **écart-type d'échantillon** $s = 1,1$ million de dh. Le chiffre d'affaires moyen m de l'ensemble des entreprises marocaines du secteur reste, lui, **inconnu**. »
- (c) C'est bien davantage qu'une maladresse de rédaction : c'est **l'erreur fondamentale** du cours, signalée explicitement dans l'introduction. Elle traduit une confusion conceptuelle entre ce qui est **fixe et inconnu** (le paramètre de la population) et ce qui est **connu mais variable d'un échantillon à l'autre** (la statistique) — une confusion qui, si elle passe inaperçue, conduit à présenter un résultat d'échantillon comme une certitude sur la population entière, sans jamais mentionner l'incertitude qui l'accompagne.

Correction — Exercice 3

- (a) Non, les cinq proportions (3 %, 5 %, 2 %, 6 %, 4 %) ne sont **pas identiques**. Cela ne devrait **pas surprendre** même si le taux réel de défaut de la chaîne était resté parfaitement constant : le **hasard du tirage** de chaque échantillon de 100 articles suffit à expliquer ces variations, sans qu'il soit besoin de supposer une quelconque dérive réelle du processus de production.
- (b) Étendue = $6 \% - 2 \% = 4$ points de pourcentage.
- (c) Ce résultat illustre exactement l'idée centrale du cours : la proportion observée sur un échantillon, notée F , n'est **pas un nombre unique et fixe**, mais une grandeur qui **change d'un échantillon à l'autre**, même lorsque rien ne change dans la population sous-jacente. C'est précisément parce que F varie de façon imprévisible, mais selon des règles qu'on peut modéliser, qu'on la traite comme une **variable aléatoire**, dotée d'une loi de probabilité, d'une espérance et d'un écart-type — c'est tout l'objet des chapitres suivants du cours.

2 Applications en sciences économiques

Correction — Exercice 4

- (a) Mesurer la durée de vie d'une ampoule est un test **destructif** : l'ampoule est allumée jusqu'à ce qu'elle grille. Tester les 2 millions d'ampoules produites reviendrait donc à **détruire l'intégralité** de la production, ne laissant plus rien à vendre.
- (b) C'est ici la **destruction** qui est la raison la plus déterminante (bien que le coût et le délai jouent également un rôle) : contrairement à un sondage ou un contrôle non destructif, il est ici **physiquement impossible**, et non simplement coûteux, de recenser la population entière tout en conservant un produit à vendre.

(c) Tester la moitié de la production détruirait la moitié du chiffre d'affaires potentiel de l'entreprise pour un gain de précision statistique généralement **marginal** par rapport à un échantillon de taille raisonnable (quelques centaines d'ampoules suffisent, comme le montreront les chapitres sur l'intervalle de confiance) : le coût de cette « prudence » est sans commune mesure avec le bénéfice informatif qu'elle apporterait.

Correction — Exercice 5

(a) **Estimation ponctuelle** : on cherche une valeur unique, la meilleure estimation disponible du panier moyen réel.

(b) **Intervalle de confiance** : on cherche un encadrement du paramètre inconnu, assorti d'un niveau de confiance.

(c) **Test d'hypothèse** : on cherche à trancher entre deux affirmations concurrentes (le programme a un effet réel / l'écart observé n'est que du hasard d'échantillonnage).

Ce qui distingue ces trois démarches, c'est la **nature de la question posée** (une valeur ponctuelle ; une fourchette assortie d'un risque d'erreur ; une décision entre deux hypothèses) — mais toutes trois s'appuient sur le **même objet sous-jacent**, la loi de la statistique d'échantillonnage (ici, celle du panier moyen $\bar{X}$), qui seule permet de quantifier à quel point un résultat d'échantillon est ou non représentatif de la population entière.