

Statistique inférentielle

Introduction : La troisième face

Jaouad Madkour

24 septembre 2026

Plan de l'introduction

Prérequis	1
Ce que ce cours suppose acquis	1
Ce que le cours établit lui-même	2
Où nous sommes	2
Deux cours derrière nous, et une question restée sans réponse	2
Les trois faces d'une même discipline	2
Ce que la figure établit	3
Le vocabulaire	3
Paramètre et statistique	3
Le mot le plus important est « aléatoire »	3
La démarche	4
Les six étapes, une fois pour toutes	4
Les trois questions que l'on saura traiter	4
Ce que cela change en gestion	4
Le fil rouge du cours	5
Les mêmes cinq cents salariés	5
L'échantillon de travail	5
Ce qu'il faut retenir	6
Le résumé du chapitre	6

Prérequis

Ce que ce cours suppose acquis

Le cours qui précède

Probabilités, dont ce cours utilise en permanence les lois et le théorème central limite.

Les notions mobilisées

Variable aléatoire, espérance, variance. Les lois **normale**, de **Student**, du **khi-deux** et de **Fisher**. Le théorème central limite, qui justifie à lui seul la moitié du cours.

Ce que le cours établit lui-même

Repris depuis le début

Échantillonnage, estimation, intervalle de confiance et test d'hypothèse sont construits ici. **Le cours ferme la boucle du bloc statistique** : la descriptive décrivait un échantillon, les probabilités modélisaient le hasard, l'inférence conclut de l'un à l'autre.

Où nous sommes

Deux cours derrière nous, et une question restée sans réponse

Ce que nous savons faire

La **statistique descriptive** a résumé cinq cents salaires : moyenne 7 158,26, écart-type 2 598,10, une droite qui relie salaire et ancienneté.


Le **calcul des probabilités** a construit le langage du hasard : lois, espérance, variance, et deux théorèmes de convergence.

Ce que nous ne savons pas encore faire

Un institut interroge 50 salariés et trouve une moyenne de 7 005,80 dirhams.

Que peut-il en dire de la **population entière** ? Rien, pour l'instant — et c'est précisément l'objet de ce cours.

Les trois faces d'une même discipline



Les trois cours ne sont pas trois matières : ce sont trois sens de circulation entre les deux mêmes boîtes.

La *descriptive* reste dans l'échantillon et le résumé. Les *probabilités* descendent de la population vers l'échantillon : le modèle est donné, on en calcule les conséquences. L'*inférence* remonte en sens inverse, et c'est le seul trajet incertain des trois — d'où la nécessité de mesurer cette incertitude.

L'*économétrie* prolongera la flèche orange : au lieu d'un seul paramètre m , elle remontera vers toute une relation entre variables.

Ce que la figure établit

Deux boîtes, trois trajets

Discipline	Trajet	Nature
Statistique descriptive	dans l'échantillon	résumer
Calcul des probabilités	population → échantillon	déduction
Statistique inférentielle	échantillon → population	induction

Le seul trajet incertain est le nôtre

Descendre est sûr : si l'on sait que $p = 0,04$, on calcule sans risque la probabilité de 14 défauts.

Remonter ne l'est pas : d'un échantillon, plusieurs populations différentes auraient pu naître.

L'inférence ne supprime jamais cette incertitude — elle la mesure. C'est là toute sa valeur.

Le vocabulaire

Paramètre et statistique

Deux mots qu'il ne faut jamais confondre

Un **paramètre** décrit la population. Il est **fixe** et **inconnu** : m, σ, p .

Une **statistique** se calcule sur l'échantillon. Elle est **connue** et **aléatoire** : $\bar{x}, s, f$.

La convention de notation, à respecter dès maintenant

Lettres **grecques** ou majuscules latines pour les paramètres ; lettres **latines minuscules** pour les statistiques.

$$m \leftrightarrow \bar{x} \quad \sigma \leftrightarrow s \quad p \leftrightarrow f \quad \beta_1 \leftrightarrow \hat{\beta}_1$$

Une copie qui écrit « la moyenne de la population vaut 7 005,80 » commet, en une phrase, l'erreur fondamentale du cours.

Le mot le plus important est « aléatoire »

Sur nos données

Prélevons trois échantillons de 40 salariés dans les mêmes 500. Les moyennes obtenues sont

$$6\,863 \quad 7\,001 \quad 7\,895$$

Trois nombres différents, calculés sur la même population, par la même méthode.


La conséquence

$\bar{X}$ n'est pas un nombre : c'est une **variable aléatoire**, avec une loi, une espérance et un écart-type.

Toute la statistique inférentielle consiste à connaître cette loi, puis à s'en servir.

La démarche

Les six étapes, une fois pour toutes



La quatrième étape est la seule qui demande un cours entier de probabilités, et c'est elle qui rend l'inférence possible : sans connaître la loi de $\bar{X}$, un écart entre 7 005,80 et une valeur annoncée ne voudrait rien dire.

Les six étapes ne changent jamais. Seule change la statistique calculée à l'étape 3 — une moyenne, une proportion, une variance, une pente de régression — et donc la loi de l'étape 4.

Les trois questions que l'on saura traiter

Le programme du cours

Question	Réponse	Chapitres
Quelle valeur retenir ?	estimation ponctuelle	6 à 8
Avec quelle précision ?	intervalle de confiance	9 à 12
Cette affirmation tient-elle ?	test d'hypothèse	13 à 19

Trois questions, un seul outil

Les trois reposent sur la même chose : la **loi de la statistique calculée**.

Estimer, encadrer et tester ne sont pas trois méthodes ; ce sont trois façons de lire une même distribution d'échantillonnage.

Ce que cela change en gestion

Trois décisions, trois inférences

- Un **contrôle qualité** ne teste pas tous les articles : il conclut sur le lot à partir de quelques pièces.
- Un **sondage** interroge mille personnes et annonce un résultat national.
- Une **étude de marché** teste un produit sur un quartier et décide d'un lancement.

Dans les trois cas, la décision porte sur ce qu'on n'a **pas** observé.

Pourquoi on ne mesure pas tout

Trois raisons, et elles suffisent : le **coût**, le **délai**, et la **destruction** — on ne peut pas tester la durée de vie de toutes les ampoules produites, il n'en resterait aucune à vendre.

Quand un recensement complet est possible et peu coûteux, l'inférence est inutile. Elle n'est pas une commodité intellectuelle : elle est une **nécessité économique**.

Le fil rouge du cours

Les mêmes cinq cents salariés

Le jeu de données

Le fichier `salaires.csv` du cours de statistique descriptive : 500 salariés, six colonnes — identifiant, salaire, ancienneté, diplôme, région, sexe.

Grandeur	Valeur
Effectif N	500
Moyenne m	7 158,26
Écart-type σ	2 598,10

Un dispositif inhabituel, et volontaire

Ces cinq cents salariés seront traités comme **la population**, dont nous connaissons donc les paramètres.

Nous y tirerons des échantillons, nous ferons semblant d'ignorer m , et nous **vérifierons** à chaque étape que la méthode retrouve bien la vraie valeur. C'est la seule façon de voir fonctionner l'inférence de l'intérieur.

L'échantillon de travail

Un salarié sur dix

Nous retiendrons les individus dont l'identifiant est un multiple de dix : $n = 50$ observations.

Grandeur	Symbole	Valeur
Moyenne d'échantillon	$\bar{x}$	7 005,80
Écart-type corrigé	s	2 250,98
Erreur-type	$s/\sqrt{n}$	318,34

Un choix reproductible

Ce tirage ne dépend d'aucune graine aléatoire : n'importe quel étudiant, sous R, sous Python ou sur tableur, retrouvera exactement ces trois nombres.

C'est une exigence de méthode : **un résultat statistique qu'on ne peut pas reproduire n'est pas un résultat**.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. La descriptive résume l'échantillon ; les probabilités descendent vers lui ; l'inférence **remonte** vers la population.
2. Le trajet inférentiel est le seul **incertain** — et le cours sert à mesurer cette incertitude.
3. Un **paramètre** est fixe et inconnu ; une **statistique** est connue et aléatoire.
4. $\bar{X}$ change d'un échantillon à l'autre : c'est une **variable aléatoire**.
5. Trois questions — estimer, encadrer, tester — reposent sur un seul objet : la **distribution d'échantillonnage**.
6. Le fil rouge : 500 salariés de moyenne 7 158,26, dont on tire 50 individus de moyenne 7 005,80.

La suite

Tout ce qui précède suppose une chose que nous n'avons pas encore examinée : que l'échantillon **représente** la population.

Cette condition n'est pas automatique, et aucune formule ne la remplace. Le chapitre 1 lui est entièrement consacré.