

Statistique inférentielle

Chapitre 18 : L'analyse de la variance

Jaouad Madkour

19 août 2026

Faculté d'Économie et de Gestion de Tanger

Pourquoi un outil de plus

La décomposition

L'application

Ce qu'il faut retenir

Pourquoi un outil de plus



Trois groupes, trois comparaisons

Bac contre Bac+2, Bac+2 contre Bac+5, Bac contre Bac+5. Trois tests à 5 % chacun.

$$P(\text{au moins un rejet à tort}) = 1 - (0,95)^3 = 0,143$$

Le risque réel n'est plus 5 % mais 14 % – et il monte à 40 % avec cinq groupes.

La solution


Un **test unique**, portant sur les trois moyennes à la fois :

$$H_0 : m_1 = m_2 = m_3 \quad H_1 : \text{au moins une diffère}$$

Le risque annoncé redevient le risque réel.

La décomposition

Ce que l'ANOVA regarde



La décomposition, en une ligne

$$\underbrace{SCT}_{3\,375\,061} = \underbrace{SCE}_{869\,848} + \underbrace{SCR}_{2\,505\,213}$$

(en milliers)

$$\eta^2 = \frac{869\,848}{3\,375\,061} = 0,258$$

Le diplôme explique 25,8 % de la dispersion des salaires. Les trois quarts restants viennent d'ailleurs.

C'est déjà le R^2 de la régression — la même quantité, sous un autre nom, et le chapitre 20 le montrera.

L'ANOVA n'est pas une méthode de plus : c'est la décomposition de la variance du cours de descriptive, transformée en test.

La décomposition, déjà vue en descriptive

$$\underbrace{\text{SCT}}_{\text{variation totale}} = \underbrace{\text{SCE}}_{\text{entre les groupes}} + \underbrace{\text{SCR}}_{\text{à l'intérieur}}$$

$$\text{SCT} = \sum_{i,j} (x_{ij} - \bar{x})^2 \quad \text{SCE} = \sum_i n_i (\bar{x}_i - \bar{x})^2 \quad \text{SCR} = \sum_{i,j} (x_{ij} - \bar{x}_i)^2$$

Le nom du test est trompeur

On appelle cela « analyse de la variance », et l'on y compare pourtant des **moyennes**.

La raison est dans la figure : si les moyennes de groupe s'écartaient peu, la dispersion entre elles serait faible devant la dispersion interne. **C'est en comparant deux dispersions qu'on juge des moyennes.**

La statistique de test

$$F = \frac{SCE/(k-1)}{SCR/(n-k)} \sim \text{Fisher à } (k-1) \text{ et } (n-k) \text{ degrés de liberté}$$

où k est le nombre de groupes et n l'effectif total.

Pourquoi cette forme

On divise chaque somme de carrés par son nombre de degrés de liberté — la règle du chapitre 4, appliquée deux fois.

Sous H_0 , les deux quantités estiment la même variance résiduelle : leur rapport vaut 1 en moyenne. Un F nettement supérieur à 1 signale que les moyennes diffèrent.

L'application


Le diplôme explique-t-il le salaire

Les trois groupes

Diplôme	n_i	Moyenne
Bac	219	6 058,90
Bac+2	174	7 080,75
Bac+5	107	9 534,39
Ensemble	500	7 158,26

Le tableau d'analyse de la variance

Source	Somme de carrés	ddl	Carré moyen
Entre (SCE)	869 847 811	2	434 923 906
Résiduelle (SCR)	2 505 213 175	497	5 040 671
Totale	3 375 060 986	499	



Lire la statistique F

$$F = \frac{SCE/(k-1)}{SCR/(n-k)} = \frac{434\,924}{5\,041} = 86,28$$

Numérateur : la dispersion *entre* les diplômes. Dénominateur : la dispersion *résiduelle*.

Sous H_0 , les trois moyennes sont égales et le rapport vaut 1 en moyenne. Ici il vaut 86.

$p < 0,0001$. Le diplôme a un effet, et le doute n'est pas permis.

Mais l'ANOVA s'arrête là : elle dit que *les moyennes diffèrent*, pas *lesquelles*. Il faut ensuite des comparaisons deux à deux.

Le résultat

$$F = \frac{434\,923\,906}{5\,040\,671} = 86,28 \quad \text{contre un seuil de } 3,01$$

$p < 0,0001$: on rejette H_0 . Les salaires moyens diffèrent selon le diplôme.

Le rapport de corrélation, et ce qu'il ajoute

$$\eta^2 = \frac{\text{SCE}}{\text{SCT}} = \frac{869\,848}{3\,375\,061} = 0,258$$

Le diplôme explique 25,8 % de la dispersion des salaires. **Les trois quarts viennent d'ailleurs** — ancienneté, poste, performance, hasard.

Le test dit que l'effet est réel; η^2 dit qu'il est important sans être déterminant. Les deux sont nécessaires.

Elle rejette en bloc

« Au moins une moyenne diffère » : elle ne dit pas laquelle, ni de combien.

Ici la lecture des trois moyennes suffit — l'écart Bac / Bac+5 dépasse trois mille dirhams. Sur des cas moins nets, il faut des **comparaisons multiples** avec un seuil corrigé.

Les conditions de validité

1. Échantillons **indépendants**.
2. Population **normale** dans chaque groupe — ou effectifs suffisants.
3. Variances **comparables** entre groupes.

La troisième est la plus fragile; l'ANOVA la supporte assez bien si les effectifs sont équilibrés, mal s'ils ne le sont pas.

Ce qu'il faut retenir

Six points

1. Comparer k groupes deux à deux **gonfle le risque réel** : 14 % pour trois groupes, 40 % pour cinq.
2. L'ANOVA teste toutes les moyennes en **un seul test**.
3. $SCT = SCE + SCR$: la décomposition du cours de statistique descriptive.
4. F compare deux dispersions pour juger des **moyennes**; sous H_0 il vaut 1 en moyenne.
5. Sur nos données : $F = 86,28$, $p < 0,0001$, et $\eta^2 = 0,258$.
6. L'ANOVA rejette **en bloc** : elle ne désigne pas les groupes responsables.

La suite

Il reste un type de données non traité : les **effectifs de tableau**, quand les deux variables sont qualitatives.

Le chapitre 19 y consacre le dernier test du cours — celui qui ferme la boucle avec le tableau de contingence de la statistique descriptive.