Statistique inférentielle

Chapitre 1 : Échantillonner

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 22 octobre 2026

Plan du chapitre

La condition de tout le cours

Du tirage au modèle

Avec ou sans remise

Les plans de sondage, en bref

Ce qui ruine un échantillon

S'entraîner

Ce qu'il faut retenir

La condition de tout le cours

Ce que les vingt chapitres suivants supposent

Une hypothèse unique

Toutes les formules à venir — intervalles, tests, régressions — reposent sur une hypothèse unique : l'échantillon a été tiré **au hasard** dans la population visée.

Si elle est fausse, les formules continuent de fonctionner. Elles donnent des résultats précis, présentables, publiables. Et faux.

La condition, énoncée

Chaque individu de la population doit avoir une probabilité **connue** et **non nulle** d'être sélectionné.

Connue : sinon on ne peut pas calculer. *Non nulle* : sinon une partie de la population est invisible, quoi qu'on fasse.

Deux points de vue sur le même tirage

Le cours d'**Échantillonnage** part de la population, finie et réelle : il étudie les **plans de sondage** — aléatoire simple, stratifié, par grappes — et leurs estimateurs.

Ce cours-ci part du **modèle** : il traite l'échantillon comme une suite de variables aléatoires, et en tire des intervalles et des tests.

Ce que ce chapitre fait

Il construit le pont entre les deux : comment un tirage au hasard devient le modèle « $X_1, \dots, X_n$ indépendantes de même loi », à quelle condition ce modèle est exact, et ce qui le ruine.

Les plans de sondage n'y sont que résumés ; leur étude complète est l'objet du cours d'Échantillonnage.

Du tirage au modèle

La variable X

Tirons **un** salarié au hasard parmi les 500, chacun avec la probabilité $1/500$, et notons X son salaire.

X est une variable aléatoire dont la loi est exactement la **distribution des salaires** de la population : pour tout seuil a, $P(X \leq a)$ est la proportion de salariés gagnant au plus a.

Sur nos 500 salariés

Événement	Probabilité
$X \leq 5\,000$	$99/500 = 0{,}198$
$X \leq 6\,000$	$189/500 = 0{,}378$
$X > 10\,000$	$67/500 = 0{,}134$

Et $E(X) = m = 7\,158{,}26$, $\sigma(X) = \sigma = 2\,598{,}10$: les paramètres de la population sont l'espérance et l'écart-type de X.

Le modèle de tout le cours

Un **échantillon aléatoire simple** de taille n est une suite $X_1, X_2, \ldots, X_n$ de variables aléatoires

1. **indépendantes** entre elles,
2. de **même loi** que X : même espérance m, même écart-type σ.

On dit aussi : un échantillon **i.i.d.**, pour « indépendantes et identiquement distribuées ».

Ce que le modèle exprime

Même loi : chaque observation est un tirage dans la **même** population — personne n'est favorisé.

Indépendance : le résultat d'un tirage ne renseigne pas sur le suivant — on ne choisit pas le deuxième salarié en fonction du premier.

Deux objets distincts

Avant le tirage	Après le tirage
$X_1, \dots, X_{50}$, variables aléatoires	$x_1, \dots, x_{50}$, cinquante nombres
$\overline{X} = \frac{1}{50} \sum X_i$, aléatoire	$\overline{x} = 7\,005{,}80$, un nombre
on peut calculer $E(\overline{X})$, $V(\overline{X})$	on ne peut que le comparer

Notre échantillon fil rouge

Les cinquante salaires des identifiants $10, 20, \dots, 500$ sont **une** réalisation $(x_1, \dots, x_{50})$ du vecteur $(X_1, \dots, X_{50})$.

Les dix échantillons systématiques de l'introduction en sont dix réalisations. Le modèle décrit la loi commune de toutes celles qui auraient pu sortir.

Les deux résultats qui suivent du modèle

Par linéarité de l'espérance, puis par indépendance :

$$E(\overline{X}) = \frac{1}{n}\sum_{i=1}^{n} E(X_i) = m \qquad V(\overline{X}) = \frac{1}{n^2}\sum_{i=1}^{n} V(X_i) = \frac{\sigma^2}{n}$$

La première égalité n'utilise que *même loi* ; la seconde exige *indépendance*.

Sur le fil rouge

Avec $\sigma = 2\,598{,}10$ et $n = 50$:

$$\sigma(\overline{X}) = \frac{2\,598{,}10}{\sqrt{50}} = \frac{2\,598{,}10}{7{,}071} = 367{,}4 \text{ dirhams}$$

Une moyenne d'échantillon s'écarte typiquement de m de quelques centaines de dirhams. Le chapitre 2 en fait la loi complète.

Avec ou sans remise

Le modèle est exact avec remise

Deux façons de tirer cinquante salariés

Avec remise : on tire un salarié, on note son salaire, on le remet dans l'urne. Les tirages sont indépendants et de même loi : le modèle i.i.d. est **exact**.

Sans remise : un salarié tiré ne peut plus l'être. Chaque X_i garde la même loi que X, mais les tirages ne sont plus **indépendants**.

Pourquoi l'indépendance se perd

Si le premier salarié tiré est le mieux payé de l'entreprise, il manque aux tirages suivants : le deuxième salaire a une espérance légèrement plus faible.

L'effet est minuscule quand on tire peu dans une grande population, et il devient sensible quand on tire une part importante de la population.

La variance sans remise

Pour un tirage sans remise de n individus parmi N :

$$V(\overline{X}) = \frac{\sigma^2}{n} \times \frac{N-n}{N-1}$$

Le facteur $(N-n)/(N-1) \approx 1-f$, où $f = n/N$ est le **taux de sondage**.

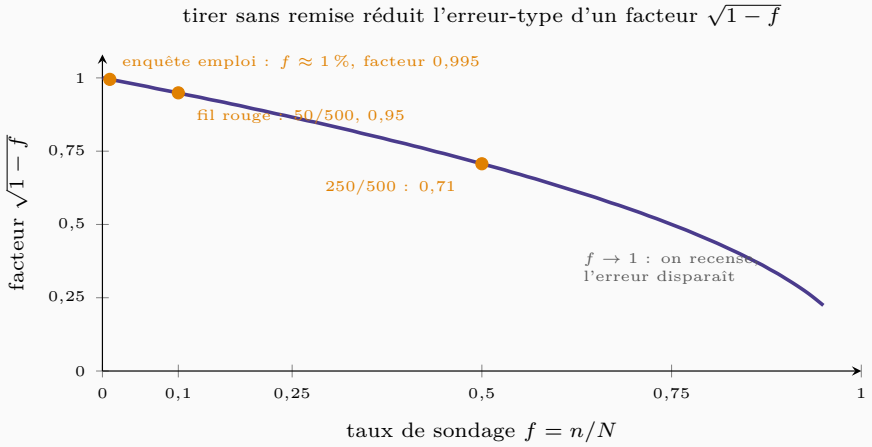
Sur le fil rouge

$N = 500$, $n = 50$: $(500-50)/499 = 0{,}902$, et $\sqrt{0{,}902} = 0{,}950$.

$$\sigma(\overline{X}) = 367{,}4 \times 0{,}950 = 348{,}9 \text{ dirhams}$$

C'est bien la dispersion des dix moyennes systématiques de l'introduction : 346.

Le facteur selon le taux de sondage



La règle pratique

Situation	n	N	$f = n/N$	$\sqrt{1-f}$
Enquête emploi	$90\,000$	$9{,}3$ M	$1\,\%$	$0{,}995$
Fil rouge	50	500	$10\,\%$	$0{,}95$
La moitié	250	500	$50\,\%$	$0{,}71$

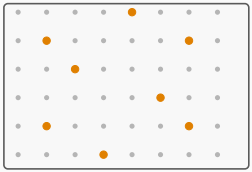
Ce que fait le reste du cours

On néglige le facteur quand f est inférieur à 5 ou $10\,\%$: c'est le cas de presque toutes les enquêtes. Le cours raisonne donc **comme si** les tirages étaient indépendants.

Ce n'est pas la taille de la population qui compte, mais la **part** qu'on en tire : $1\,000$ personnes informent aussi bien sur le Maroc que sur une ville.

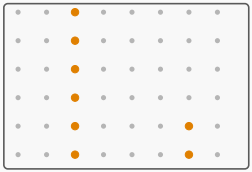
Les plans de sondage, en bref

Quatre façons de tirer



Aléatoire simple

chacun a la même chance ; c'est la référence



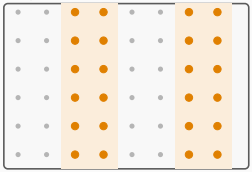
Systématique

un individu tous les k ; simple, mais dangereux si les données sont ordonnées



Stratifié

on découpe en groupes homogènes et on tire dans chacun ; *plus précis*



Par grappes

on tire des groupes entiers ; *moins cher, moins précis*

Ce qui compte n'est pas la taille, c'est le tirage.

Un échantillon de mille personnes bien tiré vaut infiniment mieux qu'un échantillon de cent mille volontaires.

La seule condition de tout ce cours : chaque individu de la population doit avoir une probabilité connue et non nulle d'être tiré.

Sans elle, aucune des formules des chapitres suivants n'a de sens — et aucune quantité de données ne rattrape un tirage biaisé.

Quatre plans, une seule question : la précision

Plan	Idée	Précision, à n égal
Aléatoire simple	tous la même chance	la référence
Systématique	un sur k, départ au hasard	proche de la référence
Stratifié	tirer dans chaque groupe	meilleure
Par grappes	tirer des groupes entiers	moins bonne

Ce que le cours retient

Les formules de ce cours sont celles de l'**aléatoire simple**. Pour les autres plans, elles changent ; le cours d'Échantillonnage établit les bonnes.

La logique, elle, ne change jamais : une statistique, sa loi, un risque accepté.

Tirer 50 salariés en respectant les diplômes

Les Bac, Bac+2 et Bac+5 représentent $43{,}8$, $34{,}8$ et $21{,}4\,\%$ des salariés. Un tirage stratifié proportionnel prend 22, 17 et 11 salariés dans chaque groupe.

Il supprime la part de variance due aux écarts entre diplômes ($\eta^2 = 0{,}258$) :

Plan, $n = 50$	Écart-type de la moyenne
Aléatoire simple	349 dh
Stratifié par diplôme	301 dh

Un gain de précision gratuit

La variance est multipliée par $0{,}746$: le tirage stratifié de 50 salariés vaut un aléatoire simple de 67.

Il suffit de connaître le diplôme de chacun **avant** de tirer — une information que le fichier du personnel contient déjà.

Un sur dix, sur notre fichier

Notre fil rouge est systématique. Il équivaut à un aléatoire simple si l'ordre du fichier est **sans rapport** avec le salaire.

Ici, la corrélation entre l'identifiant et le salaire vaut $-0{,}09$: l'ordre est presque neutre, et les dix moyennes systématiques ont bien la dispersion d'un aléatoire simple.

Un exemple qui a réellement coûté cher

Un contrôle de production prélève une pièce toutes les heures. La machine comporte quatre têtes qui tournent à raison d'une par quart d'heure.

Le prélèvement horaire retombe toujours sur la **même tête**. Trois têtes sur quatre n'ont jamais été contrôlées, et l'échantillon paraît pourtant parfaitement régulier.

Ce que font réellement les instituts

Presque jamais un tirage aléatoire simple : il exige une liste complète de la population, que l'on n'a presque jamais.

Le plan courant combine les deux : **stratification** par région et milieu, puis **grappes** géographiques à l'intérieur — c'est le principe des grandes enquêtes auprès des ménages.

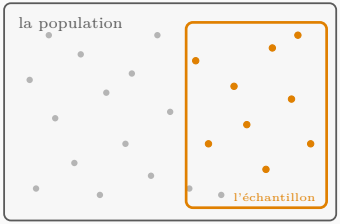
Ce que ce cours suppose

Nous travaillerons systématiquement en **aléatoire simple**. C'est le cadre dans lequel toutes les formules classiques sont exactes, et c'est celui des examens.

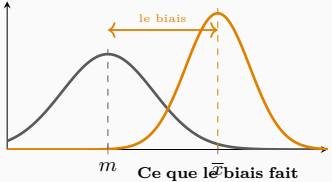
Un plan de sondage se conçoit avec un statisticien **avant** la collecte, jamais après.

Ce qui ruine un échantillon

Le biais de sélection



Un échantillon biaisé
il ne couvre qu'une partie de la population, et rien ne le signale



Ce que le biais fait
il déplace le centre — et *aucune* augmentation de n ne le corrige

Le biais de sélection est la seule erreur que les mathématiques ne rattrapent pas.

L'intervalle de confiance se resserre quand n grandit — autour de la mauvaise valeur. Un échantillon biaisé de cent mille personnes est *plus* trompeur qu'un échantillon biaisé de mille : il donne une fausse précision.

Les trois sources à connaître : le champ mal défini (on n'interroge pas ceux qu'on prétend décrire), l'auto-sélection (ceux qui répondent diffèrent de ceux qui ne répondent pas), et la survie (on n'observe que ce qui a subsisté).

Trois façons de rater sa population

Les sources classiques

1. **Champ mal défini** : on n'interroge pas ceux dont on prétend parler.
2. **Auto-sélection** : ceux qui répondent diffèrent systématiquement de ceux qui se taisent.
3. **Biais de survie** : on n'observe que ce qui a subsisté.

L'échec fondateur, en 1936

Un magazine américain interroge par courrier des millions de personnes ; environ **deux millions quatre cent mille** répondent, et il annonce la défaite de Roosevelt. Celui-ci est élu avec environ $61\,\%$ des voix.

Le fichier venait des annuaires du téléphone et des propriétaires d'automobile : en pleine crise, une population plus aisée que l'électorat. Deux millions de réponses biaisées valaient moins que quelques milliers bien tirées.

Les mieux payés répondent davantage

Supposons qu'une enquête sur les salaires obtienne la réponse de $80\,\%$ des salariés au-dessus de la médiane ($6\,770$ dh), mais de $40\,\%$ seulement en dessous.

Le taux de réponse global est de $60\,\%$, et la moyenne des répondants vaut

$$\frac{\sum \pi_k \, x_k}{\sum \pi_k} = 7\,806{,}9 \text{ dirhams, pour } m = 7\,158{,}3$$

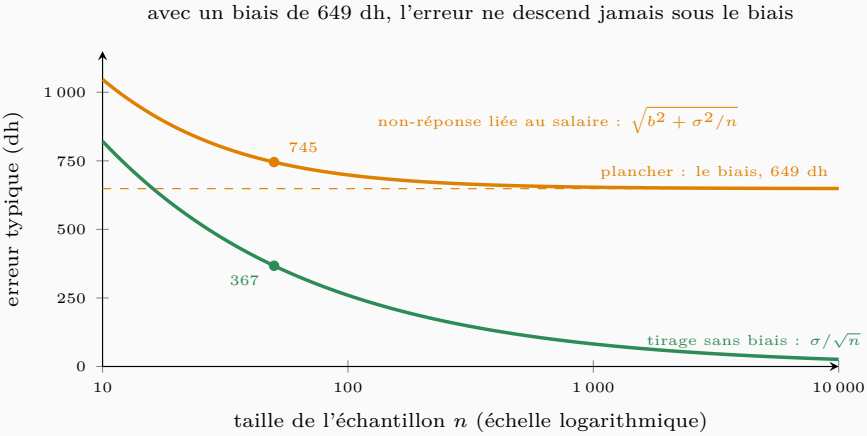
Le biais

Le **biais** est l'écart entre ce que la méthode vise en moyenne et la vraie valeur :

$$b = 7\,806{,}9 - 7\,158{,}3 = 648{,}6 \text{ dirhams}$$

Il ne dépend pas de n : avec 50 comme avec $50\,000$ répondants, la moyenne obtenue se centre sur $7\,807$, pas sur $7\,158$.

Ce que le nombre ne rattrape pas



L'erreur typique, avec et sans biais

L'erreur typique combine les deux : $\sqrt{b^2 + \sigma^2/n}$ (chapitre 6).

n	Sans biais : $\sigma/\sqrt{n}$	Avec le biais de 649 dh
50	367	745
500	116	659
$5\,000$	37	650

La leçon centrale du chapitre

Augmenter n réduit la **dispersion** — l'intervalle se resserre. Cela ne touche **pas** le biais.

Un grand échantillon biaisé est donc **plus dangereux** qu'un petit : il donne une fausse impression de précision autour d'une valeur fausse.

Dix mille avis ne font pas un échantillon

Les notes des plateformes commerciales reposent sur les clients qui prennent la peine d'écrire — souvent les très satisfaits et les très mécontents. Les autres, la majorité, ne disent rien.

Aucun volume de données ne corrige cette asymétrie : dix mille avis auto-sélectionnés restent dix mille avis auto-sélectionnés.

Le critère

La question n'est jamais « combien d'observations ? » mais « **qui** a pu être observé, et avec quelle probabilité ? ».

Si cette probabilité dépend de la variable étudiée — le salaire, la satisfaction — le biais est inévitable.

Trois autres, à surveiller

Biais	Mécanisme
Non-réponse	ceux qui refusent diffèrent des autres
Formulation	la question oriente la réponse
Déclaration	le répondant embellit ou dissimule

Ils sont hors de portée du calcul

Aucune de ces trois erreurs n'apparaît dans les formules du cours, et aucune n'est mesurée par la marge d'erreur publiée.

L'erreur statistique est souvent la plus petite erreur d'une enquête. C'est pourtant la seule que l'on annonce, parce que c'est la seule que l'on sait chiffrer.

S’entraîner

Le facteur de correction

Une banque compte $N = 1\,000$ clients ; l'écart-type de leur solde moyen mensuel est $\sigma = 4\,000$ dirhams. On tire $n = 100$ clients.

1. Calculer l'écart-type de $\overline{X}$ pour un tirage avec remise.
2. Même question sans remise. De combien l'erreur-type diminue-t-elle ?
3. Que devient le facteur si la banque compte $100\,000$ clients ? Conclure.

Ce qui compte est la part tirée

1. Avec remise : $\sigma/\sqrt{n} = 4\,000/10 = 400$ dirhams.
2. Sans remise : $(1\,000 - 100)/999 = 0{,}901$, $\sqrt{0{,}901} = 0{,}949$, d'où $400 \times 0{,}949 = 380$ dirhams : $5\,\%$ de moins.
3. $(100\,000 - 100)/99\,999 = 0{,}999$: le facteur vaut pratiquement 1, et l'erreur-type reste 400 dirhams.

À n fixé, l'erreur-type ne dépend presque pas de la taille de la population dès que celle-ci est grande. C'est ce qui rend les sondages nationaux possibles.

La satisfaction des clients

Une agence de voyages compte $2\,000$ clients, dont $1\,400$ satisfaits ($70\,\%$). Elle envoie un questionnaire à tous. Les satisfaits répondent avec la probabilité $0{,}5$, les mécontents avec la probabilité $0{,}2$.

1. Combien de réponses peut-on attendre, et de quel type ?
2. Quelle proportion de satisfaits l'agence observera-t-elle parmi les répondants ? Quel est le biais ?
3. L'agence relance tous les clients et double ainsi chaque taux de réponse. Le biais diminue-t-il ?

Le biais vient du rapport des taux, pas du nombre

1. $1\,400 \times 0{,}5 = 700$ satisfaits et $600 \times 0{,}2 = 120$ mécontents : 820 réponses.
2. $700/820 = 0{,}854$, soit $85{,}4\,\%$ au lieu de $70\,\%$: un biais de $15{,}4$ points.
3. Avec des taux 1 et $0{,}4$: $1\,400$ satisfaits et 240 mécontents, d'où $1\,400/1\,640 = 0{,}854$.

   Le biais est identique : les taux restent dans le rapport $2{,}5$, et c'est ce rapport qui déforme le résultat.

Ce que la relance aurait dû viser

Une relance utile cible les **non-répondants** du groupe qui répond le moins, pour rapprocher les taux. Doubler les deux ne fait que multiplier les réponses biaisées.

Exercice 3 : quel biais ?

Quatre enquêtes

Pour chaque cas, nommer le biais principal et dire dans quel sens il joue.

a. Pour estimer le revenu des ménages d'une ville, on interroge les clients d'un centre commercial haut de gamme.
b. Pour mesurer la rentabilité des fonds d'investissement, on étudie les fonds encore ouverts aujourd'hui.
c. Pour mesurer la consommation d'alcool, on demande à chacun combien de verres il boit par semaine.
d. Une enquête téléphonique sur l'emploi appelle en journée, sur des lignes fixes.

Exercice 3 : solution

Quatre mécanismes

a. **Champ mal défini** : la clientèle n'est pas la population de la ville ; le revenu est **surestimé**.
b. **Biais de survie** : les fonds peu rentables ont fermé et disparu des données ; la rentabilité est **surestimée**.
c. **Biais de déclaration** : on minimise ce qui est mal vu ; la consommation est **sous-estimée**.
d. **Champ et non-réponse** : en journée, les actifs occupés sont absents, et beaucoup de ménages n'ont plus de fixe ; la part des actifs occupés est **sous-estimée**.

Un point commun

Dans les quatre cas, la probabilité d'être observé — ou de dire vrai — dépend de la variable mesurée. C'est exactement la situation que le modèle i.i.d. exclut.

Ce qu’il faut retenir

Six points

1. Toutes les formules du cours supposent un tirage **aléatoire** dans la population visée.
2. Tirer au hasard fait du résultat une variable X de loi celle de la population : $E(X) = m$, $\sigma(X) = \sigma$.
3. Le modèle : $X_1, \ldots, X_n$ **indépendantes**, de **même loi**. Il donne $E(\overline{X}) = m$ et $V(\overline{X}) = \sigma^2/n$.
4. Sans remise, la variance est multipliée par $(N-n)/(N-1)$; on l'oublie quand n/N est petit.
5. Le **biais** déplace le centre ; augmenter n ne le corrige jamais.
6. Non-réponse, formulation, déclaration : des erreurs qu'aucune marge d'erreur ne mesure.

De la variance à la loi complète

Le modèle a déjà donné l'espérance et la variance de $\overline{X}$. Il reste à connaître sa **loi** : quelle est la probabilité que la moyenne d'échantillon tombe à moins de 500 dirhams de m ?

La réponse vient du cours de probabilités — le théorème central limite. Le chapitre 2 en fait l'outil central de tout le reste.

La question, posée sur nos données

Sur les dix échantillons systématiques, huit ont une moyenne à moins de 350 dirhams de m, et deux s'en écartent de plus de 600.

Est-ce la proportion attendue ? Le chapitre 2 répond par le calcul.