Statistique inférentielle

Chapitre 5 : Estimateur et biais

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 22 octobre 2026

Plan du chapitre

Estimer

Le biais

Comparer des recettes

Le biais en économie

S'entraîner

Ce qu'il faut retenir

Estimer

Deux mots à distinguer

Estimateur et estimation

Un **estimateur** est une *recette* : une formule appliquée à un échantillon quelconque. C'est une variable aléatoire, notée $\hat{\theta}$.

Une **estimation** est le *nombre* obtenu sur l'échantillon dont on dispose.

Sur nos données

L'estimateur : $\overline{X} = \frac{1}{n} \sum_i X_i$.

L'estimation : $\overline{x} = 7\,005{,}80$ dirhams.

La recette est la même pour tout le monde ; le nombre change avec l'échantillon.

On juge la recette, jamais le nombre

$7\,005{,}80$ n'est ni bon ni mauvais : c'est un nombre. On ne peut pas dire s'il est proche de m, puisqu'on ignore m.

En revanche, on peut étudier la **méthode** : où se situe-t-elle en moyenne, de combien varie-t-elle ? Ce sont des questions sur la loi de $\hat{\theta}$ — et le chapitre 2 nous a appris à y répondre.

Les estimateurs usuels

Paramètre	Estimateur	Sur nos données
m	$\overline{X}$	$7\,005{,}80$
p	F	$0{,}26$
σ^2	S^2	$5\,066\,894$
σ	S	$2\,250{,}98$

Quatre façons d'estimer le salaire moyen

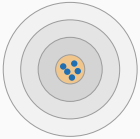
Recette	Ce qu'elle fait	Estimation
Moyenne	tous les salaires, poids égaux	$7\,005{,}80$
Médiane	la valeur du milieu	$6\,450$
Moyenne tronquée	sans les 5 plus bas ni les 5 plus hauts	$6\,851$
Milieu de l'étendue	$(3\,090 + 13\,600)/2$	$8\,345$

Quatre nombres, une seule cible

Les quatre recettes visent le même m et s'étalent sur près de $1\,900$ dirhams. Le chapitre ne demande pas « lequel est juste ? » — on ne le saura jamais — mais « laquelle des **recettes** vise juste en moyenne ? ».

Le biais

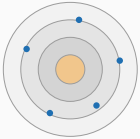
La cible



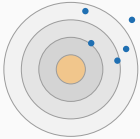
sans biais, précis
l'estimateur idéal



biaisé, précis
se trompe toujours
de la même façon



sans biais, imprécis
juste en moyenne,
inutilisable une fois



biaisé, imprécis
le pire des cas

Le centre de la cible est le paramètre m ; chaque impact est une estimation obtenue sur un échantillon différent.

Le **biais** est la distance entre le centre du nuage d'impacts et le centre de la cible : $\text{biais}(\widehat{\theta}) = E(\widehat{\theta}) - \theta$. La **variance** est l'étalement du nuage. Un estimateur n'est bon que si les deux sont petits — et l'on verra au chapitre 7 que l'on doit parfois *échanger* un peu de l'un contre l'autre.

Le deuxième cas est le plus traître : il est régulier, donc rassurant, et faux à chaque fois.

Biais d'un estimateur

$$\text{biais}(\hat{\theta}) = E(\hat{\theta}) - \theta$$

L'estimateur est dit **sans biais** lorsque ce nombre est nul : en moyenne sur tous les échantillons possibles, il vise juste.

Sans biais ne veut pas dire exact

Un estimateur sans biais se trompe presque toujours — parfois beaucoup. Il ne se trompe pas *systématiquement dans le même sens.*

La troisième cible de la figure le montre : sans biais, mais si dispersée qu'un tirage unique n'apprend rien.

Trois vérifications

$$E(\overline{X}) = m \qquad E(F) = p \qquad E(S^2) = \sigma^2$$

Les deux premières viennent du chapitre 2, la troisième du chapitre 3 — c'est le rôle du $n - 1$.

Un piège classique

S^2 est sans biais pour σ^2. **Mais S n'est pas sans biais pour σ.**

La racine carrée est une fonction concave : elle déforme l'espérance. En pratique le biais est faible et l'on s'en accommode — mais « sans biais » ne traverse pas les transformations.

Dix salariés, vingt mille fois

On tire $20\,000$ échantillons de 10 salariés avec remise et l'on calcule chaque fois s^2 et s :

	Moyenne des $20\,000$ valeurs	Vraie valeur	Rapport
S^2	$6\,766\,740$	$\sigma^2 = 6\,750\,122$	$1{,}002$
S	$2\,478{,}7$	$\sigma = 2\,598{,}1$	$0{,}954$

Ce que dit le tableau

S^2 vise juste, à la fluctuation de simulation près. S sous-estime σ de $4{,}6\,\%$ en moyenne.

Pour une population normale, le biais serait de $2{,}7\,\%$ à $n = 10$; nos salaires, étirés à droite, l'aggravent. À $n = 50$, il devient négligeable.

La variance divisée par n

$$E\left(\frac{1}{n}\sum_i (X_i - \overline{X})^2\right) = \frac{n-1}{n}\,\sigma^2$$

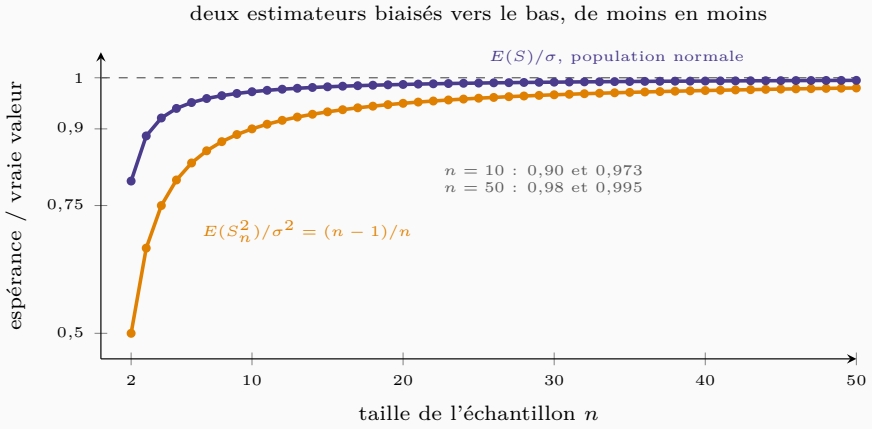
Pour $n = 10$, la théorie annonce $0{,}9 \times 6\,750\,122 = 6\,075\,110$; les $20\,000$ échantillons donnent $6\,090\,066$.

Le sens du biais compte autant que sa taille

Ce biais est **négatif** : la dispersion est sous-estimée.

En gestion des risques, un estimateur qui sous-estime la volatilité est bien plus dangereux qu'un estimateur imprécis. **Un biais rassurant est le pire de tous** — c'est celui qu'on ne cherche pas à corriger.

Le biais selon la taille de l'échantillon



Quand le biais est proportionnel

Si $E(\hat{\theta}) = c\,\theta$ avec c connu, alors $\hat{\theta}/c$ est sans biais.

C'est exactement ce que fait S^2 : S_n^2 a pour espérance $\frac{n-1}{n}\sigma^2$, et

$$S^2 = \frac{n}{n-1}\,S_n^2$$

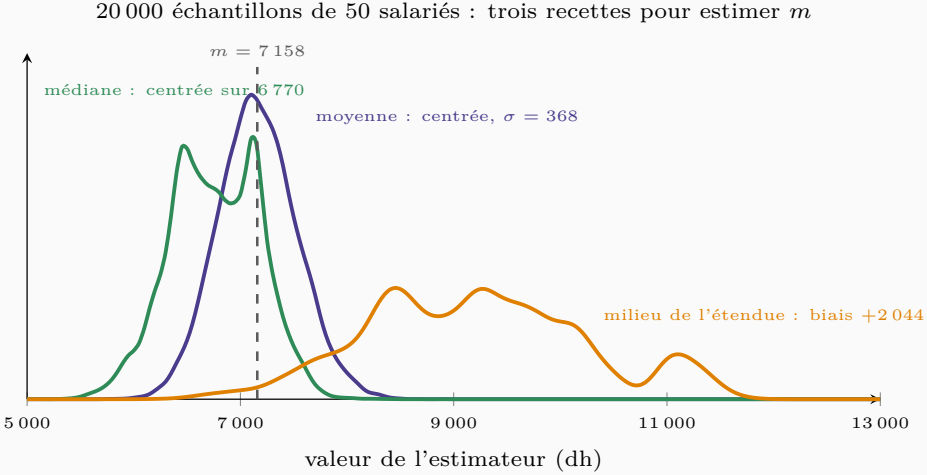
Un estimateur asymptotiquement sans biais

Le biais de S_n^2 vaut $-\sigma^2/n$: il tend vers 0 quand n grandit. On dit que S_n^2 est **asymptotiquement sans biais**.

Pour $n = 500$, diviser par n ou $n-1$ ne change la variance que de $0{,}2\,\%$. Le débat sur le dénominateur n'a de sens que pour les petits échantillons.

Comparer des recettes

Trois estimateurs de m, simulés



Ce que montre la simulation

Vingt mille échantillons de 50 salariés

Recette	Espérance	Biais pour m	Écart-type
Moyenne	$7\,160$	$+2$	368
Moyenne tronquée	$6\,895$	-263	354
Médiane	$6\,759$	-400	416
Milieu de l'étendue	$9\,203$	$+2\,044$	$1\,027$

La moyenne, seule à viser juste

La moyenne est la seule recette sans biais pour m : son biais simulé, $+2$, n'est que du bruit de simulation.

Le milieu de l'étendue cumule tous les défauts : il dépend des deux salaires extrêmes, et un seul gros salaire suffit à le faire bondir.

Biaisé pour quel paramètre ?

Un estimateur est biaisé pour un paramètre donné

La médiane d'échantillon est biaisée pour $m = 7\,158$, mais elle est centrée sur la **médiane** de la population, $6\,770$: pour ce paramètre-là, elle est un bon estimateur.

Dans une population symétrique, médiane et moyenne coïncident, et la médiane d'échantillon devient sans biais pour m.

Moyenne ou médiane des salaires ?

Les deux sont légitimes, mais ne répondent pas à la même question. La **moyenne** sert à calculer une masse salariale ; la **médiane**, à décrire le salaire d'un salarié « typique ».

Le biais ne vient pas de la recette seule, mais du rapport entre la recette et ce qu'on prétend estimer.

Moins de dispersion, un peu de biais

Retirer les $10\,\%$ extrêmes réduit l'écart-type de 368 à 354 dirhams : les gros salaires ne pèsent plus. Mais cela introduit un biais de -263, car ces gros salaires font partie de la population.

Est-ce un bon marché ? Le chapitre 6 donne le critère qui permet de trancher : l'**erreur quadratique moyenne**.

Un premier calcul

Erreur typique totale $= \sqrt{\text{biais}^2 + \text{variance}}$:

Recette	Calcul	Erreur typique
Moyenne	$\sqrt{2^2 + 368^2}$	368
Moyenne tronquée	$\sqrt{263^2 + 354^2}$	441

Le biais en économie

Le même mot pour la même chose

Le chapitre 1 a parlé de **biais de sélection** : des répondants qui ne ressemblent pas à la population. C'est un biais d'estimateur au sens de ce chapitre.

Avec la non-réponse liée au salaire, la moyenne des répondants a pour espérance $7\,807$: un biais de $+649$ dirhams pour m, quelle que soit la taille de l'échantillon.

Deux origines, un même effet

Le biais peut venir de la **recette** — la variance divisée par n — ou de la **collecte** — un échantillon déformé. La première se corrige par une formule ; la seconde, presque jamais après coup.

Quand on choisit un estimateur biaisé

Trois raisons légitimes

1. **Il est plus précis** : un petit biais contre une forte baisse de variance — c'est l'idée de la moyenne tronquée, et de nombreuses méthodes modernes de prévision.
2. **Le paramètre est mal défini** sans lui : un taux de croissance moyen se calcule par une moyenne géométrique, biaisée pour la moyenne arithmétique.
3. **Il est prudent** : un régulateur bancaire préfère un estimateur du risque biaisé **vers le haut**.

La seule faute

Le biais n'est pas une faute en soi. La faute est d'**ignorer** son sens et sa taille, et de présenter une estimation biaisée comme si elle ne l'était pas.

S’entraîner

Biais de trois estimateurs

$X_1, \dots, X_n$ est un échantillon aléatoire simple de moyenne m. On propose :

$$T_1 = \overline{X} \qquad T_2 = \frac{X_1 + X_n}{2} \qquad T_3 = \frac{X_1 + \cdots + X_n}{n+1}$$

1. Calculer l'espérance de chacun. Lesquels sont sans biais ?
2. Le biais de T_3 disparaît-il quand n grandit ?
3. T_1 et T_2 sont sans biais. Pourquoi préfère-t-on évidemment T_1 ?

Sans biais ne suffit pas à choisir

1. $E(T_1) = m$; $E(T_2) = (m+m)/2 = m$; $E(T_3) = n\,m/(n+1)$. T_1 et T_2 sont sans biais ; T_3 a un biais $-m/(n+1)$.
2. Oui : $-m/(n+1) \to 0$. T_3 est asymptotiquement sans biais.
3. T_2 n'utilise que deux observations : $V(T_2) = \sigma^2/2$, contre σ^2/n pour T_1. Les deux visent juste, mais T_2 est bien plus dispersé. C'est le critère du chapitre 6.

Cinq jours de ventes

On reprend les cinq ventes du chapitre 3 : $\sum(x_i - \overline{x})^2 = 26$. On suppose que la vraie variance des ventes est $\sigma^2 = 6$.

1. Calculer s_n^2 et s^2.
2. Calculer $E(S_n^2)$ et le biais de S_n^2.
3. Quel facteur faut-il appliquer à S_n^2 pour obtenir un estimateur sans biais ?

Exercice 2 : solution

Un biais de 20 pour cent à n = 5

1. $s_n^2 = 26/5 = 5{,}2$ et $s^2 = 26/4 = 6{,}5$.
2. $E(S_n^2) = \frac{4}{5} \times 6 = 4{,}8$, d'où un biais de $4{,}8 - 6 = -1{,}2$, soit $-20\,\%$.
3. $n/(n-1) = 5/4 : \frac{5}{4} \times 5{,}2 = 6{,}5 = s^2$.

Une estimation n'a pas de biais

$s^2 = 6{,}5$ dépasse la vraie valeur 6, et $s_n^2 = 5{,}2$ est en dessous. Cela ne dit rien du biais : seule la **recette** en a un, en moyenne sur tous les échantillons.

Des numéros de série

Une société de location numérote ses véhicules de 1 à θ, nombre inconnu. On observe au hasard 4 véhicules : 19, 40, 42, 60.

On admet que, pour des numéros tirés uniformément, le plus grand des n observés a pour espérance environ $\frac{n}{n+1}\,\theta$.

1. Le plus grand numéro, 60, est-il un estimateur biaisé de θ ? Dans quel sens ?
2. Proposer un estimateur sans biais, et l'appliquer.
3. Comparer avec l'estimateur $2\,\overline{x}$, fondé sur la moyenne.

Exercice 3 : solution

Le maximum sous-estime toujours

1. Oui : le plus grand numéro observé ne peut pas dépasser θ. Son espérance, $\frac{4}{5}\theta$, est **inférieure** à θ : biais négatif.
2. On corrige par $\frac{n+1}{n}$: $\widehat{\theta} = \frac{5}{4} \times 60 = 75$ véhicules.
3. La moyenne des numéros tirés vaut environ $\theta/2$, d'où $2\,\overline{x} = 2 \times 40{,}25 = 80{,}5$. Les deux sont sans biais ; le premier est en général bien plus précis.

Un problème historique

Pendant la Seconde Guerre mondiale, les Alliés ont estimé ainsi la production de chars allemands à partir des numéros relevés sur les engins capturés — avec une précision bien supérieure à celle du renseignement classique.

Ce qu’il faut retenir

Six points

1. Un **estimateur** est une formule aléatoire ; une **estimation** est le nombre obtenu.
2. On juge la méthode, jamais le nombre : c'est la loi de $\widehat{\theta}$ que l'on étudie.
3. $\text{biais}(\widehat{\theta}) = E(\widehat{\theta}) - \theta$; il est nul pour $\overline{X}$, F et S^2, mais pas pour S.
4. **Sans biais n'est pas exact** : l'estimateur se trompe, mais pas toujours dans le même sens.
5. Un estimateur est biaisé **pour un paramètre donné** : la médiane vise la médiane, non la moyenne.
6. Le biais de la variance non corrigée vaut $-\sigma^2/n$: il **sous-estime** le risque.

L'absence de biais ne suffit pas

La troisième cible de la figure était sans biais et pourtant inutilisable ; T_2, sans biais, était bien plus dispersé que $\overline{X}$.

Il faut aussi que l'estimateur soit **précis**, et qu'il s'améliore quand l'échantillon grandit. C'est l'objet du chapitre 6.

La question laissée ouverte

Moyenne : biais 2, écart-type 368. Moyenne tronquée : biais -263, écart-type 354.

Peut-on combiner biais et dispersion en un seul nombre pour comparer les deux ? Le chapitre 6 répond par l'erreur quadratique moyenne.