


# Statistique inférentielle

## Chapitre 11 : Proportion et variance



---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 23 août 2026

L'intervalle pour une proportion

L'intervalle pour une variance

Ce qu'il faut retenir

## L'intervalle pour une proportion

---

### Intervalle de confiance d'une proportion

$$f \pm z_{\alpha/2} \sqrt{\frac{f(1-f)}{n}}$$

valable si  $nf \geq 5$  et  $n(1-f) \geq 5$ .

### Une entorse assumée

L'écart-type théorique fait intervenir  $p$ , que l'on cherche justement à estimer. On le remplace donc par  $f$ .

C'est une approximation, non un théorème. Elle est acceptable dès que  $n$  dépasse quelques dizaines, et c'est la formule que tout le monde emploie.

### La part de diplômés Bac+5

Sur les 50 salariés de l'échantillon, 13 sont titulaires d'un Bac+5.

$$f = \frac{13}{50} = 0,26 \quad \sqrt{\frac{0,26 \times 0,74}{50}} = 0,0620$$


$$IC_{95\%} = 0,26 \pm 1,96 \times 0,0620 = [0,138 ; 0,382]$$

### La vérification, et la leçon

La proportion réelle vaut 0,214 : elle est bien dans l'intervalle.

Mais celui-ci s'étend de 14 % à 38 % — presque du simple au triple. **Cinquante observations ne permettent pas d'estimer une proportion avec finesse**, et c'est un ordre de grandeur qu'il faut avoir en tête avant de commander une enquête.

# La marge d'erreur, telle qu'on l'annonce



D'où vient le « plus ou moins trois points »

$$1,96 \sqrt{\frac{0,5 \times 0,5}{1000}} = 0,031$$

On prend  $p = 0,5$  parce que c'est le **cas le plus défavorable** :  $p(1-p)$  y est maximal. La marge annoncée est donc toujours une majoration.

**La courbe s'aplatit.** Passer de 1 000 à 4 000 personnes quadruple le coût et ne gagne que 1,5 point.

C'est pourquoi tous les instituts, dans tous les pays, s'arrêtent autour du millier — ce n'est pas une convention, c'est un calcul.

# Pourquoi les proportions exigent de gros échantillons

## Comparaison des deux paramètres

| Paramètre  | Estimation | Demi-largeur | En part de la valeur |
|------------|------------|--------------|----------------------|
| Moyenne    | 7 005,80   | $\pm 640$    | 9 %                  |
| Proportion | 0,26       | $\pm 0,122$  | 47 %                 |

## L'explication

Une variable indicatrice ne prend que deux valeurs : elle est extrêmement pauvre en information. Chaque observation n'apporte qu'un bit.

C'est pourquoi les sondages politiques interrogent mille personnes là où une enquête de salaires en interroge cent : **estimer une proportion coûte structurellement plus cher.**

## L'intervalle pour une variance

---



### La loi utilisée

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2$$

L'intervalle s'obtient en encadrant cette quantité par les deux quantiles du khi-deux, puis en isolant  $\sigma^2$ .

### La formule

$$\left[ \frac{(n-1)s^2}{\chi_{1-\alpha/2; n-1}^2} ; \frac{(n-1)s^2}{\chi_{\alpha/2; n-1}^2} \right]$$

## Ce qui change par rapport aux deux autres

### Trois différences à repérer

1. L'intervalle **n'est pas symétrique** autour de  $s^2$  : la loi du khi-deux ne l'est pas.
2. Il n'y a **pas de  $\pm$**  : les deux bornes se calculent séparément.
3. Les quantiles sont **inversés** : le grand quantile va au dénominateur de la borne inférieure.

### Sur nos données

$n = 50$ ,  $s^2 = 5\,066\,894$ ,  $\nu = 49$ .

$$\chi_{0,975;49}^2 = 70,222 \quad \chi_{0,025;49}^2 = 31,555$$

$$IC_{95\%}(\sigma^2) = \left[ \frac{49 \times 5\,066\,894}{70,222} ; \frac{49 \times 5\,066\,894}{31,555} \right] = [3\,535\,592 ; 7\,868\,118]$$

On prend la racine des deux bornes

$$IC_{95\%}(\sigma) = [1\,880,3 ; 2\,805,0]$$

La valeur réelle,  $\sigma = 2\,598,10$ , est bien dans l'intervalle.

Prendre la racine est ici légitime

La racine est une fonction croissante : elle conserve l'ordre des bornes, donc le niveau de confiance.

Attention toutefois : cet intervalle est correct pour  $\sigma$ , mais son centre n'est pas  $s$  — la transformation déplace le milieu.

## Une condition beaucoup plus stricte

La loi  $\chi^2$  pour  $s^2$  exige que la **population soit normale**. Contrairement à l'intervalle de la moyenne, aucun théorème central limite ne vient sauver le cas général.

Sur une population à queues épaisses — rendements financiers, montants de sinistres — cet intervalle peut être gravement faux, même avec un grand  $n$ .

## Le contraste à retenir

$\bar{X}$  est robuste à la non-normalité       $s^2$  ne l'est pas

C'est un point que beaucoup d'utilisateurs ignorent, et c'est l'une des raisons pour lesquelles l'estimation de la volatilité est un sujet difficile en finance.

Ce qu'il faut retenir

---

## Six points

1. **Proportion** :  $f \pm z_{\alpha/2} \sqrt{f(1-f)/n}$ , valable si  $nf \geq 5$  et  $n(1-f) \geq 5$ .
2. Sur 50 observations :  $[0,138 ; 0,382]$  — très large. Une proportion exige un gros échantillon.
3. **Variance** : intervalle **asymétrique**, construit sur le khi-deux, sans  $\pm$ .
4. Les quantiles y sont **croisés** : le grand au dénominateur de la borne basse.
5. Pour  $\sigma$ , on prend la racine des deux bornes :  $[1\,880,3 ; 2\,805,0]$ .
6. L'intervalle de la variance exige la **normalité de la population** ; celui de la moyenne, non.

## La suite

Tous ces intervalles se sont révélés larges. La question qui vient naturellement est celle du gestionnaire : **combien d'observations faut-il pour atteindre la précision voulue ?**

Le chapitre 12 y répond par une formule, et par un calcul de budget.