Statistique inférentielle

Chapitre 3 : Proportion et variance

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 22 octobre 2026

Plan du chapitre

La proportion

La variance

La loi de la variance d'échantillon

S'entraîner

Ce qu'il faut retenir

La proportion

Le déguisement

Posons $X_i = 1$ si l'individu possède le caractère étudié, 0 sinon. Alors

$$F = \frac{X_1 + \cdots + X_n}{n} = \overline{X}$$

La fréquence observée **est** la moyenne d'une variable indicatrice.

Tout le chapitre 2 s'applique sans un mot de plus

Il suffit de savoir que pour une indicatrice, $E(X_i) = p$ et $\sigma(X_i) = \sqrt{p(1-p)}$ – c'est la loi de Bernoulli.

$$E(F) = p \qquad \sigma(F) = \sqrt{\frac{p(1-p)}{n}}$$

Aucun résultat nouveau : la même formule, avec un σ particulier.

Treize Bac+5 sur cinquante

L'indicatrice vaut 1 pour les 13 Bac+5 et 0 pour les 37 autres : sa moyenne est $f = 13/50 = 0{,}26$.

Dans la population, $p = 0{,}214$. D'où l'erreur-type

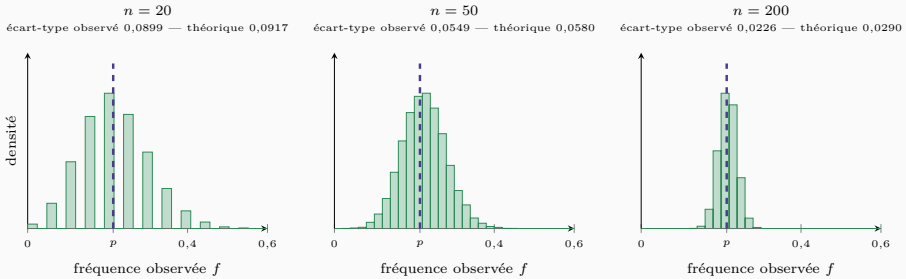
$$\sigma(F) = \sqrt{\frac{0{,}214 \times 0{,}786}{50}} = \sqrt{0{,}003\,364} = 0{,}058$$

Un écart ordinaire

L'écart $0{,}26 - 0{,}214 = 0{,}046$ représente $0{,}046/0{,}058 = 0{,}79$ erreur-type : moins d'une.

Notre échantillon surreprésente les Bac+5 — mais pas plus qu'un échantillon sur quatre. C'est la réponse à la première question laissée par le chapitre 2.

Sa distribution d'échantillonnage



Une proportion n'est qu'une moyenne : celle d'une variable qui vaut 1 ou 0.

Tout ce qui a été dit de $\overline{X}$ s'applique donc mot pour mot, avec $\sigma = \sqrt{p(1-p)}$:

$$E(F) = p \qquad \sigma_F = \sqrt{\frac{p(1-p)}{n}} \qquad \text{et } F \text{ tend vers une normale.}$$

À $n = 20$, la loi est encore visiblement discrète et dissymétrique — l'approximation normale serait abusive. La règle usuelle est $np \geq 5$ et $n(1-p) \geq 5$: ici $20 \times 0{,}214 = 4{,}3$, insuffisant.

Derrière la proportion, une binomiale

Le nombre de Bac+5 tirés, nF, suit **exactement** une loi binomiale $\mathcal{B}(n\,;p)$ — pour un tirage avec remise.

La normale n'en est qu'une approximation, d'autant meilleure que n est grand et p éloigné de 0 et de 1.

Les deux premiers moments du nombre de Bac+5

$$E(nF) = 50 \times 0{,}214 = 10{,}7 \qquad \sigma(nF) = \sqrt{50 \times 0{,}214 \times 0{,}786} = 2{,}90$$

On divise par $n = 50$ pour retrouver ceux de F : $0{,}214$ et $0{,}058$.

Trois calculs de la même probabilité

P(au moins 13 Bac+5 sur 50)

Méthode	Calcul	Probabilité
Binomiale exacte	$P(X \geq 13)$	$0{,}261$
Normale brute	$P\big(Z \geq (13 - 10{,}7)/2{,}90\big)$	$0{,}214$
Normale corrigée	$P\big(Z \geq (12{,}5 - 10{,}7)/2{,}90\big)$	$0{,}267$

La normale brute se trompe de cinq points

Elle traite 13 comme un point, alors que la binomiale lui attribue tout un bâton. La version corrigée retrouve la valeur exacte à six millièmes près.

Une demi-unité de chaque côté

La binomiale ne prend que des valeurs entières ; la normale, toutes les valeurs. Pour approcher $P(X \geq 13)$, on prend la normale à partir de $12{,}5$: le bâton de 13 occupe l'intervalle $[12{,}5\,;\,13{,}5]$.

Quand s'en soucier

Avec $n = 50$, l'oubli de la correction change la probabilité de $0{,}26$ à $0{,}21$: une erreur de cinq points. Avec $n = 1\,000$, l'écart deviendrait négligeable.

Les logiciels calculent la binomiale exacte : la correction sert surtout au calcul à la main.

Quand peut-on lire une table normale

$$np \geq 5 \qquad \text{et} \qquad n(1-p) \geq 5$$

Ces deux conditions viennent de l'approximation normale de la binomiale, chapitre 17 de Probabilités.

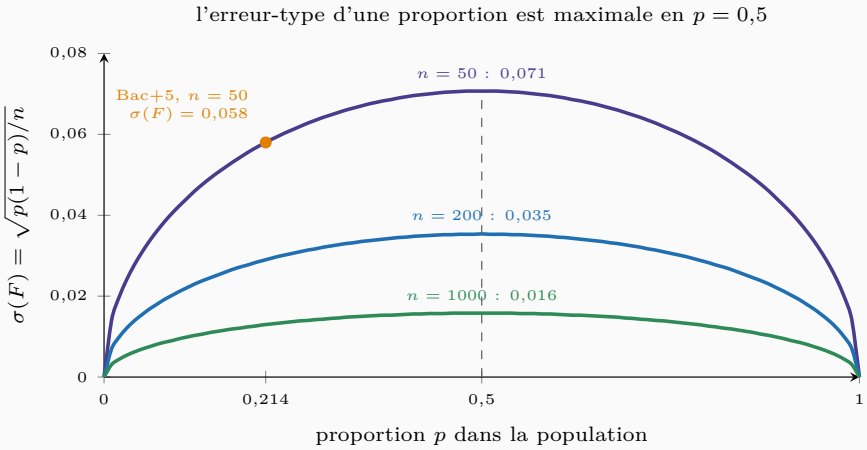
Sur nos données

Proportion de diplômés Bac+5 dans la population : $p = 0{,}214$.

$n = 20$: $np = 4{,}3$ — **insuffisant**, la figure montre une loi encore visiblement discrète.

$n = 50$: $np = 10{,}7$ et $n(1-p) = 39{,}3$ — les deux conditions sont remplies.

L'erreur-type selon la proportion



Le pire cas est en p = 0,5

La fonction $p(1-p)$ est maximale en $p = 0{,}5$, où elle vaut $0{,}25$.

$$\sigma(F) \leq \frac{0{,}5}{\sqrt{n}} \qquad \text{quelle que soit la valeur de } p$$

Pourquoi les instituts annoncent toujours la même marge

Ne connaissant pas p avant l'enquête, on dimensionne au cas le plus défavorable.

C'est pourquoi la marge d'erreur publiée est la même quel que soit le résultat : elle est **majorée**, donc valable pour toutes les questions du questionnaire à la fois.

La marge maximale, au niveau de confiance 0,95

La marge est $1{,}96 \times 0{,}5/\sqrt{n} \approx 1/\sqrt{n}$:

Taille n	400	$1\,000$	$2\,500$	$10\,000$
Erreur-type	$0{,}025$	$0{,}016$	$0{,}010$	$0{,}005$
Marge, points	$\pm 4{,}9$	$\pm 3{,}1$	$\pm 2{,}0$	$\pm 1{,}0$

Lire un sondage d'opinion

Un sondage de $1\,000$ personnes donne un candidat à $52\,\%$: la vraie valeur peut aller de 49 à $55\,\%$. « En tête » n'est pas établi. Pour situer le candidat à un point près, il faudrait $10\,000$ personnes : dix fois plus.

Les dix échantillons systématiques

La proportion de Bac+5 dans chacun

Départ r	0	1	2	3	4	5	6	7	8	9
Bac+5	13	11	10	12	11	10	11	9	11	9

La moyenne des dix proportions vaut exactement $107/500 = 0{,}214 = p$: la proportion d'échantillon est centrée.

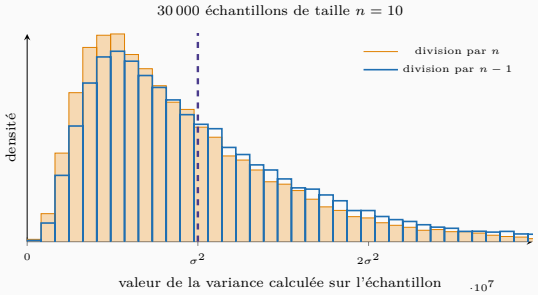
Un fichier plus régulier que le hasard

Les dix nombres vont de 9 à 13 : bien moins dispersés qu'un tirage au hasard, qui irait couramment de 6 à 16.

L'ordre du fichier répartit régulièrement les diplômes ; le tirage systématique en profite. Pour le salaire, il n'avait rien changé (chapitre 1) : l'effet d'un plan dépend de la variable étudiée.

La variance

L'énigme du dénominateur



Le décalage se voit à l'œil.

En divisant par n, la moyenne des 30 000 valeurs vaut 6107414 — soit $0.90\,\sigma^2$: **trop petite**.

En divisant par $n - 1$, elle vaut 6786015, soit σ^2 exactement.

Pourquoi ? Les écarts sont mesurés à $\overline{x}$, qui est *lui-même* calculé sur l'échantillon et se place donc au plus près des points. On sous-estime nécessairement la dispersion autour du vrai m.

Le facteur $\dfrac{n}{n-1}$ corrige exactement ce rapprochement. C'est le *degré de liberté* perdu à estimer m.

Deux formules, deux comportements

$$s_n^2 = \frac{1}{n}\sum_i (x_i - \overline{x})^2 \qquad\qquad s^2 = \frac{1}{n-1}\sum_i (x_i - \overline{x})^2$$

La première **sous-estime** systématiquement σ^2. La seconde est sans biais : $E(S^2) = \sigma^2$.

La raison, en une phrase

Les écarts sont mesurés à $\overline{x}$, qui est calculé **sur le même échantillon** et se place donc au plus près des points.

La somme des carrés obtenue est ainsi la plus petite possible — plus petite que si l'on avait mesuré les écarts au vrai m, que l'on ignore. On sous-estime nécessairement la dispersion.

Les seize échantillons du chapitre 2

Pour un couple $(a\,;b)$, la moyenne est $(a+b)/2$ et les deux écarts valent $\pm(a-b)/2$. D'où

$$s_n^2 = \frac{(a-b)^2}{4} \qquad\qquad s^2 = \frac{(a-b)^2}{2}$$

Sur les seize couples, $(a-b)^2$ vaut en moyenne 19 : $E(S_n^2) = 4{,}75$ et $E(S^2) = 9{,}5$.

Le verdict

La vraie variance est $\sigma^2 = 9{,}5$. Diviser par $n = 2$ donne en moyenne **la moitié** de la vraie valeur ; diviser par $n-1 = 1$ donne **exactement** la vraie valeur.

Le facteur manquant est $(n-1)/n = 1/2$.

Décomposer autour de m

On écrit $x_i - m = (x_i - \overline{x}) + (\overline{x} - m)$, on élève au carré et l'on somme. Le double produit disparaît, car $\sum(x_i - \overline{x}) = 0$:

$$\sum (x_i - m)^2 = \sum (x_i - \overline{x})^2 + n\,(\overline{x} - m)^2$$

Puis passer aux espérances

À gauche, $E\big(\sum (X_i - m)^2\big) = n\,\sigma^2$. À droite, $E\big(n(\overline{X} - m)^2\big) = n\,V(\overline{X}) = \sigma^2$. Donc

$$E\Big(\sum (X_i - \overline{X})^2\Big) = n\,\sigma^2 - \sigma^2 = (n-1)\,\sigma^2$$

Il faut diviser par $n - 1$ pour retrouver σ^2 en moyenne.

Ce que le n − 1 compte

Une fois $\overline{x}$ calculé, les n écarts $(x_i - \overline{x})$ ne sont plus libres : leur somme est **nulle** par construction.

Connaissant $n - 1$ d'entre eux, le dernier est déterminé. Il n'y a donc que $n - 1$ écarts réellement indépendants : c'est le **nombre de degrés de liberté**.

Une règle qui reviendra sans cesse

On perd un degré de liberté par paramètre estimé à partir des données.

Ici, un seul : m, remplacé par $\overline{x}$. Au chapitre 19, la régression en estimera deux — pente et ordonnée — et le dénominateur sera $n - 2$. Le principe ne change jamais.

Population et échantillon

	Formule	Valeur
Population ($N = 500$)	division par N	$\sigma = 2\,598{,}10$
Échantillon ($n = 50$)	division par $n - 1$	$s = 2\,250{,}98$
Échantillon ($n = 50$)	division par n	$s_n = 2\,228{,}35$

Le point de vocabulaire

Sur la **population**, on divise par N : ce n'est pas une estimation, c'est une définition. Le cours de descriptive faisait cela.

Sur un **échantillon** dont on veut estimer σ, on divise par $n - 1$. R (`var`, `sd`) divise par $n - 1$; numpy (`np.var`) divise par n sauf indication contraire. Le chapitre 21 y reviendra.

Les dix écarts-types corrigés

r	0	1	2	3	4
s	2 251	2 662	2 809	2 542	2 715
r	5	6	7	8	9
s	2 943	2 897	2 197	2 424	2 453

Centré sur la bonne valeur

La moyenne des dix variances s^2 vaut $6\,765\,607$, presque exactement la variance de la population calculée en $N-1$: $6\,763\,649$.

Notre échantillon, avec $s = 2\,251$, est simplement l'un des plus bas : il sous-estime la dispersion **par hasard**, non par construction.

La loi de la variance d'échantillon

Le résultat, pour une population normale

$$\frac{(n-1)\,S^2}{\sigma^2} \;\sim\; \chi^2_{n-1}$$

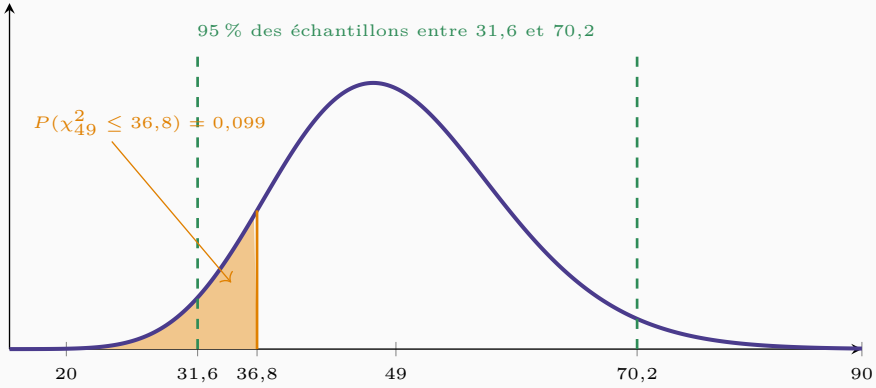
La variance d'échantillon, correctement normalisée, suit une loi du khi-deux à $n-1$ degrés de liberté.

Cela n'a rien d'étonnant

S^2 est une **somme de carrés** d'écarts. Or le khi-deux a été défini, au chapitre 18 de Probabilités, comme une somme de carrés de normales centrées réduites.

Le degré de liberté $n-1$ est le même que celui du dénominateur : ce n'est pas une coïncidence, c'est la même perte d'information.

la loi χ^2_{49}, et la valeur de notre échantillon



$(n-1)\,S^2/\sigma^2$

Le calcul

$$\frac{(n-1)\,s^2}{\sigma^2} = \frac{49 \times 2\,250{,}98^2}{2\,598{,}10^2} = 36{,}78$$

La loi χ^2_{49} a pour espérance 49 et pour écart-type $\sqrt{98} = 9{,}9$. Notre valeur se situe $1{,}2$ écart-type en dessous de l'espérance, et $P(\chi^2_{49} \leq 36{,}78) = 0{,}099$.

La réponse à la seconde question

Un échantillon sur dix environ sous-estime la variance au moins autant que le nôtre. C'est peu fréquent, mais pas exceptionnel.

Le chapitre 10 retournera ce calcul pour encadrer σ à partir de s.

La normalité, cette fois, n'est pas facultative

Pour la moyenne, le théorème central limite rattrape une population non normale. Pour la variance, **rien ne la rattrape** : la loi du khi-deux suppose une population normale.

Nos salaires sont étirés à droite, avec un aplatissement de $4{,}8$ contre 3 pour une normale. Les probabilités calculées sur S^2 ne sont alors qu'indicatives.

Ce qu'il faut retenir pour la pratique

Un intervalle ou un test sur une **moyenne** est robuste à la forme de la population. Sur une **variance**, il ne l'est pas : on vérifie d'abord la normalité, ou l'on a recours à d'autres méthodes.

S’entraîner

Les ménages équipés d'une voiture

Dans une ville, $30\,\%$ des ménages possèdent une voiture. Une enquête interroge 200 ménages pris au hasard ; F est la proportion d'équipés observée.

1. Les conditions d'approximation normale sont-elles remplies ?
2. Calculer $E(F)$ et $\sigma(F)$.
3. Calculer, sans correction de continuité, $P(F > 0{,}35)$.
4. Quelle serait la marge d'erreur maximale à $95\,\%$ pour cette taille ?

Une proportion, une moyenne

1. $np = 60$ et $n(1-p) = 140$: largement.
2. $E(F) = 0{,}30$ et $\sigma(F) = \sqrt{0{,}30 \times 0{,}70/200} = \sqrt{0{,}001\,05} = 0{,}032\,4$.
3. $z = (0{,}35 - 0{,}30)/0{,}032\,4 = 1{,}54$, d'où $P(F > 0{,}35) = 0{,}061$.
4. $1{,}96 \times 0{,}5/\sqrt{200} = 0{,}069$: $\pm 6{,}9$ points. Ici, la marge réelle est plus petite, $1{,}96 \times 0{,}032\,4 = 0{,}064$, car $p = 0{,}30$ est éloigné de $0{,}5$.

Exercice 2 : une variance à la main

Cinq ventes quotidiennes

Un magasin relève ses ventes de cinq jours tirés au hasard, en milliers de dirhams : 8, 10, 7, 12, 13.

1. Calculer $\overline{x}$, les cinq écarts à la moyenne, et vérifier que leur somme est nulle.
2. Calculer s_n^2 et s^2. Lequel retenir pour estimer la variance des ventes ?
3. On ne communique que quatre écarts : -2, 0, -3, $+2$. Retrouver le cinquième. Que vient-on d'illustrer ?

Quatre degrés de liberté

1. $\overline{x} = 50/5 = 10$. Écarts : -2, 0, -3, $+2$, $+3$; somme nulle.
2. $\sum (x_i - \overline{x})^2 = 4 + 0 + 9 + 4 + 9 = 26$, d'où $s_n^2 = 26/5 = 5{,}2$ et $s^2 = 26/4 = 6{,}5$. Pour estimer la variance des ventes, on retient $s^2 = 6{,}5$, sans biais.
3. La somme doit être nulle : le cinquième vaut $-(-2 + 0 - 3 + 2) = +3$. Cinq écarts, mais quatre seulement sont libres : $n - 1 = 4$ degrés de liberté.

Le poids des paquets

Une machine remplit des paquets dont le poids suit une loi normale d'écart-type $\sigma = 5$ grammes. Chaque matin, on pèse 10 paquets et l'on calcule s^2.

1. Quelle est la loi de $9\,S^2/25$?
2. Le service qualité alerte si $s^2 > 50$, soit le double de σ^2. Quelle est la probabilité d'une fausse alerte un matin donné ?
3. À partir de quel seuil s^2 n'y aurait-il que $5\,\%$ de fausses alertes ? (Le quantile à $95\,\%$ de χ^2_9 vaut $16{,}92$.)

La table du khi-deux

1. $(n-1)S^2/\sigma^2 = 9\,S^2/25 \sim \chi^2_9$, la population étant normale.
2. $s^2 > 50$ équivaut à $9 \times 50/25 = 18 : P(\chi^2_9 > 18) = 0{,}035$. Une fausse alerte tous les trente matins environ.
3. $9\,s^2/25 > 16{,}92$, soit $s^2 > 47$. Le seuil de 50 est donc un peu plus prudent que la règle des $5\,\%$.

Pourquoi la normalité est ici crédible

Le poids d'un paquet résulte de nombreuses petites variations — dosage, vibration, humidité : c'est le cas typique où la loi normale décrit bien les données.

Ce qu’il faut retenir

Six points

1. Une **proportion est une moyenne** d'indicatrices : $E(F) = p$ et $\sigma(F) = \sqrt{p(1-p)/n}$.
2. Conditions de normalité : $np \geq 5$ **et** $n(1-p) \geq 5$; à la main, la correction de continuité améliore l'approximation.
3. $p(1-p)$ est maximal en $0{,}5$: la marge maximale à $95\,\%$ vaut environ $1/\sqrt{n}$.
4. La variance d'échantillon se divise par $n-1$: $E(S^2) = \sigma^2$, alors que $E(S_n^2) = \frac{n-1}{n}\,\sigma^2$.
5. **Un degré de liberté perdu par paramètre estimé** — la règle vaudra jusqu'à la régression.
6. Pour une population normale, $(n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$; ce résultat ne tolère pas l'écart à la normalité.

Trois distributions, trois lois

Trois distributions d'échantillonnage sont maintenant établies : moyenne, proportion, variance.

Deux lois du cours de probabilités y sont apparues sans qu'on sache encore à quoi elles servent : le khi-deux, et — dès que σ est inconnu — la loi de Student. Le chapitre 4 boucle cette dette.

La question qui ouvre le chapitre 4

En pratique, σ est inconnu : on le remplace par s. Mais $(\overline{X} - m)/(S/\sqrt{n})$ n'est plus normale, puisque S varie aussi d'un échantillon à l'autre.

Quelle est sa loi ? Pour notre échantillon, elle vaut $(7\,005{,}80 - 7\,158{,}26)/318{,}34 = -0{,}48$.