

Statistique inférentielle

Chapitre 4 : Proportion et variance

Jaouad Madkour

16 août 2026

Faculté d'Économie et de Gestion de Tanger

La proportion

La variance

Ce qu'il faut retenir

La proportion



Une proportion est une moyenne

Le déguisement

Posons $X_i = 1$ si l'individu possède le caractère étudié, 0 sinon. Alors

$$F = \frac{X_1 + \dots + X_n}{n} = \bar{X}$$

La fréquence observée **est** la moyenne d'une variable indicatrice.


Tout le chapitre 3 s'applique sans un mot de plus

Il suffit de savoir que pour une indicatrice, $E(X_i) = p$ et $\sigma(X_i) = \sqrt{p(1-p)}$ – c'est la loi de Bernoulli.

$$E(F) = p \qquad \sigma(F) = \sqrt{\frac{p(1-p)}{n}}$$

Aucun résultat nouveau : la même formule, avec un σ particulier.

Sa distribution d'échantillonnage



Une proportion n'est qu'une moyenne : celle d'une variable qui vaut 1 ou 0.

Tout ce qui a été dit de $\bar{X}$ s'applique donc mot pour mot, avec $\sigma = \sqrt{p(1-p)}$:

$$E(F) = p \quad \sigma_F = \sqrt{\frac{p(1-p)}{n}} \quad \text{et } F \text{ tend vers une normale.}$$

À $n = 20$, la loi est encore visiblement discrète et dissymétrique — l'approximation normale serait abusive. La règle usuelle est $np \geq 5$ et $n(1-p) \geq 5$: ici $20 \times 0,214 = 4,3$, insuffisant.

Quand peut-on lire une table normale

$$np \geq 5 \quad \text{et} \quad n(1 - p) \geq 5$$

Ces deux conditions viennent directement de l'approximation normale de la binomiale, chapitre 18 des probabilités.

Sur nos données

Proportion de diplômés Bac+5 dans la population : $p = 0,214$.

$n = 20$: $np = 4,3$ – **insuffisant**, la figure montre une loi encore visiblement discrète. $n = 50$: $np = 10,7$ et $n(1 - p) = 39,3$ – les deux conditions sont remplies.

Le pire cas est en $p = 0,5$

La fonction $p(1 - p)$ est maximale en $p = 0,5$, où elle vaut 0,25.

$$\sigma(F) \leq \frac{0,5}{\sqrt{n}} \quad \text{quelle que soit la valeur de } p$$


Pourquoi les instituts annoncent toujours la même marge

Ne connaissant pas p avant l'enquête, on dimensionne au cas le plus défavorable.

C'est pourquoi la marge d'erreur publiée est la même quel que soit le résultat : elle est **majorée**, donc valable pour toutes les questions du questionnaire à la fois.

La variance

L'énigme du dénominateur



Le décalage se voit à l'œil.

En divisant par n , la moyenne des 30 000 valeurs vaut 6107414 — soit $0.90 \sigma^2$:
trop petite.

En divisant par $n - 1$, elle vaut 6786015, soit σ^2 exactement.

Pourquoi ? Les écarts sont mesurés à $\bar{x}$, qui est *lui-même* calculé sur l'échantillon et se place donc au plus près des points. On sous-estime nécessairement la dispersion autour du vrai m .

Le facteur $\frac{n}{n-1}$ corrige exactement ce rapprochement. C'est le *degré de liberté* perdu à estimer m .

Deux formules, deux comportements

$$s_n^2 = \frac{1}{n} \sum_i (x_i - \bar{x})^2 \qquad s^2 = \frac{1}{n-1} \sum_i (x_i - \bar{x})^2$$

La première **sous-estime** systématiquement σ^2 . La seconde est sans biais : $E(s^2) = \sigma^2$.

La raison, en une phrase

Les écarts sont mesurés à $\bar{x}$, qui est calculé **sur le même échantillon** et se place donc au plus près des points.

La somme des carrés obtenue est ainsi la plus petite possible — plus petite que si l'on avait mesuré les écarts au vrai m , que l'on ignore. On sous-estime nécessairement la dispersion.

Ce que le $n - 1$ compte

Une fois $\bar{x}$ calculé, les n écarts $(x_i - \bar{x})$ ne sont plus libres : leur somme est **nulle** par construction.

Connaissant $n - 1$ d'entre eux, le dernier est déterminé. Il n'y a donc que $n - 1$ écarts réellement indépendants : c'est le **nombre de degrés de liberté**.

Une règle qui reviendra sans cesse

On perd un degré de liberté par paramètre estimé à partir des données.

Ici, un seul : m , remplacé par $\bar{x}$. Au chapitre 20, la régression en estimera deux — pente et ordonnée — et le dénominateur sera $n - 2$. Le principe ne change jamais.

Population et échantillon

	Formule	Valeur
Population ($N = 500$)	division par N	$\sigma = 2\,598,10$
Échantillon ($n = 50$)	division par $n - 1$	$s = 2\,250,98$

Le point de vocabulaire

Sur la **population**, on divise par N : ce n'est pas une estimation, c'est une définition. Le cours de descriptive faisait cela.

Sur un **échantillon** dont on veut estimer σ , on divise par $n - 1$. Les deux formules sont correctes, chacune dans son rôle — et c'est pourquoi les calculatrices proposent les deux touches.

Le résultat, pour une population normale

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2$$

La variance d'échantillon, correctement normalisée, suit une loi du khi-deux à $n - 1$ degrés de liberté.

Cela n'a rien d'étonnant

s^2 est une **somme de carrés** d'écarts. Or le khi-deux a été défini, au chapitre 19 des probabilités, comme une somme de carrés de normales centrées réduites.

Le degré de liberté $n - 1$ est le même que celui du dénominateur : ce n'est pas une coïncidence, c'est la même perte d'information.

Ce qu'il faut retenir

Six points

1. Une **proportion est une moyenne** d'indicatrices : tout le chapitre 3 s'y applique.
2. $E(F) = p$ et $\sigma(F) = \sqrt{p(1-p)/n}$.
3. Conditions de normalité : $np \geq 5$ et $n(1-p) \geq 5$.
4. $p(1-p)$ est maximal en 0,5 : c'est le cas défavorable, et donc celui qu'annoncent les sondeurs.
5. La variance d'échantillon se divise par $n - 1$: les écarts sont mesurés à $\bar{x}$, ce qui les rend trop petits.
6. **Un degré de liberté perdu par paramètre estimé** — la règle vaudra jusqu'à la régression.

La suite

Trois distributions d'échantillonnage sont maintenant établies : moyenne, proportion, variance.

Deux d'entre elles font apparaître des lois que le cours de probabilités avait présentées sans dire à quoi elles servaient. Le chapitre 5 boucle cette dette.