Statistique inférentielle

Chapitre 19 : La régression devient un modèle

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 22 octobre 2026

Plan du chapitre

Le changement de statut

Les hypothèses du modèle

Les estimateurs

S'entraîner

Ce qu'il faut retenir

Le changement de statut

Un résumé, et rien de plus

Le chapitre 13 du cours de descriptive calculait, sur les 500 salariés, la droite qui minimise la somme des carrés des écarts :

$$\hat{y} = 4\,347{,}23 + 277{,}17\,x$$

C'était un **résumé du nuage** — une façon commode de décrire cinq cents points par deux nombres. Aucune question d'échantillon n'était en jeu.

Une relation vraie, et son estimation

On pose qu'il existe une relation **vraie**, dans la population, dont les observations ne sont qu'une réalisation :

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

β_0 et β_1 sont des **paramètres** : fixes, inconnus. La droite calculée sur un échantillon n'en est qu'une **estimation**.

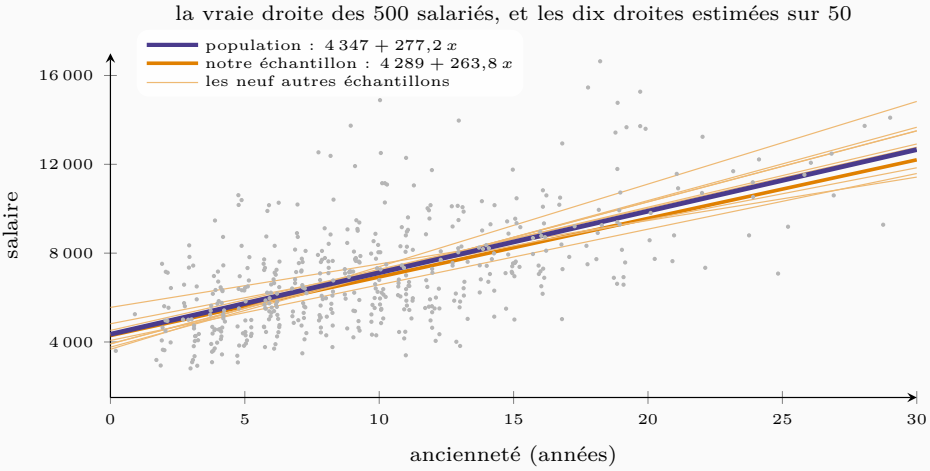
Dans notre cours, la vraie droite est connue

Comme pour $m = 7\,158$, nous connaissons la population. La droite des 500 salariés joue le rôle de la vraie relation :

$$\beta_0 = 4\,347{,}23 \qquad \beta_1 = 277{,}17$$

Le praticien n'a que son échantillon de 50 ; nous pourrons juger ce qu'il en tire.

La droite change avec l'échantillon



Dix échantillons, dix pentes

r	0	1	2	3	4	5	6	7	8	9
$\hat{\beta}_1$	264	320	285	196	275	320	372	251	234	330

Une pente, ça fluctue

Selon l'échantillon tiré, une année d'ancienneté « vaut » de 196 à 372 dirhams. La moyenne des dix pentes, 285, est proche de la vraie valeur 277.

$\hat{\beta}_1$ est une **statistique**, aussi variable que $\overline{x}$: tout le cours s'y applique.

Ce que le terme d'erreur représente

Tout ce qui influence le salaire sans figurer dans le modèle : le poste, la performance, la négociation, la chance.

C'est l'écart entre la vraie droite et l'observation individuelle — **pas** l'écart à la droite estimée, qui s'appelle le *résidu*.

Deux mots à ne pas confondre

$$\varepsilon_i = y_i - (\beta_0 + \beta_1 x_i) \qquad e_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$$

L'**erreur** est inconnue, comme les paramètres. Le **résidu** est calculé, comme la droite. La même distinction que m et $\overline{x}$, appliquée à chaque point.

Un salarié de l'échantillon : 11 ans, 9 170 dirhams

Erreur, par la vraie droite :

$$9\,170 - (4\,347{,}23 + 277{,}17 \times 11) = 9\,170 - 7\,396{,}1 = 1\,773{,}9.$$

Résidu, par la droite estimée :

$$9\,170 - (4\,288{,}72 + 263{,}79 \times 11) = 9\,170 - 7\,190{,}5 = 1\,979{,}5.$$

Proches, mais différents

Les deux écarts diffèrent parce que la droite estimée n'est pas la vraie droite. Ils se rapprochent quand n grandit et que $\widehat{\beta}$ converge vers β.

Les résidus ont une propriété que les erreurs n'ont pas : leur somme vaut exactement **zéro**, par construction. Sur l'échantillon, les 50 erreurs somment à $-9\,813$ dirhams.

Les hypothèses du modèle

Ce qu'il faut supposer pour aller plus loin

Les quatre hypothèses

1. **Linéarité** : la relation vraie est bien une droite.
2. **Espérance nulle** : $E(\varepsilon_i) = 0$ — les erreurs ne penchent pas d'un côté.
3. **Homoscédasticité** : $V(\varepsilon_i) = \sigma_\varepsilon^2$, la même pour tous.
4. **Indépendance** : les erreurs ne sont pas liées entre elles.

Elles ne sont pas décoratives

Sans la deuxième, l'estimateur est biaisé. Sans la troisième et la quatrième, il reste sans biais mais son **écart-type est faux** — donc tous les tests et intervalles qui suivront sont faux.

L'économétrie consiste largement à détecter la violation de ces hypothèses et à y remédier.

Une cinquième, pour les petits échantillons

La normalité des erreurs

Si les ε_i sont normales, tous les résultats du chapitre 20 sont **exacts**, quel que soit n.

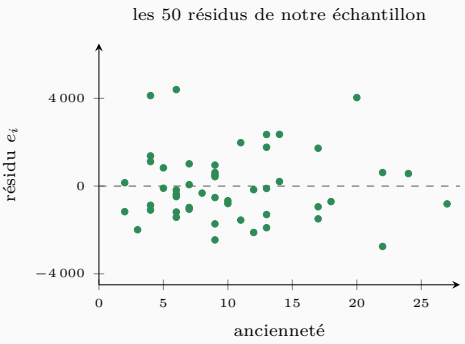
Sinon, ils restent valables **approximativement** pour n grand — par le théorème central limite, une fois de plus.

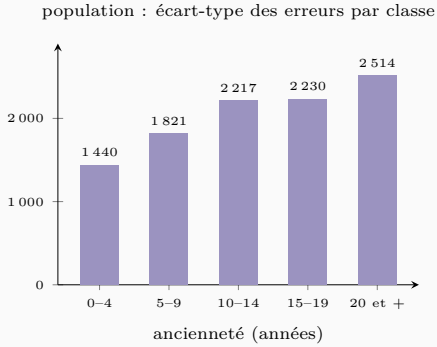
Ce que cela signifie en pratique

Sur cinq cents observations, la normalité des erreurs a peu d'importance.

Sur quinze, elle est décisive — et il faut regarder l'histogramme des résidus avant de publier le moindre test.

Contrôler les hypothèses sur nos données





Ce que montrent les résidus

Deux écarts aux hypothèses

Asymétrie : quelques résidus très positifs (jusqu'à $+4\,400$), aucun aussi négatif. Coefficient d'asymétrie $0{,}90$ sur l'échantillon : les erreurs ne sont pas normales.

Hétéroscédasticité : dans la population, l'écart-type des erreurs passe de $1\,440$ dirhams chez les moins de 5 ans d'ancienneté à $2\,514$ au-delà de 20 ans.

Ce que cela annonce

Les salaires des anciens sont plus dispersés que ceux des nouveaux venus : l'hypothèse 3 est fausse ici.

Le chapitre 20 en mesurera la conséquence : l'erreur-type calculée par la formule classique **sous-estime** la vraie dispersion de la pente.

Les estimateurs

Les moindres carrés ordinaires

$$\hat{\beta}_1 = \frac{\mathrm{cov}(x,y)}{V(x)} = \frac{\sum_i (x_i - \overline{x})(y_i - \overline{y})}{\sum_i (x_i - \overline{x})^2} \qquad \hat{\beta}_0 = \overline{y} - \hat{\beta}_1 \, \overline{x}$$

Ce sont exactement les formules du cours de descriptive. **Le calcul ne change pas ; c'est son interprétation qui change.**

Les cinq nombres nécessaires

n	$\overline{x}$	$\overline{y}$	$\sum(x_i - \overline{x})^2$	$\sum(x_i - \overline{x})(y_i - \overline{y})$
50	10,30	7 005,80	1 716,5	452 803

$$\hat{\beta}_1 = \frac{452\,803}{1\,716{,}5} = 263{,}79 \qquad \hat{\beta}_0 = 7\,005{,}80 - 263{,}79 \times 10{,}30 = 4\,288{,}72$$

Face à la vérité

Pente : $263{,}79$ pour une vraie valeur de $277{,}17$, soit 13 dirhams de moins. Constante : $4\,289$ pour $4\,347$.

Une estimation honorable, mais une estimation : le chapitre 20 dira de combien elle aurait pu se tromper.

Lire les deux coefficients

Ce que dit chaque coefficient

$\hat{\beta}_1 = 263{,}79$: une année d'ancienneté de plus s'accompagne, **en moyenne**, de 264 dirhams de salaire mensuel en plus.

$\hat{\beta}_0 = 4\,288{,}72$: le salaire moyen estimé d'un salarié **sans** ancienneté.

Deux précautions

« S'accompagne de » et non « provoque » : la régression mesure une liaison, comme la corrélation. L'ancienneté va de pair avec l'expérience, l'âge, les promotions.

Et la constante n'a de sens que si $x = 0$ est dans le domaine observé : notre échantillon va de 2 à 27 ans, la constante est donc une **extrapolation**.

Le théorème de Gauss-Markov

Sous les quatre hypothèses, les estimateurs des moindres carrés sont **sans biais** et de **variance minimale** parmi tous les estimateurs linéaires sans biais.

$$E(\hat{\beta}_1) = \beta_1 \qquad V(\hat{\beta}_1) = \frac{\sigma_\varepsilon^2}{\sum_i (x_i - \overline{x})^2}$$

C'est le vocabulaire du chapitre 6

Sans biais, efficace : les deux qualités demandées à un estimateur, démontrées ici pour la pente.

Gauss-Markov n'introduit rien de neuf. Il applique à $\hat{\beta}_1$ les critères que le chapitre 6 avait posés pour $\overline{X}$.

La pente est une moyenne pondérée des erreurs

En remplaçant y_i par $\beta_0 + \beta_1 x_i + \varepsilon_i$ dans la formule :

$$\hat{\beta}_1 = \beta_1 + \sum_i w_i \, \varepsilon_i, \qquad w_i = \frac{x_i - \overline{x}}{\sum_j (x_j - \overline{x})^2}$$

Les deux résultats en découlent

Si $E(\varepsilon_i) = 0$, alors $E(\hat{\beta}_1) = \beta_1$: **sans biais**.

Si les ε_i sont indépendantes de même variance σ_ε^2, alors
$V(\hat{\beta}_1) = \sigma_\varepsilon^2 \sum_i w_i^2 = \sigma_\varepsilon^2 / \sum_i (x_i - \overline{x})^2$.

Lire la formule de la variance

Trois enseignements pratiques

$$V(\hat{\beta}_1) = \frac{\sigma_\varepsilon^2}{\sum_i (x_i - \overline{x})^2}$$

- Moins de **bruit** (σ_ε petit) : pente mieux estimée.
- Plus d'**observations** : le dénominateur grandit, la variance baisse.
- Des x plus **étalés** : le dénominateur grandit aussi.

Le troisième point est le moins connu et le plus utile

Vingt salariés d'ancienneté 1 à 20 ans donnent $\sum (x_i - \overline{x})^2 = 665$. Cent salariés entre 9 et 11 ans ne donnent qu'environ 67.

L'erreur-type est $\sqrt{665/67} \approx 3$ fois plus petite avec vingt observations bien réparties : **on mesure une pente d'autant mieux que le levier est long.**

S’entraîner

À partir des sommes

Sur 10 magasins, on relève la surface x (en centaines de m²) et le chiffre d'affaires y (en millions de dirhams) : $\overline{x} = 5$, $\overline{y} = 20$, $\sum (x_i - \overline{x})^2 = 40$, $\sum (x_i - \overline{x})(y_i - \overline{y}) = 60$.

1. Estimer β_1 et β_0.
2. Interpréter la pente.
3. Prévoir le chiffre d'affaires d'un magasin de 800 m². Et d'un magasin de $3\,000$ m² ?

Les formules de la descriptive

1. $\widehat{\beta}_1 = 60/40 = 1{,}5$ et $\widehat{\beta}_0 = 20 - 1{,}5 \times 5 = 12{,}5$.
2. Cent m² de plus s'accompagnent en moyenne de $1{,}5$ million de chiffre d'affaires en plus.
3. $x = 8 : 12{,}5 + 1{,}5 \times 8 = 24{,}5$ millions. Pour $x = 30$, le calcul donne $57{,}5$, mais c'est une **extrapolation** très loin des données (surfaces autour de 5) : on ne la publie pas.

Un monde simulé où la vraie droite est connue

On sait que $Y = 2 + 3X + \varepsilon$. Trois observations : $(1\,;6)$, $(2\,;7)$, $(3\,;12)$.

1. Calculer les trois erreurs ε_i.
2. Estimer la droite par les moindres carrés.
3. Calculer les trois résidus et comparer leur somme à celle des erreurs.

Les résidus somment à zéro, pas les erreurs

1. $\varepsilon_i = y_i - (2 + 3x_i) : 6 - 5 = 1\,;\, 7 - 8 = -1\,;\, 12 - 11 = 1$. Somme : 1.
2. $\overline{x} = 2, \overline{y} = 8{,}33\,;\, \sum (x_i - \overline{x})^2 = 2, \sum (x_i - \overline{x})(y_i - \overline{y}) = 6$. D'où $\widehat{\beta}_1 = 3$ et $\widehat{\beta}_0 = 2{,}33$.
3. Résidus : $0{,}67\,;\, -1{,}33\,;\, 0{,}67$. Somme : 0. La droite estimée « absorbe » la moyenne des erreurs dans $\widehat{\beta}_0$ ($2{,}33$ au lieu de 2).

Où placer trente observations ?

On veut estimer l'effet du prix x sur les ventes, en testant 30 magasins. L'écart-type des erreurs vaut $\sigma_\varepsilon = 2\,000$.

- Plan A : 10 magasins à chacun des prix 9, 10 et 11 dirhams.
- Plan B : 10 magasins à chacun des prix 1, 10 et 19 dirhams.

1. Calculer $\sum (x_i - \overline{x})^2$ et l'écart-type de $\hat{\beta}_1$ pour chaque plan.
2. Quelle limite le plan B rencontre-t-il ?

Le levier

1. Plan A : $10 \times (1+0+1) = 20$, écart-type $2\,000/\sqrt{20} = 447$. Plan B : $10 \times (81+0+81) = 1\,620$, écart-type $2\,000/\sqrt{1\,620} = 49{,}7$: neuf fois plus précis, à effectif égal.
2. Le plan B suppose que la relation reste **linéaire** de 1 à 19 dirhams. Si elle ne l'est pas, une pente très précise décrit mal la réalité : le levier se paie par l'hypothèse 1.

Ce qu’il faut retenir

Six points

1. La descriptive **résumait** un nuage ; l'inférence pose une relation **vraie** $Y = \beta_0 + \beta_1 X + \varepsilon$. Ici, $\beta_1 = 277{,}17$.
2. **Erreur** ε : inconnue. **Résidu** e : calculé, de somme nulle. Comme m et $\overline{x}$.
3. Quatre hypothèses (linéarité, espérance nulle, variance constante, indépendance), plus la normalité pour les petits n. Nos salaires violent la troisième.
4. Les formules des moindres carrés sont **inchangées** : sur l'échantillon, $\hat{\beta}_1 = 263{,}79$, $\hat{\beta}_0 = 4\,288{,}72$.
5. **Gauss-Markov** : sans biais et de variance minimale — les critères du chapitre 6, appliqués à la pente.
6. $V(\hat{\beta}_1) = \sigma_\varepsilon^2 / \sum (x_i - \overline{x})^2$: moins de bruit, plus d'observations, des x plus étalés.

Une statistique comme les autres

$\widehat{\beta}_1$ est une variable aléatoire dotée d'une loi. Tout ce que le cours a construit — intervalle, test, p-value — s'y applique donc sans une formule nouvelle.

Le prochain chapitre

Le chapitre 20 teste la pente estimée sur l'échantillon, construit son intervalle de confiance, et fait apparaître, dans l'ordre, tous les nombres qu'affiche un logiciel d'économétrie.