Statistique inférentielle

Chapitre 11 : Choisir la taille de l'échantillon

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 31 octobre 2026

Plan du chapitre

La question du commanditaire

Le cas d'une proportion

La taille de la population

Les ajustements du terrain

S'entraîner

Ce qu'il faut retenir

La question du commanditaire

On connaît la réponse avant de collecter

Les chapitres précédents partaient de n pour obtenir une précision. Ici on part de la **précision voulue** et l'on en déduit n.

C'est le seul ordre correct en pratique : la taille d'échantillon se décide **avant** la collecte, jamais après.

Pour une moyenne

$$e = z_{\alpha/2}\,\frac{\sigma}{\sqrt{n}} \qquad \Longrightarrow \qquad \boxed{n = \left(\frac{z_{\alpha/2}\,\sigma}{e}\right)^2}$$

où e est la demi-largeur acceptée, dans l'unité de la variable.

Le salaire moyen à 300 dirhams près

On veut $e = 300$ dirhams à $95\,\%$, avec $\sigma \approx 2\,598$:

$$\sqrt{n} = \frac{1{,}96 \times 2\,598}{300} = 16{,}97 \qquad n = 16{,}97^2 = 288{,}1$$

On arrondit **toujours vers le haut** : $n = 289$ salariés.

Pourquoi vers le haut

Avec 288 observations, la demi-largeur serait de $300{,}05$ dirhams : à peine au-dessus de l'objectif, mais au-dessus. L'arrondi vers le haut garantit la précision promise.

La formule suppose aussi un tirage aléatoire simple et un quantile normal ; pour de petits n, on remplacerait $1{,}96$ par le quantile de Student.

La formule demande un écart-type que l'on ignore

Trois solutions, dans l'ordre de préférence :

1. une **étude antérieure** sur la même population ;
2. un **pré-test** sur une trentaine d'observations ;
3. la règle de l'**étendue** : $\sigma \approx (\max - \min)/4$.

Les trois solutions, sur nos données

Source de σ	Valeur	n pour ± 300 dh
La vraie valeur	$2\,598$	289
Pré-test : les 30 premiers du fil rouge	$2\,255$	218
Étendue des 50 : $(13\,600 - 3\,090)/4$	$2\,628$	295

Un écart-type estimé trop bas

Le pré-test sous-estime σ de $13\,\%$, et la taille calculée de $25\,\%$: avec 218 salariés, la demi-largeur réelle serait de 345 dirhams, et non de 300.

L'écart-type d'un petit échantillon est lui-même imprécis — le chapitre 10 l'a montré. Il entre au carré dans la formule.

La règle de prudence

On majore l'écart-type tiré d'un pré-test, par exemple en prenant la borne haute de son intervalle de confiance, ou en ajoutant 10 à $20\,\%$.

Une enquête trop petite ne peut plus être rattrapée après coup ; une enquête un peu trop grande coûte seulement un peu plus cher.

La taille selon la précision voulue

Avec $\sigma \approx 2\,598$ et une confiance de $95\,\%$:

Précision voulue	± 500 dh	± 300 dh	± 150 dh	± 100 dh
n nécessaire	104	289	$1\,153$	$2\,593$

La taille selon le niveau de confiance

Pour ± 300 dirhams :

Confiance	$90\,\%$	$95\,\%$	$99\,\%$
n nécessaire	203	289	498

Le cas d’une proportion

Pour une proportion

$$n = \frac{z^2_{\alpha/2}\, p(1-p)}{e^2}$$

Ne connaissant pas p, on prend $p = 0{,}5$, qui maximise $p(1-p)$ et donne donc la taille la plus grande — donc sûre.

Les valeurs à connaître

Marge d'erreur	± 5 points	± 3 points	± 2 points	± 1 point
n	385	1 068	2 401	9 604

La marge de 5 points selon la proportion attendue

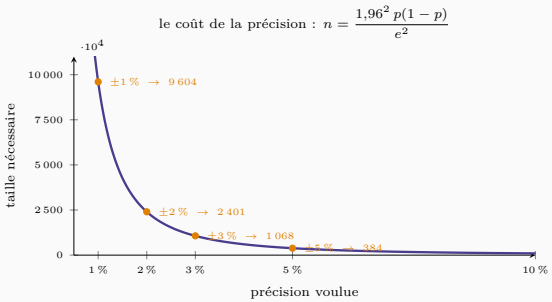
p attendu	$0{,}1$	$0{,}2$	$0{,}214$	$0{,}3$	$0{,}5$
n nécessaire	139	246	259	323	385

Un gain réel, et un risque

Pour les Bac+5, dont on sait la part voisine de $20\,\%$, 259 salariés suffisent au lieu de 385 : un tiers d'économie.

Mais si la proportion réelle est plus proche de $0{,}5$ que prévu, la marge obtenue sera plus large que promis. Le pire cas reste la seule garantie.

Le coût de la précision



Trois usages en gestion

Avant de collecter, on fixe la précision voulue et la formule donne n. C'est le seul ordre correct.

Le budget est une contrainte, pas une variable d'ajustement : diviser n par deux ne dégrade la précision que de $\sqrt{2}$, mais diviser la marge par deux quadruple le coût.

Pour une moyenne, la même logique donne
$n = \left(\dfrac{1{,}96\,\sigma}{e}\right)^2$,
où σ vient d'une étude antérieure ou d'un pré-test.

La précision est un bien à rendement décroissant

n varie comme $1/e^2$: **diviser la marge par deux quadruple la taille**, donc à peu près le budget.

Passer de ± 3 à ± 1 point multiplie le coût par neuf pour gagner deux points.

Pourquoi tant de sondages font mille personnes

Ce chiffre n'a rien de réglementaire : c'est d'abord un compromis économique, la zone où la courbe commence à s'aplatir.

En dessous, on gagne beaucoup de précision pour peu d'argent. Au-dessus, on dépense beaucoup pour peu de précision supplémentaire.

La taille de la population

La taille de la population n'intervient pas

La formule ne contient pas N.

Estimer une proportion à ± 3 points demande environ mille personnes — que la population compte cent mille habitants ou cinquante millions.

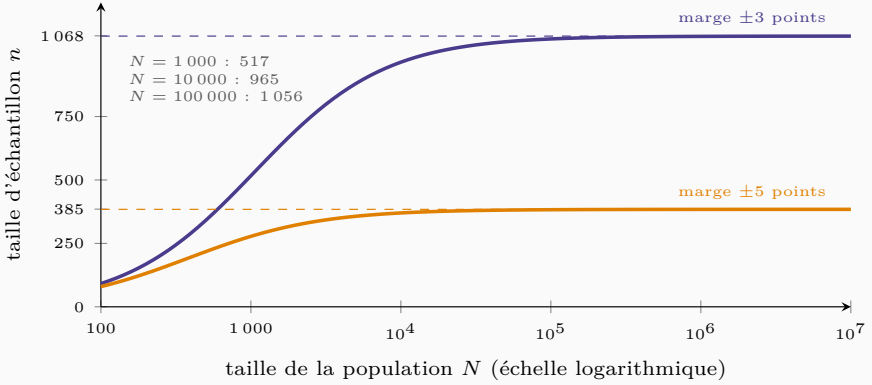
L'image qui le fait comprendre

Pour juger d'une soupe, il faut goûter une cuillère. Il n'en faut pas davantage si la marmite est plus grande — **à condition qu'elle soit bien remuée**.

Ce « bien remuée » est exactement l'hypothèse du chapitre 1 : le tirage doit être aléatoire.

Ce que change la correction de population finie

au-delà de quelques milliers, la taille de la population ne compte plus



La taille ajustée

Si n dépasse $5\,\%$ de N, on peut réduire la taille calculée :

$$n_{\text{ajusté}} = \frac{n}{1 + \dfrac{n-1}{N}}$$

Marge de 3 points, selon N

Population N	$1\,000$	$4\,000$	$10\,000$	$100\,000$	infinie
n ajusté	517	844	966	$1\,057$	$1\,068$

Arrondis à l'entier supérieur, comme partout dans ce chapitre.

Les ajustements du terrain

Contacter plus que l'on n'interroge

Si l'on n'attend que $60\,\%$ de réponses, il faut contacter $n/0{,}60$ personnes pour en obtenir n.

Cela suppose que les non-répondants ressemblent aux répondants. Sinon, contacter plus de monde ne corrige pas le **biais** de non-réponse (chapitre 1).

Un calcul complet, comme en cabinet

Objectif : ± 3 points sur une population de $4\,000$ salariés, taux de réponse attendu $60\,\%$.

$n = 1\,068$, puis ajustement : $1\,068/(1 + 1\,067/4\,000) = 843{,}1$, soit 844.

Enfin : $844/0{,}60 = 1\,406{,}7$, soit $1\,407$ questionnaires à envoyer. **C'est ce dernier nombre qui figure au devis.**

Une précision par région

Une enquête nationale à ± 5 points demande 385 personnes. Si l'on veut **la même précision dans chacune des quatre régions**, il en faut 385 par région : $1\,540$ au total.

La précision se paie par sous-groupe

Un commanditaire qui demande des résultats « par région, par âge et par sexe » multiplie la taille nécessaire par le nombre de cases. C'est la première question à lui poser, avant tout devis.

Multiplier par l’effet de plan

Les formules supposent un tirage aléatoire simple. Pour un autre plan, on multiplie la taille par l’**effet de plan** (*deff*) :

$$n_{\text{plan}} = \text{deff} \times n_{\text{aléatoire simple}}$$

Deux exemples

Un tirage stratifié par diplôme a, sur nos salaires, un effet de plan de $0{,}746$ (chapitre 1) : $289 \times 0{,}746 = 215{,}6$, soit 216 salariés suffisent pour ± 300 dirhams.

Un tirage par grappes d’effet de plan 2 en demande au contraire 578. Le cours d’Échantillonnage calcule ces effets.

Coût fixe et coût unitaire

Le coût d'une enquête s'écrit souvent $C = C_0 + c\,n$: un coût fixe (conception, logiciel, analyse) et un coût par entretien.

Pour un budget B, la taille maximale est $n = (B - C_0)/c$, et la précision accessible s'en déduit.

Un budget de 60 000 dirhams

Coût fixe $15\,000$ dirhams, 150 dirhams par entretien : $n = 45\,000/150 = 300$ salariés.

La demi-largeur accessible pour le salaire moyen vaut $1{,}96 \times 2\,598/\sqrt{300} = 294$ dirhams. Si l'on exige ± 200, le budget ne suffit pas : il faudrait 649 entretiens.

S’entraîner

Une étude sur les loyers

Une étude antérieure donne un écart-type des loyers de $1\,200$ dirhams.

1. Combien de logements faut-il pour estimer le loyer moyen à ± 100 dirhams, à $95\,\%$?
2. Même question à $99\,\%$.
3. Le pré-test donne finalement $s = 1\,400$. De combien la taille du point 1 change-t-elle ?

L'écart-type entre au carré

1. $n = (1{,}96 \times 1\,200/100)^2 = 23{,}52^2 = 553{,}2$, soit 554 logements.
2. $n = (2{,}576 \times 1\,200/100)^2 = 955{,}6$, soit 956 logements.
3. $n = (1{,}96 \times 1\,400/100)^2 = 753{,}0$, soit 753 : $+36\,\%$ pour un écart-type supérieur de $17\,\%$, car $1{,}4^2/1{,}2^2 = 1{,}36$.

Le taux d'équipement en ordinateur

Une enquête veut estimer la part des ménages ruraux équipés d'un ordinateur à ± 3 points, à $95\,\%$. Une enquête ancienne situait cette part vers $15\,\%$.

1. Calculer la taille avec $p = 0{,}15$, puis avec $p = 0{,}5$.
2. Laquelle retenir ? Quel est le risque de chaque choix ?

Économie contre garantie

1. Avec $p = 0{,}15$: $1{,}96^2 \times 0{,}15 \times 0{,}85 / 0{,}03^2 = 544{,}2$, soit 545. Avec $p = 0{,}5$: $1\,068$.
2. 545 ménages suffisent **si** la part reste proche de $15\,\%$. Si l'équipement a progressé jusqu'à $30\,\%$, la marge réelle serait de $\pm 3{,}8$ points. Un compromis raisonnable : prendre $p = 0{,}25$ ou $0{,}30$, plausible maximum aujourd'hui.

La satisfaction des clients d'une banque

Une banque régionale compte $2\,500$ clients. Elle veut leur taux de satisfaction à ± 4 points, à $95\,\%$. Le taux de réponse attendu est de $50\,\%$; chaque questionnaire envoyé coûte 20 dirhams.

1. Calculer la taille théorique, puis la taille ajustée à la population.
2. Combien de questionnaires envoyer, et pour quel coût ?
3. Pourquoi ce calcul suppose-t-il que les non-répondants ressemblent aux répondants ?

Trois étapes, un devis

1. $n = 1{,}96^2 \times 0{,}25 / 0{,}04^2 = 600{,}25$, soit 601. Ajustement : $601 / (1 + 600/2\,500) = 484{,}7$, soit 485 réponses.
2. $485 / 0{,}5 = 970$ questionnaires, pour $970 \times 20 = 19\,400$ dirhams.
3. Doubler les envois augmente le nombre de réponses, pas leur représentativité. Si les mécontents répondent moins, le taux de satisfaction sera surestimé, quelle que soit la taille.

Ce qu’il faut retenir

Six points

1. La taille se calcule **avant** la collecte, à partir de la précision voulue, et s'arrondit vers le haut.
2. Moyenne : $n = (z_{\alpha/2}\,\sigma/e)^2$, avec σ venu d'une étude antérieure ou d'un pré-test — à majorer par prudence.
3. Proportion : $n = z_{\alpha/2}^2\,p(1-p)/e^2$, et l'on prend $p = 0{,}5$ par prudence : 385, $1\,068$, $2\,401$.
4. n varie en $1/e^2$: **diviser la marge par deux quadruple le coût**.
5. La **taille de la population n'intervient presque pas** au-delà de quelques milliers — seule compte la qualité du tirage.
6. Sur le terrain : population finie, taux de réponse, sous-groupes, effet de plan, budget.

La troisième question de l'inférence

Nous savons estimer et encadrer. Reste la troisième question, et la plus fréquente en gestion : **une affirmation est-elle compatible avec les données ?**

C'est la théorie des tests, qui occupe les sept chapitres suivants.

Trois affirmations à mettre à l'épreuve

« Le salaire moyen dépasse $6\,500$ dirhams. » « La part des Bac+5 est de $15\,\%$. » « Les hommes et les femmes ont le même salaire moyen. »

Le chapitre 12 pose la logique commune aux trois tests.