Statistique inférentielle

Chapitre 4 : Les trois lois de l'inférence

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 22 octobre 2026

Plan du chapitre

Une dette envers les probabilités

La loi du khi-deux

La loi de Student

La loi de Fisher

La carte des lois

S'entraîner

Ce qu'il faut retenir

Une dette envers les probabilités

Trois lois présentées, jamais employées

Le chapitre 18 de Probabilités les annonçait

Khi-deux, Student et Fisher y étaient définies comme des lois **fabriquées** à partir de la normale — sans qu'aucun phénomène économique ne les suive.

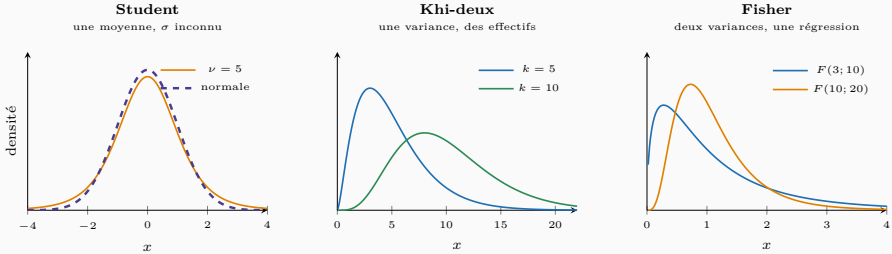
Il était dit qu'elles ne serviraient qu'aux tests. Nous y sommes.

Leur point commun

Aucune ne décrit une population. Toutes décrivent le comportement d'une **statistique calculée sur un échantillon** :

- une variance estimée ;
- une moyenne dont on a dû estimer l'écart-type ;
- un rapport de deux variances estimées.

Les trois, ensemble



Ces trois lois sont exactement celles du chapitre 19 des probabilités — et voici enfin à quoi elles servent.

Student apparaît dès qu'on remplace σ par s : moyenne, différence de moyennes, coefficient de régression.
Khi-deux apparaît dès qu'on additionne des écarts *au carré* : variance d'un échantillon, adéquation, indépendance.
Fisher apparaît dès qu'on compare deux variances : analyse de la variance, test global d'une régression.

Le fil est toujours le même : *quelle statistique je calcule* détermine *quelle loi je dois lire.*

Trois constructions à partir de la normale

Soit $Z, Z_1, \dots, Z_k$ des variables $\mathcal{N}(0\,;1)$ indépendantes.

Loi	Construction	Espérance	Variance
χ^2_k	$Z_1^2 + \cdots + Z_k^2$	k	$2k$
t_k	$Z \Big/ \sqrt{\chi^2_k / k}$	0	$k/(k-2)$
$F_{d_1,\,d_2}$	$(\chi^2_{d_1}/d_1) \Big/ (\chi^2_{d_2}/d_2)$	$d_2/(d_2-2)$	$-$

Le nombre de degrés de liberté

Dans les trois cas, k compte le nombre de carrés **indépendants** que l'on a additionnés. C'est le même nombre que le chapitre 3 a appelé degré de liberté : $n-1$ écarts libres autour de $\overline{x}$.

La loi du khi-deux

Le cas le plus simple : un seul carré

$\chi^2_1 = Z^2$. Or $Z^2 \leq 3{,}84$ équivaut à $|Z| \leq 1{,}96$:

$$P(\chi^2_1 \leq 3{,}84) = P(-1{,}96 \leq Z \leq 1{,}96) = 0{,}95$$

Le quantile à $95\,\%$ du khi-deux à un degré est le carré du quantile normal : $1{,}96^2 = 3{,}84$.

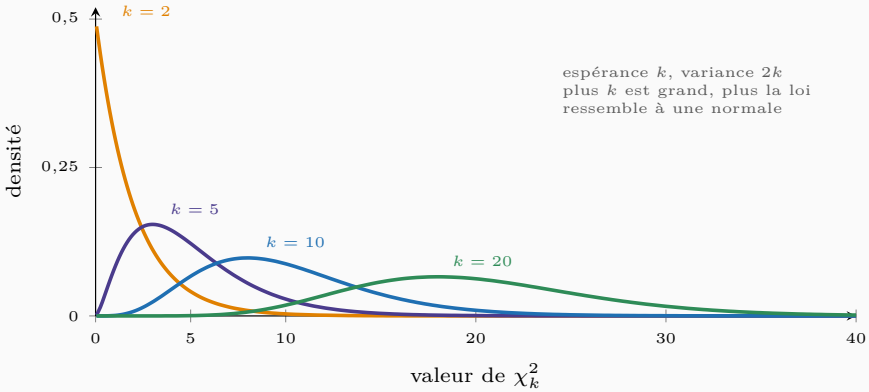
Ajouter des carrés

Chaque carré ajouté apporte en moyenne 1 : d'où $E(\chi^2_k) = k$. La somme ne peut être négative, et elle est étirée à droite, car un seul grand écart suffit à la gonfler.

Quand k grandit, le théorème central limite s'applique à cette somme : la loi devient presque normale.

Sa forme selon le nombre de degrés de liberté

la loi du khi-deux : positive, étirée à droite, centrée sur k



Lire une table du khi-deux

Quelques quantiles

k	$2{,}5\,\%$	$95\,\%$	$97{,}5\,\%$
1	$0{,}001$	$3{,}841$	$5{,}024$
5	$0{,}831$	$11{,}070$	$12{,}833$
10	$3{,}247$	$18{,}307$	$20{,}483$
49	$31{,}555$	$66{,}339$	$70{,}222$

Une loi qui n'est pas symétrique

Pour $k = 49$, l'espérance vaut 49, mais les quantiles à $2{,}5$ et $97{,}5\,\%$ sont à $17{,}4$ en dessous et $21{,}2$ au-dessus.

On ne peut donc jamais écrire « $49 \pm$ quelque chose » : les deux bornes se lisent séparément dans la table. Le chapitre 10 en tirera un intervalle **non centré** pour σ^2.

Variance et tableaux d'effectifs

$$\frac{(n-1)\,S^2}{\sigma^2} \sim \chi^2_{n-1} \qquad \sum_{\text{cases}} \frac{(\text{observé} - \text{attendu})^2}{\text{attendu}} \approx \chi^2$$

Estimation d'une variance d'un côté (chapitres 3 et 10) ; tests d'adéquation et d'indépendance de l'autre (chapitre 18).

Le signe qui ne trompe pas

Dès qu'une procédure additionne des **écarts au carré**, un khi-deux apparaît.

Deux conséquences immédiates : la loi est **positive**, et le test des tableaux est **unilatéral à droite** — seuls les grands écarts contredisent l'hypothèse.

La loi de Student

Le problème

Le chapitre 2 a établi que $\dfrac{\overline{X} - m}{\sigma/\sqrt{n}}$ suit une loi normale.

Mais σ est un paramètre de la population : **inconnu**. On le remplace par S, calculé sur l'échantillon — et la quantité change de loi.

Le résultat, pour une population normale

$$T = \frac{\overline{X} - m}{S/\sqrt{n}} \sim t_{n-1}, \text{ Student à } n-1 \text{ degrés de liberté}$$

Diviser haut et bas par σ

$$T = \frac{\dfrac{\overline{X} - m}{\sigma/\sqrt{n}}}{\sqrt{\dfrac{(n-1)S^2/\sigma^2}{n-1}}} = \frac{Z}{\sqrt{\chi^2_{n-1}/(n-1)}}$$

Le numérateur est normal (chapitre 2) ; le carré du dénominateur est un khi-deux divisé par son degré de liberté (chapitre 3).

La condition cachée

La définition de Student exige que Z et χ^2 soient **indépendantes**. Pour une population normale, $\overline{X}$ et S^2 le sont — un résultat remarquable, propre à la loi normale.

σ a disparu du résultat : c'est ce qui rend T **utilisable**.

Deux sources d'incertitude au lieu d'une

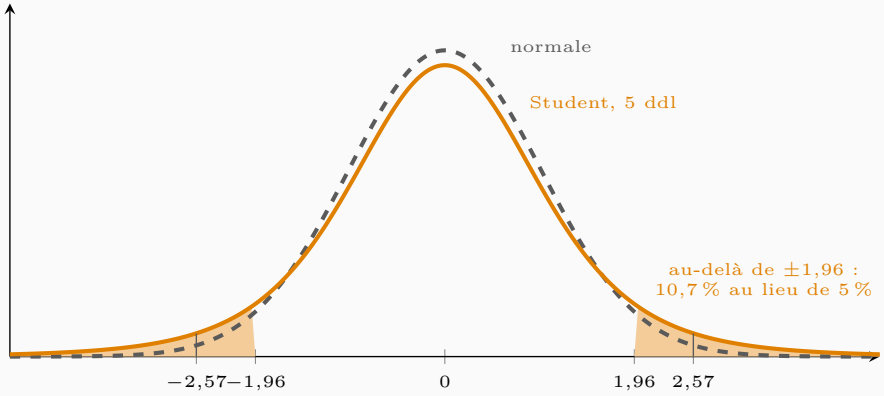
Au numérateur, $\overline{X}$ varie. Au dénominateur, S varie **aussi**.

Quand un petit échantillon donne par hasard un s trop petit, le rapport explose. C'est pourquoi Student a des **queues plus épaisses** que la normale : les valeurs extrêmes y sont plus fréquentes.

Le prix, chiffré

Degrés de liberté	Quantile à $97{,}5\,\%$	Surcoût
5	$2{,}571$	$+31\,\%$
10	$2{,}228$	$+14\,\%$
30	$2{,}042$	$+4\,\%$
∞	$1{,}960$	$-$

Student à 5 degrés de liberté contre la loi normale



Ce qu'on risque à garder 1,96

ddl k	5	10	15	30	49	∞
risque réel	$10{,}7\,\%$	$7{,}8\,\%$	$6{,}9\,\%$	$5{,}9\,\%$	$5{,}6\,\%$	$5\,\%$
variance	$1{,}67$	$1{,}25$	$1{,}15$	$1{,}07$	$1{,}04$	1

Le risque réel est $P(|T_k| > 1{,}96)$; la variance de T_k vaut $k/(k-2)$.

L'erreur que l'on commet sans Student

Avec six observations, utiliser $1{,}96$ au lieu de $2{,}571$ fait passer le risque d'erreur annoncé de $5\,\%$ à plus de $10\,\%$: on se croit deux fois plus sûr qu'on ne l'est.

Au-delà de trente observations, l'écart devient minime.

Cinquante salariés

$n = 50$, donc $\nu = 49$ degrés de liberté, et $t_{0{,}975\,;49} = 2{,}010$ — contre $1{,}96$ pour la normale : un élargissement de $2{,}6\,\%$.

La statistique annoncée à la fin du chapitre 3 vaut $t = (7\,005{,}80 - 7\,158{,}26)/318{,}34 = -0{,}48$, et $P(|T_{49}| \geq 0{,}48) = 0{,}63$: une valeur des plus ordinaires.

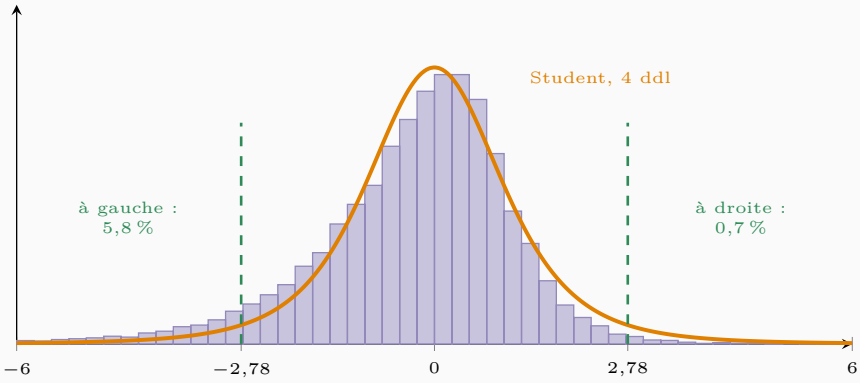
La règle pratique

Utilisez **toujours** Student dès que σ est inconnu, c'est-à-dire pratiquement toujours.

Les logiciels le font sans qu'on le demande. Au-delà de trente observations, la différence ne se voit plus — mais elle ne coûte rien, et en dessous elle est indispensable.

Quand la population n'est pas normale

20 000 valeurs de T calculées sur 5 salaires tirés parmi les 500



attendu : 2,5 % de chaque côté

Cinq salaires, puis cinquante

On tire $20\,000$ échantillons avec remise dans nos salaires, étirés à droite, et l'on calcule T chaque fois.

n	$T < -t$	$T > t$	Total	Attendu
5	$5{,}8\,\%$	$0{,}7\,\%$	$6{,}6\,\%$	$5\,\%$
50	$4{,}3\,\%$	$1{,}4\,\%$	$5{,}8\,\%$	$5\,\%$

Pourquoi la loi penche à gauche

Un échantillon qui contient un gros salaire a une moyenne élevée, mais aussi un s élevé : le rapport reste modéré. Un échantillon de petits salaires a une moyenne basse **et** un petit s : le rapport devient très négatif.

Le total reste proche de $5\,\%$ dès $n = 50$; la répartition entre les deux côtés, non. Le chapitre 15 s'en souviendra pour les tests unilatéraux.

La loi de Fisher

La construction

$$F = \frac{\chi^2_{d_1}/d_1}{\chi^2_{d_2}/d_2}$$

Deux degrés de liberté, un pour chaque variance comparée : d_1 au numérateur, d_2 au dénominateur. L'ordre compte.

Le rapport de deux variances d'échantillon

Pour deux échantillons indépendants, tirés de populations normales de **même** variance :

$$\frac{S_1^2}{S_2^2} \sim F_{n_1-1,\, n_2-1}$$

Si les deux variances sont égales, le rapport est proche de 1 ; un rapport très éloigné de 1 les met en doute.

Comparer deux dispersions, sur nos données

Les hommes et les femmes de l'échantillon

Groupe	Effectif	Écart-type s
Hommes	28	$2\,344{,}86$
Femmes	22	$2\,142{,}01$

$F = 2\,344{,}86^2 / 2\,142{,}01^2 = 1{,}198$, à comparer à $F_{27,\,21}$: 95 % des valeurs sont entre $0{,}447$ et $2{,}335$.

La conclusion

$1{,}198$ est au milieu de la zone : rien n'indique que les salaires des hommes soient plus dispersés que ceux des femmes.

Ce résultat servira au chapitre 16, où la comparaison des **moyennes** suppose, dans sa version classique, des variances égales.

ANOVA et régression

L'analyse de la variance (chapitre 17) compare la dispersion *entre* les groupes à la dispersion *à l'intérieur* des groupes.

Le test global d'une régression (chapitre 20) compare la variance expliquée à la variance résiduelle. Le « F de Fisher » qu'affiche tout logiciel d'économétrie sort de là.

Deux quantiles qui reviendront

$F_{0,95}(2\,;47) = 3{,}195$: le seuil de l'ANOVA des trois diplômes sur notre échantillon de 50.

$F_{0,95}(1\,;48) = 4{,}043 = 2{,}0106^2$: le carré du quantile de Student à 48 degrés.

Une seule famille

Relation	Ce qu'elle dit
$\chi^2_1 = Z^2$	un khi-deux à un degré est un carré de normale
$t_k^2 = F_{1,\,k}$	un Student au carré est un Fisher à un degré
$t_k \to \mathcal{N}(0\,;1)$	Student devient normale quand k grandit
$d_1\, F_{d_1,\,k} \to \chi^2_{d_1}$	Fisher devient khi-deux quand k grandit

Pourquoi c'est utile

Un test de Student bilatéral et un test de Fisher à un degré de liberté donnent **exactement** la même conclusion. Le chapitre 20 le vérifiera sur la régression : $t^2 = F$.

La carte des lois

La carte, en une ligne par cas

Ce que l'on calcule	Loi à lire
une moyenne, σ **connu**	normale
une moyenne, σ **estimé**	Student, $n-1$ ddl
une proportion, n grand	normale
une variance	khi-deux, $n-1$ ddl
des effectifs de tableau	khi-deux
un rapport de variances	Fisher

Le seul réflexe à acquérir

La question n'est jamais « quelle formule ? » mais **« quelle statistique ai-je calculée ? »**.

La statistique détermine la loi ; la loi fournit le seuil ; le seuil donne la conclusion. Cet enchaînement est celui de tous les chapitres qui suivent, sans exception.

Les quantiles en une instruction

Quantile	R	Python (`scipy.stats`)
$t_{0,975\,;49}$	`qt(0.975, 49)`	`t.ppf(0.975, 49)`
$\chi^2_{0,95\,;10}$	`qchisq(0.95, 10)`	`chi2.ppf(0.95, 10)`
$F_{0,95}(2\,;47)$	`qf(0.95, 2, 47)`	`f.ppf(0.95, 2, 47)`

La table papier reste utile

À l'examen, on lit la table ; en entreprise, on demande au logiciel. Dans les deux cas, il faut savoir **quelle** loi et **quels** degrés de liberté demander : aucun logiciel ne le décide à notre place.

S’entraîner

Quatre lectures

À l'aide des tables (ou d'un logiciel), donner :

a. le quantile $t_{0,975}$ à 15 degrés de liberté ;
b. le quantile à $95\,\%$ du khi-deux à 10 degrés de liberté ;
c. le quantile à $95\,\%$ de $F_{3,\,20}$;
d. la probabilité $P(T_{10} > 2{,}228)$.

Puis vérifier que $1{,}96^2 = 3{,}84$ et dire de quel quantile il s'agit.

Quatre valeurs de table

a. $t_{0,975\,;15} = 2{,}131$.
b. $\chi^2_{0,95\,;10} = 18{,}307$.
c. $F_{0,95}(3\,;20) = 3{,}098$.
d. $2{,}228$ est le quantile à $97{,}5\,\%$ de t_{10} : $P(T_{10} > 2{,}228) = 0{,}025$.

$1{,}96^2 = 3{,}8416$: c'est le quantile à $95\,\%$ de χ^2_1, puisque $\chi^2_1 = Z^2$.

Trois statistiques

On dispose de deux échantillons indépendants, de tailles $n_1 = 16$ et $n_2 = 21$, tirés de populations normales de même variance σ^2 ; $\overline{X}_1$ et S_1^2 sont la moyenne et la variance du premier.

Donner la loi de :

1. $\dfrac{\overline{X}_1 - m_1}{S_1/4}$;
2. $15\, S_1^2/\sigma^2$;
3. S_1^2/S_2^2.

La statistique dicte la loi

1. $\sqrt{16} = 4$: c'est le T de Student, à $n_1 - 1 = 15$ degrés de liberté.
2. $(n_1 - 1)S_1^2/\sigma^2 \sim \chi^2_{15}$.
3. Les variances étant égales, $S_1^2/S_2^2 \sim F_{15,\,20}$.

Ce qui fait l'hypothèse

Les trois résultats exigent des populations **normales**. Le troisième exige en plus l'égalité des variances : c'est précisément ce qu'un test de Fisher met à l'épreuve.

Six relevés de prix

Un analyste relève le prix d'un produit dans 6 magasins tirés au hasard. Il calcule $\overline{x}$ et s, puis écrit que la vraie moyenne a $95\,\%$ de chances d'être dans $\overline{x} \pm 1{,}96\, s/\sqrt{6}$.

1. Quel quantile aurait-il dû utiliser ?
2. De combien son intervalle est-il trop étroit ?
3. Quelle est la vraie probabilité de couverture de son intervalle, sachant que $P(|T_5| \leq 1{,}96) = 0{,}893$?

Exercice 3 : solution

Une assurance surévaluée

1. σ est estimé, $n = 6$: Student à 5 degrés de liberté, $t_{0{,}975\,;5} = 2{,}571$.
2. $2{,}571/1{,}96 = 1{,}31$: l'intervalle correct est $31\,\%$ plus large.
3. Son intervalle ne couvre la vraie moyenne qu'avec la probabilité $0{,}893$: il annonce $5\,\%$ de risque et en prend près de $11\,\%$.

La leçon

L'erreur ne se voit pas sur un seul échantillon : elle se paie en moyenne, sur toutes les études faites de la même façon.

Ce qu’il faut retenir

Six points

1. Khi-deux, Student et Fisher décrivent des **statistiques d'échantillon**, jamais des populations.
2. **Khi-deux** : une somme de carrés ; positive, étirée à droite, d'espérance k.
3. **Student** apparaît dès qu'on remplace σ par S : queues plus épaisses, prix de l'ignorance — $31\,\%$ à cinq degrés, $4\,\%$ à trente.
4. Avec une population asymétrique, T penche : le total des queues reste proche de $5\,\%$, leur répartition non.
5. **Fisher** apparaît dès qu'on compare deux variances : ANOVA et régression ; $t_k^2 = F_{1,\,k}$.
6. La statistique calculée détermine la loi à lire — c'est le seul enchaînement à retenir.

La boîte à outils est complète

Nous savons comment se comportent la moyenne, la proportion et la variance d'un échantillon, et quelles lois lire.

La troisième partie s'en sert pour répondre à la première question de l'inférence : **quelle valeur unique retenir pour le paramètre ?**

Trois candidats pour le salaire moyen

Pour estimer m, on pourrait retenir la moyenne $7\,005{,}80$, la médiane de l'échantillon, ou le milieu entre le plus petit et le plus grand salaire.

Lequel est le meilleur, et selon quel critère ? Le chapitre 5 commence par définir ce qu'est un **bon** estimateur.