Statistique inférentielle

Introduction : La troisième face

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 22 octobre 2026

Plan de l'introduction

Prérequis

Où nous sommes

Le vocabulaire

La démarche

Le fil rouge du cours

Le plan du cours

S'entraîner

Ce qu'il faut retenir

Prérequis

Les deux cours qui précèdent

Probabilités : variable aléatoire, espérance, variance, lois **normale**, **binomiale**, **de Student**, **du khi-deux** et **de Fisher**, loi des grands nombres et **théorème central limite**.

Échantillonnage : comment on tire un échantillon, et pourquoi le hasard du tirage est ce qui rend le calcul possible.

Trois quantiles à connaître par cœur

Pour $Z \sim \mathcal{N}(0\,;1)$, la valeur z telle que $P(-z \leq Z \leq z)$ vaut :

Probabilité centrale	$90\,\%$	$95\,\%$	$99\,\%$
Quantile z	$1{,}645$	$1{,}960$	$2{,}576$

Le plus utilisé du cours est le deuxième : $P(-1{,}96 \leq Z \leq 1{,}96) = 0{,}95$.

Repris depuis le début

Distribution d'échantillonnage, estimation, intervalle de confiance et test d'hypothèse sont construits ici, pas à pas.

Le cours ferme la boucle du bloc statistique : la descriptive décrivait un échantillon, les probabilités modélisaient le hasard, l'échantillonnage organisait le tirage — l'inférence conclut de l'échantillon à la population.

Les rappels utilisés sans cesse

Pour des variables $X_1, \dots, X_n$ indépendantes, d'espérance m et d'écart-type σ :

$$E\Big(\sum X_i\Big) = n\,m \qquad V\Big(\sum X_i\Big) = n\,\sigma^2 \qquad V(aX) = a^2\,V(X)$$

Ces trois règles suffisent à établir les deux formules centrales du chapitre 2 : $E(\overline{X}) = m$ et $V(\overline{X}) = \sigma^2/n$.

Où nous sommes

Trois cours derrière nous, et une question restée sans réponse

Ce que nous savons faire

La **statistique descriptive** a résumé cinq cents salaires : moyenne $7\,158{,}26$, écart-type $2\,598{,}10$, une droite qui relie salaire et ancienneté.

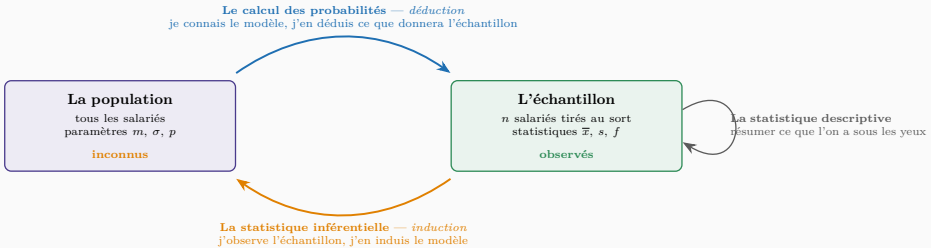
Le **calcul des probabilités** a construit le langage du hasard ; l'**échantillonnage**, la façon de tirer.

Ce que nous ne savons pas encore faire

Un institut interroge 50 salariés et trouve une moyenne de $7\,005{,}80$ dirhams.

Que peut-il en dire de la **population entière** ? Rien, pour l'instant — et c'est précisément l'objet de ce cours.

Les trois faces d'une même discipline



Les trois cours ne sont pas trois matières : ce sont trois sens de circulation entre les deux mêmes boîtes.

La *descriptive* reste dans l'échantillon et le résume. Les *probabilités* descendent de la population vers l'échantillon : le modèle est donné, on en calcule les conséquences. L'*inférence* remonte en sens inverse, et c'est le seul trajet incertain des trois — d'où la nécessité de mesurer cette incertitude.

L'**économétrie** prolongera la flèche orange : au lieu d'un seul paramètre m, elle remontera vers toute une relation entre variables.

Ce que la figure établit

Deux boîtes, trois trajets

Discipline	Trajet	Nature
Statistique descriptive	dans l'échantillon	résumer
Calcul des probabilités	population $\longrightarrow$ échantillon	**déduction**
Statistique inférentielle	échantillon $\longrightarrow$ population	**induction**

Le seul trajet incertain est le nôtre

Descendre est sûr : si l'on sait que $p = 0{,}04$, on calcule sans risque la probabilité de 14 défauts.

Remonter ne l'est pas : d'un échantillon, plusieurs populations différentes auraient pu naître. **L'inférence ne supprime jamais cette incertitude — elle la mesure.** C'est là toute sa valeur.

La déduction, sur nos données

Dans l'entreprise, $21{,}4\,\%$ des salariés ont un Bac+5. On en tire 50 au hasard, avec remise. Le nombre X de Bac+5 tirés suit une loi binomiale $\mathcal{B}(50\,;0{,}214)$:

$$E(X) = 50 \times 0{,}214 = 10{,}7 \qquad P(X = 13) = \binom{50}{13} 0{,}214^{13}\, 0{,}786^{37} = 0{,}095$$

et $P(X \geq 13) = 0{,}261$: un échantillon sur quatre contient au moins treize Bac+5.

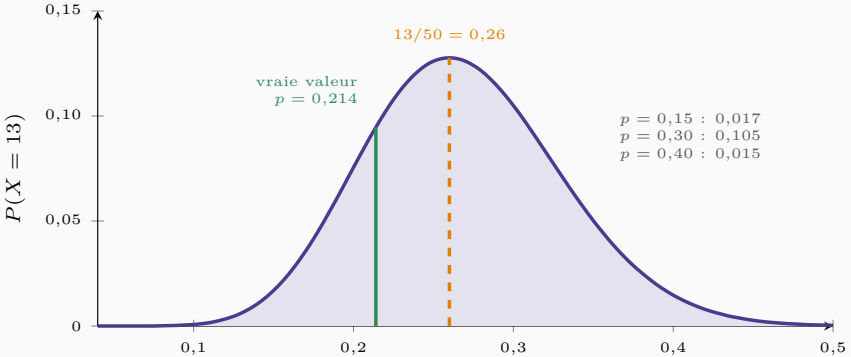
Ce que ce calcul suppose

Il suppose **connue** la proportion $p = 0{,}214$. C'est la situation du cours de probabilités : le modèle est donné, on en déduit ce que l'échantillon produira.

La réponse est un nombre unique, exact. Aucune décision n'est à prendre.

Remonter : plusieurs populations possibles

on observe 13 Bac+5 sur 50 : plusieurs populations ont pu produire ce résultat



L'induction, sur les mêmes données

On ignore maintenant p, et l'on observe 13 Bac+5 sur 50. La courbe donne, pour chaque valeur possible de p, la probabilité d'observer exactement ce résultat :

p	$0{,}15$	$0{,}214$	$0{,}26$	$0{,}30$	$0{,}40$
$P(X = 13)$	$0{,}017$	$0{,}095$	$0{,}128$	$0{,}105$	$0{,}015$

Trois leçons d'un seul tableau

La valeur la plus vraisemblable est $13/50 = 0{,}26$ — pas la vraie valeur $0{,}214$. Des valeurs voisines restent plausibles ; des valeurs éloignées, comme $0{,}10$ ou $0{,}45$, ne le sont presque plus.

Estimer, encadrer, rejeter : les trois gestes du cours sont déjà dans cette courbe.

Le vocabulaire

Deux mots qu'il ne faut jamais confondre

Un **paramètre** décrit la population. Il est **fixe** et **inconnu** : m, σ, p.

Une **statistique** se calcule sur l'échantillon. Elle est **connue** et **aléatoire** : $\overline{x}$, s, f.

La convention de notation, à respecter dès maintenant

Lettres **grecques** ou majuscules latines pour les paramètres ; lettres **latines minuscules** pour les statistiques.

$$m \longleftrightarrow \overline{x} \qquad \sigma \longleftrightarrow s \qquad p \longleftrightarrow f \qquad \beta_1 \longleftrightarrow \widehat{\beta}_1$$

Une copie qui écrit « la moyenne de la population vaut $7\,005{,}80$ » commet, en une phrase, l'erreur fondamentale du cours.

Une même grandeur, trois écritures

Majuscule, minuscule, chapeau

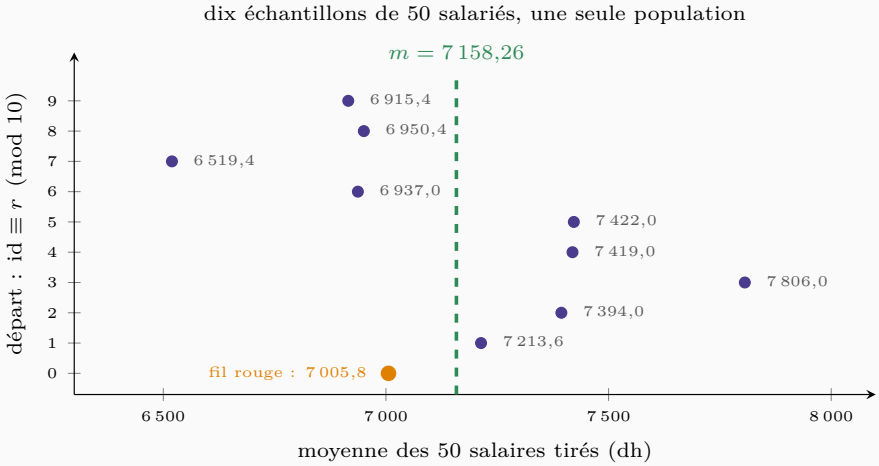
Écriture	Sens	Exemple
m	le paramètre, fixe et inconnu	$7\,158{,}26$
$\overline{X}$	la statistique **avant** le tirage	variable aléatoire
$\overline{x}$	sa valeur **après** le tirage	$7\,005{,}80$
$\widehat{m}$	l'estimation retenue pour m	ici $\widehat{m} = \overline{x}$

Pourquoi distinguer X et x

Avant le tirage, on peut parler de la loi de $\overline{X}$, de son espérance, de sa variance. Après, $\overline{x}$ est un nombre : il n'a ni espérance ni variance.

Les formules du cours portent toutes sur les majuscules ; les applications numériques, sur les minuscules.

Le mot le plus important est « aléatoire »



Dix échantillons, dix réponses

Ce que montre la figure

Les 500 salariés se répartissent en dix échantillons systématiques de 50, selon le dernier chiffre de l'identifiant. Les dix moyennes vont de $6\,519{,}4$ à $7\,806{,}0$ dirhams.

Dix nombres différents, calculés sur la même population, par la même méthode. Le nôtre, $7\,005{,}80$, n'est que l'un d'eux.

La conséquence

$\overline{X}$ n'est pas un nombre : c'est une **variable aléatoire**, avec une loi, une espérance et un écart-type.

Toute la statistique inférentielle consiste à connaître cette loi, puis à s'en servir.

Ce que les dix moyennes ont en commun

Deux calculs sur les dix moyennes

Leur **moyenne** vaut exactement $7\,158{,}26 = m$: les dix échantillons se partagent les 500 salariés, chacun compte une fois.

Leur **écart-type** vaut 346 dirhams. La théorie du chapitre 2 annonce, pour un tirage aléatoire simple de 50 parmi 500, une valeur de 349 : la dispersion des moyennes était prévisible.

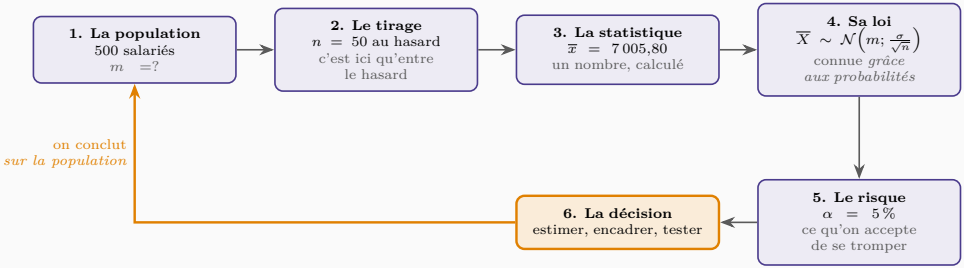
Le centre et la largeur

Une méthode d'estimation se juge à deux choses : se trompe-t-elle **en moyenne** — ici non — et **de combien** se trompe-t-elle d'un échantillon à l'autre — ici d'environ 350 dirhams.

Ce sont les deux notions des chapitres 5 et 6 : le **biais** et la **variance** d'un estimateur.

La démarche

Les six étapes, une fois pour toutes



La quatrième étape est la seule qui demande un cours entier de probabilités, et c'est elle qui rend l'inférence possible : sans connaître la loi de $\overline{X}$, un écart entre 7 005,80 et une valeur annoncée ne voudrait rien dire.

Les six étapes ne changent jamais. Seule change la statistique calculée à l'étape 3 — une moyenne, une proportion, une variance, une pente de régression — et donc la loi de l'étape 4.

Les six étapes sur un exemple

Le salaire moyen dépasse-t-il 6 500 dirhams ?

1. **Population** : les 500 salariés, de moyenne m inconnue.
2. **Tirage** : 50 salariés, un identifiant sur dix.
3. **Statistique** : $\overline{x} = 7\,005{,}80$, $s = 2\,250{,}98$.
4. **Sa loi** : si $m = 6\,500$, $T = (\overline{X} - 6\,500)/(S/\sqrt{50})$ suit une loi de Student à 49 degrés de liberté.
5. **Le risque** : on accepte $5\,\%$ de conclusions fausses.
6. **La décision** : $t = 1{,}59$, inférieur au seuil $1{,}68$; on ne conclut pas.

Une conclusion prudente, et juste

La vraie moyenne, $7\,158{,}26$, dépasse bien $6\,500$. Le test n'a pas su le montrer avec cinquante salariés — il ne s'est pas trompé pour autant : il a dit qu'il ne savait pas.

Le chapitre 14 reviendra sur ce résultat, dont la p-value vaut $0{,}059$.

Le programme du cours

Question	Réponse	Chapitres
Quelle valeur retenir ?	**estimation ponctuelle**	5 à 7
Avec quelle précision ?	**intervalle de confiance**	8 à 11
Cette affirmation tient-elle ?	**test d'hypothèse**	12 à 18

Trois questions, un seul outil

Les trois reposent sur la même chose : la **loi de la statistique calculée**.

Estimer, encadrer et tester ne sont pas trois méthodes ; ce sont trois façons de lire une même distribution d'échantillonnage.

Les trois réponses, sur notre échantillon

Ce que le cours permettra d'écrire

Question	Réponse sur les 50 salariés	Chapitre
Estimer m	$\widehat{m} = 7\,005{,}80$ dirhams	5
Encadrer m	$[6\,366\,;\,7\,646]$ à $95\,\%$	9
Tester $m > 6\,500$	p-value $0{,}059$: non conclu	15

Et la vraie valeur ?

$m = 7\,158{,}26$: l'estimation se trompe de 152 dirhams, l'intervalle contient la vraie valeur, le test reste prudent.

Nous connaissons m parce que la population est sous nos yeux. Dans la vraie vie, on ne le saura jamais — d'où l'intérêt de méthodes dont on connaît **à l'avance** la fiabilité.

Trois décisions, trois inférences

- Un **contrôle qualité** ne teste pas tous les articles : il conclut sur le lot à partir de quelques pièces.
- Un **sondage** interroge mille personnes et annonce un résultat national.
- Une **étude de marché** teste un produit sur un quartier et décide d'un lancement.

Dans les trois cas, la décision porte sur ce qu'on n'a **pas** observé.

Pourquoi on ne mesure pas tout

Trois raisons, et elles suffisent : le **coût**, le **délai**, et la **destruction** — on ne peut pas tester la durée de vie de toutes les ampoules produites, il n'en resterait aucune à vendre.

Quand un recensement complet est possible et peu coûteux, l'inférence est inutile. Elle n'est pas une commodité intellectuelle : elle est une **nécessité économique**.

Un chiffre officiel est presque toujours une estimation

L'enquête emploi du HCP

Le taux de chômage publié chaque trimestre au Maroc ne vient pas d'un recensement : l'Enquête nationale sur l'emploi interroge environ $90\,000$ ménages par an, sur plus de 9 millions.

Un ménage sur cent environ. Le chiffre annoncé est une **statistique**, et le vrai taux, un **paramètre** que personne n'observe.

Ce que cela impose de lire

Une hausse du chômage de $0{,}2$ point d'un trimestre à l'autre est-elle réelle, ou due au seul hasard du tirage ? La question n'a de réponse qu'avec les outils de ce cours.

Lire un chiffre officiel sans sa précision, c'est prendre une statistique pour un paramètre.

Le fil rouge du cours

Le jeu de données

Le fichier `salaires.csv` du cours de statistique descriptive : 500 salariés, six colonnes — identifiant, salaire, ancienneté, diplôme, région, sexe.

Effectif N	Moyenne m	Écart-type σ	Bac+5 p
500	$7\,158{,}26$	$2\,598{,}10$	$0{,}214$

Les variables que le cours mobilisera

Variable	Nature	Servira à
salaire	quantitative continue	moyennes, intervalles, tests
ancienneté	quantitative discrète	régression (ch. 19 et 20)
diplôme	qualitative ordonnée, 3 modalités	ANOVA (ch. 17)
sexe	qualitative, 2 modalités	deux groupes, khi-deux

Un dispositif volontaire

Une population dont on connaît tout

Ces cinq cents salariés seront traités comme **la population**, dont nous connaissons donc les paramètres.

Nous y tirerons des échantillons, nous ferons semblant d'ignorer m, et nous **vérifierons** à chaque étape que la méthode retrouve bien la vraie valeur. C'est la seule façon de voir fonctionner l'inférence de l'intérieur.

Ce que la vraie vie ne permet pas

Un institut ne connaît jamais m : s'il la connaissait, il n'aurait pas besoin d'enquêter. Il ne peut donc pas vérifier son résultat.

Sa seule garantie est la **méthode** : un procédé dont on a établi, une fois pour toutes, qu'il se trompe rarement et de peu. Notre population connue sert à établir cette garantie.

Un salarié sur dix

Nous retiendrons les individus dont l'identifiant est un multiple de dix : $n = 50$ observations.

Grandeur	Symbole	Valeur
Moyenne d'échantillon	$\overline{x}$	$7\,005{,}80$
Écart-type corrigé	s	$2\,250{,}98$
Erreur-type	$s/\sqrt{n}$	$318{,}34$
Part des Bac+5	f	$13/50 = 0{,}26$

Un choix reproductible

Ce tirage ne dépend d'aucune graine aléatoire : n'importe quel étudiant, sous R, sous Python ou sur tableur, retrouvera exactement ces nombres.

C'est une exigence de méthode : **un résultat statistique qu'on ne peut pas reproduire n'est pas un résultat.**

Le calcul, étape par étape

On somme les 50 salaires : $350\,290$ dirhams, d'où $\overline{x} = 350\,290/50 = 7\,005{,}80$.

On somme les carrés des écarts à $\overline{x}$: $248\,277\,818$. On divise par $n - 1 = 49$, et l'on prend la racine :

$$s = \sqrt{\frac{248\,277\,818}{49}} = \sqrt{5\,066\,894{,}2} = 2\,250{,}98$$

Enfin $s/\sqrt{50} = 2\,250{,}98/7{,}071 = 318{,}34$.

Pourquoi diviser par 49 et non par 50

Le cours de statistique descriptive divisait par n. L'inférence divise par $n - 1$ dès qu'il s'agit d'**estimer** la variance de la population.

Le chapitre 3 montre pourquoi : diviser par n sous-estime la variance, en moyenne, d'un facteur $(n - 1)/n$.

Le plan du cours

Le parcours

Partie	Unités	Partie	Unités
1. La démarche	intro, 1	5. Décider	12 à 14
2. Les lois	2 à 4	6. Les tests usuels	15 à 18
3. Estimer	5 à 7	7. Vers l'économétrie	19 à 21
4. Encadrer	8 à 11		

La colonne vertébrale

Les parties 3 à 6 utilisent toutes les lois établies dans la partie 2. La partie 7 applique la même mécanique à une pente de régression : c'est l'entrée directe dans le cours d'économétrie.

S’entraîner

Exercice 1 : paramètre ou statistique ?

Six phrases à classer

Pour chaque phrase, dire si le nombre est un **paramètre** ou une **statistique**, et donner son symbole.

a. Le salaire moyen des 500 salariés de l'entreprise est de $7\,158{,}26$ dirhams.
b. Les 50 salariés interrogés gagnent en moyenne $7\,005{,}80$ dirhams.
c. $26\,\%$ des salariés interrogés ont un Bac+5.
d. La part des Bac+5 dans l'entreprise est de $21{,}4\,\%$.
e. L'écart-type des salaires de l'échantillon vaut $2\,250{,}98$ dirhams.
f. Le taux de chômage publié par le HCP pour un trimestre.

Exercice 1 : solution

Le critère : sur qui porte le calcul ?

a. **Paramètre** m : il porte sur toute la population.

b. **Statistique** $\overline{x}$: elle porte sur les 50 interrogés.

c. **Statistique** $f = 0{,}26$.

d. **Paramètre** $p = 0{,}214$.

e. **Statistique** s.

f. **Statistique** : elle est calculée sur l'échantillon de l'enquête emploi. Le vrai taux de chômage, inconnu, est le paramètre qu'elle estime.

Le piège de la phrase f

Le chiffre publié **ressemble** à un paramètre, parce qu'il parle de tout le pays. Mais il est calculé sur un échantillon : c'est une statistique, entachée d'une erreur que la publication devrait accompagner.

Un lot de pièces

Une machine produit $4\,\%$ de pièces défectueuses. On contrôle 50 pièces, tirées au hasard d'un très grand lot. Soit X le nombre de défauts.

1. Quelle est la loi de X ? Calculer $E(X)$, $P(X = 0)$ et $P(X \leq 2)$.
2. Un jour, le contrôle trouve 5 défauts. Sachant que $P(X \geq 5) = 0{,}049$ quand $p = 0{,}04$, que peut-on en penser ?
3. Laquelle des deux questions relève du calcul des probabilités, laquelle de l'inférence ?

Deux trajets opposés

1. $X \sim \mathcal{B}(50\,;0{,}04)$, $E(X) = 2$. $P(X = 0) = 0{,}96^{50} = 0{,}130$ et $P(X \leq 2) = 0{,}677$.
2. Si la machine produisait vraiment $4\,\%$ de défauts, un résultat aussi mauvais n'arriverait qu'une fois sur vingt environ. C'est possible, mais peu crédible : on soupçonne un **déréglage**.
3. La question 1 **descend** du modèle connu vers l'échantillon : probabilités. La question 2 **remonte** de l'échantillon vers le modèle : inférence. Le chapitre 12 en fera un test.

Ce que coûte le hasard du tirage

Les dix moyennes de la figure sont : $7\,005{,}8$; $7\,213{,}6$; $7\,394{,}0$; $7\,806{,}0$; $7\,419{,}0$; $7\,422{,}0$; $6\,937{,}0$; $6\,519{,}4$; $6\,950{,}4$; $6\,915{,}4$.

1. Calculer leur moyenne et la comparer à $m = 7\,158{,}26$. Pourquoi l'égalité est-elle exacte ?
2. Quelle est la plus grande erreur commise sur m par l'un des dix échantillons ?
3. Un institut qui ne tire qu'un échantillon peut-il savoir lequel des dix il a obtenu ?

Juste en moyenne, faux pour chacun

1. La somme vaut $71\,582{,}6$, la moyenne $7\,158{,}26 = m$. L'égalité est exacte parce que les dix échantillons, de même taille, se partagent toute la population.
2. L'échantillon de départ 3 : $7\,806{,}0 - 7\,158{,}26 = 647{,}7$ dirhams, soit $9\,\%$ de la vraie valeur.
3. **Non**. C'est tout le problème : on ne connaît pas l'erreur de **son** échantillon, seulement la loi des erreurs possibles. L'inférence raisonne sur cette loi.

Ce qu’il faut retenir

Six points

1. Les probabilités descendent vers l'échantillon ; l'inférence **remonte** vers la population.
2. Ce trajet est le seul **incertain** : le cours sert à mesurer cette incertitude.
3. Un **paramètre** est fixe et inconnu ; une **statistique** est connue et aléatoire.
4. $\overline{X}$ change d'un échantillon à l'autre : c'est une **variable aléatoire**.
5. Estimer, encadrer, tester : trois lectures d'une même **distribution d'échantillonnage**.
6. Le fil rouge : 500 salariés ($m = 7\,158{,}26$), dont 50 tirés ($\overline{x} = 7\,005{,}80$).

La condition de tout le reste

Tout ce qui précède suppose une chose que nous n'avons pas encore examinée : que l'échantillon **représente** la population.

Cette condition n'est pas automatique, et aucune formule ne la remplace. Le chapitre 1 précise ce qu'elle exige de l'inférence.

Le modèle que le chapitre 1 va poser

Les observations $X_1, X_2, \dots, X_n$ seront traitées comme des variables aléatoires **indépendantes**, de **même loi** que la variable étudiée dans la population.

C'est le modèle d'**échantillon aléatoire simple**. Tout le cours en découle ; tout le cours en dépend.