

Chapitre 9

La détection de communautés


Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Théorie des réseaux

1 Exercices du chapitre

Correction — Exercice 1



(a) Degrés : $k_A = 2, k_B = 3, k_C = 3, k_D = 3, k_E = 4, k_F = 2, k_G = 3, k_H = 2$. Somme = $2 + 3 + 3 + 3 + 4 + 2 + 3 + 2 = 22 = 2m$ (avec $m = 11$). ✓

(b) Groupe $\{A, B, C, D\}$: $m_c = 5$ (arêtes AB, AC, BC, BD, CD), $d_c = 2 + 3 + 3 + 3 = 11$. Groupe $\{E, F, G, H\}$: $m_c = 5$ (arêtes EF, EG, EH, FG, GH), $d_c = 4 + 2 + 3 + 2 = 11$.

$$Q = \left(\frac{5}{11} - \left(\frac{11}{22} \right)^2 \right) \times 2 = 2 \times (0,4545 - 0,25) = \mathbf{0,4091}$$

(c) Groupe $\{A, B, E, F\}$: arêtes internes = AB et EF seulement, $m_c = 2$; $d_c = 2 + 3 + 4 + 2 = 11$. Groupe $\{C, D, G, H\}$: arêtes internes = CD et GH , $m_c = 2$; $d_c = 3 + 3 + 3 + 2 = 11$.

$$Q = 2 \times \left(\frac{2}{11} - \left(\frac{11}{22} \right)^2 \right) = 2 \times (0,1818 - 0,25) = \mathbf{-0,1364}$$

Le signe négatif indique que cette partition regroupe **moins** de liens en interne que ce que le hasard produirait à degrés égaux : c'est une pire partition que l'absence totale de partition ($Q = 0$).

(d) Groupe $\{A, B, C\}$: $m_c = 3$ (triangle complet), $d_c = 2 + 3 + 3 = 8$. Groupe $\{D, E, F, G, H\}$: arêtes internes = DE, EF, EG, EH, FG, GH , soit $m_c = 6$; $d_c = 3 + 4 + 2 + 3 + 2 = 14$.

$$Q = \left(\frac{3}{11} - \left(\frac{8}{22} \right)^2 \right) + \left(\frac{6}{11} - \left(\frac{14}{22} \right)^2 \right) = (0,2727 - 0,1322) + (0,5455 - 0,4050) = \mathbf{0,2810}$$

C'est **moins bon** que la partition (b) ($0,2810 < 0,4091$) : déplacer D vers le second groupe dilue la cohésion de $\{A, B, C\}$ (qui perd son quatrième membre bien connecté) sans gain compensatoire côté droit. Le nœud D appartient bien plus naturellement au premier groupe.

Correction — Exercice 2

(a) $\Delta Q = \frac{A_{ij}}{m} - \frac{k_i k_j}{2m^2}$: le premier terme est le gain de lien direct (normalisé), le second est la pénalité liée au produit des degrés (plus les deux nœuds sont déjà connectés au reste du réseau, plus leur rapprochement était « attendu par le hasard », donc moins il rapporte).

(b) $3 \rightarrow \{1\}$: $\Delta Q = \frac{1}{7} - \frac{3 \times 2}{2 \times 49} = 0,142857 - 0,061224 = \mathbf{0,081633}$.

(c) $3 \rightarrow \{2\}$: par symétrie ($A_{32} = 1, k_2 = 2$), $\Delta Q = \mathbf{0,081633}$ également. $3 \rightarrow \{4\}$: $\Delta Q = \frac{1}{7} - \frac{3 \times 3}{2 \times 49} = 0,142857 - 0,091837 = \mathbf{0,051020}$.

(d) Le gain est **maximal et à égalité** pour rejoindre 1 ou 2 (0,0816), strictement supérieur au gain de rejoindre 4 (0,0510) malgré le fait que 3 soit tout autant lié à 4 ($A_{34} = A_{31} = A_{32} = 1$). La règle gloutonne choisit donc 1 ou 2 (à égalité, on tranche arbitrairement) — **pas** nécessairement ce que l'intuition suggérerait en pensant à 3 comme « pont » entre les deux triangles. La raison est purement arithmétique : $k_4 = 3 > k_2 = k_1 = 2$, donc la pénalité $k_3 k_4 / (2m^2)$ est plus lourde que $k_3 k_1 / (2m^2)$. Ce résultat illustre que Louvain optimise une quantité précise (ΔQ), pas une notion intuitive de « où le nœud semble appartenir ».

Correction — Exercice 3

(a) Séparés, T_1 contribue $m_{c_1}/m - (d_{c_1}/2m)^2$ avec $m_{c_1} = 3$ et $d_{c_1} = k_1 + k_2 + k_3 = 2 + 2 + 3 = 7$ (le nœud 3 compte le pont dans son degré). De même pour T_2 : $m_{c_2} = 3, d_{c_2} = 7$. Somme $= 2 \left(\frac{3}{m} - \left(\frac{7}{2m} \right)^2 \right) = \frac{6}{m} - 2 \left(\frac{7}{2m} \right)^2$.

(b) Fusionnés, le pont 3-4 devient interne : $m_c = 3 + 3 + 1 = 7, d_c = 7 + 7 = 14$. Contribution $= \frac{7}{m} - \left(\frac{14}{2m} \right)^2$.

(c) $\Delta Q = (b) - (a) = \left(\frac{7}{m} - \frac{6}{m} \right) - \left(\frac{49}{m^2} - \frac{2 \times 49}{4m^2} \right) = \frac{1}{m} - \frac{49 - 24,5}{m^2} = \frac{1}{m} - \frac{24,5}{m^2} = \frac{m - 24,5}{m^2}$.

$\Delta Q > 0 \iff m > 24,5$: la fusion devient préférable dès que le réseau total dépasse 24 à 25 arêtes, **quelle que soit la densité interne** de T_1 et T_2 (qui, elle, ne change jamais : ce sont toujours deux triangles parfaits).

(d) Avec $p = 5$ ($m = 17 < 24,5$) : $Q_{\text{séparé}} = 0,5104 > Q_{\text{fusionné}} = 0,4844$ — la séparation est bien optimale, comme l'intuition le suggère (deux triangles denses reliés par un seul pont). Avec $p = 8$ ($m = 35 > 24,5$) : $Q_{\text{séparé}} = 0,3114 < Q_{\text{fusionné}} = 0,3200$ — la modularité **préfère désormais la fusion**, alors que T_1 et T_2 n'ont pas changé d'un iota ! Seul le reste du réseau a grandi. Ce contraste illustre exactement la limite de résolution de Fortunato et Barthélemy : sur un grand réseau, la modularité maximise en fusionnant systématiquement les petites communautés denses, même parfaitement séparées, parce que le terme attendu $k_i k_j / 2m$ se dilue avec la taille totale m du réseau. La modularité n'est donc **pas** un outil fiable, en toute généralité, pour détecter de petites structures dans un grand réseau.

2 Exercice cumulatif

Correction — Exercice 4

(a) $m_c = 4$ (arêtes 12, 13, 23, 34), $d_c = 2 + 2 + 3 + 2 = 9$. Second groupe : $m_c = 3$ (arêtes 45, 56, 57, 67... attention, seules 56, 57, 67 sont internes à $\{5, 6, 7\}$, donc $m_c = 3$), $d_c = 3 + 2 + 2 = 7$.

$$Q = \left(\frac{4}{8} - \left(\frac{9}{16} \right)^2 \right) + \left(\frac{3}{8} - \left(\frac{7}{16} \right)^2 \right) = (0,5 - 0,3164) + (0,375 - 0,1914) = \mathbf{0,3672}$$

(b) Par symétrie du réseau (l'échange $1 \leftrightarrow 7, 2 \leftrightarrow 6, 3 \leftrightarrow 5, 4 \rightarrow 4$ est un automorphisme du graphe — déjà noté au chapitre 3 pour expliquer l'égalité $C_C(3) = C_C(5)$), la partition $\{1, 2, 3\} \cup \{4, 5, 6, 7\}$ est l'image miroir exacte de la partition (a) : $m_c = 3$ et 4, $d_c = 7$ et 9, donnant **le même** $Q = 0,3672$.

(c) Groupe $\{1, 2, 3\}$: $m_c = 3, d_c = 7$. Groupe $\{4\}$: $m_c = 0, d_c = 2$. Groupe $\{5, 6, 7\}$: $m_c = 3, d_c = 7$.


$$Q = \left(\frac{3}{8} - \left(\frac{7}{16} \right)^2 \right) + \left(0 - \left(\frac{2}{16} \right)^2 \right) + \left(\frac{3}{8} - \left(\frac{7}{16} \right)^2 \right) = 0,1836 + 0,1836 - 0,0156 = \mathbf{0,3516}$$

C'est **moins bon** que (a)/(b) ($0,3516 < 0,3672$) : isoler 4 dans sa propre communauté coûte en modularité, même si cela paraît plus « honnête » vis-à-vis de son rôle ambigu.

(d) Calcul direct (Brandes, chapitre 3) : l'arête 3-4 porte une intermédialité de 12, tout comme 4-5 — toutes deux strictement supérieures à celles des autres arêtes (1 pour 1-2 et 6-7, 5 pour les quatre arêtes des deux triangles). Ceci confirme numériquement l'affirmation du cours. Girvan-Newman retirerait donc en premier l'une de ces deux arêtes (à égalité), fragmentant immédiatement le réseau en trois morceaux $\{1, 2, 3\}, \{4\}$ (ou $\{4, 5, 6, 7\}$ selon laquelle des deux arêtes à égalité est retirée en premier) et le reste — retrouvant, par une voie complètement différente (les chemins les plus courts plutôt que la densité de liens), la même conclusion que la modularité à la question (c) : le nœud 4 n'appartient vraiment à aucune des deux communautés.

3 Applications en sciences économiques

Correction — Exercice 5



- (a) $k_{C_1} = 2$ (vers C_2, C_3) + 9 (vers chaque P_i) = **11**. $k_{P_1} = 3$ (vers C_1, C_2, C_3), soit **3** pour chaque banque périphérique.
- (b) Groupe $\{C_1, P_1, P_2, P_3\}$: arêtes internes = C_1P_1, C_1P_2, C_1P_3 (les arêtes C_1C_2 et C_1C_3 sont **coupées**, de même que P_1C_2, P_1C_3 , etc.) = 3; $d_c = 11 + 3 + 3 + 3 = 20$. Par symétrie, les trois groupes ont chacun $m_c = 3, d_c = 20$.

$$Q = 3 \times \left(\frac{3}{30} - \left(\frac{20}{60} \right)^2 \right) = 3 \times (0,1 - 0,1111) = \mathbf{-0,0333}$$

Négatif : cette partition regroupe **moins** de liens en interne que ne le ferait un recâblage purement aléatoire à degrés identiques.

- (c) Groupe cœur $\{C_1, C_2, C_3\}$: $m_c = 3$ (le triangle interne), $d_c = 11 \times 3 = 33$. Groupe périphérie : $m_c = 0$ (aucune arête P_i-P_j), $d_c = 3 \times 9 = 27$.

$$Q = \left(\frac{3}{30} - \left(\frac{33}{60} \right)^2 \right) + \left(0 - \left(\frac{27}{60} \right)^2 \right) = (0,1 - 0,3025) + (0 - 0,2025) = \mathbf{-0,4050}$$

Bien pire encore.

- (d) $Q = 0$ (aucune partition, tout le réseau en un seul bloc) est le point de référence « neutre ». Les deux partitions testées font **moins bien** que ce point neutre ($-0,0333$ et $-0,4050$, toutes deux négatives). Il faut en conclure qu'**aucune partition sensée de ce réseau n'améliore la modularité** : la structure cœur-périphérie ne possède, par construction, aucune communauté au sens de Newman-Girvan. Ceci confirme exactement l'avertissement du cours : les banques périphériques sont reliées de façon symétrique aux trois banques cœur (jamais entre elles), si bien qu'aucun sous-groupe n'est « plus dense en interne qu'avec l'extérieur » — appliquer un algorithme de détection de communautés à ce marché produirait une partition arbitraire et trompeuse. Le bon outil ici n'est pas la détection de communautés, mais une mesure de centralité (chapitres 3-4) pour identifier le cœur.

Correction — Exercice 6

- (a) $k_{E_1} = 2$ (vers E_2, E_3) + 2 (accords avec A_1 et M_1) = **4**. $k_{E_2} = 2$ (vers E_1, E_3 seulement) = **2**.
- (b) Chaque zone : $m_c = 3$ (clique interne), $d_c = 4 + 2 + 2 = 8$ (un hub à degré 4, deux non-hubs à degré 2).

$$Q = 3 \times \left(\frac{3}{12} - \left(\frac{8}{24} \right)^2 \right) = 3 \times (0,25 - 0,1111) = \mathbf{0,4167}$$

- (c) Groupe Eurasie $\{E_1, E_2, E_3, A_1, A_2, A_3\}$: arêtes internes = les deux cliques ($3 + 3 = 6$) + l'accord

E_1-A_1 (désormais interne) = 7; $d_c = 8 + 8 = 16$. Groupe Amérique : $m_c = 3$, $d_c = 8$.

$$Q = \left(\frac{7}{12} - \left(\frac{16}{24} \right)^2 \right) + \left(\frac{3}{12} - \left(\frac{8}{24} \right)^2 \right) = (0,5833 - 0,4444) + (0,25 - 0,1111) = \mathbf{0,2778}$$

C'est **moins bon** que la partition en trois blocs ($0,2778 < 0,4167$) : fusionner deux zones dilue leur cohésion propre sans que le lien unique E_1-A_1 suffise à compenser.

(d) Un calcul d'intermédiarité d'arête (algorithme de Brandes étendu aux arêtes, chapitre 3) confirme que les trois accords E_1-A_1 , A_1-M_1 , M_1-E_1 portent chacun une intermédiarité de 9, contre au plus 7 pour les arêtes internes à une zone reliant un hub à un non-hub, et 1 pour l'arête entre les deux non-hubs de chaque zone : ce sont bien les arêtes de plus forte intermédiarité du réseau, exactement le rôle des « ponts » identifiés par Girvan-Newman. Économiquement, cela signifie qu'un choc affectant un pays hub (par exemple E_1) ne se contente pas de perturber sa propre zone : il emprunte le chemin le plus court vers les deux autres continents par l'accord bilatéral dont il est un des deux extrémités, ce qui en fait un point de passage obligé pour toute transmission interzone — une vulnérabilité systémique concentrée sur seulement trois pays parmi les neuf.