

Théorie des réseaux

Chapitre 6 : Composantes, distances et petit monde

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Théorie des réseaux

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	4

1 Exercices du chapitre

Exercice 1 — Le parcours en largeur, couche par couche

Une chaîne logistique relie une usine à deux distributeurs, chacun relié à deux magasins ; l'un des magasins est en outre relié à un client final : $\text{Usine}-D_1$, $\text{Usine}-D_2$, D_1-M_1 , D_1-M_2 , D_2-M_3 , D_2-M_4 , M_1-C_1 .

- Dérouler le parcours en largeur (BFS) depuis Usine : lister les nœuds de chaque couche, avec leur distance.
- Quelle est l'excentricité de Usine ? Quel nœud (ou quels nœuds) réalise(nt) cette distance maximale ?
- Combien de couches le BFS explore-t-il au total ? À quoi ce nombre correspond-il exactement (en lien avec la question précédente) ?
- Le coût du BFS est annoncé par le cours comme $O(n + m)$ pour un sommet. Ici, $n = 8$ et $m = 7$: combien d'opérations « de base » (visite de sommet ou d'arête) le parcours a-t-il effectivement dû faire, et cet ordre de grandeur est-il cohérent avec $n + m = 15$?

Exercice 2 — Excentricité, diamètre, rayon et centre

Deux petits groupes très soudés sont reliés par une chaîne à deux maillons : triangle $T_1-T_2-T_3$, puis T_3-M_1 , M_1-M_2 , M_2-T_4 , puis triangle $T_4-T_5-T_6$.

- Calculer l'excentricité $e(i)$ de chacun des huit sommets.
- En déduire le diamètre et le rayon du graphe.
- Quel est le centre du graphe ? Comparer à celui du réseau du cours (chapitre 6, un seul nœud) : combien de sommets compte le centre ici, et pourquoi (indice : la présence de **deux** maillons intermédiaires M_1, M_2 , au lieu d'un seul comme le nœud 4 du cours, introduit-elle une symétrie supplémentaire) ?
- Si l'on devait installer un entrepôt unique desservant les huit sites avec un temps de trajet garanti minimal dans le **pire cas**, où le placer ? Que se passerait-il si l'on choisissait T_3 à la place ?

Exercice 3 — Composante géante et croissance logarithmique

Un réseau d'anciens élèves compte quatorze membres : dix d'entre eux forment une composante richement connectée (« la promotion active »), trois autres se connaissent entre eux mais sont coupés du reste, et un dernier n'a aucun contact.

- Combien de composantes connexes ce réseau a-t-il ? Quelle proportion des membres appartient à la plus grande (la composante « géante ») ?
- Le cours cite 90 % pour le Web, 85 % pour les coauteurs en physique, > 95 % pour l'interbancaire européen. La proportion trouvée ici est-elle du même ordre ? Qu'est-ce que la petite taille de ce réseau ($n = 14$) change à la pertinence de la comparaison ?
- Calculer $\ell \approx \ln(n) / \ln(\bar{k})$ pour $n = 1\,000$ et $\bar{k} = 10$ (ce cas a une réponse exacte et ronde). Calculer ensuite ℓ pour $n = 500\,000$ et $\bar{k} = 30$, puis pour $n = 5\,000\,000$ (dix fois plus) au même $\bar{k} = 30$.
- Commenter : en multipliant la population par 10, de combien de pas supplémentaires a-t-on besoin ? Cette lenteur de croissance est-elle compatible avec l'intuition selon laquelle « un réseau dix fois plus grand devrait être bien plus difficile à traverser » ?

2 Exercice cumulatif (chapitre 6 et chapitres précédents)

Exercice 4 — Le réseau du cours : le centre, sixième (et septième) manifestation du nœud 4

On reprend le réseau du cours, $V = \{1, \dots, 7\}$, $E = \{12, 13, 23, 34, 45, 56, 57, 67\}$.

- (a) Le cours donne $e(4) = 2$, le minimum du réseau, faisant de 4 l'unique centre. Vérifier $e(1) = 4$ à partir des distances établies au chapitre 1, et confirmer que 4 est bien l'unique sommet d'excentricité 2.
- (b) Dresser la liste complète des rôles tenus par le nœud 4 depuis le chapitre 1 : pont et point d'articulation (ch. 1), rang $r = 4$ dans $(A^r)_{1,6}$ (ch. 2), maximum de C_C et C_B mais minimum de C_D (ch. 3), **pas** maximum de C_E (ch. 4), $C_i = 0$ (ch. 5), et maintenant centre du graphe (ch. 6). Combien de ces sept résultats vont « dans le même sens » (nœud 4 structurellement singulier), et lequel fait **exception** ?
- (c) Calculer $\ell \approx \ln(n)/\ln(\bar{k})$ pour ce réseau ($n = 7$, $\bar{k} = 16/7$), et comparer au diamètre réel (4). L'estimation sous-évalue-t-elle ou surévalue-t-elle la distance réelle ? En quoi le clustering élevé du réseau ($\bar{C} \approx 0,667$, chapitre 5) explique-t-il cet écart, conformément à la mise en garde du cours (« un réseau très clusterisé a des distances longues, pas courtes ») ?
- (d) Ce réseau à 7 sommets est-il, à lui seul, un bon exemple pour illustrer la notion de « composante géante » du cours ? Pourquoi cette notion n'a-t-elle vraiment de sens que sur des réseaux beaucoup plus grands ?

3 Applications en sciences économiques

Exercice 5 — Composante géante d'un marché

Sur une place de marché en ligne comptant 200 vendeurs actifs, l'analyse du réseau des transactions croisées (deux vendeurs sont reliés s'ils ont vendu à un acheteur commun) révèle une composante de 178 vendeurs mutuellement reliés, et le reste réparti en six petits groupes indépendants (de 2 à 4 vendeurs chacun, totalisant 22 vendeurs), sans aucun lien ni entre eux, ni avec la grande composante.

- (a) Quelle proportion des vendeurs appartient à la composante géante ?
- (b) En quoi cette structure (une immense composante, une poussière de petites) est-elle typique des grands réseaux réels, d'après le cours ?
- (c) Un vendeur nouvellement inscrit, isolé au départ, réalise sa première vente croisée avec un acheteur qui a déjà acheté à un vendeur de la composante géante. Que devient sa situation dans le réseau ? Combien de **nouvelles** transactions croisées, au minimum, suffiraient pour que les 22 vendeurs « hors composante géante » rejoignent tous la composante géante (indice : une seule transaction bien choisie peut-elle faire rejoindre un groupe entier, ou faut-il une transaction par vendeur) ?

Exercice 6 — Un programme de parrainage, et le biais de Milgram


Une entreprise marocaine lance un programme de recommandation : chaque client parrain transmet un code promotionnel à ses contacts, qui peuvent eux-mêmes le retransmettre. Sur 480 chaînes de parrainage initiées, 96 seulement aboutissent effectivement à un nouvel achat, avec une médiane de 4 intermédiaires parmi les chaînes abouties.

- (a) Quelle proportion des chaînes initiées aboutit ? Comparer à la proportion de lettres abouties dans l'expérience de Milgram (64 sur 296).
- (b) Le service marketing annonce fièrement : « notre réseau de clients n'est qu'à 4 intermédiaires de distance ! ». En quoi cette affirmation commet-elle exactement la même erreur méthodologique que la lecture naïve de l'expérience de Milgram ?
- (c) Calculer $\ell \approx \ln(n)/\ln(\bar{k})$ pour le marché national ($n = 37\,000\,000$ clients potentiels, $\bar{k} = 50$ contacts moyens), puis pour un marché dix fois plus grand ($370\,000\,000$, même $\bar{k}$). La différence est-elle cohérente avec la médiane de 4 intermédiaires observée sur les chaînes abouties ?

- (d) Quelle mesure, indépendante du biais d'attrition des chaînes de parrainage, l'entreprise pourrait-elle utiliser pour estimer la distance moyenne **réelle** de son réseau de clients (indice : que fait l'exemple de Facebook 2016 cité par le cours, que ne fait pas l'expérience de Milgram) ?


1 Exercices du chapitre

Correction — Exercice 1



- (a) Couche 0 : {Usine}, distance 0. Couche 1 : {D₁, D₂}, distance 1. Couche 2 : {M₁, M₂, M₃, M₄}, distance 2. Couche 3 : {C₁}, distance 3.
- (b) $e(\text{Usine}) = 3$, réalisée uniquement par C₁ (le sommet le plus éloigné).
- (c) 4 couches au total (couches 0 à 3). Ce nombre est exactement $e(\text{Usine}) + 1$: la dernière couche non vide correspond, par définition, à l'excentricité du sommet de départ.
- (d) Le BFS visite chacun des $n = 8$ sommets exactement une fois, et examine chacune des $m = 7$ arêtes au plus deux fois (une fois depuis chaque extrémité) : l'ordre de grandeur des opérations est bien $O(n + m) = O(15)$, cohérent avec un parcours qui, concrètement, a dû traiter 8 sommets et parcourir 7 arêtes pour les découvrir.

Correction — Exercice 2



- (a) Par symétrie ($T_1 \leftrightarrow T_2 \leftrightarrow T_5 \leftrightarrow T_6$, $T_3 \leftrightarrow T_4$, $M_1 \leftrightarrow M_2$), on calcule pour un représentant de chaque classe. $e(T_1)$: la distance la plus longue est vers T₅ ou T₆, via $T_1 \rightarrow T_3 \rightarrow M_1 \rightarrow M_2 \rightarrow T_4 \rightarrow T_5$, longueur 5. $e(T_3)$: la plus longue est vers T₅/T₆, via $T_3 \rightarrow M_1 \rightarrow M_2 \rightarrow T_4 \rightarrow T_5$, longueur 4. $e(M_1)$: la plus longue est vers T₁/T₂ ou T₅/T₆ (symétrique), via $M_1 \rightarrow T_3 \rightarrow T_1$ (longueur 2) ou $M_1 \rightarrow M_2 \rightarrow T_4 \rightarrow T_5$ (longueur 3) : le maximum est 3.

$$e(T_1) = e(T_2) = e(T_5) = e(T_6) = 5, \quad e(T_3) = e(T_4) = 4, \quad e(M_1) = e(M_2) = 3$$

- (b) Diamètre = $\max e(i) = 5$ (entre {T₁, T₂} et {T₅, T₆}). Rayon = $\min e(i) = 3$.
- (c) Centre = {M₁, M₂}, **deux** sommets, contre un seul ({4}) pour le réseau du cours. C'est directement lié à la présence de **deux** maillons intermédiaires plutôt qu'un seul : avec un pont **unique** (nœud 4 du cours), la symétrie du réseau place un seul sommet à équidistance optimale des deux groupes. Avec **deux** maillons intermédiaires (M₁, M₂), aucun des deux n'est individuellement plus central que l'autre : ils sont ex æquo, chacun légèrement plus proche d'un des deux groupes mais à excentricité identique par symétrie globale.
- (d) Il faudrait placer l'entrepôt en M₁ **ou** M₂ (les deux sont optimaux, excentricité 3). En choisissant T₃ à la place (excentricité 4), le pire cas de trajet augmenterait d'une unité : un client situé en T₁ ou T₂ n'en pâtirait pas (T₃ est mieux placé pour eux), mais un client situé en T₅ ou T₆ devrait parcourir 4 arêtes au lieu de 3 — un choix optimal pour une partie du réseau mais pas pour le pire cas global, exactement ce que le centre est censé éviter.

Correction — Exercice 3

- (a) **Trois** composantes connexes : la promotion active (10 membres), le petit groupe coupé (3 membres), le membre isolé (1 membre). La composante géante représente $10/14 \approx 71,4\%$ des membres.
- (b) Le même ordre de grandeur (autour de 70–95 % selon les exemples du cours), quoique plus bas que les 90–95 % typiques des grands réseaux réels cités par le cours (Web, coauteurs, interbancaire). Sur un réseau aussi petit ($n = 14$), un seul membre isolé ou un petit groupe de 3 pèse **beaucoup plus** en proportion que sur un réseau de millions de nœuds : la comparaison reste qualitativement pertinente (une composante dominante existe bien), mais les pourcentages eux-mêmes ne sont pas directement comparables — exactement comme au chapitre 5, où l'on avait établi que la densité elle-même n'est pas comparable entre réseaux de tailles différentes.
- (c) Pour $n = 1\,000$, $\bar{k} = 10$: $\ell = \ln(1\,000)/\ln(10) = 3 \ln(10)/\ln(10) = 3,000$ exactement (puisque $1\,000 = 10^3$). Pour $n = 500\,000$, $\bar{k} = 30$: $\ell \approx 3,858$. Pour $n = 5\,000\,000$ (dix fois plus), même $\bar{k} = 30$: $\ell \approx 4,535$.
- (d) En multipliant la population par 10, il ne faut que $4,535 - 3,858 \approx 0,68$ pas supplémentaire — moins d'un intermédiaire de plus pour dix fois plus de monde. Cette lenteur extrême (croissance en $\ln n$, pas en n) est **contre-intuitive** : l'intuition naïve suggérerait qu'un réseau dix fois plus grand devrait être proportionnellement plus difficile à traverser, alors qu'il ne l'est presque pas. C'est exactement le point du cours : « multiplier la population par mille n'ajoute que trois pas ».

2 Exercice cumulatif

Correction — Exercice 4

- (a) Distances depuis 1 (chapitre 1) : $d(1,2) = 1$, $d(1,3) = 1$, $d(1,4) = 2$, $d(1,5) = 3$, $d(1,6) = 4$, $d(1,7) = 4$. Le maximum est 4, donc $e(1) = 4$, conforme au cours. En excluant 4 (excentricité 2), tous les autres sommets ont une excentricité ≥ 3 (calcul analogue par symétrie : $e(2) = e(1) = 4$, $e(3) = e(5) = 3$, $e(6) = e(7) = 4$) : 4 est bien l'**unique** sommet d'excentricité 2, donc l'unique centre.
- (b)

Chapitre	Rôle du nœud 4
1	pont (3–4, 4–5) et point d'articulation
2	$(A^r)_{1,6} = 0$ pour $r < 4$, $= 1$ à $r = 4$ (distance retrouvée par les puissances)
3	maximum de C_C et C_B ; minimum de C_D
4	$C_E(4) = 0,854 < 1,000$: pas le maximum
5	$C_4 = 0$ (clustering nul, cohérent avec le statut de pont)
6	centre du graphe (excentricité minimale)

Sur ces **six** résultats, **cinq** vont dans le même sens (nœud 4 structurellement singulier, « central » au sens topologique) : pont/articulation, C_C maximal, C_B maximal, $C_4 = 0$, centre du graphe. **Un seul** fait exception : $C_E(4)$ n'est **pas** maximal (dépassé par 3 et 5), parce que C_E récompense le fait d'être bien **entouré**, une notion différente de celle d'occuper une position centrale ou de contrôler un passage. Le degré (C_D), quant à lui, ne va pas non plus dans le même sens : 4 y est **minimal**, précisément parce que C_D ne regarde qu'à un pas.

- (c) $\ell \approx \ln(7)/\ln(16/7) = \ln(7)/\ln(2,286) \approx 2,354$. La formule **sous-évalue** nettement le diamètre réel (4) : elle prédit un peu plus de 2 pas, alors qu'il en faut 4 dans le pire cas. Le clustering élevé du réseau ($\bar{C} \approx 0,667$) est exactement la cause identifiée par le cours : la formule $\ell \approx \ln n / \ln \bar{k}$ suppose implicitement que les contacts de chaque sommet ne « se recoupent » pas (chaque nouveau pas atteint $\bar{k}$ personnes **entièrement nouvelles**) ; or ici, les voisins de 1 (2 et 3) sont eux-mêmes voisins l'un de l'autre ($C_1 = 1$), donc le deuxième pas depuis 1 n'apporte **aucun** nouveau sommet net au-delà de ce qu'un seul pas aurait déjà permis d'atteindre en combinant les deux triangles — exactement le mécanisme que le cours résume par « un réseau très clusterisé a des distances longues, pas courtes ».
- (d) Non : à $n = 7$ sommets, il n'y a tout simplement pas assez de nœuds pour distinguer une « composante géante » d'une poussière de petites composantes — le réseau du cours est de toute façon

entièrement connexe (une seule composante, la géante représentant 100 %). La notion de composante géante n'a de sens statistique que lorsque n est assez grand pour que **plusieurs** configurations de connexité soient possibles et que la comparaison entre « une immense composante » et « une poussière de petites » devienne significative — ce qui exige des dizaines, centaines, voire millions de nœuds, pas sept.

3 Applications en sciences économiques

Correction — Exercice 5

(a) $178/200 = 89\%$.

(b) Le cours établit que « presque tous les grands réseaux réels ont une composante qui contient la majorité des nœuds, et une poussière de petites composantes autour » : ce marché en ligne, avec 89 % des vendeurs dans une seule composante et le reste éparpillé en six petits groupes de 2 à 4, reproduit exactement ce schéma — une valeur cohérente avec la fourchette citée par le cours (85 à > 95 % selon les exemples).

(c) Dès que ce nouveau vendeur réalise une vente croisée avec un acheteur déjà relié à la composante géante, il **rejoint** immédiatement cette composante (il n'est plus isolé) : la composante géante passe de 178 à 179 membres. Pour que les 22 vendeurs restants la rejoignent tous, il ne faut **pas** 22 nouvelles transactions individuelles : puisqu'ils sont déjà regroupés en **six** petits groupes mutuellement connectés en interne, **une seule** transaction bien choisie entre un membre de chaque petit groupe et un membre de la composante géante suffit à faire basculer **tout** le groupe dans la composante géante d'un coup (la connexité se propage à travers les liens internes déjà existants). Il faut donc au minimum 6 nouvelles transactions croisées — une par groupe isolé — et non 22.

Correction — Exercice 6

(a) $96/480 = 20\%$ des chaînes aboutissent, à comparer aux $64/296 \approx 21,6\%$ de l'expérience de Milgram — des proportions très proches, et dans les deux cas une **minorité** substantielle des chaînes se rend jusqu'au bout.

(b) Exactement la même erreur : la médiane de 4 intermédiaires ne porte que sur les 96 chaînes **abouties**, pas sur les 480 chaînes **initiées**. Comme le note le cours à propos de Milgram, « les chaînes longues avaient plus d'occasions de s'interrompre » : les chaînes de parrainage qui auraient nécessité de nombreux intermédiaires ont, plus souvent que les courtes, été abandonnées en cours de route. Le chiffre de 4 intermédiaires est donc **biaisé vers le bas** : la distance **réelle** moyenne entre clients potentiels du réseau est probablement supérieure à ce que suggèrent les seules chaînes abouties.

(c) $\ell(37\,000\,000, 50) \approx 4,455$. $\ell(370\,000\,000, 50) \approx 5,043$ (dix fois plus de clients potentiels, moins d'un pas de plus). La médiane observée de 4 intermédiaires sur les chaînes **abouties** est du même ordre de grandeur que cette estimation théorique (4,5), mais — conformément à la question (b) — elle est probablement **légèrement sous-estimée** par le biais d'attrition : la vraie distance moyenne du réseau complet est vraisemblablement un peu plus proche de l'estimation théorique, voire au-delà, que de la médiane biaisée des seules chaînes abouties.

(d) L'entreprise devrait mesurer la distance directement sur l'**intégralité** de son réseau de clients (par exemple à partir des données de connexion ou de contacts de son application, si elle en dispose), plutôt que de se fier aux seules chaînes de parrainage abouties. C'est exactement ce que fait l'exemple de Facebook (2016) cité par le cours : la distance moyenne de 3,57 y est mesurée sur la totalité du réseau (1,6 milliard de comptes), « sans biais d'attrition », contrairement à l'expérience de Milgram qui ne pouvait observer que les lettres arrivées à destination.