

Chapitre 5

Densité, clustering et assortativité


Corrigé

Jaouad Madkour


Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Théorie des réseaux

1 Exercices du chapitre

Correction — Exercice 1




Réseau A ($n = 5, m = 6$)



Réseau B ($n = 10, m = 12$)

- (a) $\rho_A = \frac{2 \times 6}{5 \times 4} = \frac{12}{20} = 0,600$. $\rho_B = \frac{2 \times 12}{10 \times 9} = \frac{24}{90} \approx 0,267$. Au sens de ρ , A est plus « dense » que B.
- (b) $\bar{k}_A = 2 \times 6/5 = 2,4$, $\bar{k}_B = 2 \times 12/10 = 2,4$. **Les deux degrés moyens sont identiques**, alors que les densités diffèrent du simple au double.
- (c) $\rho = 2m/[n(n-1)]$ a un dénominateur qui croît en n^2 , alors que le numérateur ($2m$) ne croît, dans ces deux réseaux, qu'à peu près comme n (chaque filiale garde à peu près le même nombre de liaisons, $\bar{k} \approx 2,4$, quelle que soit la taille du réseau). Comparer ρ_A à ρ_B revient donc essentiellement à comparer $1/n$ à $1/(2n)$ — un artefact mécanique de la taille, pas une différence réelle de connectivité « par filiale ». $\bar{k} = 2m/n$, en revanche, ne divise que par n (pas par n^2) : il mesure directement le nombre moyen de partenaires par filiale, une quantité qui reste comparable indépendamment de la taille du réseau.
- (d) Si l'on multipliait n par 10 en gardant $\bar{k}_B$ constant (donc m multiplié par 10 aussi, puisque $m = n\bar{k}/2$), ρ deviendrait environ $\rho_B \times \frac{10}{10} \times \frac{9}{99} \approx \rho_B/10$: la densité serait divisée par environ un facteur 10, simplement parce que le dénominateur $n(n-1)$ croît en n^2 alors que le numérateur $2m$ ne croît qu'en n . C'est exactement le mécanisme qui rend $\rho \approx 10^{-7}$ sur Facebook malgré des centaines d'amis par utilisateur.


Correction — Exercice 2




- (a) $C_{\text{Hub}} = 0$ (aucune arête parmi ses 6 voisins $\{l_1, \dots, l_5, A\}$). $C_{l_i} = 0$ pour $i = 1, \dots, 5$ (degré 1, clustering nul par convention). C_A : voisins $\{\text{Hub}, B, C\}$, seule $B-C$ existe parmi les $\binom{3}{2} = 3$ paires possibles, donc $C_A = 1/3$. C_B : voisins $\{A, C\}$, $A-C$ existe, $C_B = 1$. $C_C = 1$ de même.
- (b) $\bar{C} = \frac{0 \times 6 + 1/3 + 1 + 1}{9} = \frac{2,333}{9} \approx 0,259$.
- (c) Un seul triangle ($\{A, B, C\}$). Triples connectés : $\sum_i \binom{k_i}{2} = \binom{6}{2} + 5 \times \binom{1}{2} + \binom{3}{2} + \binom{2}{2} + \binom{2}{2} = 15 + 0 + 3 + 1 + 1 = 20$. $T = \frac{3 \times 1}{20} = 0,150$.
- (d) C'est T (transitivité) qui est le plus « tiré vers le bas » par Hub. $\bar{C}$ moyenne les C_i à poids égal :

le nœud Hub ne compte que pour 1 voix sur 9, comme n'importe quel l_i . T , en revanche, pèse chaque nœud par $\binom{k_i}{2}$ — et Hub, avec $\binom{6}{2} = 15$ triples sur un total de 20 (soit 75 % du dénominateur), domine presque entièrement le calcul de T malgré son clustering nul. C'est précisément la mise en garde du cours : « la transitivité pèse chaque nœud par $\binom{k_i}{2}$: les hubs dominent ».

Correction — Exercice 3



Réseau P



Réseau Q (trois groupes disjoints)

- (a) Toutes les arêtes de P relient H (degré 4) à un L_i (degré 1) : **toutes** les paires de degrés le long des arêtes sont du type $(4, 1)$ ou $(1, 4)$ — jamais $(4, 4)$ ni $(1, 1)$. On s'attend à r_P fortement **négatif**.
- (b) Groupe $\{x_1, x_2\}$: chacun de degré 1, l'unique arête relie $(1, 1)$. Groupe $\{y_1, y_2, y_3\}$ (triangle) : chacun de degré 2, les trois arêtes relient $(2, 2)$. Groupe $\{z_1, \dots, z_4\}$ (complet) : chacun de degré 3, les six arêtes relient $(3, 3)$. **Chaque** arête du réseau Q relie deux sommets de **même** degré. On s'attend à r_Q fortement **positif**.
- (c) Oui : $r \in [-1, 1]$ par définition d'une corrélation, et $r_P = -1$, $r_Q = +1$ atteignent **exactement** les deux bornes théoriques. $r = -1$ représente le cas où **toute** arête relie un degré « haut » à un degré « bas », sans aucune exception (structure en étoile pure) ; $r = +1$ représente le cas où **toute** arête relie deux sommets de degré rigoureusement identique (ici, obtenu en juxtaposant des composantes régulières de degrés différents).
- (d) Non, Q n'est **pas** connexe (trois composantes distinctes, aucune arête ne les relie). Cela ne remet nullement en cause le calcul de r_Q : l'assortativité se calcule sur l'ensemble des **arêtes** du réseau (chacune contribuant une paire de degrés), sans jamais faire intervenir de notion de distance ou de chemin entre sommets non adjacents. Contrairement à C_C (qui a besoin d'un chemin fini vers **chaque** autre sommet pour être définie) ou à C_E (qui exige, via Perron-Frobenius, un graphe connexe pour garantir un vecteur propre dominant strictement positif), r ne regarde que des paires de sommets **directement reliés** : la connexité globale du graphe est simplement hors sujet pour cette mesure.

2 Exercice cumulatif

Correction — Exercice 4

- (a) $n = 7, m = 8$. $\rho = \frac{2 \times 8}{7 \times 6} = \frac{16}{42} \approx 0,381$, conforme au cours. $\bar{k} = 16/7 \approx 2,286$.
- (b) C_1 : voisins $\{2, 3\}$, et $2-3 \in E$, donc $C_1 = 1$. C_4 : voisins $\{3, 5\}$, et $3-5 \notin E$, donc $C_4 = 0$, conforme au cours. Ce résultat est directement lié au fait, établi au chapitre 1, que $3-4$ et $4-5$ sont des **ponts** : si 3 et 5 étaient reliés, cette arête fermerait un triangle $\{3, 4, 5\}$ et $3-4, 4-5$ ne seraient plus des ponts (chacune aurait désormais une voie alternative via l'autre). $C_4 = 0$ est donc la traduction algébrique exacte du statut de pont de ses deux arêtes incidentes.
- (c) Exactement comme à la question (d) de l'exercice 2 : $\bar{C}$ moyenne les 7 valeurs de C_i à poids égal, où $C_4 = 0$ ne pèse qu'un **septième** du total ; T pèse chaque nœud par $\binom{k_i}{2}$, où le nœud 4 (degré 2, donc $\binom{2}{2} = 1$ triple) pèse en réalité assez peu, mais ce sont les nœuds 3 et 5 (degré 3, $\binom{3}{2} = 3$ triples chacun) qui contribuent le plus au dénominateur de T — et **eux aussi** ont un clustering local

modeste ($C_3 = C_5 = 1/3$, chacun ayant un pont parmi ses trois liaisons). C'est pourquoi $T \approx 0,545$ est notablement inférieur à $\bar{C} \approx 0,667$: la transitivity, en pesant par $\binom{k_i}{2}$, amplifie l'effet des nœuds à cheval entre un triangle et un pont, alors que la moyenne simple les dilue parmi les quatre sommets purement « internes » aux triangles ($C_i = 1$).


(d) $r \approx -0,600 < 0$: le réseau est **dissortatif**. C'est cohérent : l'unique paire de hubs du réseau (3 et 5, degré 3) n'est **pas** directement reliée — ce sont les nœuds de degré 2 (4, mais aussi 1, 2, 6, 7) qui assurent la jonction, produisant des arêtes de type « degré fort–degré faible » (3–4, 4–5, mais aussi 1–3, 2–3, 5–6, 5–7) bien plus nombreuses que les arêtes « fort–fort » (aucune entre 3 et 5) ou « faible–faible » (seulement 1–2 et 6–7).

(e) C_D, C_C, C_B, C_E et le clustering local C_i caractérisent chacun un **nœud** particulier (une propriété qui varie sommet par sommet). La densité ρ , le clustering moyen $\bar{C}$, la transitivity T et l'assortativité r caractérisent le réseau **entier** : ce sont des nombres uniques, calculés une fois pour tout le graphe, qui ne « pointent » vers aucun sommet en particulier. Ce chapitre marque un changement d'échelle net par rapport aux quatre premiers : après avoir demandé « qui, dans ce réseau, est important ? », on demande désormais « ce réseau, dans son ensemble, est-il dense ? cliqué ? assortatif ? » — des questions qui permettraient, par exemple, de comparer **deux réseaux différents** entre eux, ce qu'aucune centralité individuelle ne permettrait de faire directement.

(f) Si tous les voisins d'un sommet i sont mutuellement interconnectés ($C_i = 1$), alors i et l'ensemble de ses voisins forment une **clique** (un sous-graphe complet). Retirer i de cette clique laisse ses anciens voisins **toujours tous mutuellement reliés entre eux** (les arêtes entre eux ne dépendaient pas de i) : ils restent donc connectés les uns aux autres, indépendamment de i . Si, de plus, i n'a **aucun** voisin en dehors de cette clique, sa suppression ne peut déconnecter personne : i ne peut donc pas être un point d'articulation. Ce n'est que si i possède **un lien supplémentaire** vers l'extérieur de sa clique (ce qui, par définition, ferait immédiatement chuter C_i en dessous de 1, puisque ce nouveau voisin ne serait pas connecté aux autres) que i pourrait redevenir indispensable à la connexité du reste du réseau. D'où la règle générale : **un sommet de clustering local égal à 1 ne peut jamais être un point d'articulation** — c'est la version générale, valable pour tout graphe, de l'observation ponctuelle du cours sur le nœud 4.

3 Applications en sciences économiques

Correction — Exercice 5



(a) $n = 6, m = 6$. $\rho = \frac{2 \times 6}{6 \times 5} = \frac{12}{30} = 0,400$. $\bar{k} = 2 \times 6/6 = 2,000$. C_{Core} : voisins $\{P_1, \dots, P_5\}$, une seule arête parmi eux (P_1 – P_2) sur $\binom{5}{2} = 10$ paires possibles, donc $C_{\text{Core}} = 0,100$.


(b) $r \approx -0,833 < 0$: le réseau est **dissortatif**, et nettement plus que la fourchette empirique interbancaire typique ($-0,2$ à $-0,3$) — ce système stylisé, très centralisé autour d'une chambre de compensation unique, est structurellement plus extrême que la moyenne des réseaux interbancaires réels.

(c) Oui, exactement : un unique nœud de degré très élevé (Core, degré 5) entouré de nœuds de

degré faible (P_3, P_4, P_5 , degré 1; P_1, P_2 , degré 2), avec très peu de liens **entre** périphériques — c'est la définition même d'une structure cœur-périphérie.

(d) Le régulateur devrait surveiller Core en priorité : c'est le seul nœud dont dépend la connexité de l'ensemble du système. Si Core faisait défaut, le réseau se fragmenterait en **quatre** morceaux : P_3, P_4, P_5 isolés chacun, et $\{P_1, P_2\}$ restant connectés entre eux (grâce à leur lien direct) mais coupés du reste. C'est une illustration directe de « protéger quelques nœuds protège tout le système » sur un réseau dissortatif : ici, un **seul** nœud à surveiller suffit, contrairement à un réseau assortatif où le risque serait diffus entre plusieurs hubs de taille comparable.

Correction — Exercice 6



(a) $k_A = 4$ (seul « senior » relié à un « junior »), $k_B = k_C = k_D = 3$, $k_E = 3$ (relié aux deux autres juniors et à A), $k_F = k_G = 2$. $\bar{k} = (4 + 3 + 3 + 3 + 3 + 2 + 2)/7 = 20/7 \approx 2,857$.

(b) $r \approx +0,250 > 0$: le réseau est **assortatif**. C'est cohérent avec l'affirmation du cours selon laquelle les réseaux sociaux sont typiquement assortatifs (homophilie, r compris entre +0,1 et +0,3 dans l'exemple donné) — notre valeur tombe précisément dans cette fourchette.

(c) $T = 3 \times 5/20 = 0,750$. Pour $\bar{C}$: $C_A = 1/2$ (voisins $\{B, C, D, E\}$, 3 arêtes parmi eux sur $\binom{4}{2} = 6$), $C_B = C_C = C_D = 1$ (chacun dans le complet $\{A, B, C, D\}$ moins soi-même), $C_E = 1/3$ (voisins $\{A, F, G\}$, seule $F-G$ existe sur $\binom{3}{2} = 3$), $C_F = C_G = 1$. $\bar{C} = (0,5 + 1 + 1 + 1 + 0,333 + 1 + 1)/7 \approx 0,833$. Ici, clustering élevé et assortativité positive sont **les deux faces d'une même cause structurelle** : les deux groupes sont chacun de fortes cliques (d'où le clustering élevé) reliées par un lien **unique** et rare (d'où le fait que la quasi-totalité des arêtes connectent des degrés proches, internes à chaque clique). Ce n'est pas que l'un cause l'autre : les deux résultent conjointement de la même architecture « cliques denses, peu de ponts ».

(d) Intuitivement, on pourrait s'attendre à ce qu'une seconde amitié intergénérationnelle **augmente** le mélange et donc, pensait-on, l'assortativité perçue comme « cohérence ». Le calcul montre l'**inverse** : r chute de 0,250 à **0,0435**. Le mécanisme : avant l'ajout, B a degré 3 et F a degré 2 ; l'arête $B-F$, une fois ajoutée, porte elle-même sur des degrés **mixtes** (4 et 3 après mise à jour), donc n'est pas elle-même « homophile ». Mais l'effet le plus important est **indirect** : B passe de degré 3 à 4, ce qui rend **désassorties** les arêtes $B-C$ et $B-D$ (auparavant 3–3, parfaitement appariées, désormais 4–3) ; de même, F passe de 2 à 3, désassortant $F-G$ (auparavant 2–2, désormais 3–2). Un unique nouveau pont dégrade ainsi, par ricochet, l'appariement de **quatre** arêtes qui étaient auparavant parfaitement homophiles — exactement le type d'effet récursif et non intuitif déjà rencontré avec PageRank au chapitre 4 (exercice 3) : dans un réseau, une modification locale se répercute rarement de façon purement locale.