

Chapitre 12

L'identification des effets de pairs

Corrigé

Jaouad Madkour


Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Théorie des réseaux

1 Exercices du chapitre

Correction — Exercice 1

(a) $\bar{x}_A = (10 + 20 + 30)/3 = 20$. $\bar{x}_B = (5 + 20 + 35)/3 = 20$. $\bar{x}_C = (15 + 25 + 35)/3 = 25$.


(b) $\bar{y} = \frac{2 + (0,3 + 0,5) \times 20}{1 - 0,4} = \frac{2 + 16}{0,6} = \frac{18}{0,6} = 30,000$ pour les deux groupes A et B (puisque $\bar{x}_A = \bar{x}_B$).



(c) La formule ne dépend que de $\bar{x}$, jamais de la dispersion interne des x_i : $\bar{y}$ prédit est donc **rigoureusement identique** pour A et B, malgré leurs compositions internes très différentes. Un économètre qui n'observerait que les moyennes de groupe $(\bar{y}, \bar{x})$ ne pourrait **absolument pas** distinguer les deux groupes : ils occupent exactement le même point sur le graphique.

(d) $\bar{y}_C = \frac{2 + 0,8 \times 25}{0,6} = \frac{22}{0,6} \approx 36,667$. Pente = $\frac{36,667 - 30}{25 - 20} = \frac{6,667}{5} = 1,333$, et $(\gamma + \delta)/(1 - \beta) = 0,8/0,6 = 1,333$: la pente observée est bien exactement ce ratio composite. Mais cette pente ne renvoie qu'un **seul** nombre, $(\gamma + \delta)/(1 - \beta)$, alors qu'il y a **trois** paramètres inconnus (β, γ, δ) à l'intérieur : une infinité de triplets (β, γ, δ) différents produisent exactement la même pente observée. C'est le problème du reflet : les données de groupes partitionnés ne contiennent tout simplement pas assez d'information pour séparer les trois effets, quelle que soit la précision de l'estimation.

Correction — Exercice 2



(a)

$$\mathbf{G} = \begin{pmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 1 & 0 \end{pmatrix}$$

(b)

$$\mathbf{G}^2 = \begin{pmatrix} 2 & 1 & 1 & 1 & 0 \\ 1 & 2 & 1 & 1 & 0 \\ 1 & 1 & 3 & 0 & 1 \\ 1 & 1 & 0 & 2 & 0 \\ 0 & 0 & 1 & 0 & 1 \end{pmatrix}$$

$(\mathbf{G}^2)_{14} = 1$: c'est le nombre de chemins de longueur 2 entre 1 et 4 (ici, l'unique chemin 1–3–4), c'est-à-dire le nombre d'amis communs de 1 et 4.

(c) $G_{14} = 0$ (confirmé dans $\mathbf{G}$) alors que $(\mathbf{G}^2)_{14} = 1 \neq 0$. Or, à la position (1,4), $\mathbf{I}_{14} = 0$ et $G_{14} = 0$: toute combinaison $a\mathbf{I} + b\mathbf{G}$ vaut donc 0 en position (1,4), quels que soient a, b . Puisque $\mathbf{G}^2$ vaut 1 $\neq 0$ à cette même position, $\mathbf{G}^2$ ne peut **jamais** s'écrire comme une combinaison linéaire de $\mathbf{I}$ et $\mathbf{G}$: les trois matrices sont linéairement indépendantes (rang 3, vérifié numériquement).

(d) Le nœud 4 n'est pas un ami direct de 1 : ses caractéristiques propres (x_4) n'entrent donc **jamais** directement dans l'équation de 1 (pas de terme δx_4 , ni même de terme γ puisque $4 \notin$ voisinage de 1). Mais 4 influence 3 (qui est ami de 1), donc influence indirectement le comportement de 3, qui à son tour influence 1 via le terme $\beta \bar{y}_{-1}$. x_4 affecte donc y_1 **uniquement** par ce canal indirect (à travers 3), exactement la définition d'un instrument valide : corrélé avec le régresseur endogène ($\bar{y}_{-1}$, via y_3) mais sans effet direct sur y_1 .

Correction — Exercice 3

(a) P_1 ($y=11$) a pour pair P_2 ($y=9$) ; $P_2 \rightarrow 11$; $P_3(22) \rightarrow 18$; $P_4(18) \rightarrow 22$; $P_5(14) \rightarrow 16$; $P_6(16) \rightarrow 14$.

(b) Avec $y = (11, 9, 22, 18, 14, 16)$ et $y_{\text{pair}} = (9, 11, 18, 22, 16, 14)$: $\bar{y} = 15$, et le calcul donne $\text{corr}(y, y_{\text{pair}}) \approx 0,786$.

(c) Une corrélation individu/pair de 0,786 apparaît alors que le modèle générateur n'a, par construction, **aucun** effet endogène ($\beta = 0$) : elle provient **entièrement** du choc corrélé c_g , partagé au sein de chaque paire. Ignorer l'appartenance aux groupes (donc l'existence de c_g) conduira un économètre naïf à interpréter cette corrélation comme la preuve d'une influence réciproque authentique entre pairs, alors qu'il s'agit d'un pur artefact de l'environnement commun.

(d) Avec le nouveau regroupement, $y = (11, 16, 9, 22, 14, 18)$ et $y_{\text{pair}} = (16, 11, 22, 9, 18, 14)$, on obtient $\text{corr} \approx -0,875$: le signe **s'inverse** et l'intensité change radicalement, alors que les 6 valeurs individuelles de y sont rigoureusement identiques à la question (b). Ce contraste démontre que la corrélation « pair à pair » n'a **rien à voir** avec un quelconque comportement individuel (les y_i n'ont pas changé) : elle est entièrement déterminée par la façon dont on **découpe** la population en groupes. Une statistique aussi sensible au simple choix arbitraire du regroupement ne peut, en toute rigueur, mesurer une influence causale.

2 Exercice cumulatif

Correction — Exercice 4

(a) Non, $4 \notin \{2, 3\}$: 4 n'est pas un ami direct de 1. Oui, 1–3–4 est un chemin de longueur 2 : 4 est un ami de l'ami 3 de 1.

(b) $(\mathbf{A}^2)_{1,4} = 1$ (déjà présent dans le calcul de $\mathbf{A}^2$ du chapitre 2) : non nul, confirmant l'existence exacte d'un chemin de longueur 2 (et un seul) entre 1 et 4.

(c) Puisque $A_{1,4} = 0$ mais $(\mathbf{A}^2)_{1,4} = 1 \neq 0$, les caractéristiques de 4 constituent un instrument valide pour l'équation de 1, par le même argument qu'à l'exercice 2. En balayant systématiquement toutes les paires à distance exactement 2 (diamètre = 4, chapitre 6, donc de telles paires existent en abondance), on trouve : $\{1, 4\}$, $\{2, 4\}$, $\{3, 5\}$, $\{4, 6\}$, $\{4, 7\}$ — **toutes** impliquent le nœud 4, qui est exactement le nœud-pont identifié dès le chapitre 1 comme le seul point d'articulation du réseau. C'est cohérent : dans un réseau aussi compact ($n = 7$, diamètre 4), les paires à distance 2 passent presque toujours par l'unique goulot d'étranglement structurel.

(d) Il faudrait être prêt à défendre l'hypothèse que le réseau lui-même est **exogène**, c'est-à-dire non corrélé avec le terme d'erreur ε_i — en particulier, que les étudiants ne se sont pas liés d'amitié à **cause** de caractéristiques inobservées qui déterminent aussi y_i . Le simple fait que $\mathbf{I}$, $\mathbf{G}$, $\mathbf{G}^2$ soient linéairement indépendantes ne règle qu'un problème **algébrique** (l'absence de colinéarité parfaite entre régresseurs) ; elle ne dit rien sur la façon dont les liens du réseau ont été **formés**. Si un étudiant choisit ses amis en fonction de traits qui influencent aussi son propre résultat y_i (la sélection homophile), l'instrument x_4 est lui-même corrélé à ε_1 via la chaîne de sélection, et l'identification

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Avec les paires (2,8;3,0), (3,5;3,2), (2,5;2,9), (3,8;3,6), (3,0;2,7) : $\text{corr} \approx 0,808$.
- (b) Avec les paires (2,8;2,9), (3,5;3,6), (2,5;2,6), (3,8;3,7), (3,0;3,1) : $\text{corr} \approx 0,991$.
- (c) Sous assignation aléatoire, aucun étudiant n'a choisi son colocataire en fonction d'affinités préexistantes : la corrélation de 0,808 ne peut donc **pas** provenir d'un biais de sélection (par construction, il n'y en a aucun). C'est bien l'esprit du résultat de Sacerdote (2001) : un effet de pairs significatif apparaît **malgré** l'assignation aléatoire, ce qui en fait une estimation crédible d'une influence causale authentique — même si un effet corrélé résiduel (même bâtiment, mêmes ressources du campus) ne peut jamais être totalement exclu sans plus de détails sur le dispositif.
- (d) L'écart entre 0,991 (choix par affinité) et 0,808 (assignation aléatoire), soit environ 0,18 point de corrélation, peut se lire comme la part **ajoutée par la sélection** : les étudiants qui choisissent eux-mêmes un ami de GPA proche gonflent artificiellement la corrélation observée, par-dessus l'effet de pairs authentique déjà détecté sous assignation aléatoire. Le dispositif expérimental (a) isole ce dernier ; le dispositif observationnel (b), lui, mélange les deux composantes sans possibilité de les séparer — exactement le risque que l'assignation aléatoire est conçue pour éliminer.

Correction — Exercice 6

- (a) Bloc 1 : l'étudiant à 40 a pour colocataire 41, et réciproquement. Bloc 2 : 44 $\leftrightarrow$ 43. Bloc 3 : 42 $\leftrightarrow$ 43.
- (b) Avec $y = (40, 41, 44, 43, 42, 43)$ et $y_{\text{pair}} = (41, 40, 43, 44, 43, 42)$: $\text{corr} \approx 0,723$.
- (c) Cette corrélation est **loin** d'être proche de zéro : elle est même substantielle (0,723), alors que la pointure de pied d'un adulte ne peut, physiologiquement, subir **aucune** influence sociale de la part d'un colocataire. Elle provient entièrement du fait que les blocs de dortoir ont des « niveaux » moyens de pointure différents (peut-être liés à la taille moyenne des étudiants qui y ont été affectés, ou à un pur hasard d'affectation) : un effet corrélé de composition de groupe, rigoureusement analogue au choc c_g de l'exercice 3, mais ici appliqué à une variable dont la contagion sociale est **a priori** impossible.
- (d) Puisqu'une méthode qui « détecte » une contagion sociale de la pointure de pied ne peut, par définition, mesurer une véritable influence comportementale (aucun mécanisme causal plausible n'existe), toute « détection » de ce type prouve que la méthode capte en réalité un effet corrélé ou un artefact de composition de groupe, et non l'effet endogène qu'elle prétend isoler. C'est exactement ce que Cohen-Cole et Fletcher (2008) ont démontré en répliquant la méthode de Christakis et Fowler sur l'acné et la taille : si la méthode « trouve » une contagion pour des traits manifestement non contagieux, elle ne peut être crédible pour l'obésité non plus, à moins de disposer d'arguments supplémentaires (assignation aléatoire, instrument validé indépendamment) qui excluent spécifiquement les effets corrélés et de sélection pour **ce** résultat précis. Le test de falsification est « le moins coûteux et le plus décisif » précisément parce qu'il ne demande aucune donnée supplémentaire : il suffit d'appliquer la même méthode à un résultat dont on est **certain a priori** qu'il ne peut pas se transmettre socialement.