

Théorie des réseaux

Chapitre 12 : L'identification des effets de pairs

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Théorie des réseaux

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	4

1 Exercices du chapitre

Exercice 1 — Le problème du reflet, en chiffres

On étudie le modèle linéaire en moyenne de Manski, $y_i = \alpha + \beta\bar{y}_{-i} + \gamma\bar{x}_{-i} + \delta x_i + \varepsilon_i$, avec $\alpha = 2$, $\beta = 0,4$, $\gamma = 0,3$, $\delta = 0,5$. On admet la forme réduite du cours (groupes formant une partition, tous les membres partageant les mêmes pairs) :

$$\bar{y} = \frac{\alpha + (\gamma + \delta)\bar{x}}{1 - \beta}$$

Trois groupes de 3 étudiants ont les caractéristiques suivantes : groupe A, $x = \{10, 20, 30\}$; groupe B, $x = \{5, 20, 35\}$; groupe C, $x = \{15, 25, 35\}$.

- Calculer $\bar{x}$ pour chacun des trois groupes.
- Calculer $\bar{y}$ prédit pour les groupes A et B à l'aide de la formule.
- Les groupes A et B ont une dispersion interne de x très différente (écart-type bien plus grand pour B), mais le même $\bar{x}$. Que peut-on en conclure sur $\bar{y}$ prédit pour les deux groupes ? Un économètre qui observerait uniquement $(\bar{y}, \bar{x})$ pourrait-il distinguer un groupe de l'autre ?
- Calculer $\bar{y}$ pour le groupe C, puis la pente $(\bar{y}_C - \bar{y}_A)/(\bar{x}_C - \bar{x}_A)$. Vérifier qu'elle vaut exactement $(\gamma + \delta)/(1 - \beta)$. Expliquer pourquoi cette seule pente, aussi précisément estimée soit-elle, ne permet **jamais** de récupérer séparément β , γ et δ .

Exercice 2 — Construire l'instrument de Bramoullé, Djebbari et Fortin

On considère un réseau à 5 étudiants, $V = \{1, \dots, 5\}$, $E = \{12, 13, 23, 34, 45\}$ (1 et 2 sont amis de 3 ; 3 est également ami de 4, qui est ami de 5).

- Écrire la matrice d'adjacence $\mathbf{G}$ (5×5).
- Calculer $\mathbf{G}^2$ (produit matriciel, chapitre 2). Que représente l'entrée $(\mathbf{G}^2)_{14}$?
- Vérifier que $G_{14} = 0$ (pas d'amitié directe entre 1 et 4) mais $(\mathbf{G}^2)_{14} \neq 0$. En déduire que $\mathbf{G}^2$ ne peut pas s'écrire comme une combinaison linéaire de $\mathbf{I}$ et $\mathbf{G}$ seuls (ces deux dernières matrices ont une entrée nulle en position (1, 4), quelle que soit la combinaison).
- En quoi les caractéristiques du nœud 4 (ami d'un ami de 1, mais pas ami direct de 1) fournissent-elles un **instrument** valide pour identifier séparément β et γ dans l'équation de 1 ?

Exercice 3 — Un effet corrélé qui imite un effet de pairs

Trois paires d'amis subissent chacune un choc d'environnement commun (même quartier, même établissement) c_g , sans **aucune** influence réciproque réelle : $y_i = c_g + \eta_i$ (le hasard individuel η_i seul distingue les deux membres d'une paire). On observe : paire 1 ($c_1 = 10$) : $y_{P_1} = 11$, $y_{P_2} = 9$; paire 2 ($c_2 = 20$) : $y_{P_3} = 22$, $y_{P_4} = 18$; paire 3 ($c_3 = 15$) : $y_{P_5} = 14$, $y_{P_6} = 16$.

- Pour chacun des 6 individus, noter la valeur de y de son « pair » (l'autre membre de sa paire).
- Calculer le coefficient de corrélation de Pearson entre y_i (les 6 valeurs) et y du pair correspondant.
- Sachant que le modèle générateur ne contient, par construction, **aucun** effet endogène ($\beta = 0$ dans l'équation de Manski) — uniquement un effet corrélé c_g — que révèle la corrélation calculée en (b) sur le risque de confondre effet corrélé et effet de pairs si l'on ignore l'appartenance aux paires ?
- On reprend exactement les **mêmes** 6 valeurs de y , mais en les associant différemment en paires (paire 1' : 11 et 16 ; paire 2' : 9 et 22 ; paire 3' : 14 et 18). Recalculer la corrélation y_i/pair . Le signe et l'intensité changent-ils ? Qu'est-ce que ce contraste — à données individuelles identiques — démontre sur l'origine purement **structurelle** (liée au découpage en groupes), et non comportementale, de la corrélation observée ?

2 Exercice cumulatif (chapitre 12 et chapitres précédents)

Exercice 4 — L'instrument sur le réseau du cours

On reprend $V = \{1, \dots, 7\}$, $E = \{12, 13, 23, 34, 45, 56, 57, 67\}$. La matrice A et ses puissances ont déjà été calculées au chapitre 2.

- (a) Le nœud 1 a pour amis 2 et 3 (chapitre 1). Le nœud 4 est-il un ami direct de 1 ? Est-il un ami d'un ami de 1 (passer par 3) ?
- (b) Calculer $(A^2)_{1,4}$ (déjà obtenu au chapitre 2 dans le calcul de A^2) et vérifier qu'il est non nul, confirmant l'existence d'au moins un chemin de longueur 2 entre 1 et 4.
- (c) En déduire que les caractéristiques du nœud 4 constituent un instrument valide pour l'équation de 1. Quelles **autres** paires de nœuds du réseau du cours sont, de la même façon, « amis d'amis mais pas amis » (aidez-vous du diamètre du réseau, chapitre 6, pour balayer systématiquement les paires à distance 2) ?
- (d) Le réseau du cours a été **construit à la main** par l'enseignant à des fins pédagogiques, et non observé sur une population réelle d'étudiants qui auraient choisi leurs propres amis. Si l'on voulait appliquer la méthode de Bramoullé, Djebbari et Fortin à un **vrai** réseau d'amitiés scolaires structurellement identique à celui du cours, quelle hypothèse cruciale (rappelée en fin de section du cours) faudrait-il être prêt à défendre, et pourquoi le simple fait que I , G , G^2 soient linéairement indépendantes ne suffit-il pas, à lui seul, à garantir une identification convaincante ?

3 Applications en sciences économiques

Exercice 5 — Colocataires assignés au hasard versus amis choisis

Une université observe les moyennes (GPA) de 5 paires d'étudiants. Dans le premier dispositif, les colocataires sont **assignés au hasard** par l'administration (à la Sacerdote, 2001) : (2,8;3,0), (3,5;3,2), (2,5;2,9), (3,8;3,6), (3,0;2,7). Dans le second, les mêmes 5 premiers étudiants ont plutôt choisi eux-mêmes un ami proche par affinité : (2,8;2,9), (3,5;3,6), (2,5;2,6), (3,8;3,7), (3,0;3,1).

- (a) Calculer la corrélation de Pearson entre les deux colonnes du dispositif « assignation aléatoire ».
- (b) Calculer la corrélation de Pearson entre les deux colonnes du dispositif « choix par affinité ».
- (c) Sachant que l'assignation aléatoire élimine par construction tout biais de sélection (l'étudiant i ne choisit pas son colocataire), comment interpréter la corrélation trouvée en (a) ? Peut-on, dans ce seul dispositif, l'attribuer sans ambiguïté à un effet de pairs authentique ?
- (d) La corrélation du dispositif « choix par affinité » (b) est nettement plus élevée que celle du dispositif aléatoire (a), alors que les valeurs de la première colonne sont **identiques** dans les deux cas. Décomposer, au moins qualitativement, l'écart entre les deux corrélations en une partie « effet de pairs authentique » (déjà présente sous assignation aléatoire) et une partie « sélection » (ajoutée par le libre choix de l'ami).

Exercice 6 — Le test de falsification, appliqué à une pointure de chaussure

Trois blocs de dortoir (deux étudiants chacun) ont chacun un environnement commun (même bâtiment, même cantine). On mesure une variable qui **ne peut structurellement pas** se transmettre par imitation sociale : la pointure de chaussure. Bloc 1 : (40, 41). Bloc 2 : (44, 43). Bloc 3 : (42, 43).

- (a) Pour chacun des 6 étudiants, noter la pointure de son colocataire de bloc.
- (b) Calculer la corrélation de Pearson entre la pointure d'un étudiant et celle de son colocataire.
- (c) Cette corrélation est-elle proche de zéro (comme on l'attendrait d'une variable non contagieuse) ou, au contraire, substantielle ? Expliquer d'où elle provient, sachant qu'aucune influence sociale ne peut plausiblement agir sur la pointure d'un adulte.


- (d) Un article affirme avoir détecté une « contagion sociale de l'obésité » de 57 % (Christakis et Fowler, 2007) à l'aide d'une méthode comparable. Cohen-Cole et Fletcher (2008) répliquent la même méthode sur l'acné et la taille, et trouvent des « effets de contagion » tout aussi significatifs. Expliquer, à la lumière du calcul des questions (a)-(c), pourquoi ce test de falsification est « le contrôle le moins coûteux et le plus décisif » selon le cours, et ce qu'il implique pour l'interprétation causale de la corrélation trouvée sur l'obésité elle-même.

1 Exercices du chapitre

Correction — Exercice 1

(a) $\bar{x}_A = (10 + 20 + 30)/3 = 20$. $\bar{x}_B = (5 + 20 + 35)/3 = 20$. $\bar{x}_C = (15 + 25 + 35)/3 = 25$.


(b) $\bar{y} = \frac{2 + (0,3 + 0,5) \times 20}{1 - 0,4} = \frac{2 + 16}{0,6} = \frac{18}{0,6} = 30,000$ pour les deux groupes A et B (puisque $\bar{x}_A = \bar{x}_B$).



(c) La formule ne dépend que de $\bar{x}$, jamais de la dispersion interne des x_i : $\bar{y}$ prédit est donc **rigoureusement identique** pour A et B, malgré leurs compositions internes très différentes. Un économètre qui n'observerait que les moyennes de groupe $(\bar{y}, \bar{x})$ ne pourrait **absolument pas** distinguer les deux groupes : ils occupent exactement le même point sur le graphique.

(d) $\bar{y}_C = \frac{2 + 0,8 \times 25}{0,6} = \frac{22}{0,6} \approx 36,667$. Pente = $\frac{36,667 - 30}{25 - 20} = \frac{6,667}{5} = 1,333$, et $(\gamma + \delta)/(1 - \beta) = 0,8/0,6 = 1,333$: la pente observée est bien exactement ce ratio composite. Mais cette pente ne renvoie qu'un seul nombre, $(\gamma + \delta)/(1 - \beta)$, alors qu'il y a **trois** paramètres inconnus (β, γ, δ) à l'intérieur : une infinité de triplets (β, γ, δ) différents produisent exactement la même pente observée. C'est le problème du reflet : les données de groupes partitionnés ne contiennent tout simplement pas assez d'information pour séparer les trois effets, quelle que soit la précision de l'estimation.

Correction — Exercice 2



(a)

$$\mathbf{G} = \begin{pmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 1 & 0 \end{pmatrix}$$

(b)

$$\mathbf{G}^2 = \begin{pmatrix} 2 & 1 & 1 & 1 & 0 \\ 1 & 2 & 1 & 1 & 0 \\ 1 & 1 & 3 & 0 & 1 \\ 1 & 1 & 0 & 2 & 0 \\ 0 & 0 & 1 & 0 & 1 \end{pmatrix}$$

$(\mathbf{G}^2)_{14} = 1$: c'est le nombre de chemins de longueur 2 entre 1 et 4 (ici, l'unique chemin 1–3–4), c'est-à-dire le nombre d'amis communs de 1 et 4.

(c) $G_{14} = 0$ (confirmé dans $\mathbf{G}$) alors que $(\mathbf{G}^2)_{14} = 1 \neq 0$. Or, à la position (1,4), $\mathbf{I}_{14} = 0$ et $G_{14} = 0$: toute combinaison $a\mathbf{I} + b\mathbf{G}$ vaut donc 0 en position (1,4), quels que soient a, b . Puisque $\mathbf{G}^2$ vaut 1 $\neq 0$ à cette même position, $\mathbf{G}^2$ ne peut **jamais** s'écrire comme une combinaison linéaire de $\mathbf{I}$ et $\mathbf{G}$: les trois matrices sont linéairement indépendantes (rang 3, vérifié numériquement).

(d) Le nœud 4 n'est pas un ami direct de 1 : ses caractéristiques propres (x_4) n'entrent donc **jamais** directement dans l'équation de 1 (pas de terme δx_4 , ni même de terme γ puisque $4 \notin$ voisinage de 1). Mais 4 influence 3 (qui est ami de 1), donc influence indirectement le comportement de 3, qui à son tour influence 1 via le terme $\beta \bar{y}_{-1}$. x_4 affecte donc y_1 **uniquement** par ce canal indirect (à travers 3), exactement la définition d'un instrument valide : corrélé avec le régresseur endogène ($\bar{y}_{-1}$, via y_3) mais sans effet direct sur y_1 .

Correction — Exercice 3

(a) P_1 ($y=11$) a pour pair P_2 ($y=9$) ; $P_2 \rightarrow 11$; $P_3(22) \rightarrow 18$; $P_4(18) \rightarrow 22$; $P_5(14) \rightarrow 16$; $P_6(16) \rightarrow 14$.

(b) Avec $y = (11, 9, 22, 18, 14, 16)$ et $y_{\text{pair}} = (9, 11, 18, 22, 16, 14)$: $\bar{y} = 15$, et le calcul donne $\text{corr}(y, y_{\text{pair}}) \approx 0,786$.

(c) Une corrélation individu/pair de 0,786 apparaît alors que le modèle générateur n'a, par construction, **aucun** effet endogène ($\beta = 0$) : elle provient **entièrement** du choc corrélé c_g , partagé au sein de chaque paire. Ignorer l'appartenance aux groupes (donc l'existence de c_g) conduira un économètre naïf à interpréter cette corrélation comme la preuve d'une influence réciproque authentique entre pairs, alors qu'il s'agit d'un pur artefact de l'environnement commun.

(d) Avec le nouveau regroupement, $y = (11, 16, 9, 22, 14, 18)$ et $y_{\text{pair}} = (16, 11, 22, 9, 18, 14)$, on obtient $\text{corr} \approx -0,875$: le signe **s'inverse** et l'intensité change radicalement, alors que les 6 valeurs individuelles de y sont rigoureusement identiques à la question (b). Ce contraste démontre que la corrélation « pair à pair » n'a **rien à voir** avec un quelconque comportement individuel (les y_i n'ont pas changé) : elle est entièrement déterminée par la façon dont on **découpe** la population en groupes. Une statistique aussi sensible au simple choix arbitraire du regroupement ne peut, en toute rigueur, mesurer une influence causale.

2 Exercice cumulatif

Correction — Exercice 4

(a) Non, $4 \notin \{2, 3\}$: 4 n'est pas un ami direct de 1. Oui, 1–3–4 est un chemin de longueur 2 : 4 est un ami de l'ami 3 de 1.

(b) $(\mathbf{A}^2)_{1,4} = 1$ (déjà présent dans le calcul de $\mathbf{A}^2$ du chapitre 2) : non nul, confirmant l'existence exacte d'un chemin de longueur 2 (et un seul) entre 1 et 4.

(c) Puisque $A_{1,4} = 0$ mais $(\mathbf{A}^2)_{1,4} = 1 \neq 0$, les caractéristiques de 4 constituent un instrument valide pour l'équation de 1, par le même argument qu'à l'exercice 2. En balayant systématiquement toutes les paires à distance exactement 2 (diamètre = 4, chapitre 6, donc de telles paires existent en abondance), on trouve : $\{1, 4\}$, $\{2, 4\}$, $\{3, 5\}$, $\{4, 6\}$, $\{4, 7\}$ — **toutes** impliquent le nœud 4, qui est exactement le nœud-pont identifié dès le chapitre 1 comme le seul point d'articulation du réseau. C'est cohérent : dans un réseau aussi compact ($n = 7$, diamètre 4), les paires à distance 2 passent presque toujours par l'unique goulot d'étranglement structurel.

(d) Il faudrait être prêt à défendre l'hypothèse que le réseau lui-même est **exogène**, c'est-à-dire non corrélé avec le terme d'erreur ε_i — en particulier, que les étudiants ne se sont pas liés d'amitié à **cause** de caractéristiques inobservées qui déterminent aussi y_i . Le simple fait que $\mathbf{I}$, $\mathbf{G}$, $\mathbf{G}^2$ soient linéairement indépendantes ne règle qu'un problème **algébrique** (l'absence de colinéarité parfaite entre régresseurs) ; elle ne dit rien sur la façon dont les liens du réseau ont été **formés**. Si un étudiant choisit ses amis en fonction de traits qui influencent aussi son propre résultat y_i (la sélection homophile), l'instrument x_4 est lui-même corrélé à ε_1 via la chaîne de sélection, et l'identification

s'effondre malgré la condition de rang satisfaite.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Avec les paires (2,8;3,0), (3,5;3,2), (2,5;2,9), (3,8;3,6), (3,0;2,7) : $\text{corr} \approx 0,808$.
- (b) Avec les paires (2,8;2,9), (3,5;3,6), (2,5;2,6), (3,8;3,7), (3,0;3,1) : $\text{corr} \approx 0,991$.
- (c) Sous assignation aléatoire, aucun étudiant n'a choisi son colocataire en fonction d'affinités préexistantes : la corrélation de 0,808 ne peut donc **pas** provenir d'un biais de sélection (par construction, il n'y en a aucun). C'est bien l'esprit du résultat de Sacerdote (2001) : un effet de paires significatif apparaît **malgré** l'assignation aléatoire, ce qui en fait une estimation crédible d'une influence causale authentique — même si un effet corrélé résiduel (même bâtiment, mêmes ressources du campus) ne peut jamais être totalement exclu sans plus de détails sur le dispositif.
- (d) L'écart entre 0,991 (choix par affinité) et 0,808 (assignation aléatoire), soit environ 0,18 point de corrélation, peut se lire comme la part **ajoutée par la sélection** : les étudiants qui choisissent eux-mêmes un ami de GPA proche gonflent artificiellement la corrélation observée, par-dessus l'effet de paires authentique déjà détecté sous assignation aléatoire. Le dispositif expérimental (a) isole ce dernier ; le dispositif observationnel (b), lui, mélange les deux composantes sans possibilité de les séparer — exactement le risque que l'assignation aléatoire est conçue pour éliminer.

Correction — Exercice 6

- (a) Bloc 1 : l'étudiant à 40 a pour colocataire 41, et réciproquement. Bloc 2 : $44 \leftrightarrow 43$. Bloc 3 : $42 \leftrightarrow 43$.
- (b) Avec $y = (40, 41, 44, 43, 42, 43)$ et $y_{\text{pair}} = (41, 40, 43, 44, 43, 42)$: $\text{corr} \approx 0,723$.
- (c) Cette corrélation est **loin** d'être proche de zéro : elle est même substantielle (0,723), alors que la pointure de pied d'un adulte ne peut, physiologiquement, subir **aucune** influence sociale de la part d'un colocataire. Elle provient entièrement du fait que les blocs de dortoir ont des « niveaux » moyens de pointure différents (peut-être liés à la taille moyenne des étudiants qui y ont été affectés, ou à un pur hasard d'affectation) : un effet corrélé de composition de groupe, rigoureusement analogue au choc c_g de l'exercice 3, mais ici appliqué à une variable dont la contagion sociale est **a priori** impossible.
- (d) Puisqu'une méthode qui « détecte » une contagion sociale de la pointure de pied ne peut, par définition, mesurer une véritable influence comportementale (aucun mécanisme causal plausible n'existe), toute « détection » de ce type prouve que la méthode capte en réalité un effet corrélé ou un artefact de composition de groupe, et non l'effet endogène qu'elle prétend isoler. C'est exactement ce que Cohen-Cole et Fletcher (2008) ont démontré en répliquant la méthode de Christakis et Fowler sur l'acné et la taille : si la méthode « trouve » une contagion pour des traits manifestement non contagieux, elle ne peut être crédible pour l'obésité non plus, à moins de disposer d'arguments supplémentaires (assignation aléatoire, instrument validé indépendamment) qui excluent spécifiquement les effets corrélés et de sélection pour ce résultat précis. Le test de falsification est « le moins coûteux et le plus décisif » précisément parce qu'il ne demande aucune donnée supplémentaire : il suffit d'appliquer la même méthode à un résultat dont on est **certain a priori** qu'il ne peut pas se transmettre socialement.