

Chapitre 7

Le graphe aléatoire d'Erdős et Rényi

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Théorie des réseaux


1 Exercices du chapitre

Correction — Exercice 1

(a) $\mathbb{E}[m] = p \binom{n}{2} = 0,08 \times \frac{50 \times 49}{2} = 0,08 \times 1225 = 98,0$.

(b) $\bar{k} = p(n-1) = 0,08 \times 49 = 3,92$.


(c) $\mathbb{P}(k_i = 4) = e^{-3,92} \frac{3,92^4}{4!} \approx 0,1952$.



Distribution de Poisson de paramètre $\bar{k} = 3,92$: concentrée autour de la moyenne, quasiment nulle au-delà de $k = 10$.

(d) $\sqrt{\bar{k}} = \sqrt{3,92} \approx 1,98$. Un degré de 20 représenterait un écart de $20 - 3,92 \approx 16,08$, soit plus de 8 écarts-types au-dessus de la moyenne : sous une loi de Poisson (dont la queue décroît en $e^{-\bar{k}} \bar{k}^k / k!$, bien plus vite qu'une loi normale au-delà de quelques écarts-types), une telle valeur est **extraordinairement improbable** — pratiquement impossible sous ce modèle.

Correction — Exercice 2



(a) Pour $\bar{k} = 0,8 < 1$, $S = 0$ est bien solution : $1 - e^{-0,8 \times 0} = 1 - e^0 = 1 - 1 = 0$. ✓ C'est la **seule** solution pertinente dans ce régime sous-critique : en dessous du seuil $\bar{k} = 1$, l'exploration du réseau depuis un sommet s'éteint presque sûrement (processus de branchement sous-critique), et aucune composante de taille proportionnelle à n ne peut apparaître — seulement des composantes de taille $O(\ln n)$, négligeables face à n quand n est grand.

(b) En partant de $S_0 = 0,9$: $S_1 = 1 - e^{-1,2 \times 0,9} = 1 - e^{-1,08} \approx 1 - 0,3396 = 0,6604$. $S_2 = 1 - e^{-1,2 \times 0,6604} = 1 - e^{-0,7925} \approx 1 - 0,4528 = 0,5472$. L'itération continue de décroître et converge vers $S \approx 0,314$ après davantage d'itérations (la convergence est lente près du seuil critique) — cohérent avec la valeur donnée.

(c) Pour $\bar{k} = 4$ et $n = 10\,000$, $S \approx 0,980$ signifie qu'environ 9 800 des 10 000 sommets appartiennent à la composante géante, les 200 restants étant dispersés en petites composantes marginales.

(d) C'est précisément la définition d'une transition de phase : le comportement **qualitatif** du système (existence ou non d'une composante géante, c'est-à-dire d'ordre $O(n)$) bascule brutalement au franchissement d'un seuil précis ($\bar{k} = 1$), et non progressivement. Un changement de $\bar{k}$ aussi modeste que 0,4 ($0,8 \rightarrow 1,2$) fait passer le réseau de « aucune structure géante » à « une composante contenant déjà 31 % des sommets » — une discontinuité qualitative typique des phénomènes de seuil, par opposition à une évolution lisse et proportionnelle.

Correction — Exercice 3

(a) $p = \frac{m}{\binom{n}{2}} = \frac{900}{300 \times 299 / 2} = \frac{900}{44\,850} \approx 0,02007$. $\bar{k} = 2m/n = 1\,800/300 = 6,000$.

(b) $\mathbb{E}[C] = p \approx 0,0201$.

(c) $C_{\text{obs}}/\mathbb{E}[C] = 0,35/0,0201 \approx 17,4$.

(d) Non, ce rapport (≈ 17) est bien plus modeste que ceux du tableau du cours ($\approx 2\,500$ à $2\,900$). La taille plus réduite de ce réseau ($n = 300$) explique directement cet écart : $\mathbb{E}[C] = p = \bar{k}/(n-1)$ décroît avec n à $\bar{k}$ fixé, donc plus n est grand, plus $\mathbb{E}[C]$ devient **minuscule** tout en laissant le clustering **réel** à peu près constant (le clustering observé dépend de la sociologie de la collaboration, pas de la taille du réseau) — l'écart **grandit mécaniquement** avec n . Sur un réseau de 300 chercheurs seulement, p reste assez grand (2 %) pour que l'écart, bien réel, ne soit encore que d'une petite vingtaine de fois, et non de plusieurs milliers.

2 Exercice cumulatif

Correction — Exercice 4

(a) $\bar{k} = p(n-1) = 0,381 \times 6 \approx 2,286 = 16/7$. ✓ Coïncidence exacte avec le chapitre 5, par construction : p a été choisi égal à ρ , et $\rho \times (n-1) = \bar{k}$ est une identité algébrique (chapitre 5).

(b) $\mathbb{E}[C] = p \approx 0,381$. Clustering réel : $\bar{C} \approx 0,667$. Rapport $\approx 0,667/0,381 \approx 1,75$.

(c) Non, ce rapport ($\approx 1,75$) est très loin des rapports de 1 000 à 3 000 observés par le cours sur de vrais grands réseaux. La raison tient à la formule même : $p = \bar{k}/(n-1)$. Quand $n \rightarrow \infty$ à $\bar{k}$ fixé (ce qui est la situation des grands réseaux réels du cours, où $\bar{k}$ reste de l'ordre de quelques unités à quelques dizaines même pour des millions de nœuds), $p \rightarrow 0$: $\mathbb{E}[C] = p$ devient donc **minuscule**, alors que le clustering réel, lui, ne diminue pas avec n (il reflète une propriété sociologique ou structurelle stable). L'écart entre les deux **grandit mécaniquement** avec n . Sur le réseau du cours, $n = 7$ est si petit que $p = 0,381$ reste une valeur « normale », pas infinitésimale : l'écart entre prédiction et réalité, bien réel qualitativement (le réel dépasse la prédiction), ne peut structurellement pas atteindre plusieurs ordres de grandeur à cette échelle.

(d) Le réseau du cours est connexe à 100 % (chapitre 6 : une seule composante, comprenant les 7 sommets), alors que le modèle $G(7, p)$ ne prédit que 86 % ($S \approx 0,860$). C'est un écart attendu : le résultat de la transition de phase d'Erdős-Rényi est un résultat **asymptotique**, valable quand $n \rightarrow \infty$. Sur un réseau de 7 sommets seulement, les « effets de petite taille » dominent largement le comportement moyen prédit par la théorie — de plus, le réseau du cours n'a **pas** été engendré par un tirage aléatoire $G(7, p)$, il a été **construit délibérément** pour être connexe (afin d'illustrer distances, ponts, centralités, etc. sur un exemple pédagogique unique) : comparer sa connexité effective à celle d'un $G(n, p)$ typique n'a donc de sens qu'à titre d'illustration du **contraste**, pas comme un test rigoureux du modèle.

(e) Le modèle $G(n, p)$ appliqué au réseau du cours **échoue** nettement à en reproduire les propriétés structurelles : il sous-estime le clustering réel (même si l'écart n'est que d'un facteur $\approx 1,75$ ici, contre des milliers sur de grands réseaux) et sous-estime la connexité (86 % prédits contre 100 % réels). C'est parfaitement cohérent avec le bilan du cours : le modèle « réussit les distances » (chapitre 6 : ℓ croît lentement) et « la composante géante au-delà de $\bar{k} = 1$ » (qualitativement vrai ici aussi, bien que quantitativement imprécis à si petite échelle), mais « échoue sur le clustering », une régularité qui se manifeste ici même sur un réseau minuscule — une preuve supplémentaire que l'échec du clustering n'est pas un simple artefact de très grande taille, mais un trait **qualitatif** du modèle purement aléatoire.

3 Applications en sciences économiques

Correction — Exercice 5

(a) $\mathbb{E}[m] = p \binom{n}{2} = 0,003 \times \frac{1\,000 \times 999}{2} = 0,003 \times 499\,500 = \mathbf{1\,498,5}$. $\bar{k} = p(n-1) = 0,003 \times 999 = \mathbf{2,997}$.

(b) $\mathbb{P}(k_i = 3) = e^{-2,997} \frac{2,997^3}{3!} \approx \mathbf{0,2240}$.

(c) $\mathbb{P}(k_i = 30) \approx \mathbf{3,76 \times 10^{-20}}$ — un ordre de grandeur absolument négligeable, essentiellement nul en pratique (bien plus rare qu'un événement « impossible » dans n'importe quel contexte empirique).

(d) Non, le modèle $G(n, p)$ ne peut, par construction, **jamais** produire un individu avec des centaines ou des milliers de contacts dans une population de cette taille : la probabilité en est astronomiquement faible, comme le montre la question (c). L'hypothèse directement responsable est l'**indépendance** des liens : chaque paire de personnes se connaît indépendamment avec la même probabilité p , sans aucun mécanisme qui permettrait à un individu particulier (par exemple, un recruteur professionnel dont le **métier** est justement d'accumuler des contacts) d'accumuler des liens à un rythme disproportionné. Le modèle ignore toute hétérogénéité *a priori* entre les individus quant à leur propension à créer des liens — exactement la lacune que le chapitre 8 corrigera par une règle d'attachement préférentiel.

Correction — Exercice 6

(a) $S(\bar{k} = 0,7) = \mathbf{0,000}$; $S(\bar{k} = 1,3) = \mathbf{0,423}$; $S(\bar{k} = 2,5) = \mathbf{0,893}$.

(b) Ce seuil est crucial parce qu'il indique qu'une action régulatoire relativement **modeste** sur $\bar{k}$ (le nombre moyen de contreparties par banque) peut avoir un effet radical sur la structure du risque systémique : passer d'un système *sous-critique* ($\bar{k} < 1$, aucune composante géante, contagion structurellement limitée) à un système *sur-critique* ($\bar{k} > 1$, une composante géante qui peut englober l'essentiel du système) ne demande qu'un changement modeste de $\bar{k}$. Un régulateur qui maintiendrait $\bar{k}$ proche de 1 mais en dessous, en plafonnant le nombre de contreparties autorisées par banque, empêcherait structurellement l'émergence d'une composante systémique de grande taille.

(c) $p = \frac{200}{80 \times 79/2} = \frac{200}{3\,160} \approx \mathbf{0,0633}$. $\bar{k} = 2 \times 200/80 = \mathbf{5,000}$. $\mathbb{E}[C] = p \approx \mathbf{0,0633}$.

(d) $C_{\text{obs}}/\mathbb{E}[C] = 0,28/0,0633 \approx \mathbf{4,4}$. Ce rapport, nettement inférieur aux « milliers de fois » typiques des grands réseaux sociaux, reflète, exactement comme à l'exercice 4, un **effet de taille** et non une différence de nature entre réseaux financiers et réseaux sociaux : avec seulement $n = 80$ banques, $p = \bar{k}/(n-1)$ reste relativement élevé (6,3 %), donc $\mathbb{E}[C]$ n'est pas infinitésimal. Si ce même système comptait des milliers de banques à $\bar{k}$ constant, p s'effondrerait et le rapport $C_{\text{obs}}/\mathbb{E}[C]$ se rapprocherait des ordres de grandeur observés sur les grands réseaux sociaux ou techniques — le modèle $G(n, p)$ échouerait alors tout aussi spectaculairement à représenter le clustering interbancaire réel qu'il échoue à représenter celui des coauteurs ou des acteurs de cinéma.