

Théorie des réseaux

Chapitre 7 : Le graphe aléatoire d'Erdos et Renyi

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Théorie des réseaux

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Les premiers moments de $G(n, p)$

On simule un réseau $G(n, p)$ avec $n = 50$ sommets et $p = 0,08$.

- (a) Calculer $\mathbb{E}[m]$, le nombre attendu d'arêtes.
- (b) Calculer $\bar{k} = p(n - 1)$.
- (c) En approximant la loi des degrés par une loi de Poisson de paramètre $\bar{k}$, calculer $\mathbb{P}(k_i = 4)$.
- (d) L'écart-type d'une loi de Poisson de paramètre $\bar{k}$ vaut $\sqrt{\bar{k}}$. Le calculer ici. Un nœud de degré 20 serait-il, d'après vous, plausible sous ce modèle (sans calcul exact, à partir du nombre d'écarts-types que représente un tel écart) ?

Exercice 2 — Le seuil de la composante géante

On étudie l'équation de point fixe $S = 1 - e^{-\bar{k}S}$ pour trois valeurs de $\bar{k}$: 0,8, 1,2 et 4.

- (a) Pour $\bar{k} = 0,8$ (< 1), que vaut la solution non triviale de l'équation ? Vérifier que $S = 0$ est bien solution, et pourquoi c'est la seule solution pertinente dans ce régime.
- (b) Pour $\bar{k} = 1,2$ (> 1), on donne $S \approx 0,314$. Vérifier numériquement (par une itération ou deux de $S \leftarrow 1 - e^{-1,2S}$ à partir de $S_0 = 0,9$) que ce point fixe est cohérent.
- (c) Pour $\bar{k} = 4$, on donne $S \approx 0,980$. Que signifie concrètement cette valeur pour un réseau de $n = 10\,000$ sommets ?
- (d) Entre $\bar{k} = 0,8$ et $\bar{k} = 1,2$ (un changement de seulement 0,4), le comportement qualitatif du réseau change du tout au tout. En quoi ceci illustre-t-il l'idée de « transition de phase » évoquée par le cours ?

Exercice 3 — Le clustering prédit, à l'échelle d'un vrai réseau

Un réseau de collaboration comprend $n = 300$ chercheurs et $m = 900$ collaborations, modélisé comme un $G(n, p)$ de même densité.

- (a) Calculer p et $\bar{k}$ pour ce réseau.
- (b) En déduire $\mathbb{E}[C] = p$, le clustering prédit par le modèle aléatoire pur.
- (c) Le clustering réellement observé sur ce réseau est $C_{\text{obs}} = 0,35$. Calculer le rapport $C_{\text{obs}}/\mathbb{E}[C]$.
- (d) Ce rapport est-il du même ordre de grandeur que ceux du tableau du cours (coauteurs $\approx 0,45/0,00018 \approx 2\,500$, acteurs $\approx 0,79/0,00027 \approx 2\,900$) ? Qu'est-ce que la taille plus modeste de ce réseau ($n = 300$ contre des millions dans les exemples du cours) change à l'ampleur de l'écart ?

2 Exercice cumulatif (chapitre 7 et chapitres précédents)

Exercice 4 — Le réseau du cours, vu comme un $G(n, p)$ (et pourquoi ce n'en est pas un)

On modélise le réseau du cours ($n = 7, m = 8$) comme un $G(7, p)$ de même densité que celle calculée au chapitre 5, $p = \rho \approx 0,381$.

- (a) Calculer $\bar{k} = p \times (n - 1)$ pour ce modèle, et vérifier qu'il coïncide avec le $\bar{k} = 16/7$ du réseau réel (chapitre 5).
- (b) Calculer $\mathbb{E}[C] = p$ sous ce modèle aléatoire. Le comparer au clustering **réellement observé** sur le réseau du cours, $\bar{C} \approx 0,667$ (chapitre 5). Calculer le rapport.
- (c) Ce rapport ($\approx 1,75$) est-il du même ordre de grandeur que les rapports de « trois ordres de grandeur » (facteur $\approx 1\,000$ à $3\,000$) que le cours observe sur de vrais grands réseaux ? Pourquoi la petite taille ($n = 7$) du réseau du cours rend-elle cette comparaison structurellement différente

— en particulier, que devient $p = \bar{k}/(n-1)$ quand n devient très grand à $\bar{k}$ fixé, et pourquoi cela change-t-il la nature de l'écart ?

- (d) On résout $S = 1 - e^{-\bar{k}S}$ avec $\bar{k} = 16/7 \approx 2,286$: on obtient $S \approx 0,860$. Le réseau du cours est-il, en réalité, connexe à 100 % (chapitre 6) ou seulement à 86 % comme le prédit le modèle ? Expliquer cet écart par la nature **asymptotique** ($n \rightarrow \infty$) du résultat d'Erdős-Rényi sur la composante géante, largement invalidée sur un réseau de seulement 7 sommets par des effets de « petite taille ».
- (e) En synthèse : le modèle $G(n, p)$ appliqué au réseau du cours réussit-il, ou échoue-t-il, à en reproduire les propriétés structurelles (clustering, connexité) ? Est-ce cohérent avec le bilan du cours (« deux succès, deux échecs ») ?

3 Applications en sciences économiques

Exercice 5 — Un marché du travail purement aléatoire

On modélise, à titre d'expérience de pensée, un marché du travail de $n = 1\,000$ actifs où chaque paire de personnes se connaît, indépendamment, avec probabilité $p = 0,003$.

- (a) Calculer $\mathbb{E}[m]$ et $\bar{k}$.
- (b) Calculer $\mathbb{P}(k_i = 3)$ sous l'approximation de Poisson.
- (c) Calculer $\mathbb{P}(k_i = 30)$ (un individu extrêmement bien connecté, dix fois la moyenne). Commenter l'ordre de grandeur obtenu.
- (d) Dans un marché du travail **réel**, certains individus (des recruteurs professionnels, des figures très en vue d'un secteur) ont des centaines voire des milliers de contacts professionnels. Le modèle $G(n, p)$ peut-il, par construction, produire un tel individu ? Quelle hypothèse du modèle (rappeler laquelle, parmi celles du cours) est directement responsable de cette impossibilité ?

Exercice 6 — Seuil de connexité interbancaire et clustering

Un régulateur étudie un système de $n = 80$ banques, avec $\bar{k}$ contreparties en moyenne par banque, modélisé en première approximation comme un $G(n, p)$.

- (a) Calculer S (fraction dans la composante géante) pour $\bar{k} = 0,7$, $\bar{k} = 1,3$ et $\bar{k} = 2,5$ (on résoudra $S = 1 - e^{-\bar{k}S}$ par itération, ou on admettra les valeurs 0,000 ; 0,423 ; 0,893).
- (b) Sachant que $\bar{k} > 1$ déclenche l'apparition d'une composante géante, pourquoi ce seuil est-il une information cruciale pour un régulateur qui voudrait limiter la taille de la composante systémique du réseau interbancaire (par exemple en plafonnant le nombre moyen de contreparties par banque) ?
- (c) On observe $m = 200$ relations effectives dans ce système. Calculer p , $\bar{k}$, puis $\mathbb{E}[C] = p$.
- (d) Le clustering interbancaire réellement observé est $C_{\text{obs}} = 0,28$. Calculer le rapport à $\mathbb{E}[C]$. En quoi ce rapport (nettement inférieur aux « milliers de fois » typiques des grands réseaux sociaux) reflète-t-il, comme à l'exercice 4, un effet de taille plutôt qu'une différence de nature entre réseaux financiers et réseaux sociaux ?


1 Exercices du chapitre

Correction — Exercice 1

(a) $\mathbb{E}[m] = p \binom{n}{2} = 0,08 \times \frac{50 \times 49}{2} = 0,08 \times 1225 = 98,0$.

(b) $\bar{k} = p(n-1) = 0,08 \times 49 = 3,92$.


(c) $\mathbb{P}(k_i = 4) = e^{-3,92} \frac{3,92^4}{4!} \approx 0,1952$.



Distribution de Poisson de paramètre $\bar{k} = 3,92$: concentrée autour de la moyenne, quasiment nulle au-delà de $k = 10$.

(d) $\sqrt{\bar{k}} = \sqrt{3,92} \approx 1,98$. Un degré de 20 représenterait un écart de $20 - 3,92 \approx 16,08$, soit plus de 8 écarts-types au-dessus de la moyenne : sous une loi de Poisson (dont la queue décroît en $e^{-\bar{k}} \bar{k}^k / k!$, bien plus vite qu'une loi normale au-delà de quelques écarts-types), une telle valeur est **extraordinairement improbable** — pratiquement impossible sous ce modèle.

Correction — Exercice 2



(a) Pour $\bar{k} = 0,8 < 1$, $S = 0$ est bien solution : $1 - e^{-0,8 \times 0} = 1 - e^0 = 1 - 1 = 0$. ✓ C'est la **seule** solution pertinente dans ce régime sous-critique : en dessous du seuil $\bar{k} = 1$, l'exploration du réseau depuis un sommet s'éteint presque sûrement (processus de branchement sous-critique), et aucune composante de taille proportionnelle à n ne peut apparaître — seulement des composantes de taille $O(\ln n)$, négligeables face à n quand n est grand.

(b) En partant de $S_0 = 0,9$: $S_1 = 1 - e^{-1,2 \times 0,9} = 1 - e^{-1,08} \approx 1 - 0,3396 = 0,6604$. $S_2 = 1 - e^{-1,2 \times 0,6604} = 1 - e^{-0,7925} \approx 1 - 0,4528 = 0,5472$. L'itération continue de décroître et converge vers $S \approx 0,314$ après davantage d'itérations (la convergence est lente près du seuil critique) — cohérent avec la valeur donnée.

(c) Pour $\bar{k} = 4$ et $n = 10\,000$, $S \approx 0,980$ signifie qu'environ 9 800 des 10 000 sommets appartiennent à la composante géante, les 200 restants étant dispersés en petites composantes marginales.

(d) C'est précisément la définition d'une transition de phase : le comportement **qualitatif** du système (existence ou non d'une composante géante, c'est-à-dire d'ordre $O(n)$) bascule brutalement au franchissement d'un seuil précis ($\bar{k} = 1$), et non progressivement. Un changement de $\bar{k}$ aussi modeste que 0,4 ($0,8 \rightarrow 1,2$) fait passer le réseau de « aucune structure géante » à « une composante contenant déjà 31 % des sommets » — une discontinuité qualitative typique des phénomènes de seuil, par opposition à une évolution lisse et proportionnelle.

Correction — Exercice 3

(a) $p = \frac{m}{\binom{n}{2}} = \frac{900}{300 \times 299/2} = \frac{900}{44850} \approx 0,02007$. $\bar{k} = 2m/n = 1800/300 = 6,000$.

(b) $\mathbb{E}[C] = p \approx 0,0201$.

(c) $C_{\text{obs}}/\mathbb{E}[C] = 0,35/0,0201 \approx 17,4$.

(d) Non, ce rapport (≈ 17) est bien plus modeste que ceux du tableau du cours (≈ 2500 à 2900). La taille plus réduite de ce réseau ($n = 300$) explique directement cet écart : $\mathbb{E}[C] = p = \bar{k}/(n-1)$ décroît avec n à $\bar{k}$ fixé, donc plus n est grand, plus $\mathbb{E}[C]$ devient **minuscule** tout en laissant le clustering **réel** à peu près constant (le clustering observé dépend de la sociologie de la collaboration, pas de la taille du réseau) — l'écart **grandit mécaniquement** avec n . Sur un réseau de 300 chercheurs seulement, p reste assez grand (2 %) pour que l'écart, bien réel, ne soit encore que d'une petite vingtaine de fois, et non de plusieurs milliers.

2 Exercice cumulatif

Correction — Exercice 4

(a) $\bar{k} = p(n-1) = 0,381 \times 6 \approx 2,286 = 16/7$. ✓ Coïncidence exacte avec le chapitre 5, par construction : p a été choisi égal à ρ , et $\rho \times (n-1) = \bar{k}$ est une identité algébrique (chapitre 5).

(b) $\mathbb{E}[C] = p \approx 0,381$. Clustering réel : $\bar{C} \approx 0,667$. Rapport $\approx 0,667/0,381 \approx 1,75$.

(c) Non, ce rapport ($\approx 1,75$) est très loin des rapports de 1 000 à 3 000 observés par le cours sur de vrais grands réseaux. La raison tient à la formule même : $p = \bar{k}/(n-1)$. Quand $n \rightarrow \infty$ à $\bar{k}$ fixé (ce qui est la situation des grands réseaux réels du cours, où $\bar{k}$ reste de l'ordre de quelques unités à quelques dizaines même pour des millions de nœuds), $p \rightarrow 0$: $\mathbb{E}[C] = p$ devient donc **minuscule**, alors que le clustering réel, lui, ne diminue pas avec n (il reflète une propriété sociologique ou structurelle stable). L'écart entre les deux **grandit mécaniquement** avec n . Sur le réseau du cours, $n = 7$ est si petit que $p = 0,381$ reste une valeur « normale », pas infinitésimale : l'écart entre prédiction et réalité, bien réel qualitativement (le réel dépasse la prédiction), ne peut structurellement pas atteindre plusieurs ordres de grandeur à cette échelle.

(d) Le réseau du cours est connexe à 100 % (chapitre 6 : une seule composante, comprenant les 7 sommets), alors que le modèle $G(7, p)$ ne prédit que 86 % ($S \approx 0,860$). C'est un écart attendu : le résultat de la transition de phase d'Erdős-Rényi est un résultat **asymptotique**, valable quand $n \rightarrow \infty$. Sur un réseau de 7 sommets seulement, les « effets de petite taille » dominent largement le comportement moyen prédit par la théorie — de plus, le réseau du cours n'a **pas** été engendré par un tirage aléatoire $G(7, p)$, il a été **construit délibérément** pour être connexe (afin d'illustrer distances, ponts, centralités, etc. sur un exemple pédagogique unique) : comparer sa connexité effective à celle d'un $G(n, p)$ typique n'a donc de sens qu'à titre d'illustration du **contraste**, pas comme un test rigoureux du modèle.

(e) Le modèle $G(n, p)$ appliqué au réseau du cours **échoue** nettement à en reproduire les propriétés structurelles : il sous-estime le clustering réel (même si l'écart n'est que d'un facteur $\approx 1,75$ ici, contre des milliers sur de grands réseaux) et sous-estime la connexité (86 % prédits contre 100 % réels). C'est parfaitement cohérent avec le bilan du cours : le modèle « réussit les distances » (chapitre 6 : ℓ croît lentement) et « la composante géante au-delà de $\bar{k} = 1$ » (qualitativement vrai ici aussi, bien que quantitativement imprécis à si petite échelle), mais « échoue sur le clustering », une régularité qui se manifeste ici même sur un réseau minuscule — une preuve supplémentaire que l'échec du clustering n'est pas un simple artefact de très grande taille, mais un trait **qualitatif** du modèle purement aléatoire.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) $\mathbb{E}[m] = p \binom{n}{2} = 0,003 \times \frac{1\,000 \times 999}{2} = 0,003 \times 499\,500 = \mathbf{1\,498,5}$. $\bar{k} = p(n-1) = 0,003 \times 999 = \mathbf{2,997}$.
- (b) $\mathbb{P}(k_i = 3) = e^{-2,997} \frac{2,997^3}{3!} \approx \mathbf{0,2240}$.
- (c) $\mathbb{P}(k_i = 30) \approx \mathbf{3,76 \times 10^{-20}}$ — un ordre de grandeur absolument négligeable, essentiellement nul en pratique (bien plus rare qu'un événement « impossible » dans n'importe quel contexte empirique).
- (d) Non, le modèle $G(n, p)$ ne peut, par construction, **jamais** produire un individu avec des centaines ou des milliers de contacts dans une population de cette taille : la probabilité en est astronomiquement faible, comme le montre la question (c). L'hypothèse directement responsable est l'**indépendance** des liens : chaque paire de personnes se connaît indépendamment avec la même probabilité p , sans aucun mécanisme qui permettrait à un individu particulier (par exemple, un recruteur professionnel dont le **métier** est justement d'accumuler des contacts) d'accumuler des liens à un rythme disproportionné. Le modèle ignore toute hétérogénéité *a priori* entre les individus quant à leur propension à créer des liens — exactement la lacune que le chapitre 8 corrigera par une règle d'attachement préférentiel.

Correction — Exercice 6

- (a) $S(\bar{k} = 0,7) = \mathbf{0,000}$; $S(\bar{k} = 1,3) = \mathbf{0,423}$; $S(\bar{k} = 2,5) = \mathbf{0,893}$.
- (b) Ce seuil est crucial parce qu'il indique qu'une action régulatoire relativement **modeste** sur $\bar{k}$ (le nombre moyen de contreparties par banque) peut avoir un effet radical sur la structure du risque systémique : passer d'un système *sous-critique* ($\bar{k} < 1$, aucune composante géante, contagion structurellement limitée) à un système *sur-critique* ($\bar{k} > 1$, une composante géante qui peut englober l'essentiel du système) ne demande qu'un changement modeste de $\bar{k}$. Un régulateur qui maintiendrait $\bar{k}$ proche de 1 mais en dessous, en plafonnant le nombre de contreparties autorisées par banque, empêcherait structurellement l'émergence d'une composante systémique de grande taille.
- (c) $p = \frac{200}{80 \times 79/2} = \frac{200}{3\,160} \approx \mathbf{0,0633}$. $\bar{k} = 2 \times 200/80 = \mathbf{5,000}$. $\mathbb{E}[C] = p \approx \mathbf{0,0633}$.
- (d) $C_{\text{obs}}/\mathbb{E}[C] = 0,28/0,0633 \approx \mathbf{4,4}$. Ce rapport, nettement inférieur aux « milliers de fois » typiques des grands réseaux sociaux, reflète, exactement comme à l'exercice 4, un **effet de taille** et non une différence de nature entre réseaux financiers et réseaux sociaux : avec seulement $n = 80$ banques, $p = \bar{k}/(n-1)$ reste relativement élevé (6,3 %), donc $\mathbb{E}[C]$ n'est pas infinitésimal. Si ce même système comptait des milliers de banques à $\bar{k}$ constant, p s'effondrerait et le rapport $C_{\text{obs}}/\mathbb{E}[C]$ se rapprocherait des ordres de grandeur observés sur les grands réseaux sociaux ou techniques — le modèle $G(n, p)$ échouerait alors tout aussi spectaculairement à représenter le clustering interbancaire réel qu'il échoue à représenter celui des coauteurs ou des acteurs de cinéma.