

Chapitre 15

Mise en œuvre sur R et Python


Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Théorie des réseaux

1 Exercices du chapitre

Correction — Exercice 1



(a) A : atteint B (dist. 1) et C (dist. 2), soit 2 nœuds, somme = 3 : $C_C(A) = 2/3 \approx 0,667$. B : atteint A et C (dist. 1 chacun), 2 nœuds, somme = 2 : $C_C(B) = 2/2 = 1,000$. C : symétrique à A , $C_C(C) \approx 0,667$. D : atteint seulement E (dist. 1), 1 nœud, somme = 1 : $C_C(D) = 1/1 = 1,000$. $C_C(E) = 1,000$ de même.

(b) Oui, $C_C(B) = C_C(D) = C_C(E) = 1,000$: les trois valeurs sont **rigoureusement égales**.

(c) Non, absolument pas : B a accès à 2 des 4 autres nœuds du réseau (A et C), tandis que D (ou E) n'a accès qu'à 1 seul des 4 autres nœuds (E , respectivement D) — les 3 nœuds de l'autre composante leur restent structurellement inaccessibles. Le nombre « 1,000 » ne dit rien de cette différence : il mesure seulement la proximité **au sein du sous-ensemble atteint**, en ignorant silencieusement tout le reste du réseau.

(d) C'est exactement le piège décrit par le cours : le logiciel calcule un nombre parfaitement valide en apparence ($C_C = 1,000$, la valeur maximale possible), sans jamais signaler que le graphe est déconnecté ni que ce nombre ne porte que sur une infime fraction du réseau. Un analyste pressé pourrait conclure, à tort, que D et E sont « aussi centraux que possible », alors qu'ils sont en réalité isolés de l'essentiel du réseau. Le réflexe qui aurait détecté le problème immédiatement : vérifier d'abord si le graphe est connexe (une fonction disponible en une ligne dans `igraph` comme dans `networkx`) **avant** de calculer et d'interpréter toute mesure de distance.

Correction — Exercice 2

(a) $(n-1)(n-2)/2 = (7-1)(7-2)/2 = 6 \times 5/2 = 15$.

(b) $b'_1 = b'_2 = b'_6 = b'_7 = 0/15 = 0$. $b'_3 = b'_5 = 8/15 \approx 0,533$. $b'_4 = 9/15 = 0,600$.

(c) Non, elles ne sont **pas** en désaccord : 9 (la valeur brute, non normalisée) et 0,6 (la même quantité divisée par 15) désignent exactement le **même** résultat sous-jacent, exprimé dans deux échelles différentes. $9/15 = 0,6$ précisément.

(d) La confusion vient de ce qu'`igraph` et `networkx` ne partagent **pas** la même convention de normalisation par défaut (`igraph` : brute par défaut; `networkx` : normalisée par défaut), un piège explicitement cité par le cours. Pour l'éviter systématiquement, il faut toujours vérifier, avant toute comparaison entre logiciels, (i) quelle est la valeur par défaut de l'argument de normalisation dans chacun des deux, et (ii) idéalement, reproduire le calcul **à la main** sur un petit réseau connu (comme celui du cours) pour confirmer que les deux logiciels, une fois correctement paramétrés, donnent bien le même résultat sous-jacent.

Correction — Exercice 3

(a) Le degré « réel » (nombre de voisins **distincts**) de X est 3 (Y_1, Y_2, Y_3) : une boucle ne relie X à aucun voisin supplémentaire, seulement à lui-même.

(b) Avec la convention usuelle (une boucle ajoute 2 au degré), le logiciel affichera $3 + 2 = 5$ pour X — un degré supérieur de 2 au degré réel, sans qu'aucun message ne signale l'anomalie.

(c) Sur 1 000 articles, 50 contaminés par une boucle ajoutent chacun 2 unités de degré « fantômes », soit 100 unités de degré en trop sur l'ensemble du réseau. Le $\bar{k}$ calculé sera donc supérieur de $100/1\,000 = 0,1$ au $\bar{k}$ réellement souhaité — une distorsion discrète mais systématique, d'autant plus trompeuse qu'elle est difficile à repérer visuellement sur un grand réseau.

(d) Le logiciel ne peut pas, par construction, distinguer une boucle « légitime » (dans certains contextes, par exemple une entreprise qui investit dans sa propre R&D) d'une boucle « parasite » issue d'une erreur de nettoyage des données : la présence d'une boucle est, en elle-même, une donnée parfaitement valide au sens du format de graphe, donc rien ne déclenche d'avertissement.

La vérification systématique à effectuer avant toute analyse est un simple test de présence de boucles (`any(which_loop(g))` sous `igraph`, `nx.number_of_selfloops(G)` sous `networkx`), suivi, le cas échéant, de leur suppression explicite et délibérée (`simplify()` en `igraph`) plutôt que de leur inclusion silencieuse.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Oui, ces nombres correspondent **exactement** à ceux déjà établis : $n = 7$, $m = 8$ (chapitre 1), degrés $\{2, 2, 3, 2, 3, 2, 2\}$ (chapitre 1), $\lambda_1 \approx 2,343$ (chapitre 10, réutilisé aux chapitres 11 et 12). C'est précisément le « réflexe de vérification » du cours à l'œuvre : ces nombres constituent une signature suffisamment précise pour confirmer qu'il s'agit bien du même réseau.
- (b) Chaque arête non orientée $\{i, j\}$ du fichier d'origine, interprétée à tort comme un couple de liens orientés réciproques, produit **deux** arêtes orientées ($i \rightarrow j$ et $j \rightarrow i$) au lieu d'une seule arête non orientée. Avec 8 arêtes non orientées au départ, on obtient donc $8 \times 2 = 16$ arêtes orientées.
- (c) Oui : dans cette conversion « totalement réciproque » particulière, chaque nœud reçoit exactement un lien sortant pour chacun de ses voisins d'origine (puisque **toutes** les arêtes ont été dupliquées dans les deux sens). Le degré **sortant** de chaque nœud coïncide donc, dans ce cas précis, avec son degré non orienté d'origine — ce qui signifie que cette erreur particulière est **invisible** si l'on ne vérifie que les degrés un par un : c'est seulement le nombre **total** d'arêtes (16 au lieu de 8) qui la révèle.
- (d) Si l'arête $4 \rightarrow 3$ est supprimée (alors que $3 \rightarrow 4$ est conservée), le degré **sortant** de 4 diminue de 1 (il passe de 2 à 1, puisque 4 perd son lien sortant vers 3), tandis que le degré **entrant** de 3 diminue également de 1 (il passe de 2 à 1, puisque 3 ne reçoit plus le lien venant de 4) — alors que le degré **entrant** de 4 et le degré **sortant** de 3, eux, restent inchangés. Ce type d'erreur (réciprocité brisée sur une seule arête, parmi beaucoup d'autres) est beaucoup plus difficile à détecter que celle de la question (b) : le nombre total d'arêtes (15 au lieu de 16) ne signale qu'un déséquilibre **global** sans indiquer où il se situe, alors qu'une vérification degré par degré (comparer chaque degré sortant et entrant à la valeur non orientée attendue, 2 ou 3 selon le nœud) le localiserait précisément sur les nœuds 3 et 4. C'est un argument supplémentaire, très concret, en faveur du réflexe du cours : comparer aux nombres **complets** d'un petit réseau connu (tous les degrés, pas seulement leur somme ou leur nombre total), pas seulement à un unique agrégat global.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Le clustering observé (0,667) est **nettement au-dessus** de la moyenne nulle ($\approx 0,192$) — plus de trois fois supérieur — et au-dessus également de la médiane nulle ($\approx 0,238$).
- (b) 10,2 % correspond à un résultat qui se situe **dans le haut** de la distribution nulle (proche du 90^e centile), mais qui n'est **pas** extrêmement rare au sens statistique usuel (un seuil de rareté serait plutôt fixé autour de 1 à 5 %). Le clustering du réseau du cours est donc élevé par rapport au hasard à degrés conservés, mais pas au point d'être un événement exceptionnel isolé.
- (c) Avec seulement $n = 7$ nœuds et $m = 8$ arêtes, le nombre de configurations distinctes que peut prendre un recâblage à degrés conservés est lui-même **très limité** : la distribution nulle est nécessairement grossière (elle va de 0 à 0,905 par paliers assez larges), ce qui rend difficile de distinguer un résultat « franchement significatif » d'un résultat « notablement élevé mais plausible sous le hasard ». Sur un réseau de plusieurs milliers de nœuds, le nombre de recâblages possibles est immense, la distribution nulle devient beaucoup plus fine, et un écart de même ampleur relative serait bien plus facilement qualifié de statistiquement significatif.
- (d) Version rigoureuse : « Le clustering observé (0,667) est environ 3,5 fois supérieur à la moyenne d'un modèle nul à degrés conservés ($\approx 0,192$), et se situe dans le décile supérieur de cette distribution

nulle (10,2 % des réseaux recâblés l'égalent ou le dépassent). Compte tenu de la très petite taille du réseau ($n = 7$), ce résultat doit être interprété comme **suggestif d'une structure en communautés** plutôt que comme une preuve statistique définitive. »

Correction — Exercice 6

- (a) La question 1 relève directement du **paradoxe de l'ami** et de la stratégie « vacciner un ami au hasard » (chapitre 10) : ce n'est pas une centralité au sens strict qu'il faut calculer, mais la propriété statistique $\mathbb{E}[k_{\text{voisin}}] = \mathbb{E}[k^2]/\bar{k} \geq \bar{k}$, qui justifie **pourquoi** cet échantillonnage indirect (tirer un nœud puis l'un de ses voisins) atteint les hubs sans les avoir identifiés au préalable. Ce n'est en aucun cas un choix de commodité logicielle : c'est un résultat théorique précis qui explique le **mécanisme** par lequel la stratégie fonctionne, indépendamment de tout package.
- (b) Seule l'**intercentralité** (chapitre 11), $c_i = x_i^2 / [(\mathbf{I} - \phi \mathbf{A})^{-1}]_{ii}$, répond correctement à cette question : elle mesure la perte totale d'activité économique induite par le retrait d'un joueur, ce qu'aucune centralité de degré ou de proximité ne capture — le cours rappelle explicitement que le « joueur clé » n'est presque jamais le nœud le plus actif en apparence.
- (c) Une centralité de degré simple compte seulement le **nombre** de contreparties d'une banque, sans tenir compte des montants engagés ni de la **position** structurelle (cœur ou périphérie, pont ou nœud redondant). Or le chapitre 13 a montré qu'une banque de bilan modeste mais occupant une position de pont peut causer un effondrement systémique bien plus large qu'une banque plus grosse mais périphérique : il faut donc mobiliser soit le DebtRank (qui pondère par les expositions réelles et propage la détresse à travers le réseau), soit une analyse explicite de la position de pont (points d'articulation, chapitre 1), et non un simple comptage de liens.
- (d) Pour la question 1 : la centralité de degré ne dit rien sur **qui** interroger pour atteindre un hub sans le connaître au préalable — c'est le paradoxe de l'ami, pas le degré lui-même, qui justifie la stratégie. Pour la question 2 : le degré ignore entièrement l'effet de **renforcement mutuel** entre voisins (une banque de faible degré mais entourée de partenaires très actifs peut avoir une intercentralité élevée, et inversement) ; se limiter au degré risquerait de subventionner la mauvaise banque. Pour la question 3 : le degré ne capture ni les **montants** des expositions, ni le rôle de **pont** qui, comme démontré au chapitre 13, peut rendre une petite banque plus dangereuse pour le système qu'une grande banque bien diversifiée. Dans les trois cas, c'est le **mécanisme économique sous-jacent** à chaque question (diffusion, jeu stratégique, cascade de défauts) qui détermine la mesure pertinente — jamais la facilité de calcul d'une fonction disponible par défaut dans un package.