

Théorie des réseaux

Chapitre 15 : Mise en œuvre sur R et Python

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Théorie des réseaux

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	4

1 Exercices du chapitre

Exercice 1 — Le piège du graphe non connexe

Un analyste importe par erreur un réseau de collaborations en deux morceaux disjoints : $\{A, B, C\}$ formant une chaîne ($A-B-C$) et $\{D, E\}$ formant une paire isolée ($D-E$), sans aucun lien entre les deux groupes.

- Calculer, pour chacun des 5 nœuds, la centralité de proximité « naïve » telle que la calculerait par défaut un logiciel qui ignore silencieusement les paires non connectées : $C_C(v) = \frac{\text{nombre de nœuds atteignables}}{\text{somme des distances vers eux}}$.
- Comparer la valeur obtenue pour B (au centre de la chaîne à 3) et pour D ou E (isolés à deux, mais connectés entre eux). Ces deux valeurs sont-elles égales ?
- D et E n'ont pourtant accès qu'à **un seul** des 4 autres nœuds du réseau, contre 2 sur 4 pour B . Le nombre obtenu en (a) reflète-t-il cette différence réelle d'accessibilité au reste du réseau ?
- En quoi ce résultat illustre-t-il exactement la mise en garde du cours : « closeness renvoie une valeur trompeuse au lieu d'un avertissement » ? Quel réflexe simple (rappelé en fin de chapitre) aurait permis de détecter le problème avant toute interprétation économique ?

Exercice 2 — Le piège de la normalisation

Sur le réseau du cours ($V = \{1, \dots, 7\}$, $E = \{12, 13, 23, 34, 45, 56, 57, 67\}$), on calcule l'intermédiarité de sommet **brute** (nombre de paires de chemins les plus courts qui passent par chaque nœud) : $b_1 = b_2 = b_6 = b_7 = 0$, $b_3 = b_5 = 8$, $b_4 = 9$.

- La formule de normalisation usuelle (celle qu'igraph applique avec l'option `normalized=True`) divise par $(n-1)(n-2)/2$. Calculer ce dénominateur pour $n = 7$.
- En déduire l'intermédiarité normalisée de chacun des 7 nœuds.
- Un chercheur affirme, à tort, que la valeur « 9 » obtenue en R (avec `normalized=False`, la valeur par défaut d'igraph) contredit la valeur « 0,6 » obtenue par un collègue sous Python (avec `normalized=True`, la valeur par défaut de networkx) pour ce même nœud 4. Sont-elles réellement en désaccord ?
- Quelle est la source de cette confusion, et comment l'éviter systématiquement quand on compare des résultats obtenus par deux logiciels différents ?

Exercice 3 — Boucles et arêtes perdues

Un jeu de données de citations contient, par erreur de nettoyage, une boucle (un article qui se cite lui-même dans les métadonnées) sur le nœud X , qui a par ailleurs 3 citations distinctes vers d'autres articles Y_1, Y_2, Y_3 .

- Quel est le degré « réel » de X (nombre de voisins distincts) ?
- La convention usuelle (igraph et networkx) compte une boucle comme ajoutant 2 au degré total (les deux « extrémités » de la boucle touchent le même nœud). Quel degré le logiciel affichera-t-il pour X ?
- Sur un réseau de 1 000 articles où 50 contiennent une telle boucle parasite, quel est l'effet sur le degré moyen $\bar{k}$ calculé automatiquement par le logiciel, par rapport au $\bar{k}$ réellement souhaité ?
- Pourquoi ce genre d'erreur ne déclenche-t-elle, en général, **aucun message d'avertissement** de la part du logiciel ? Quelle vérification simple (portant sur la présence de boucles, une fonction standard dans igraph comme dans networkx) faudrait-il systématiquement effectuer avant toute analyse ?

2 Exercice cumulatif (chapitre 15 et chapitres précédents)

Exercice 4 — Le réflexe de vérification, appliqué au réseau du cours

Le cours recommande de « vérifier sur un petit réseau connu » avant de faire confiance à un calcul. On dispose de deux versions du fichier du réseau du cours, chargées par deux étudiants différents.

- (a) L'étudiant A obtient : 7 nœuds, 8 arêtes, degrés $\{2, 2, 3, 2, 3, 2, 2\}$, $\lambda_1 \approx 2,343$. Ces nombres correspondent-ils à ceux, déjà établis aux chapitres 1 et 2, du réseau du cours ?
- (b) L'étudiant B, qui a chargé son fichier comme un graphe **orienté** par erreur (chaque arête interprétée comme un couple de liens réciproques $i \rightarrow j$ et $j \rightarrow i$), obtient 16 arêtes orientées au lieu de 8. Pourquoi ce nombre est-il exactement le double ?
- (c) Si l'étudiant B calcule ensuite le degré **sortant** de chaque nœud sur son graphe orienté, obtient-il les mêmes valeurs que les degrés (non orientés) de l'étudiant A ? Justifier.
- (d) Si, au contraire, l'étudiant B avait accidentellement supprimé la réciprocité d'une seule arête (par exemple $3 \rightarrow 4$ conservée mais $4 \rightarrow 3$ supprimée), quel changement cela produirait-il sur le degré **sortant** de 4 et sur le degré **entrant** de 3, par rapport aux valeurs attendues (2 chacun) ? Un tel type d'erreur (orientation partiellement perdue ou corrompue) se détecte-t-il facilement en comparant seulement le nombre total d'arêtes, ou faut-il vérifier degré par degré ?

3 Applications en sciences économiques

Exercice 5 — Le clustering du réseau du cours est-il vraiment élevé ?

Le clustering moyen du réseau du cours est $\bar{C} \approx 0,667$ (chapitre 5). On construit un modèle nul par recâblage à degrés conservés (`rewire(g, keeping_degseq())` sous `igraph`), répété 1 000 fois, sur le réseau du cours.

- (a) On obtient une distribution de clustering nul de moyenne $\approx 0,192$, allant de 0 à $\approx 0,905$, de médiane $\approx 0,238$. Le clustering observé (0,667) est-il proche de cette moyenne nulle, ou nettement au-dessus ?
- (b) On admet que 10,2 % des 1 000 réseaux recâblés atteignent ou dépassent une valeur de clustering de 0,667. Ce pourcentage correspond-il à un résultat « extrêmement rare » (moins de 1 %) sous l'hypothèse nulle, ou à un résultat simplement « dans le haut de la distribution » (autour de 10 %) ?
- (c) Sachant que le réseau du cours ne compte que $n = 7$ nœuds et $m = 8$ arêtes, pourquoi la taille de l'échantillon (un seul petit réseau, comparé à seulement 1 000 permutations) limite-t-elle la puissance statistique de ce test, par rapport à un vrai réseau de plusieurs milliers de nœuds ?
- (d) Un économiste rédige, dans son rapport, la phrase « le clustering de 0,667 est élevé » sans aucune référence à un modèle nul. Réécrire cette phrase de façon rigoureuse, en tenant compte des résultats des questions (a)-(c).

Exercice 6 — Choisir la bonne centralité, pas la plus commode

Une équipe de conseil doit répondre à quatre questions distinctes concernant le même réseau interbancaire, et hésite à calculer « toutes les centralités disponibles dans le package » pour ensuite choisir celle qui « raconte la meilleure histoire ».


- (a) Question 1 : « Vers quelle banque une campagne de vaccination par les amis (chapitre 10) devrait-elle orienter son échantillonnage aléatoire ? » Quelle centralité (ou quel résultat théorique) est directement pertinent ici, et pourquoi ne s'agit-il pas d'un simple choix de commodité logicielle ?
- (b) Question 2 : « Quelle banque subventionner en priorité pour maximiser l'effort de R&D collectif du secteur (chapitre 11) ? » Quelle mesure (rappelée au chapitre 11, distincte de la centralité de degré ou de proximité) est ici la seule pertinente ?
- (c) Question 3 : « Quelle banque représente le plus grand risque systémique en cas de défaut

(chapitre 13)? » Pourquoi une centralité de degré simple serait-elle insuffisante ici, et quel outil (DebtRank, ou la position de pont) faut-il mobiliser à la place?

- (d) Un stagiaire propose de répondre aux trois questions avec la **même** mesure (la centralité de degré, la plus simple à calculer) pour « gagner du temps ». Expliquer, en une phrase pour chacune des trois questions, pourquoi cette simplification produirait une recommandation potentiellement erronée — et relier votre réponse à l’affirmation du cours : « le choix de la centralité relève du mécanisme économique, jamais du logiciel ».

1 Exercices du chapitre

Correction — Exercice 1



(a) A : atteint B (dist. 1) et C (dist. 2), soit 2 nœuds, somme = 3 : $C_C(A) = 2/3 \approx 0,667$. B : atteint A et C (dist. 1 chacun), 2 nœuds, somme = 2 : $C_C(B) = 2/2 = 1,000$. C : symétrique à A , $C_C(C) \approx 0,667$. D : atteint seulement E (dist. 1), 1 nœud, somme = 1 : $C_C(D) = 1/1 = 1,000$. $C_C(E) = 1,000$ de même.

(b) Oui, $C_C(B) = C_C(D) = C_C(E) = 1,000$: les trois valeurs sont **rigoureusement égales**.

(c) Non, absolument pas : B a accès à 2 des 4 autres nœuds du réseau (A et C), tandis que D (ou E) n'a accès qu'à 1 seul des 4 autres nœuds (E , respectivement D) — les 3 nœuds de l'autre composante leur restent structurellement inaccessibles. Le nombre « 1,000 » ne dit rien de cette différence : il mesure seulement la proximité **au sein du sous-ensemble atteint**, en ignorant silencieusement tout le reste du réseau.

(d) C'est exactement le piège décrit par le cours : le logiciel calcule un nombre parfaitement valide en apparence ($C_C = 1,000$, la valeur maximale possible), sans jamais signaler que le graphe est déconnecté ni que ce nombre ne porte que sur une infime fraction du réseau. Un analyste pressé pourrait conclure, à tort, que D et E sont « aussi centraux que possible », alors qu'ils sont en réalité isolés de l'essentiel du réseau. Le réflexe qui aurait détecté le problème immédiatement : vérifier d'abord si le graphe est connexe (une fonction disponible en une ligne dans `igraph` comme dans `networkx`) **avant** de calculer et d'interpréter toute mesure de distance.

Correction — Exercice 2

(a) $(n-1)(n-2)/2 = (7-1)(7-2)/2 = 6 \times 5/2 = 15$.

(b) $b'_1 = b'_2 = b'_6 = b'_7 = 0/15 = 0$. $b'_3 = b'_5 = 8/15 \approx 0,533$. $b'_4 = 9/15 = 0,600$.

(c) Non, elles ne sont **pas** en désaccord : 9 (la valeur brute, non normalisée) et 0,6 (la même quantité divisée par 15) désignent exactement le **même** résultat sous-jacent, exprimé dans deux échelles différentes. $9/15 = 0,6$ précisément.

(d) La confusion vient de ce qu'`igraph` et `networkx` ne partagent **pas** la même convention de normalisation par défaut (`igraph` : brute par défaut; `networkx` : normalisée par défaut), un piège explicitement cité par le cours. Pour l'éviter systématiquement, il faut toujours vérifier, avant toute comparaison entre logiciels, (i) quelle est la valeur par défaut de l'argument de normalisation dans chacun des deux, et (ii) idéalement, reproduire le calcul **à la main** sur un petit réseau connu (comme celui du cours) pour confirmer que les deux logiciels, une fois correctement paramétrés, donnent bien le même résultat sous-jacent.

Correction — Exercice 3

(a) Le degré « réel » (nombre de voisins **distincts**) de X est 3 (Y_1, Y_2, Y_3) : une boucle ne relie X à aucun voisin supplémentaire, seulement à lui-même.

(b) Avec la convention usuelle (une boucle ajoute 2 au degré), le logiciel affichera $3 + 2 = 5$ pour X — un degré supérieur de 2 au degré réel, sans qu'aucun message ne signale l'anomalie.

(c) Sur 1 000 articles, 50 contaminés par une boucle ajoutent chacun 2 unités de degré « fantômes », soit 100 unités de degré en trop sur l'ensemble du réseau. Le $\bar{k}$ calculé sera donc supérieur de $100/1\,000 = 0,1$ au $\bar{k}$ réellement souhaité — une distorsion discrète mais systématique, d'autant plus trompeuse qu'elle est difficile à repérer visuellement sur un grand réseau.

(d) Le logiciel ne peut pas, par construction, distinguer une boucle « légitime » (dans certains contextes, par exemple une entreprise qui investit dans sa propre R&D) d'une boucle « parasite » issue d'une erreur de nettoyage des données : la présence d'une boucle est, en elle-même, une donnée parfaitement valide au sens du format de graphe, donc rien ne déclenche d'avertissement.

La vérification systématique à effectuer avant toute analyse est un simple test de présence de boucles (`any(which_loop(g))` sous `igraph`, `nx.number_of_selfloops(G)` sous `networkx`), suivi, le cas échéant, de leur suppression explicite et délibérée (`simplify()` en `igraph`) plutôt que de leur inclusion silencieuse.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Oui, ces nombres correspondent **exactement** à ceux déjà établis : $n = 7$, $m = 8$ (chapitre 1), degrés $\{2, 2, 3, 2, 3, 2, 2\}$ (chapitre 1), $\lambda_1 \approx 2,343$ (chapitre 10, réutilisé aux chapitres 11 et 12). C'est précisément le « réflexe de vérification » du cours à l'œuvre : ces nombres constituent une signature suffisamment précise pour confirmer qu'il s'agit bien du même réseau.
- (b) Chaque arête non orientée $\{i, j\}$ du fichier d'origine, interprétée à tort comme un couple de liens orientés réciproques, produit **deux** arêtes orientées ($i \rightarrow j$ et $j \rightarrow i$) au lieu d'une seule arête non orientée. Avec 8 arêtes non orientées au départ, on obtient donc $8 \times 2 = 16$ arêtes orientées.
- (c) Oui : dans cette conversion « totalement réciproque » particulière, chaque nœud reçoit exactement un lien sortant pour chacun de ses voisins d'origine (puisque **toutes** les arêtes ont été dupliquées dans les deux sens). Le degré **sortant** de chaque nœud coïncide donc, dans ce cas précis, avec son degré non orienté d'origine — ce qui signifie que cette erreur particulière est **invisible** si l'on ne vérifie que les degrés un par un : c'est seulement le nombre **total** d'arêtes (16 au lieu de 8) qui la révèle.
- (d) Si l'arête $4 \rightarrow 3$ est supprimée (alors que $3 \rightarrow 4$ est conservée), le degré **sortant** de 4 diminue de 1 (il passe de 2 à 1, puisque 4 perd son lien sortant vers 3), tandis que le degré **entrant** de 3 diminue également de 1 (il passe de 2 à 1, puisque 3 ne reçoit plus le lien venant de 4) — alors que le degré **entrant** de 4 et le degré **sortant** de 3, eux, restent inchangés. Ce type d'erreur (réciprocité brisée sur une seule arête, parmi beaucoup d'autres) est beaucoup plus difficile à détecter que celle de la question (b) : le nombre total d'arêtes (15 au lieu de 16) ne signale qu'un déséquilibre **global** sans indiquer où il se situe, alors qu'une vérification degré par degré (comparer chaque degré sortant et entrant à la valeur non orientée attendue, 2 ou 3 selon le nœud) le localiserait précisément sur les nœuds 3 et 4. C'est un argument supplémentaire, très concret, en faveur du réflexe du cours : comparer aux nombres **complets** d'un petit réseau connu (tous les degrés, pas seulement leur somme ou leur nombre total), pas seulement à un unique agrégat global.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Le clustering observé (0,667) est **nettement au-dessus** de la moyenne nulle ($\approx 0,192$) — plus de trois fois supérieur — et au-dessus également de la médiane nulle ($\approx 0,238$).
- (b) 10,2 % correspond à un résultat qui se situe **dans le haut** de la distribution nulle (proche du 90^e centile), mais qui n'est **pas** extrêmement rare au sens statistique usuel (un seuil de rareté serait plutôt fixé autour de 1 à 5 %). Le clustering du réseau du cours est donc élevé par rapport au hasard à degrés conservés, mais pas au point d'être un événement exceptionnel isolé.
- (c) Avec seulement $n = 7$ nœuds et $m = 8$ arêtes, le nombre de configurations distinctes que peut prendre un recâblage à degrés conservés est lui-même **très limité** : la distribution nulle est nécessairement grossière (elle va de 0 à 0,905 par paliers assez larges), ce qui rend difficile de distinguer un résultat « franchement significatif » d'un résultat « notablement élevé mais plausible sous le hasard ». Sur un réseau de plusieurs milliers de nœuds, le nombre de recâblages possibles est immense, la distribution nulle devient beaucoup plus fine, et un écart de même ampleur relative serait bien plus facilement qualifié de statistiquement significatif.
- (d) Version rigoureuse : « Le clustering observé (0,667) est environ 3,5 fois supérieur à la moyenne d'un modèle nul à degrés conservés ($\approx 0,192$), et se situe dans le décile supérieur de cette distribution

nulle (10,2 % des réseaux recâblés l'égalent ou le dépassent). Compte tenu de la très petite taille du réseau ($n = 7$), ce résultat doit être interprété comme **suggestif d'une structure en communautés** plutôt que comme une preuve statistique définitive. »

Correction — Exercice 6

(a) La question 1 relève directement du **paradoxe de l'ami** et de la stratégie « vacciner un ami au hasard » (chapitre 10) : ce n'est pas une centralité au sens strict qu'il faut calculer, mais la propriété statistique $\mathbb{E}[k_{\text{voisin}}] = \mathbb{E}[k^2]/\bar{k} \geq \bar{k}$, qui justifie **pourquoi** cet échantillonnage indirect (tirer un nœud puis l'un de ses voisins) atteint les hubs sans les avoir identifiés au préalable. Ce n'est en aucun cas un choix de commodité logicielle : c'est un résultat théorique précis qui explique le **mécanisme** par lequel la stratégie fonctionne, indépendamment de tout package.

(b) Seule l'**intercentralité** (chapitre 11), $c_i = x_i^2 / [(\mathbf{I} - \phi \mathbf{A})^{-1}]_{ii}$, répond correctement à cette question : elle mesure la perte totale d'activité économique induite par le retrait d'un joueur, ce qu'aucune centralité de degré ou de proximité ne capture — le cours rappelle explicitement que le « joueur clé » n'est presque jamais le nœud le plus actif en apparence.

(c) Une centralité de degré simple compte seulement le **nombre** de contreparties d'une banque, sans tenir compte des montants engagés ni de la **position** structurelle (cœur ou périphérie, pont ou nœud redondant). Or le chapitre 13 a montré qu'une banque de bilan modeste mais occupant une position de pont peut causer un effondrement systémique bien plus large qu'une banque plus grosse mais périphérique : il faut donc mobiliser soit le DebtRank (qui pondère par les expositions réelles et propage la détresse à travers le réseau), soit une analyse explicite de la position de pont (points d'articulation, chapitre 1), et non un simple comptage de liens.

(d) Pour la question 1 : la centralité de degré ne dit rien sur **qui** interroger pour atteindre un hub sans le connaître au préalable — c'est le paradoxe de l'ami, pas le degré lui-même, qui justifie la stratégie. Pour la question 2 : le degré ignore entièrement l'effet de **renforcement mutuel** entre voisins (une banque de faible degré mais entourée de partenaires très actifs peut avoir une intercentralité élevée, et inversement) ; se limiter au degré risquerait de subventionner la mauvaise banque. Pour la question 3 : le degré ne capture ni les **montants** des expositions, ni le rôle de **pont** qui, comme démontré au chapitre 13, peut rendre une petite banque plus dangereuse pour le système qu'une grande banque bien diversifiée. Dans les trois cas, c'est le **mécanisme économique sous-jacent** à chaque question (diffusion, jeu stratégique, cascade de défauts) qui détermine la mesure pertinente — jamais la facilité de calcul d'une fonction disponible par défaut dans un package.