

Chapitre 15

Mise en œuvre sur R et Python

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Théorie des réseaux

1 Exercices du chapitre

Exercice 1 — Le piège du graphe non connexe

Un analyste importe par erreur un réseau de collaborations en deux morceaux disjoints : $\{A, B, C\}$ formant une chaîne ($A-B-C$) et $\{D, E\}$ formant une paire isolée ($D-E$), sans aucun lien entre les deux groupes.

- Calculer, pour chacun des 5 nœuds, la centralité de proximité « naïve » telle que la calculerait par défaut un logiciel qui ignore silencieusement les paires non connectées : $C_C(v) = \frac{\text{nombre de nœuds atteignables}}{\text{somme des distances vers eux}}$.
- Comparer la valeur obtenue pour B (au centre de la chaîne à 3) et pour D ou E (isolés à deux, mais connectés entre eux). Ces deux valeurs sont-elles égales ?
- D et E n'ont pourtant accès qu'à **un seul** des 4 autres nœuds du réseau, contre 2 sur 4 pour B . Le nombre obtenu en (a) reflète-t-il cette différence réelle d'accessibilité au reste du réseau ?
- En quoi ce résultat illustre-t-il exactement la mise en garde du cours : « `closeness` renvoie une valeur trompeuse au lieu d'un avertissement » ? Quel réflexe simple (rappelé en fin de chapitre) aurait permis de détecter le problème avant toute interprétation économique ?

Exercice 2 — Le piège de la normalisation

Sur le réseau du cours ($V = \{1, \dots, 7\}$, $E = \{12, 13, 23, 34, 45, 56, 57, 67\}$), on calcule l'intermédiarité de sommet **brute** (nombre de paires de chemins les plus courts qui passent par chaque nœud) : $b_1 = b_2 = b_6 = b_7 = 0$, $b_3 = b_5 = 8$, $b_4 = 9$.

- La formule de normalisation usuelle (celle qu'igraph applique avec l'option `normalized=True`) divise par $(n-1)(n-2)/2$. Calculer ce dénominateur pour $n = 7$.
- En déduire l'intermédiarité normalisée de chacun des 7 nœuds.
- Un chercheur affirme, à tort, que la valeur « 9 » obtenue en R (avec `normalized=False`, la valeur par défaut d'igraph) contredit la valeur « 0,6 » obtenue par un collègue sous Python (avec `normalized=True`, la valeur par défaut de networkx) pour ce même nœud 4. Sont-elles réellement en désaccord ?
- Quelle est la source de cette confusion, et comment l'éviter systématiquement quand on compare des résultats obtenus par deux logiciels différents ?

Exercice 3 — Boucles et arêtes perdues

Un jeu de données de citations contient, par erreur de nettoyage, une boucle (un article qui se cite lui-même dans les métadonnées) sur le nœud X , qui a par ailleurs 3 citations distinctes vers d'autres articles Y_1, Y_2, Y_3 .

- Quel est le degré « réel » de X (nombre de voisins distincts) ?
- La convention usuelle (igraph et networkx) compte une boucle comme ajoutant 2 au degré total (les deux « extrémités » de la boucle touchent le même nœud). Quel degré le logiciel affichera-t-il pour X ?
- Sur un réseau de 1 000 articles où 50 contiennent une telle boucle parasite, quel est l'effet sur le degré moyen $\bar{k}$ calculé automatiquement par le logiciel, par rapport au $\bar{k}$ réellement souhaité ?
- Pourquoi ce genre d'erreur ne déclenche-t-elle, en général, **aucun message d'avertissement** de la part du logiciel ? Quelle vérification simple (portant sur la présence de boucles, une fonction standard dans igraph comme dans networkx) faudrait-il systématiquement effectuer avant toute analyse ?

2 Exercice cumulatif (chapitre 15 et chapitres précédents)

Exercice 4 — Le réflexe de vérification, appliqué au réseau du cours

Le cours recommande de « vérifier sur un petit réseau connu » avant de faire confiance à un calcul. On dispose de deux versions du fichier du réseau du cours, chargées par deux étudiants différents.

- (a) L'étudiant A obtient : 7 nœuds, 8 arêtes, degrés $\{2, 2, 3, 2, 3, 2, 2\}$, $\lambda_1 \approx 2,343$. Ces nombres correspondent-ils à ceux, déjà établis aux chapitres 1 et 2, du réseau du cours ?
- (b) L'étudiant B, qui a chargé son fichier comme un graphe **orienté** par erreur (chaque arête interprétée comme un couple de liens réciproques $i \rightarrow j$ et $j \rightarrow i$), obtient 16 arêtes orientées au lieu de 8. Pourquoi ce nombre est-il exactement le double ?
- (c) Si l'étudiant B calcule ensuite le degré **sortant** de chaque nœud sur son graphe orienté, obtient-il les mêmes valeurs que les degrés (non orientés) de l'étudiant A ? Justifier.
- (d) Si, au contraire, l'étudiant B avait accidentellement supprimé la réciprocité d'une seule arête (par exemple $3 \rightarrow 4$ conservée mais $4 \rightarrow 3$ supprimée), quel changement cela produirait-il sur le degré **sortant** de 4 et sur le degré **entrant** de 3, par rapport aux valeurs attendues (2 chacun) ? Un tel type d'erreur (orientation partiellement perdue ou corrompue) se détecte-t-il facilement en comparant seulement le nombre total d'arêtes, ou faut-il vérifier degré par degré ?

3 Applications en sciences économiques

Exercice 5 — Le clustering du réseau du cours est-il vraiment élevé ?

Le clustering moyen du réseau du cours est $\bar{C} \approx 0,667$ (chapitre 5). On construit un modèle nul par recâblage à degrés conservés (`rewire(g, keeping_degseq())` sous `igraph`), répété 1 000 fois, sur le réseau du cours.

- (a) On obtient une distribution de clustering nul de moyenne $\approx 0,192$, allant de 0 à $\approx 0,905$, de médiane $\approx 0,238$. Le clustering observé (0,667) est-il proche de cette moyenne nulle, ou nettement au-dessus ?
- (b) On admet que 10,2 % des 1 000 réseaux recâblés atteignent ou dépassent une valeur de clustering de 0,667. Ce pourcentage correspond-il à un résultat « extrêmement rare » (moins de 1 %) sous l'hypothèse nulle, ou à un résultat simplement « dans le haut de la distribution » (autour de 10 %) ?
- (c) Sachant que le réseau du cours ne compte que $n = 7$ nœuds et $m = 8$ arêtes, pourquoi la taille de l'échantillon (un seul petit réseau, comparé à seulement 1 000 permutations) limite-t-elle la puissance statistique de ce test, par rapport à un vrai réseau de plusieurs milliers de nœuds ?
- (d) Un économiste rédige, dans son rapport, la phrase « le clustering de 0,667 est élevé » sans aucune référence à un modèle nul. Réécrire cette phrase de façon rigoureuse, en tenant compte des résultats des questions (a)-(c).

Exercice 6 — Choisir la bonne centralité, pas la plus commode

Une équipe de conseil doit répondre à quatre questions distinctes concernant le même réseau interbancaire, et hésite à calculer « toutes les centralités disponibles dans le package » pour ensuite choisir celle qui « raconte la meilleure histoire ».

- (a) Question 1 : « Vers quelle banque une campagne de vaccination par les amis (chapitre 10) devrait-elle orienter son échantillonnage aléatoire ? » Quelle centralité (ou quel résultat théorique) est directement pertinent ici, et pourquoi ne s'agit-il pas d'un simple choix de commodité logicielle ?
- (b) Question 2 : « Quelle banque subventionner en priorité pour maximiser l'effort de R&D collectif du secteur (chapitre 11) ? » Quelle mesure (rappelée au chapitre 11, distincte de la centralité de degré ou de proximité) est ici la seule pertinente ?
- (c) Question 3 : « Quelle banque représente le plus grand risque systémique en cas de défaut

(chapitre 13) ? » Pourquoi une centralité de degré simple serait-elle insuffisante ici, et quel outil (DebtRank, ou la position de pont) faut-il mobiliser à la place ?

- (d) Un stagiaire propose de répondre aux trois questions avec la **même** mesure (la centralité de degré, la plus simple à calculer) pour « gagner du temps ». Expliquer, en une phrase pour chacune des trois questions, pourquoi cette simplification produirait une recommandation potentiellement erronée — et relier votre réponse à l’affirmation du cours : « le choix de la centralité relève du mécanisme économique, jamais du logiciel ».